

Universitat Autònoma de Barcelona

Grau en Estadística Aplicada

Aprenentatge Automàtic II (2025-2026)

# Entrenament i Optimització de Xarxes Neuronals

*Classificació de Radiografies de Tòrax:*

*COVID-19, Pneumònia i Normal*

**Autor:**

Iker Fernández (1704341)

Professors: Víctor Navas-Portella, Laura Rodríguez Cima

19 de juny de 2026

# Índex

|          |                                                                     |           |
|----------|---------------------------------------------------------------------|-----------|
| <b>1</b> | <b>Introducció i motivació</b>                                      | <b>2</b>  |
| <b>2</b> | <b>Anàlisi exploratòria i preprocessament</b>                       | <b>3</b>  |
| 2.1      | Exploració de les dades . . . . .                                   | 3         |
| 2.2      | Preprocessament . . . . .                                           | 4         |
| <b>3</b> | <b>Arquitectura base: Multilayer Perceptron (MLP)</b>               | <b>5</b>  |
| 3.1      | Exploració de l'arquitectura i selecció d'hiperparàmetres . . . . . | 5         |
| 3.2      | Entrenament i diagnòstic . . . . .                                  | 6         |
| 3.3      | Estratègies de generalització (regularització) . . . . .            | 7         |
| <b>4</b> | <b>Arquitectures avançades: Xarxa Neuronal Convolucional (CNN)</b>  | <b>8</b>  |
| 4.1      | Selecció i justificació de l'arquitectura . . . . .                 | 8         |
| 4.2      | Implementació . . . . .                                             | 8         |
| 4.3      | Anàlisi comparatiu respecte al MLP . . . . .                        | 9         |
| 4.4      | Discussió crítica . . . . .                                         | 10        |
| <b>5</b> | <b>Comparativa amb models alternatius</b>                           | <b>11</b> |
| 5.1      | Altres models seleccionats . . . . .                                | 11        |
| 5.2      | Anàlisi comparatiu . . . . .                                        | 11        |
| 5.3      | Discussió crítica . . . . .                                         | 11        |
| <b>6</b> | <b>Anàlisi d'inferència</b>                                         | <b>12</b> |
| 6.1      | Anàlisi d'inferència (casos individuals) . . . . .                  | 12        |
| <b>7</b> | <b>Conclusions</b>                                                  | <b>14</b> |

# 1 Introducció i motivació

El treball aborda el problema de la classificació automàtica de radiografies de tòrax en tres categories: COVID-19, Pneumònia i Normal. El dataset utilitzat és el *COVID19+PNEUMONIA+NORMAL Chest X-Ray Image Dataset*, disponible a la plataforma Kaggle, i conté un total de 5.228 imatges distribuïdes de manera equilibrada entre les tres classes (COVID: 1.626, Normal: 1.802, Pneumònia: 1.800).

La rellevància d'aquest problema és evident en el context de la salut pública: un sistema capaç d'analitzar radiografies de manera automàtica pot optimitzar significativament el flux de treball clínic a través del triatge automàtic, permetent que els especialistes prioritzin els casos detectats com a crítics i reduint la càrrega assistencial i el temps de resposta.

Pel que fa a la idoneïtat de les xarxes neuronals per a aquest problema, es considera que la seva arquitectura és especialment adequada per dues raons principals. En primer lloc, les xarxes neuronals permeten delimitar regions de decisió complexes de manera eficient, essencial en tasques de classificació d'imatges. En segon lloc, a diferència dels mètodes d'aprenentatge automàtic tradicionals (SVM, Random Forest, etc.), les xarxes neuronals profundes —i en particular les xarxes convolucionals (CNN)— permeten l'extracció automàtica de característiques espacials sense necessitat de processos manuals d'enginyeria de característiques, la qual cosa resulta especialment valuosa en imatges mèdiques.

L'informe s'estructura de la manera següent: primer es presenta l'anàlisi exploratòria i el preprocessament de les dades; a continuació s'estableix un model base MLP i es discuteixen els hiperparàmetres i tècniques de regularització; seguidament s'implementa una arquitectura CNN i es compara amb el baseline; es contrasta amb models clàssics d'aprenentatge automàtic; i finalment s'avalua el millor model sobre el conjunt de test i s'extreuen les conclusions.

## 2 Anàlisi exploratòria i preprocessament


### 2.1 Exploració de les dades

El dataset conté 5.228 imatges en escala de grisos (radiografies de tòrax), organitzades en tres directoris corresponents a les tres classes a predir. La distribució de classes és la següent:


Taula 1: Distribució de classes del dataset

| Classe       | Nombre d'imatges | Proporció   |
|--------------|------------------|-------------|
| COVID-19     | 1.626            | 31,1%       |
| Normal       | 1.802            | 34,5%       |
| Pneumònia    | 1.800            | 34,4%       |
| <b>Total</b> | <b>5.228</b>     | <b>100%</b> |

La distribució és notablement equilibrada, de manera que no s'observen desequilibris de classe significatius que puguin introduir biaix cap a una categoria majoritària. En tractar-se d'imatges, no existeixen valors absents (*NA*). Pel que fa als biaixos visuals, les radiografies poden presentar diferències de contrast i il·luminació depenent de l'equip i el centre mèdic d'origen.



(a) Pneumonia



(b) Normal



(c) Covid-19

Figura 1: Exemples de la base de dades

## 2.2 Preprocessament

A partir de l'exploració anterior, s'han definit les transformacions següents per preparar les dades per als models:

- **Revisió d'integritat:** Inspecció del dataset per detectar i eliminar imatges corruptes o il·legibles.
- **Redimensionament:** Totes les imatges s'han redimensionat a una resolució uniforme de  $[128 \times 128]$  píxels per garantir la compatibilitat amb els models. S'ha triat aquesta resolució, ja que  $[256 \times 256]$ , suposava molt cost computacional i de temps i amb la mida seleccionada, ja s'obté suficient detall.
- **Normalització de píxels:** Els valors dels píxels s'han escalat a l'interval  $[0, 1]$  dividint per 255, per facilitar la convergència durant l'entrenament.
- **Aplanament (*flattening*):** Per al model base MLP, les imatges 2D s'han convertit en vectors 1D, ja que les capes denses requereixen una entrada plana.
- **Codificació de les etiquetes:** Les etiquetes de classe s'han codificat numèricament per adaptar-les al càlcul de la funció de pèrdua.
- **Partició estratificada:** El dataset s'ha dividit en tres conjunts, mantenint la proporció de classes en cadascun (2):

Taula 2: Partició estratificada del dataset

| Conjunt     | Proporció | Imatges aprox. | Ús                         |
|-------------|-----------|----------------|----------------------------|
| Entrenament | 70%       | $\sim 3.660$   | Ajust dels pesos           |
| Validació   | 15%       | $\sim 784$     | Selecció d'hiperparàmetres |
| Test        | 15%       | $\sim 784$     | Avaluació final            |

### 3 Arquitectura base: Multilayer Perceptron (MLP)

El primer objectiu és establir un model de referència mitjançant una xarxa completament connectada. Tot i que el MLP no és l'arquitectura òptima per a dades d'imatge, serveix per poder verificar que els models més complexos i espacials tenen millors resultats amb els costos computacionals que comporten que un model més "simple" aconsegueixi aquest.

#### 3.1 Exploració de l'arquitectura i selecció d'hiperparàmetres

Per no tenir només un model d'aquest tipus, s'han fet tres configuracions concretes:

1. Model Pesat (Moltes neurones en poques capes)
2. Model Eficient (Poques neurones en moltes capes)
3. Model equilibrat (Mescla de les anteriors)

Per tal d'observar si realment el que és important és tenir un moltes neurones en poques capes, poques neurones en moltes capes o un equilibri entre ambdues:

Taula 3: Exploració d'hiperparàmetres del MLP

| Config.   | Capes | Neurones          | Paràmetres | Val. Loss | Val. Acc. |
|-----------|-------|-------------------|------------|-----------|-----------|
| Config. 1 | 3     | [256, 256, 256]   | 4,326,915  | 0.1489    | 0.9503    |
| Config. 2 | 15    | [12, 12, ..., 12] | 198,843    | 0.1648    | 0.9388    |
| Config. 3 | 3     | [128, 64, 32]     | 2,107,715  | 0.1237    | 0.9554    |

A la taula 3 tenim les configuracions i resultats dels diferents models provats, per arribar al màxim rendiment dels models, s'ha utilitzat la funció *EarlyStopping* centrada en la Loss de la validació, per tal de comparar els models, s'han extret els millors resultats de la validació de cada model, quedant en general models MLP molt sòlids i correctes.

Obtenint uns resultats similars entre el model més pesat que podríem pensar que generaria overfitting però que realment ho fa molt bé i el model equilibrat, essent aquest el millor model, ja que supera en mètriques a les dues altres configuracions, cal comentar també que el model lleuger fa un molt bon treball arribant a una precisió altíssima amb moltíssims menys paràmetres, però en dades de salut com aquestes no podem agafar aquest model per molt eficient que sigui tenint altres millors.

### 3.2 Entrenament i diagnòstic




Figura 2: Corbes d'aprenentatge dels models MLP base.

A la figura 2 tenim els diferents comportament de train i validation dels models provats, si s'observa l'eix x, tenim que els models tenen un diferent número de epochs, això és degut a que la funció *EarlyStopping* decideix on parar el fitting per tenir els millors resultats possibles, com aquest mètode, té una petita permissió de baixada de rendiment per tal de no tallar l'algorisme a un mínim local i no general, és molt probable que el final de cada gràfic el model tingui un resultat pitjor que en epochs anteriors.

Fent un cop d'ull general, podem apreciar un comportament molt òptim a les tres configuracions, amb una Loss decreixent quasi fins el final i un accuracy ascendent també en algun cas fins al final, això tant al train com a la validació, per tant no podem parlar d'overfitting, sinó d'uns models que realment fan un bon treball.

Cal esmentar que observant els resultats, continuarem la resta del projecte amb el model equilibrat, ja que quant a mètriques és el millor i té un bon comportament com veiem als gràfics.

### 3.3 Estratègies de generalització (regularització)

Per tal de intentar millorar el model, s'ha provat de fer tècniques de regularització, aquestes s'utilitzen per tal de millorar la generalització del model, evitant l'overfitting, per tant, s'ha fixat el model guanyador MLP i s'han provat diferents mètodes, tots amb la funció *EarlyStopping*, la qual també és una tècnica, però ens ha semblat indispensable utilitzar-la per a tots els models provats. S'han utilitzat les diferents estratègies:

- Dropout : Aquesta tècnica consisteix en "apagar" de manera aleatòria un nombre indicat de neurones a cada iteració, al nostre cas ho hem provat amb el 30% a la primera capa i 20% a la segona i després, provant el 50% a les dos primeres capes també.
- L2 ( $\lambda = 1e^{-4}$ ) : La funció d'aquesta tècnica és afegir una penalització a la funció de pèrdues proporcional al quadrat de la magnitud dels pesos. "Multar" els pesos grans i obliga la xarxa a mantenir uns pesos petits, distribuint la importància de manera suau per tota la matriu.

Taula 4: Efecte de les tècniques de regularització sobre el MLP

| Regularització            | Val. Loss            | Val. Acc. | Epochs |
|---------------------------|----------------------|-----------|--------|
| Sense regularització      | 0.1237               | 0.9554    | 27     |
| Dropout (p=0.3. p=0.2)    | 0.2054               | 0.9247    | 22     |
| Dropout (p=0.5)           | 0.6360               | 0.6403    | 16     |
| L2 ( $\lambda=1e^{-4}$ )  | 0.1567               | 0.9426    | 23     |
| <b>Configuració final</b> | Sense regularització |           |        |

A la taula 4, s'han extret els resultats de les diferents tècniques de regularització, obtenint uns resultats que no milloren el model sense regularització, cosa que realment no sorprèn gaire ja que com s'ha vist anteriorment, no s'ha detectat cap tipus d'overfitting al model, per tant, tornem a donar com a guanyador aquest model equilibrat sense cap tècnica adient.



## 4 Architectures avançades: Xarxa Neuronal Convolutional (CNN)

### 4.1 Selecció i justificació de l'arquitectura

Per a dades d'imatge com les radiografies de tòrax, les xarxes neuronals convolucionals (CNN) representen l'elecció natural. A diferència del MLP, les CNN exploten l'estructura espacial local de les imatges mitjançant filtres convolucionals que detecten patrons (vores, textures, formes) de manera jeràrquica. Això és especialment rellevant en radiografies, on les regions d'interès clínic (consolidacions, opacitats, patrons en vidre esmerilat) estan distribuïdes espacialment i requereixen una anàlisi local.

Específicament, les CNN presenten els avantatges següents respecte al MLP per a aquest problema:

- **Invariància translacional:** Els filtres s'apliquen localment, permetent detectar patrons independentment de la seva posició a la imatge.
- **Reducció de paràmetres:** La compartició de pesos entre filtres redueix dràsticament el nombre de paràmetres respecte a un MLP equivalent.
- **Extracció jeràrquica de característiques:** Les capes inicials detecten patrons simples (vores) i les més profundes, patrons complexos (formes, textures).

### 4.2 Implementació

L'arquitectura CNN implementada segueix una estructura clàssica de blocs convolucionals seguits d'una capçalera de classificació totalment connectada. El model es resumeix a la taula següent:

Taula 5: Arquitectura de la CNN

| Capa | Tipus           | Mida / Filtres   | Activació |
|------|-----------------|------------------|-----------|
| 1    | Conv2D          | 32 filtres, 3×3  | ReLU      |
| 2    | MaxPooling2D    | 2×2              | —         |
| 3    | Conv2D          | 64 filtres, 3×3  | ReLU      |
| 4    | MaxPooling2D    | 2×2              | —         |
| 5    | Conv2D          | 128 filtres, 3×3 | ReLU      |
| 6    | MaxPooling2D    | 2×2              | —         |
| 7    | Flatten         | —                | —         |
| 8    | Dense           | 128 neurones     | ReLU      |
| 9    | Dense (sortida) | 3 neurones       | Softmax   |

El model s'ha compilat amb l'optimitzador `adam`, la funció de pèrdua `categorical_crossentropy` i la mètrica `accuracy`, de manera consistent amb el model MLP. L'entrenament s'ha realitzat amb la funció `EarlyStopping` monitoritzant la `val_loss`, per evitar l'overfitting i determinar automàticament el nombre òptim d'èpoques.

Quant a la inicialització dels pesos, Keras aplica per defecte la inicialització de **He (Kaiming)** a les capes `Conv2D` i `Dense` amb activació `ReLU`, la qual és l'opció teòricament més

adequada per evitar el problema del *vanishing gradient* en xarxes profundes amb aquesta activació.

### 4.3 Anàlisi comparatiu respecte al MLP

Taula 6: Comparació MLP vs. CNN

| Model     | Accuracy (Val) | Loss (Val) | Paràmetres | Epochs |
|-----------|----------------|------------|------------|--------|
| MLP Final | 0.9554         | 0.1237     | 2,107,715  | 27     |
| CNN Final | 0.9809         | 0.0753     | 1,289,347  | 12     |




Figura 3: Corbes d'aprenentatge del model CNN.

Observant la taula 7 i la figura 3 es pot apreciar com el CNN és un nivell superior quant a la classificació d'imatges, tenim uns resultats quasi perfectes amb un accuracy d'un 0.9809 i una Loss de 0.0753, uns resultats que superen inclús l'MLP final, fent que ens quedem amb aquesta comparació amb el CNN com a model final per fer prediccions, igualment, es farà aquest test amb els dos models per observar el comportament de tots dos a les prediccions.

## 4.4 Discussió crítica

Taula 7: Test MLP vs. CNN

| Model     | Accuracy (Test) | Loss (Test) | F1 (Macro) |
|-----------|-----------------|-------------|------------|
| MLP Final | 0.9452          | 0.1877      | 0.9458     |
| CNN Final | 0.9643          | 0.1394      | 0.9646     |




Figura 4: Matrius de Confusió (MLP VS CNN)

Observant la comparativa en les prediccions (test) dels dos models finals, a la taula 7 i a la figura 4, on podem apreciar diferents mètriques com l'Accuracy, la Loss i el F1 i també les matrius de confusió, podem dir que els dos models tenen un comportament realment bo, fent justícia realment a les mètriques mostrades a la validació, tenint l'MLP un 94.52% d'accuracy amb un 0.1877 de loss i el CNN un 96.43% d'accuracy i un 0.1394 de loss, amb aquestes mètriques i les matrius de confusió, s'observa com realment si que el CNN té un millor comportament, encara que és preocupant que en ambdós casos tenim un valor una mica elevat de casos predits com **normals** quan realment són **pneumònia**, és un valor alarmista ja que, és on més falla el CNN i es un cas amb especial delicadesa ja que estariem dient que una persona amb **pneumònia** està sana.

Per la part de la comparativa entre MLP i CNN, amb aquests resultats, i les dades que estem tractant, queda clar que encara que sigui més complexa, s'ha d'utilitzar el CNN, per tal de ser el més precís possible.

## 5 Comparativa amb models alternatius

### 5.1 Altres models seleccionats

Donat que les dades d'entrada són imatges aplanades, és possible aplicar models clàssics d'aprenentatge automàtic sobre els vectors de píxels (o sobre característiques extretes prèviament). S'han seleccionat els models següents per a la comparativa:

- **Support Vector Machine (SVM):** Mètode robust per a classificació multiclasse que pot definir fronteres de decisió complexes en espais d'alta dimensió.
- **Random Forest:** Model d'ensemble basat en arbres de decisió, que aporta bona capacitat de generalització i interpretabilitat relativa.
- **Stacking de SVM, Random Forest i CNN:** Mètode que junta diferents mètodes de classificació, fent que entre els tres escollits prenguin una decisió

### 5.2 Anàlisi comparatiu

Taula 8: Comparativa global de models

| Model         | Accuracy (test) | Temps per predir | Complexitat |
|---------------|-----------------|------------------|-------------|
| SVM           | 0.9617          | 55.52 s          | Baixa       |
| Random Forest | 0.9452          | 27.71 s          | Baixa       |
| Stacking      | 0.9643          | 30.668 s         | Alta        |
| CNN (millor)  | 0.9643          | 1 s              | Alta        |

### 5.3 Discussió crítica

Observant la taula 8, tenim diferents models alternatius provats per observar el seu comportament, amb un SVM amb 96.17% d'accuracy, el qual ho fa molt bé, un Random Forest amb un 94.52% d'accuracy, i l'Stacking amb un 96.43% d'accuracy, amb un valor igual al CNN, és possible que això sigui degut a que el CNN forma part de l'Stacking i per tant, és com si només ell treballés, en tots els casos, el CNN és millor ja que supera en accuracy als models clàssics i iguala a l'ensemble (Stacking), essent més simple ja que aquest està inclòs.

Parlant de complexitat, si el nostre cas hagués estat un altre tipus de dades podríem escollir el SVM, ja que és més simple computacionalment i presenta uns resultats boníssims, propers al CNN, però al nostre cas al voler ser el més precisos possible, el CNN és la millor opció.

## 6 Anàlisi d'inferència

### 6.1 Anàlisi d'inferència (casos individuals)

Es presenten 16 casos, 8 predits correctament i 8 predits incorrectament al test, tots els casos amb les seves probabilitats adients per analitzar el comportament del model:




Figura 5: Figures Predites correctament

Observant la figura 5 (casos predits correctament al test), es revelen diversos indicadors clau sobre la qualitat de l'aprenentatge de la CNN:

- **Alta confiança estadística:** En la pràctica totalitat dels casos d'èxit mostrats, la xarxa no només prediu la classe correcta, sinó que ho fa amb una probabilitat extremadament alta (superior al 98% en tots els exemples, arribant al 100.00% en el cas de COVID). Això demostra que el model no pateix d'incertesa en els casos prototípics i que les fronteres de decisió entre les tres patologies estan molt ben definides en l'espai de característiques extret pels filtres.
- **Identificació de patrons radiològics clars:** S'observa que la xarxa ha interioritzat correctament les diferències de les imatges. En els pacients classificats com a Normal, els pulmons es mostren predominantment clars, sense opacitats greus. En canvi, en les imatges de Pneumònia i COVID, el model reacciona de manera adient davant la presència d'opacitats, consolidacions i patrons en vidre esmerilat.
- **Discussió sobre possibles biaixos (Artefactes mèdics):** Cal fer una menció crítica a la radiografia de COVID on el model prediu la classe amb un 100.00% de seguretat. Si s'observa amb atenció, aquesta imatge presenta nombrosos cables i tubs d'equipament mèdic superposats al tòrax del pacient. En l'anàlisi d'imatges mèdiques mitjançant aprenentatge profund, és un biaix freqüent que els models aprenguin a associar la presència d'aquests artefactes amb la patologia clínica més greu, en lloc de fixar-se exclusivament en els teixits pulmonars. Aquesta certesa absoluta del 100% podria estar lleugerament influenciada per aquest fenomen associatiu, posant de manifest la importància d'una avaluació qualitativa acurada més enllà de les mètriques globals.




Figura 6: Figures mal predites

Observant la figura 6 (casos predits incorrectament al test), es poden identificar tres patrons d'error diferenciats:

- **Confusió Pneumònia → Normal (3 casos):** Aquest és l'error més preocupant des del punt de vista clínic. En el primer cas, el model prediu Normal amb un 93.08% de confiança quan realment és Pneumònia, i en el tercer cas amb un 88.46%. Això indica que les radiografies presenten opacitats molt subtils que el model interpreta erròniament com a teixit pulmonar sa. El segon cas d'aquest tipus és menys alarmant, ja que el model mostra dubtes (72.99% Normal, 27.00% Pneumònia), el que indicaria que en un context d'aplicació real s'hauria de derivar a un especialista per a una revisió manual.
- **Confusió COVID → Pneumònia (2 casos):** En ambdós casos el model confon COVID amb Pneumònia, amb un 98.13% i un 71.46% de confiança respectivament. Aquesta disfunció és clínicament comprensible, atès que les dues patologies presenten patrons visuals altament similars a les radiografies. En el segon cas, el model assigna un 27.92% a COVID, indicant que detecta indicis de la malaltia però insuficients per superar el llindar de decisió.
- **Confusió Normal → COVID/Pneumònia (3 casos):** El cas més notable és el d'una radiografia Normal classificada com a COVID amb un 99.92% de confiança. Aquesta alta certesa en un error tan flagrant suggereix la presència d'artefactes externs o característiques inusuals que el model associa esbiaixadament. Els altres dos casos (Normal → Pneumònia) presenten un patró de dubte més elevat: un amb un 82.12% i un altre amb un 53.05%.

En general, s'observa que mentre alguns errors greus es produeixen amb una alta certesa, en d'altres el model manifesta indecisió. Per tant, en aquells supòsits on es prediu la classe Normal amb el dubte de si pot tractar-se de Pneumònia, es desprèn la necessitat d'establir un protocol de seguretat. Aquest protocol requeriria enviar la imatge a un especialista per a la seva validació manual en tots els casos amb probabilitats dubtoses (per exemple, quan cap predicció supera el llindar del 75% de confiança).

## 7 Conclusions

Aquest treball ha abordat la classificació automàtica de radiografies de tòrax en tres categories (COVID-19, Pneumònia i Normal) mitjançant xarxes neuronals, obtenint resultats molt satisfactoris i extraient conclusions rellevants tant des del punt de vista tècnic com clínic.

En primer lloc, quant al model base MLP, s'ha demostrat que fins i tot una arquitectura completament connectada és capaç d'assolir un rendiment elevat (94.52% d'accuracy al test) en tasques de classificació d'imatges, sempre que el preprocessament sigui adequat. L'exploració d'hiperparàmetres ha revelat que una arquitectura equilibrada ( $[128, 64, 32]$  neurones) supera tant els models molt pesats com els molt lleugers, confirmant que la capacitat del model ha d'estar ajustada a la complexitat del problema. A més, l'absència de millora amb tècniques de regularització (Dropout, L2) indica que el model no patia overfitting, sinó que ja generalitzava correctament.

En segon lloc, la CNN ha demostrat ser clarament superior al MLP per a dades d'imatge (96.43% d'accuracy al test), confirmant la hipòtesi inicial. Amb menys paràmetres (1.289.347 vs. 2.107.715) i menys epochs d'entrenament (12 vs. 27), la CNN obté millors resultats gràcies a la seva capacitat d'explotar l'estructura espacial de les radiografies mitjançant filtres convolucionals. Això valida l'ús de CNN com a arquitectura de referència per a problemes de visió per computador en l'àmbit mèdic.

Quant a la comparativa amb models clàssics, s'ha observat que el SVM assoleix un rendiment sorprenentment competitiu (96.17%), proper al de la CNN, mentre que el Random Forest queda per darrere (94.52%). L'Stacking iguala la CNN (96.43%), però a costa d'una complexitat molt més elevada. Per tant, la CNN continua sent l'opció preferida, ja que ofereix el millor equilibri entre rendiment, complexitat i temps d'inferència.

Finalment, l'anàlisi d'inferència ha posat de manifest que l'error més crític del model és la confusió entre **Pneumònia** i **Normal**, on el model classifica casos de pneumònia com a sans amb alta confiança. En un context clínic real, aquest tipus de fals negatiu podria tenir conseqüències greus. Com a línia de millora futura, es proposa implementar una funció de pèrdua ponderada (*Weighted Cross-Entropy*) que penalitzi amb més severitat aquest tipus d'error, així com un sistema de revisió humana automàtica per als casos on cap classe superi un llindar de confiança determinat (p. ex., 75%).

En conclusió, els resultats obtinguts demostren la viabilitat de les xarxes neuronals convolucionals per al diagnòstic assistit de patologies pulmonars a partir de radiografies de tòrax, amb un rendiment que justifica la seva integració com a eina de suport en entorns clínics, sempre sota supervisió mèdica especialitzada.

## Declaració sobre l'ús d'Intel·ligència Artificial

En compliment dels principis de transparència acadèmica, es fa constar que durant la realització d'aquest treball s'han utilitzat eines basades en Intel·ligència Artificial (IA) com a assistent tècnic i de redacció. L'ús d'aquestes eines s'ha limitat estrictament als àmbits següents:

- **Optimització de codi:** Suport en la refacció de fragments de codi en Python per tal de millorar-ne l'eficiència computacional i l'estructuració.
- **Implementació de models complementaris:** Ajuda en la sintaxi i la integració de llibreries per a models no tractats explícitament a les sessions de teoria o pràctica de l'assignatura, com ara l'algorisme de *Random Forest* i la construcció del *pipeline* per a l'*Stacking*.
- **Revisió lingüística:** Suport en la correcció ortogràfica, gramatical i d'estil de la memòria final redactada en L<sup>A</sup>T<sub>E</sub>X.

Cal subratllar que el disseny metodològic, l'anàlisi exploratòria, la decisió dels hiperparàmetres, la interpretació dels resultats (incloses les matrius de confusió i els casos d'inferència) i l'elaboració de les conclusions crítiques són fruit del treball i el raonament exclusiu de l'autor.



## Referències

- [1] Saraiva, A. A., Ferreira, N. M. F., De Sousa, L. L., Costa, N. J. C., Sousa, J. V. M., Santos, D. B. S., . . . & Soares, S. (2019). Classification of Images of Childhood Pneumonia using Convolutional Neural Networks. In *Bioimaging* (pp. 112–119).
- [2] Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press. <https://www.deeplearningbook.org>
- [3] *COVID19+PNEUMONIA+NORMAL Chest X-Ray Image Dataset*. Kaggle. <https://www.kaggle.com/datasets/>