

Guia de Projecte: Entrenament i Optimització de Xarxes Neuronals amb Dades Reals

Objectiu del Projecte

L'objectiu d'aquest treball és enfrontar-se al cicle de vida complet del desenvolupament d'un model d'aprenentatge profund. No es tracta només d'obtenir una alta precisió, sinó d'entendre **com i per què** els hiperparàmetres, l'arquitectura i el preprocessament afecten el comportament de la xarxa neuronal.

El projecte es pot estructurar en les fases següents:

1 Selecció del Problema i Dataset

Trieu un dataset de la plataforma Kaggle o del UCI Machine Learning Repository.

- **Opció A (Classificació):** Predicció de categories (ex: frau, diagnòstic, abandonament de clients, classificació d'imatges, classificació de correus, etc.).
- **Opció B (Regressió):** Predicció de valors continus (ex: preu d'habitatge, demanda energètica, emissions, etc.).

2 Selecció del problema , anàlisi exploratòria i preprocessament

- **Descripció del Dataset:** Font, context del problema i justificació de la seva rellevància.
- **Anàlisi Exploratòria:** L'enfocament variarà segons la natura de les dades.
- **Preprocessament:** Documentar les transformacions derivades de l'exploració (neteja, imputació, normalització, *encoding*).
- **Partició de dades:** Definició clara dels conjunts d'entrenament, validació i test.

3 Arquitectura base: Multilayer perceptron (MLP)

El primer objectiu és establir un *baseline* de referència mitjançant una xarxa completament connectada (*fully connected*):

- **Exploració de l'arquitectura:** Estudieu i discuteu l'impacte dels hiperparàmetres estructurals (nombre de capes, neurones per capa i funcions d'activació). Justifiqueu la configuració final escollida.
- **Entrenament i diagnòstic:** Analitzeu les corbes d'aprenentatge. Estudieu la convergència i realitzeu un diagnòstic precís sobre l'estat del model en termes de **Biaix i Variància**.
- **Estratègies de generalització:** Implementeu i compareu l'efecte de diferents tècniques de regularització.

4 Experimentació amb architectures avançades

L'objectiu d'aquesta fase és transcendir l'arquitectura MLP bàsica i explorar models que aprofitin la naturalesa intrínseca de les dades seleccionades. Feu recerca i implementeu una tipologia de xarxa alternativa:

- **Selecció i justificació:** Investigueu i trieu una arquitectura avançada (p. ex. convolutional neural networks (CNN), recurrent neural networks (RNN), graph neural networks (GNN), Transformers, etc.) que consideris que pot ser adequada per al teu dataset. Cal justificar per què aquesta arquitectura pot ser, a priori, més eficient que una MLP per tractar la **geometria o l'estructura** de les teves dades.
- **Implementació:** Adapteu el disseny de la xarxa (capes especialitzades, mecanismes d'atenció, etc.) i documenteu les decisions preses durant el procés de configuració.
- **Anàlisi Comparatiu:** Compareu el rendiment final, la velocitat de convergència i la complexitat (nombre de paràmetres) respecte al model *baseline* de la secció anterior.
- **Discussió Crítica:** Determineu si l'especialització de l'arquitectura ha aportat un benefici real o si la complexitat afegida no es tradueix en una millora significativa dels resultats.

5 Comparació amb altres models d'aprenentatge

En cas que la naturalesa de les dades permeti que siguin tractades amb models clàssics, poseu en perspectiva el rendiment de les xarxes neuronals respecte a altres paradigmes:

- **Selecció de models clàssics:** Trieu almenys un mètode d'aprenentatge clàssic que pugui ser aplicat al dataset.
- **Anàlisi comparatiu:** Realitzeu una comparativa rigorosa utilitzant les mateixes particions de dades i mètriques d'avaluació. Considereu el temps de computació, la complexitat i la facilitat d'optimització.
- **Discussió crítica:** Sota quines condicions recomanaríeu un model o l'altre per a aquest problema concret?
- **Estratègia d'Ensemble:** Exploreu si la combinació de models redueix la variància o el biaix de l'error. Podeu implementar una d'aquestes tres estratègies clàssiques:
 - **Bagging (Bootstrap Aggregating):** Entrenar múltiples models (com xarxes neuronals amb diferents inicialitzacions o *Random Forests*) de forma independent i fer la mitjana de les seves prediccions.
 - **Boosting:** Utilitzar models que aprenen seqüencialment dels errors dels anteriors (p. ex. **XGBoost** o **LightGBM**) i comparar si superen la capacitat de representació de la vostra xarxa profunda.
 - **Stacking / Voting:**
 - * *Soft Voting:* Combinar la vostra millor xarxa neuronal amb el millor model clàssic mitjançant una mitjana ponderada de les probabilitats de sortida.
 - * *Stacking:* Entrenar un “meta-model” (com una regressió logística) que aprengui a combinar les sortides dels models base per obtenir la predicció final.

6 Avaluació final, inferència i conclusions

Un cop seleccionat el millor model mitjançant el procés de validació, s'ha de procedir a l'avaluació definitiva:

- **Resultats en test:** Reporteu les mètriques finals utilitzant exclusivament el conjunt de dades de **Test**.
- **Anàlisi d'inferència:** Seleccioneu 3-4 casos individuals del conjunt de test i analitzeu la predicció del model. Discutiu tant casos d'èxit com errors flagrants (*missclassifications* o residus alts).
- **Conclusions:** Sintetitzeu el que s'ha après durant el procés, les limitacions trobades i possibles línies de millora futures.

7 Lliuraments

7.1 Lliurament parcial (27 de Març)

Entrega d'un breu informe (1-2 pàgines) exposant:

- **Fitxa tècnica:** Nom del dataset, URL d'accés, nombre de mostres i nombre de variables.
- **Motivació i objectius:**
 - * Per què és rellevant aquest problema? (Ex: millorar diagnòstics, optimitzar costos, entendre un fenomen social).
 - * Per què creieu que una xarxa neuronal pot ser un bon model per a aquest problema concret en comparació amb altres mètodes que coneixeu?
- **Naturalesa, breu exploració i preparació de les dades (*input engineering*):**
 - * **Exploració i diagnòstic:** Realitzeu una breu inspecció de les dades (distribucions, valors absents, desequilibris de classe o biaixos visuals/textuals). Destaqueu aspectes que considereu rellevants de cara al desenvolupament del projecte.
 - * **Lligam amb el preprocessament:** A partir de l'exploració anterior, feu una breu recerca i expliqueu una o varies estratègies per a transformar les dades originals per fer-les "digeribles" per a la xarxa neuronal.
- **Recerca de referències:**
 - * Busqueu algun estudi, article o projecte similar que hagi utilitzat xarxes neuronals per a dades de naturalesa semblant.

7.2 Lliurament final (19 de Juny)

El lliurament final consta de dos fitxers indispensables:

1. Codi (Jupyter Notebook / Google Colab):

- El codi ha de ser **executable de principi a fi** sense errors.
- Ha d'estar organitzat en cel·les lògiques (Preprocessament, MLP, Arquitectura Avançada, Comparativa).
- Ús de gràfics clars per a les corbes d'aprenentatge i mètriques.
- Els codis han de ser nets, entenedibles i amb comentaris que expliquin els passos tècnics.

2. **Informe de síntesi (PDF):** Un document (màxim 15 pàgines) on es discuteixin els resultats. L'enfocament ha de ser la **interpretació estadística i tècnica**, evitant enganxar blocs de codi:
- **Introducció i motivació:** Presentació del dataset i justificació de l'ús de xarxes neuronals per a aquest problema.
 - **Anàlisi exploratòria i preprocessament:** Destaqueu els aspectes clau de l'EDA que han condicionat la preparació de les dades.
 - **Arquitectura base (MLP):**
 - * Discussió sobre la tria d'hiperparàmetres i tècniques de regularització.
 - * **Diagnòstic:** Comentari crític sobre les corbes d'aprenentatge (presència d'*overfitting*, *gradient vanishing*, convergència, etc.).
 - **Arquitectures avançades:**
 - * Justificació de l'arquitectura escollida.
 - * Anàlisi comparatiu respecte a la MLP: millora el rendiment? A costa de quanta complexitat?
 - **Comparativa amb models alternatius:** (Si escau) Contrast de resultats amb models clàssics i discussió estratègies d'ensembles.
 - **Anàlisi d'inferència:** Estudi detallat de casos individuals del conjunt de test (anàlisi d'èxits i errors flagrants).
 - **Conclusions:** Reflexió sobre la idoneïtat del model final i lliçons apreses.

Sobre l'ús de la IA generativa

Les eines d'IA generativa poden ser aliades potents en l'aprenentatge sempre que se'n faci un ús responsable i ètic. Tot contingut inclòs en els lliuraments ha d'haver estat contrastat, documentat i, sobretot, entès íntegrament per l'estudiant. Recordeu que sou els responsables finals de la veracitat i qualitat del vostre treball. Per aquest motiu, **el professorat es reserva el dret de convocar qualsevol estudiant a una entrevista de validació sobre els continguts i el procés d'elaboració del lliurament**. Es consideren usos inapropiats l'entrega de continguts generats automàticament sense revisió, la manca d'autoria efectiva o la incapacitat de defensar els conceptes exposats. **L'ús inapropiat o fraudulent de la IA comportarà la penalització de la nota o l'anul·lació directa de l'exercici.**