



Pràctica 1 – Part 1

Discussió

Ferran Torres

Biostatistics Unit. Medical School. Office M3/323B
Universitat Autònoma de Barcelona (UAB)

1.2 Lliuraments de pràctiques (aplica en tots els casos posteriors)

Quan s'obri l'activitat de lliurament, llavors haureu de lliurar la pràctica seguint les instruccions de sota.

Es **penalitzarà 0.5 punts** per a cada desviació sobre les instruccions donades:

- S'ha de fer usant el lliurament de tasques identificat en el Campus Virtual
- Poseu els noms i els NIUs de tots els integrants del grup a cada document.
- Cal usar la següent **nomenclatura** en el lliurament:
 - Sempre sense accents, ni 'ñ' ni espais en blanc
 - Els espais en blanc s'han de substituir amb el guió baix: "_"
 - "Grup_XX_Sintaxi_R.r" o igual però amb extensió "Rmd" per a la sintaxi
 - "Grup_XX_Memoria.pdf" per a la memòria (*altres extensions com .doc o .docx o .rtf també acceptades*)

Sent "XX" el número del grup en 2 dígit, per exemple 01, 02 ... 12

Com ara <**Grup_01_Memoria.pdf**>

Qualsevol document addicional ha de començar amb el text "Grup_XX_"

- Podeu usar Markdown o alternatives, però en aquest cas passeu igualment el fitxer de sintaxi a banda i vull veure les respostes al que es demana en "net" a la memòria. Pregunteu si no ho veieu clar...

2.2 Punts a seguir:

1. Importació de dades: Lectura de les dades en el sistema de programari estadístic escollit
2. Qualitat de les dades: veure si les dades estan preparades i son vàlides per a l'anàlisi estadística: vigileu, valors extrems, discrepàncies aparents, *missing values*. En cas contrari, penseu i discutiu internament estratègies a seguir.
3. Comparació de les característiques basals (panel demo) dels dos grups: useu les proves estadístiques més adients en cada tipus de variable. Discutiu internament quina prova seria més adient.
Useu el paquet **compareGroups**
4. Discussió sobre el possible disseny de l'estudi
5. Codi de programació ben comentat per facilitar seguir-lo

2.3 Memòria parcial

Prepareu una petita memòria **resumida** amb el contingut dels punts anteriors. Es suficient amb incloure una justificació raonada de la vostra visió respecte a cada punt i la sintaxi (en el cas que sigui aplicable)

La sintaxi usada per la preparació de les dades i l'anàlisi estadística haurà d'anar al final de la memòria. Recordeu d'incloure els comentaris i les (sub-)seccions que calgui per identificar bé els punts claus i els apartats del guió i les preguntes fetes

1.2 Lliuraments de pràctiques (aplica en tots els casos posteriors)

Quan s'obri l'activitat de lliurament, llavors haureu de lliurar la pràctica seguint les instruccions de sota.

Es **penalitzarà 0.5 punts** per a cada desviació sobre les instruccions donades:

- S'ha de fer usant el lliurament de tasques identificat en el Campus Virtual
- Poseu els noms i els NIUs de tots els integrants del grup a cada document.
- Cal usar la següent **nomenclatura** en el lliurament:
 - Sempre sense accents, ni 'ñ' ni espais en blanc
 - Els espais en blanc s'han de substituir amb el quíoi baix: " "
 - "Grup_XX_Sintaxi_R.r" o igual però amb extensió "Rmd" per a la sintaxi
 - "Grup_XX_Memoria.pdf" per a la memòria (*altres extensions com .doc o .docx o .rtf també acceptades*)

Sent "XX" el número del grup en 2 dígit, per exemple 01, 02 ... 12

Com ara <**Grup_01_Memoria.pdf**>

Conclusió

- Deixeu la memòria “neta de sintaxi” amb només *outputs* “nets” i la vostra redacció
 - Com a molt la sintaxi al final, no pel mig. No poseu el log (warnings, etc...)
- Poseu la sintaxi en un fitxer a banda
 - (ex: <Grup_01_Sintaxi_R.R>)

Índex

1. Importació de dades: Lectura de les dades en el sistema de programari estadístic escollit
2. Qualitat de les dades:
 - valors extrems
 - discrepàncies aparents
 - *missing values*
 - En cas contrari, estratègies a seguir.
3. Comparació de les característiques basals (panel demo) dels dos grups
4. Discussió sobre el possible disseny de l'estudi i la millor anàlisi a aplicar-hi

Importació

--- Import data from SAS -----

Key point: 'catalog_file' allows R to resolve SAS formats into labels.

```
demo <- read_sas(  
  data_file = "uab_demo2.sas7bdat",  
  catalog_file = "formats.sas7bcat"  
) %>%
```

```
as_tibble() %>%
```

Convert SAS labelled variables to factor using their value labels

```
mutate(across(where(is.labelled), as_factor)) %>%
```

Treat empty strings as missing (NA) BEFORE any factor conversion of character

```
mutate(across(where(is.character), ~ na_if(.x, "")))
```

```
#####
# Recode binary 0/1 variables to "No"/"Yes" (for nicer tables)
#####
demo <- demo %>%
  mutate(
    # Other fracture risk factors (0/1 -> No/Yes)
    OthRiskFract = factor(as.character(OthRiskFract),
                          levels = c("0", "1"),
                          labels = c("No", "Yes")),
    # Number of drugs >= 4 (0/1 -> No/Yes)
    CountActualGE4 = factor(as.character(CountActualGE4),
                             levels = c("0", "1"),
                             labels = c("No", "Yes"))
  )

```



```

# --- Variable-specific recoding -----
# IMPORTANT: avoid converting everything to factor blindly.
# Recode only what you need for the analyses.
#-----
# If NFractura should be numeric for analyses, make it numeric explicitly.
# (Sometimes it may come in as a factor after as_factor() if it had labels.)
demo <- demo %>%
  mutate(
    NFractura = suppressWarnings(as.numeric(as.character(NFractura))),
    # Categorical version used in descriptive tables / modelling
    NFracturaCat = case_when(
      is.na(NFractura) ~ NA_character_,
      NFractura == 0 ~ "0",
      NFractura == 1 ~ "1",
      NFractura >= 2 ~ ">=2"
    ) %>% factor(levels = c("0", "1", ">=2")),
    # Continuous version (redundant if NFractura already numeric, but explicit)
    NFracturaCont = NFractura
  )

# If you want to enforce factors for a few key variables (even if SAS labels fail),
# do it explicitly:
demo <- demo %>%
  mutate(across(
    c(Grup, Smoker, ALCOHOL, tipus_diabetis, OthRiskFract, CountActualGE4),
    ~ as.factor(.x)
  ))

```

```
#####
# Variable labels (metadata)
# Using attr(x, "label") is fine; it behaves like SAS variable labels in many
# workflows (e.g., some table packages can display them).
#####
attr(demo$PatNo, "label") <- "Subject identifier"
attr(demo$Grup, "label") <- "Group. 0: Control, 1: Case"
attr(demo$Edat, "label") <- "Age (years)"
attr(demo$Sexe, "label") <- "Sex. F: Female, M: Male"
attr(demo$ServeiAlta, "label") <- "Hospital discharge department"
attr(demo$PES, "label") <- "Weight (kg)"
attr(demo$TALLA, "label") <- "Height (cm)"
attr(demo$IMC, "label") <- "BMI (kg/m^2)"
attr(demo$ALCOHOL, "label") <- "Alcohol habit (0/1/2)"
attr(demo$Smoker, "label") <- "Smoking status (0/1/2)"
attr(demo$Hipogonad, "label") <- "Hypogonadism"
attr(demo$Artritis_reumatoide, "label") <- "Rheumatoid arthritis"
attr(demo$Fractura, "label") <- "Previous fracture"
attr(demo$NFractura, "label") <- "Number of previous fractures"
attr(demo$FX_familia, "label") <- "Family history of fractures"
attr(demo$Diabetis, "label") <- "Diabetes"
```

.....

```
#####
# Variable lists
# Goal:
#   - Define sets of variables to be treated as factors vs numeric
#   - Optionally define a subset of binary (0/1) factor variables
#####
# All variables except the first one (often an ID such as PatNo)
ListAll <- names(demo)[-1]
# Define numeric variables by name (more robust than using positions)
# NOTE: add/remove variable names here as needed
ListNum <- c("Edat", "PES", "TALLA", "IMC", "NFracturaCont")
# Everything else (in ListAll) will be treated as factor/categorical
ListFactor <- setdiff(ListAll, ListNum)
# Optional: binary (0/1) factor variables (edit this vector as needed)
# Tip: keep this by NAME, not by position, to avoid errors if columns move.
List01 <- c(
  "Hipogonad", "Artritis_reumatoide", "Fractura", "FX_familia", "Diabetis",
  "Densitometries", "Osteoporosi", "neoplasia", "HiperTiroidisme",
  "Malnutricio", "Malabsorcio", "Malaltia_Hep_Cro", "OthRiskFract",
  "CountActualGE4"
)
```

```
#####
# (A) Value labels / factor levels
# Goal:
#   - Ensure key categorical variables have readable labels AND correct ordering.
# Notes:
#   - If variables were imported from SAS with formats, they may already be factors.
#   - Therefore we convert via as.character() -> numeric when needed to avoid
#     mismatched levels.
#####
# Apply labels to multi-level categorical variables
demo <- demo %>%
  mutate(
    tipus_diabetis = factor(as.character(tipus_diabetis), levels = c("0", "1", "2"),
                           labels = c("No", "Type 1", "Type 2")),
    ALCOHOL        = factor(as.character(ALCOHOL), levels = c("0", "1", "2"),
                           labels = c("No", "Light", "Moderate")),
    Smoker         = factor(as.character(Smoker), levels = c("0", "1", "2"),
                           labels = c("No", "Active", "Former"))
  )

```

Índex

1. Importació de dades: Lectura de les dades en el sistema de programari estadístic escollit
2. Qualitat de les dades:
 - valors extrems
 - discrepàncies aparents
 - *missing values*
 - En cas contrari, estratègies a seguir.
3. Comparació de les característiques basals (panel demo) dels dos grups
4. Discussió sobre el possible disseny de l'estudi i la millor anàlisi a aplicar-hi

2. Qualitat de les dades

2. Qualitat de les dades: veure si les dades estan preparades i son vàlides per a l'anàlisi estadística: vigileu, valors extrems, discrepàncies aparents, *missing values*. En cas contrari, penseu i discutiu internament estratègies a seguir.

Descriptiva

```
##      PatNo      Grup      Edat      Sexe
##  Min.   : 1.0    Min.   :0.0000  Min.   :51.00  Length:408
## 1st Qu.:102.8    1st Qu.:0.0000  1st Qu.:78.00  Class :character
## Median :204.5    Median :0.0000  Median :84.00  Mode  :character
## Mean   :204.5    Mean   :0.3333  Mean   :82.05
## 3rd Qu.:306.2    3rd Qu.:1.0000  3rd Qu.:88.00
## Max.   :408.0    Max.   :1.0000  Max.   :95.00
##
##      NA's :42
##      ServeiAlta      PES      TALLA      IMC
## Length:408          Min.   : 38.50  Min.   :134.0  Min.   :17.90
## Class :character    1st Qu.: 57.10  1st Qu.:147.6  1st Qu.:25.41
## Mode  :character    Median : 67.50  Median :153.0  Median :28.09
##                      Mean   : 67.39  Mean   :153.7  Mean   :28.82
##                      3rd Qu.: 74.55  3rd Qu.:160.0  3rd Qu.:31.73
##                      Max.   :107.00  Max.   :179.0  Max.   :55.00
##                      NA's   :253    NA's   :286    NA's   :286
##      ALCOHOL      Smoker      Hipogonad Artritis_reumatoide
## Min.   :0.00000    Min.   :0.0000  Min.   :0    Min.   :0.000000
## 1st Qu.:0.00000    1st Qu.:0.0000  1st Qu.:0    1st Qu.:0.000000
## Median :0.00000    Median :0.0000  Median :0    Median :0.000000
## Mean   :0.07843    Mean   :0.1887  Mean   :0    Mean   :0.009804
## 3rd Qu.:0.00000    3rd Qu.:0.0000  3rd Qu.:0    3rd Qu.:0.000000
## Max.   :2.00000    Max.   :2.0000  Max.   :0    Max.   :1.000000
##
```

summary(uab)

##	PatNo	Grup	Edat	Sexe
##	0	0	42	0
##	ServeiAlta	PES	TALLA	IMC
##	0	253	286	286
##	ALCOHOL	Smoker	Hipogonad	Artritis_reumatoide
##	0	0	0	0
##	Fractura	NFractura	FX_familia	Diabetis
##	0	0	0	0
##	tipus_diabetis	Densitometries	Osteporosi	neoplasia
##	0	0	0	0
##	HiperTiroidisme	Malnutricio	Malabsorcio	Malaltia_Hep_Cro
##	0	0	0	0
##	OthRiskFract	CountActualGE4		
##	0	0		

`apply(is.na(datos), 2, sum)`

##	PatNo	Grup	Edat	Sexe
##	Mode :logical	Mode :logical	Mode :logical	Mode :logical
##	FALSE:408	FALSE:408	FALSE:366	FALSE:408
##			TRUE :42	
##	ServeiAlta	PES	TALLA	IMC
##	Mode :logical	Mode :logical	Mode :logical	Mode :logical
##	FALSE:408	FALSE:155	FALSE:122	FALSE:122
##		TRUE :253	TRUE :286	TRUE :286
##	ALCOHOL	Smoker	Hipogonad	Artritis_reumatoide
##	Mode :logical	Mode :logical	Mode :logical	Mode :logical
##	FALSE:408	FALSE:408	FALSE:408	FALSE:408

`summary(is.na(dades))`

- Els valors faltants de les edats i sexe els podríem **imputar** tenint en compte l'edat i sexe del seu cas o control respectiu, ja que agafen persones de la mateixa edat i sexe per cada cas-control.
- ...hi ha casos que tenen el **IMC mal calculat**, pel que també s'hauria de **recalcular**.

```

— Variable type: factor
skim_variable      n_missing complete_rate top_counts
1 Grup              0             1      0: 272, 1: 136
2 Sexe              29           0.929 F: 300, M: 79, emp: 0
3 ServeiAlta        0             1      MDU: 225, TRA: 134, CGU: 31, TOU: 13
4 ALCOHOL            0             1      0: 379, 1: 26, 2: 3
5 Smoker             0             1      Non: 362, For: 31, Act: 15
6 Hipogonad         0             1      No: 408
7 Artritis_reumatoide 0             1      No: 404, Si: 4
8 Fractura           0             1      No: 296, Si: 112
9 NFractura          0             1      0: 296, 1: 95, 2: 15, 6: 1
10 FX_familia        0             1      No: 408
11 Diabetis          0             1      No: 281, Si: 127
12 tipus_diabetis     0             1      No : 281, Tip: 125, Tip: 2
13 Densitometries    0             1      No: 390, Si: 18
14 Osteoporosi        0             1      No: 374, Si: 34
15 neoplasia          0             1      No: 358, Si: 50
16 HiperTiroidisme   0             1      No: 400, Si: 8
17 Malnutricio        0             1      No: 401, Si: 7
18 Malabsorcio        0             1      No: 407, Si: 1
19 Malaltia_Hep_Cro  0             1      No: 397, Si: 11
20 OthRiskFract      0             1      0: 334, 1: 74
21 CountActualGE4    0             1      1: 314, 0: 94

```


skimr::skim(df.demo)

```

— Variable type: numeric
skim_variable n_missing complete_rate mean sd p0 p25 p50 p75 p100 hist
1 PatNo        0             1      204. 118. 1 103. 204. 306. 408
2 Edat         42           0.897 82.0 8.84 51 78 84 88 95
3 PES          253           0.380 67.4 13.1 38.5 57.1 67.5 74.5 107
4 TALLA        286           0.299 154. 8.47 134 148. 153 160 179
5 IMC          286           0.299 28.8 5.62 17.9 25.4 28.1 31.7 55
6 NFracturaCont 0             1      0.338 0.689 0 0 0 1 7

```

```
pairs(demo2[c(2:5)])
```






Figura 1: Descriptiva univariant de les variables numèriques

Missings


```
demo %>% gather(key = "variable", value = "valor", -PatNo) %>%  
  group_by(variable) %>%  
  dplyr::summarize(percentatge_NA = 100 * sum(is.na(valor)) / length(valor)) %>%  
  print(n = nrow(demo)) #hacer un round?
```



```
## # A tibble: 25 x 2  
##   variable      percentatge_NA  
##   <chr>          <dbl>  
## 1 ALCOHOL        0  
## 2 Artritis_reumatoide 0  
## 3 CountActualGE4    0  
## 4 Densitometries    0  
## 5 Diabetis         0  
## 6 Edat          10.3  
## 7 Fractura         0  
## 8 FX_familia       0  
## 9 Grup            0  
## 10 HiperTiroidisme  0  
## 11 Hipogonad        0  
## 12 IMC             70.1  
## 13 Malabsorcio       0  
## 14 Malaltia_Hep_Cro  0  
## 15 Malnutricio       0  
## 16 neoplasia        0  
## 17 NFractura        0  
## 18 Osteoporosi      0  
## 19 OthRiskFract     0  
## 20 PES             62.0  
## 21 ServeiAlta       0  
## 22 Sexe            7.11  
## 23 Smoker           0  
## 24 TALLA           70.1  
## 25 tipus_diabetis   0
```

Table 1: Valors faltants


Variable	Percentatge missings
TALLA	70.098039
IMC	70.098039
PES	62.009804
Edat	10.294118
Sexe	7.107843
PatNo	0.000000
Grup	0.000000
ServeiAlta	0.000000
ALCOHOL	0.000000
Smoker	0.000000


```
demo_long <- df.demo %>% gather(key = "variable", value = "valor")
demo_long %>%
  group_by(variable) %>%
  dplyr::summarize(porcentaje_NA = 100 * sum(is.na(valor)) / length(valor)) %>%
  ggplot(aes(x = reorder(variable, desc(porcentaje_NA)), y = porcentaje_NA)) +
  geom_col() +
  labs(title = "Porcentaje valores ausentes por variable",
       x = "Variable", y = "Porcentaje NAs") +
  theme_bw()+ theme(axis.text.x=element_text(angle=90))
```






```
# Anàlisi dels valors perduts  
library(naniar)|
```







Gràfico 1: patrón de valores faltantes en el dataset.

variable	n_miss	n_miss_cumsum
Edat	42	42
Sexe	29	71
PES	253	324
TALLA	286	610
IMC	286	896

Tabla 1: Tabla de variables con datos faltantes

Descripció de les dades:

Com que les dades tenen *missing values*, comprovem quants casos complets tenim i creem una nova base de dades amb *només aquests casos*. S'observen valors buits també a la variable **sexe**, per tant, els passem a *NA*'s.

Un cop mirats quants casos complets tenim, veiem que la gran majoria dels missing pertanyen a les variables **pes, talla i IMC**; creiem que són **MNAR**, per tant, creem una nova variable factor, que podria ser rellevant en el model, on **sí** pertany a que hi ha missing values en aquell individu en alguna de les variables, i **no** altrament.

Discrepancies

```
table(demo$Diabetis,demo$tipus_diabetis) # diabetis ok
```

```
##
```

```
##      no Tipus 1 Tipus 2
```

```
## no 281 0 0
```

```
## si 0 2 125
```

```
table(demo$Fractura,demo$NFractura) # fractures ok
```

```
##
```

```
##      0 1 2+
```

```
## no 296 0 0
```

```
## si 0 95 17
```


IMC

```
which(dades$IMC == dades$PES/(dades$TALLA*100)^2)
```

```
## integer(0)
```

```
which(dades$IMC != dades$PES/(dades$TALLA*100)^2)
```

```
## [1] 1 2 6 7 13 19 22 25 31 32 37 41 42 46 49 51 52 54
## [19] 62 69 72 78 83 91 95 96 97 101 102 106 109 111 115 116 118 119
## [37] 123 133 143 144 145 147 149 151 152 157 160 162 164 165 167 169 171 176
## [55] 179 180 184 189 192 205 206 209 216 217 226 228 229 230 233 234 241 247
## [73] 248 252 253 254 263 267 268 269 276 279 283 286 287 288 291 292 293 295
## [91] 304 305 307 313 314 315 317 322 327 328 332 335 342 344 348 352 357 358
## [109] 361 365 371 379 385 389 392 393 396 401 402 403 405 407
```

```


> IMC=demo$PES/(demo$TALLA/100)^2
> IMC<-round(IMC[!is.nan(IMC)],2)
> IMC2<-round(demo$IMC[!is.nan(demo$IMC)],2)
>
> IMC_comp<-data.frame(IMC,IMC2,IMC2-IMC)
>
> summary(IMC_comp)



```

##	IMC	IMC2	IMC2...IMC
##	Min. :17.90	Min. :17.90	Min. : -0.7700
##	1st Qu.:25.34	1st Qu.:25.41	1st Qu.: 0.0000
##	Median :28.09	Median :28.09	Median : 0.0000
##	Mean :28.52	Mean :28.82	Mean : 0.2931
##	3rd Qu.:31.43	3rd Qu.:31.73	3rd Qu.: 0.0000
##	Max. :43.37	Max. :55.00	Max. :31.1900


Extremes

```
par(mfrow=c(2,2), mar = c(2, 5, 2, 2))
boxplot(demo$Edat, ylab = "Edat (anys)")
boxplot(demo$PES, ylab = "Pes (kg)")
boxplot(demo$TALLA, ylab = "Talla (cm)")
boxplot(demo$IMC, ylab = expression(paste("Índex de Massa Corporal ( ", kg/m^2, ")")))
```





```
#boxplot con todas las numericas  
boxplot(uab_demo1[,-1])
```



IMC

```
#####  
# IMC  
#####  
# Coincidences  
#-----  
# 1. without rounding  
# sum(df.demo$IMC == df.demo$PES/((df.demo$TALLA/100)^2), na.rm = TRUE)  
# only 20 coincidences  
# df.demo$IMC<-df.demo$PES/((df.demo$TALLA/100)^2)  
#-----  
# 2. with rounding  
imc_malament<-which(0.5<=df.demo$IMC-round(df.demo$PES/(df.demo$TALLA/100)^2,digits = 4))  
df.demo[imc_malament,c("PatNo", "PES", "TALLA", "IMC")]  
#-----
```

A tibble: 5 × 4

	PatNo	PES	TALLA	IMC
	<dbl>	<dbl>	<dbl>	<dbl>
1	1	75.3	162	29.5
2	123	76.7	154	33.7
3	162	66.9	161	27.0
4	365	55	152.	55
5	392	70.9	157	29.4

Variables poc informatives

```
nearZeroVar(demo2, saveMetrics = T)
```

##	freqRatio	percentUnique	zeroVar	nzv
## PatNo	1.000000	100.000000	FALSE	FALSE
## Edat	1.148148	8.0882353	FALSE	FALSE
## PES	1.000000	24.2647059	FALSE	FALSE
## TALLA	1.000000	17.6470588	FALSE	FALSE
## IMC	1.000000	27.9411765	FALSE	FALSE
## Grup	2.000000	0.4901961	FALSE	FALSE
## Sexe	3.797468	0.4901961	FALSE	FALSE
## ServeiAlta	1.679104	1.7156863	FALSE	FALSE
## ALCOHOL	14.576923	0.7352941	FALSE	FALSE
## Smoker	11.677419	0.7352941	FALSE	FALSE
## Hipogonad	0.000000	0.2450980	TRUE	TRUE
## Artritis_reumatoide	101.000000	0.4901961	FALSE	TRUE
## Fractura	2.642857	0.4901961	FALSE	FALSE
## NFractura	3.115789	1.2254902	FALSE	FALSE
## FX familia	0.000000	0.2450980	TRUE	TRUE
## Diabetis	2.212598	0.4901961	FALSE	FALSE
## tipus_diabetis	2.248000	0.7352941	FALSE	FALSE
## Densitometries	21.666667	0.4901961	FALSE	TRUE
## Osteoporosi	11.000000	0.4901961	FALSE	FALSE
## neoplasia	7.160000	0.4901961	FALSE	FALSE
## HiperTiroidisme	50.000000	0.4901961	FALSE	TRUE
## Malnutricio	57.285714	0.4901961	FALSE	TRUE
## Malabsorcio	407.000000	0.4901961	FALSE	TRUE
## Malaltia_Hep_Cro	36.090909	0.4901961	FALSE	TRUE

Conclusió qualitat

- Discrepàncies aparents ?
- Missings
 - Estratègies possibles
 - Aclariments per solucionar les dades
 - Exclusió pacients
 - Imputació

Índex

1. Importació de dades: Lectura de les dades en el sistema de programari estadístic escollit
2. Qualitat de les dades:
 - valors extrems
 - discrepàncies aparents
 - *missing values*
 - En cas contrari, estratègies a seguir
3. Comparació de les característiques basals (panel demo) dels dos grups
4. Discussió sobre el possible disseny de l'estudi i la millor anàlisi a aplicar-hi

3. Comparació de les característiques basals

```

""
## ----- Summary of results by groups of 'Grup'-----
##
##
##      var                N  p.value  method      selection
##  1  Edat                366  0.931   continuous normal ALL
##  2  PES                 155  0.098*  continuous normal ALL
##  3  TALLA               122  0.262   continuous normal ALL
##  4  IMC                 122  0.091*  continuous normal ALL
##  5  Sexe                379  1.000   categorical      ALL
##  6  ServeiAlta          408  <0.001** categorical      ALL
##  7  ALCOHOL             408  0.197   categorical      ALL
##  8  Smoker              408  0.756   categorical      ALL
##  9  Hipogonad           408  .        categorical      ALL
## 10  Artritis_reumatoide 408  1.000   categorical      ALL
## 11  Fractura            408  <0.001** categorical      ALL
## 12  NFractura           408  <0.001** categorical      ALL
## 13  FX_familia         408  .        categorical      ALL
## 14  Diabetis            408  0.473   categorical      ALL
## 15  tipus_diabetis      408  0.433   categorical      ALL
## 16  Densitometries      408  0.201   categorical      ALL
## 17  Osteoporosi         408  0.006** categorical      ALL
## 18  neoplasia           408  0.311   categorical      ALL
## 19  HiperTiroidisme     408  0.449   categorical      ALL
## 20  Malnutricio         408  0.690   categorical      ALL
## 21  Malabsorcio         408  1.000   categorical      ALL
## 22  Malaltia_Hep_Cro    408  0.517   categorical      ALL
## 23  OthRiskFract       408  0.751   categorical      ALL
## 24  CountActualGE4     408  0.967   categorical      ALL
## -----
## Signif. codes:  0 '***' 0.05 '**' 0.1 ' ' 1

```

```
library(compareGroups)
```

```
tabla<-compareGroups(Grup~.,data = uab, include.miss = TRUE)
```

```
##
## -----Summary descriptives table by 'Grup'-----
##
##
```

	[ALL] N=408	0 N=272	1 N=136	p.overall	N
PatNo	204 (118)	205 (118)	204 (118)	0.989	408
Edat	82.0 (8.84)	82.1 (8.80)	82.0 (8.97)	0.931	366
Sexe:				0.988	408
F	300 (73.5%)	200 (73.5%)	100 (73.5%)		
M	79 (19.4%)	53 (19.5%)	26 (19.1%)		
ServeiAlta:				<0.001	408
CGURG	31 (7.60%)	31 (11.4%)	0 (0.00%)		
GOURG	2 (0.49%)	2 (0.74%)	0 (0.00%)		
MDURG	225 (55.1%)	225 (82.7%)	0 (0.00%)		
MED	2 (0.49%)	0 (0.00%)	2 (1.47%)		
PSURG	1 (0.25%)	1 (0.37%)	0 (0.00%)		
TOURG	13 (3.19%)	13 (4.78%)	0 (0.00%)		
TRA	134 (32.8%)	0 (0.00%)	134 (98.5%)		
PES	67.4 (13.1)	68.5 (13.7)	65.0 (11.6)	0.098	155
TALLA	154 (8.47)	154 (8.70)	152 (7.83)	0.262	122
IMC	28.8 (5.62)	29.3 (5.84)	27.5 (4.90)	0.091	122
ALCOHOL	0.08 (0.30)	0.08 (0.29)	0.07 (0.31)	0.818	408
Smoker	0.19 (0.55)	0.19 (0.57)	0.18 (0.53)	0.747	408
Artritis_reumatoide	0.01 (0.10)	0.01 (0.10)	0.01 (0.09)	0.705	408
Fractura	0.27 (0.45)	0.20 (0.40)	0.43 (0.50)	<0.001	408
NFractura	0.34 (0.69)	0.25 (0.64)	0.51 (0.75)	0.001	408
Diabetis	0.31 (0.46)	0.30 (0.46)	0.34 (0.47)	0.413	408
tipus diabetis	0.62 (0.92)	0.59 (0.91)	0.68 (0.95)	0.370	408
Densitometries	0.04 (0.21)	0.03 (0.18)	0.07 (0.25)	0.169	408
Osteporosi	0.08 (0.28)	0.06 (0.23)	0.14 (0.35)	0.011	408
neoplasia	0.12 (0.33)	0.14 (0.34)	0.10 (0.30)	0.218	408
HiperTiroidisme	0.02 (0.14)	0.01 (0.12)	0.03 (0.17)	0.367	408
Malnutricio	0.02 (0.13)	0.01 (0.12)	0.02 (0.15)	0.615	408
Malabsorcio	0.00 (0.05)	0.00 (0.06)	0.00 (0.00)	0.318	408
Malaltia_Hep_Cro	0.03 (0.16)	0.02 (0.15)	0.04 (0.19)	0.427	408
OthRiskFract	0.18 (0.39)	0.19 (0.39)	0.17 (0.38)	0.647	408
CountActualGE4	0.77 (0.42)	0.77 (0.42)	0.76 (0.43)	0.869	408

```
##
```

Discussió comparabilitat

- Descriptiva
 - N %
 - Median [P25-P75].... Mean (SD)
- Proves estadístiques
 - Fisher's exact test (ji-quadrat)
 - Mann–Whitney U test (t-Student)

```
library(compareGroups)
```

```
tabla<-compareGroups(Grup~.,data = uab, include.miss = TRUE)
```

```
##
## -----Summary descriptives table by 'Grup'-----
##
##
##
## [ALL]      0      1      p.overall  N
## N=408      N=272   N=136
## -----
## PatNo      204 (118)  205 (118)  204 (118)  0.989  408
```

Possible values in methods statement are:

- 1: forces analysis as normal-distributed
- 2: forces analysis as continuous non-normal
- 3: forces analysis as categorical
- NA: performs a Shapiro-Wilks test to decide between normal or non-normal

If the `method` argument is stated as `NA` for a variable, then a Shapiro-Wilk test for normality is used to decide if the variable is normal or non-normal distributed. To change the significance threshold:

```
compareGroups(group ~ age + smoke + waist + hormo, data = predimed,
  method = c(waist = NA), alpha = 0.01)
```

```
## Diabetis      0.31 (0.46) 0.30 (0.46) 0.34 (0.47) 0.413 408
## tipus diabetis 0.62 (0.92) 0.59 (0.91) 0.68 (0.95) 0.370 408
## Densitometries 0.04 (0.21) 0.03 (0.18) 0.07 (0.25) 0.169 408
## Osteoporosi    0.08 (0.28) 0.06 (0.23) 0.14 (0.35) 0.011 408
## neoplasia      0.12 (0.33) 0.14 (0.34) 0.10 (0.30) 0.218 408
## HiperTiroidisme 0.02 (0.14) 0.01 (0.12) 0.03 (0.17) 0.367 408
## Malnutricio    0.02 (0.13) 0.01 (0.12) 0.02 (0.15) 0.615 408
## Malabsorcio    0.00 (0.05) 0.00 (0.06) 0.00 (0.00) 0.318 408
## Malaltia_Hep_Cro 0.03 (0.16) 0.02 (0.15) 0.04 (0.19) 0.427 408
## OthRiskFract   0.18 (0.39) 0.19 (0.39) 0.17 (0.38) 0.647 408
## CountActualGE4 0.77 (0.42) 0.77 (0.42) 0.76 (0.43) 0.869 408
## -----
```

	[ALL] N=408	Control N=272	Cas N=136	p.overall
Edat	82.0 (8.84)	82.1 (8.80)	82.0 (8.97)	0.931
Sexe:				0.988
F	29 (7.11%)	19 (6.99%)	10 (7.35%)	
M	300 (73.5%)	200 (73.5%)	100 (73.5%)	
M	79 (19.4%)	53 (19.5%)	26 (19.1%)	
ServeiAlta:				<0.001
CGURG	31 (7.60%)	31 (11.4%)	0 (0.00%)	
GOURG	2 (0.49%)	2 (0.74%)	0 (0.00%)	
MDURG	225 (55.1%)	225 (82.7%)	0 (0.00%)	
MED	2 (0.49%)	0 (0.00%)	2 (1.47%)	
PSURG	1 (0.25%)	1 (0.37%)	0 (0.00%)	
TOURG	13 (3.19%)	13 (4.78%)	0 (0.00%)	
TRA	134 (32.8%)	0 (0.00%)	134 (98.5%)	
PES	67.4 (13.1)	68.5 (13.7)	65.0 (11.6)	0.098
TALLA	154 (8.47)	154 (8.70)	152 (7.83)	0.262
IMC	28.8 (5.62)	29.3 (5.84)	27.5 (4.90)	0.091
ALCOHOL:				0.197
No	379 (92.9%)	251 (92.3%)	128 (94.1%)	
Light	26 (6.37%)	20 (7.35%)	6 (4.41%)	
Moderate	3 (0.74%)	1 (0.37%)	2 (1.47%)	
Smoker:				0.756
No	362 (88.7%)	241 (88.6%)	121 (89.0%)	
Active	15 (3.68%)	9 (3.31%)	6 (4.41%)	
Former	31 (7.60%)	22 (8.09%)	9 (6.62%)	
Hipogonad: No	408 (100%)	272 (100%)	136 (100%)	.
Artritis_reumatoide:				1.000
No	404 (99.0%)	269 (98.9%)	135 (99.3%)	
Yes	4 (0.98%)	3 (1.10%)	1 (0.74%)	
Fractura:				<0.001
No	296 (72.5%)	218 (80.1%)	78 (57.4%)	
Yes	112 (27.5%)	54 (19.9%)	58 (42.6%)	
NFractura:				<0.001
0	296 (72.5%)	218 (80.1%)	78 (57.4%)	
1	95 (23.3%)	44 (16.2%)	51 (37.5%)	
2	15 (3.68%)	9 (3.31%)	6 (4.41%)	
6	1 (0.25%)	0 (0.00%)	1 (0.74%)	
7	1 (0.25%)	1 (0.37%)	0 (0.00%)	

	[ALL] N=408	Control N=272	Cas N=136	p.overall
Edat	84.0 [78.0;88.0]	84.0 [78.0;88.0]	84.0 [78.0;88.0]	1.000
Sexe:				1.000
F	300 (79.2%)	200 (79.1%)	100 (79.4%)	
M	79 (20.8%)	53 (20.9%)	26 (20.6%)	
ServeiAlta:				<0.001
CGURG	31 (7.60%)	31 (11.4%)	0 (0.00%)	
GOURG	2 (0.49%)	2 (0.74%)	0 (0.00%)	
MDURG	225 (55.1%)	225 (82.7%)	0 (0.00%)	
MED	2 (0.49%)	0 (0.00%)	2 (1.47%)	
PSURG	1 (0.25%)	1 (0.37%)	0 (0.00%)	
TOURG	13 (3.19%)	13 (4.78%)	0 (0.00%)	
TRA	134 (32.8%)	0 (0.00%)	134 (98.5%)	
PES	67.5 [57.1;74.5]	68.5 [59.0;76.7]	65.0 [57.0;71.0]	0.326
TALLA	153 [148;160]	154 [148;160]	152 [147;159]	0.689
IMC	28.1 [25.4;31.7]	28.7 [25.5;32.1]	27.4 [24.7;29.3]	0.427
ALCOHOL:				0.491
No	379 (92.9%)	251 (92.3%)	128 (94.1%)	
Light	26 (6.37%)	20 (7.35%)	6 (4.41%)	
Moderate	3 (0.74%)	1 (0.37%)	2 (1.47%)	
Smoker:				0.978
No	362 (88.7%)	241 (88.6%)	121 (89.0%)	
Active	15 (3.68%)	9 (3.31%)	6 (4.41%)	
Former	31 (7.60%)	22 (8.09%)	9 (6.62%)	
Hipogonad: No	408 (100%)	272 (100%)	136 (100%)	.
Artritis_reumatoide:				1.000
No	404 (99.0%)	269 (98.9%)	135 (99.3%)	
Yes	4 (0.98%)	3 (1.10%)	1 (0.74%)	
Fractura:				<0.001
No	296 (72.5%)	218 (80.1%)	78 (57.4%)	
Yes	112 (27.5%)	54 (19.9%)	58 (42.6%)	
NFractura:				<0.001
0	296 (72.5%)	218 (80.1%)	78 (57.4%)	
1	95 (23.3%)	44 (16.2%)	51 (37.5%)	
2+	17 (4.17%)	10 (3.68%)	7 (5.15%)	

	0	1	p.overall
Sexe:	19 (6.99%)	10 (7.35%)	0.988
Sexe: F	200 (73.5%)	100 (73.5%)	NA
Sexe: M	53 (19.5%)	26 (19.1%)	NA
ServeiAlta: CGURG	31 (11.4%)	0 (0.00%)	<0.001
ServeiAlta: GOURG	2 (0.74%)	0 (0.00%)	NA
ServeiAlta: MDURG	225 (82.7%)	0 (0.00%)	NA
ServeiAlta: MED	0 (0.00%)	2 (1.47%)	NA
ServeiAlta: PSURG	1 (0.37%)	0 (0.00%)	NA
ServeiAlta: TOURG	13 (4.78%)	0 (0.00%)	NA
ServeiAlta: TRA	0 (0.00%)	134 (98.5%)	NA
ALCOHOL: 0	251 (92.3%)	128 (94.1%)	0.197
ALCOHOL: 1	20 (7.35%)	6 (4.41%)	NA
ALCOHOL: 2	1 (0.37%)	2 (1.47%)	NA
Smoker: 0	241 (88.6%)	121 (89.0%)	0.756
Smoker: 1	9 (3.31%)	6 (4.41%)	NA
Smoker: 2	22 (8.09%)	9 (6.62%)	NA
Hipogonad: 0	272 (100%)	136 (100%)	.
Artritis_reumatoide: 0	269 (98.9%)	135 (99.3%)	1.000
Artritis_reumatoide: 1	3 (1.10%)	1 (0.74%)	NA
Fractura: 0	218 (80.1%)	78 (57.4%)	<0.001
Fractura: 1	54 (19.9%)	58 (42.6%)	NA

Table 1: Summary descriptives table by groups of 'Grup'

	[ALL] N=408	Control N=272	Caso N=136	p.overall
Edat	82.0 (8.84)	82.1 (8.80)	82.0 (8.97)	1.000
Sexe:				1.000
F	300 (79.2%)	200 (79.1%)	100 (79.4%)	
M	79 (20.8%)	53 (20.9%)	26 (20.6%)	
ServeiAlta:				<0.001
CGURG	31 (7.60%)	31 (11.4%)	0 (0.00%)	
GOURG	2 (0.49%)	2 (0.74%)	0 (0.00%)	
MDURG	225 (55.1%)	225 (82.7%)	0 (0.00%)	
MED	2 (0.49%)	0 (0.00%)	2 (1.47%)	
PSURG	1 (0.25%)	1 (0.37%)	0 (0.00%)	
TOURG	13 (3.19%)	13 (4.78%)	0 (0.00%)	
TRA	134 (32.8%)	0 (0.00%)	134 (98.5%)	
PES	67.4 (13.1)	68.5 (13.7)	65.0 (11.6)	0.361
TALLA	154 (8.47)	154 (8.70)	152 (7.83)	0.640
IMC	28.8 (5.62)	29.3 (5.84)	27.5 (4.90)	0.361
ALCOHOL:				0.553
No	379 (92.9%)	251 (92.3%)	128 (94.1%)	
Light	26 (6.37%)	20 (7.35%)	6 (4.41%)	
Moderate	3 (0.74%)	1 (0.37%)	2 (1.47%)	
Smoker:				0.978
No	362 (88.7%)	241 (88.6%)	121 (89.0%)	
Active	15 (3.68%)	9 (3.31%)	6 (4.41%)	
Former	31 (7.60%)	22 (8.09%)	9 (6.62%)	
Hipogonad: No	408 (100%)	272 (100%)	136 (100%)	.
Artritis_reumatoide:				1.000
No	404 (99.0%)	269 (98.9%)	135 (99.3%)	
Sí	4 (0.98%)	3 (1.10%)	1 (0.74%)	

FilVar_lab	FilVal_Lab	0 (n=272) n (%)	1 (n=136) n (%)	TOTAL (n=408) n (%)	p-value
NFractura	0	218 (80.1%)	78 (57.4%)	296 (72.5%)	<.0001
NFractura	1	44 (16.2%)	51 (37.5%)	95 (23.3%)	
NFractura	2	9 (3.3%)	6 (4.4%)	15 (3.7%)	
NFractura	6	0 (0.0%)	1 (0.7%)	1 (0.2%)	
NFractura	7	1 (0.4%)	0 (0.0%)	1 (0.2%)	
NFractura	TOTAL	272 (100.0%)	136 (100.0%)	408 (100.0%)	
NFractura	Missing	0	0	0	<.0001
NFractura	N	272	136	408	
NFractura	Mean(SD)	0.25 (0.64)	0.51 (0.75)	0.34 (0.69)	
NFractura	Median(P25,P75)	0.00 (0.00 , 0.00)	0.00 (0.00 , 1.00)	0.00 (0.00 , 1.00)	

Conclusió comparabilitat

- Prior history of fracture
- Osteoporosi
- Servei alta Hospitalària
- Pes (+/-)...

Índex

1. Importació de dades: Lectura de les dades en el sistema de programari estadístic escollit
2. Qualitat de les dades:
 - valors extrems
 - discrepàncies aparents
 - *missing values*
 - En cas contrari, estratègies a seguir.
3. Comparació de les característiques basals (panel demo) dels dos grups
4. Discussió sobre el possible disseny de l'estudi i la millor anàlisi a aplicar-hi

4. Discussió disseny

Alguns comentaris

- En quant a l'anàlisi descriptiu de variables continues es podria utilitzar la mitjana, mediana, desviació estàndard i interval de confiança del 95%.
- Per a la descripció de variables categòriques, el nombre i percentatge de pacients per categoria de resposta.

Alguns comentaris

- *Caldrà fer una selecció de les variables que volem incloure al multivariable*
- Segurament escolliríem entre (??):
 - pes, IMC, serveiAlta, fractura, NFractura, osteporosi
- Mètodes de selecció de subconjunts (com stepwise o regsubset)??

Alguns comentaris

- **Volem veure quins fàrmacs augmenten la probabilitat de fractura ossia, caldrà**
 - Per tal d'arribar a aquest punt, hem de saber quines variables causen més diferències entre casos i controls.
 - Volem que aquestes siguin lo mínimes possibles per poder aplicar regressió logística, que pot avaluar múltiples exposicions
 - ...quantificar la força d'associació entre l'esdeveniment d'interès o malaltia i les exposicions prèvies de manera independent, per a evitar que un factor condicioni l'efecte d'un altre

EL disseny de l'estudi no és l'adquat per tal de poder extreure unes bones conclusions. El plantejament de fer un cas-control no ajuda a determinar si els medicaments causen una pèrdua de densitat òssea. El que nosaltres proposariem com a disseny adient és fer un estudi de cohorts, on separariem a persones d'entre 50 i 90 anys en dos grups, en un posariem els que prenen medicaments i a l'altre els que no. Al final de l'estudi comprobariem si el fet de prendre medicaments causa més trencadures d'òs que els que no en prenen.

Les fractures, i per consegüent el NFractures són significatives a la variable Cas, igual que la Osteoporosi. Això és bastant evident, ja que l'estudi tracta d'aquestes variables com a base principal de l'objectiu. Per tant, tot i ser significatives, aquestes variables no ens donen cap informació.

Troblem que l'estudi, per a ser un estudi realment eficaç, ens falta informació per contrastar l'hipòtesi d'aquest, ja que les medicacions per a diferents malalties no són iguals, o no porten els mateixos components, i a la base de dades només tenim una variable que compti la medicació que pren el pacient, sense valorar de quina malaltia és.

L'article presenta un estudi observacional **descriptiu**, retrospectiu de casos i controls de base hospitalària

El disseny de casos i controls és un disseny molt òptim pel fet que ja estudiem casos de persones fracturades, però no permet calcular cap tipus de prevalença ni incidència, només Odds Ratios

Però sí: prevalença us de fàrmacs en casos i controls

...s'hauria de fer un **disseny transversal** però no només unicèntric sinó de diferents centres de tota Catalunya per poder aplicar els resultats a tota la població d'estudi

...un disseny més robust, el disseny de cohorts seria el més desitjable si es disposa dels recursos necessaris.

....el temps d'observació fins que apareguin les fractures pot ser molt llarg.

2.4 **Rebalanceig** de les dades

2:1 ... => ??

...t-Student per mirar si és significatiu o no i per a les variables factor farem un test Chi-quadrat

Sí, però...

El disseny es tracta d'un cas-control, el qual és un estudi observacional analític on es divideix la mostra en dos grups: el cas, el qual està format pels individuals malalts (o sobre els quals s'aplica el tractament), i el control, el qual està format per individus sans (o que no reben el tractament). Una limitació comuna dels estudis cas-control és el possible biaix en la selecció de la mostra. En fer una taula descriptiva, hem vist que la mostra està ben equilibrada pel que fa a l'edat (mitjana de 82.1 pel grup 0, i 82.0 pel grup 1) i el sexe (aprox. 79% de dones i 21% d'homes pels dos grups, amb la resta missing).

Donades les dades, creiem que el disseny s'ha vist corromput ja que falten molts valors en les variables identificadores sexe, alcada i pes, fet que no s'hauria de produir ja que són variables fàcils i imprescindibles de recollir per part de l'investigador.

factores de risc en situacions on els esdeveniments són poc freqüents. Encara que els estudis de casos i controls poden indicar associacions, és fonamental tenir en compte que per establir una relació causal directa seria necessari un disseny experimental com un assaig clínic aleatori.

Valors perduts

1. **Eliminar registres** amb massa valors perduts per evitar biaixos.
2. **Imputar valors** (per exemple, mitjana o regressió) per mantenir la mida de la mostra.
3. **Deixar els NA** si no afectaven l'anàlisi principal.

Punts forts del disseny:

- És adequat per estudiar malalties rares com la fractura de maluc.
- Permet estudiar múltiples factors de risc alhora.

Limitacions:

- Biaix de selecció: els pacients provenen d'un entorn hospitalari, i això pot no ser representatiu de la població general.
- Confusió per factors com edat i comorbiditats: algunes diferències poden ser degudes a altres causes no mesurades en l'estudi.

Els resultats mostren una associació entre fractura i altres factors clínics, però cal un anàlisi més profund per establir causalitat.

A continuació es realitza un `compareGroups` per tal de comparar les variables entre el grup de casos i el grup de controls. Volem analitzar si hi ha diferències significatives entre aquests per a cada variable. Les variables, segons quin tipus siguin, es tracten de diferent manera, s'apliquen diferents tests i com a conseqüència hipòtesis.

En el cas que la variable sigui contínua amb distribució Normal, s'analitza amb una ANOVA:

$$H_0 : \mu_{\text{cas}} = \mu_{\text{control}}$$

$$H_1 : \mu_{\text{cas}} \neq \mu_{\text{control}}$$

En cas de que la variable sigui continua però no segueixi una distribució Normal, s'analitza amb un Kruskall-Wallis test:

$$H_0 : \text{mediana}_{\text{cas}} = \text{mediana}_{\text{control}}$$

$$H_1 : \text{mediana}_{\text{cas}} \neq \text{mediana}_{\text{control}}$$

Per últim, en el cas que la variable sigui categòrica, s'analitza amb un test de Chi-quadrat (si totes les cel·les tenen suficients observacions) o el test exacte de Fisher (si hi ha poques dades en alguna cel·la).

$$H_0 : \text{distribució}_{\text{casos}} = \text{distribució}_{\text{controls}}$$

$$H_1 : \text{distribució}_{\text{casos}} \neq \text{distribució}_{\text{controls}}$$