

Pràctica 1 – Part 1

Discussió

Ferran Torres
Biostatistics Unit, Medical School, Office M3/323B
Universitat Autònoma de Barcelona (UAB)

Pràctica 1 – Part-1 - Discussió

1

1.2 Lliuraments de pràctiques (aplica en tots els casos posteriors)

Quan s'obri l'activitat de lliurament, llavors haureu de lliurar la pràctica seguint les instruccions de sota.

Es **penalitzarà 0.5 punts** per a cada desviació sobre les instruccions donades:

- S'ha de fer usant el lliurament de tasques identificat en el Campus Virtual
- Poseu els **noms** i els **NIUs** de tots els integrants del grup a cada document.
- Cal usar la següent **nomenclatura** en el lliurament:
 - Sempre sense accents, ni 'ñ' ni espais en blanc
 - Els espais en blanc s'han de substituir amb el guió baix: "-"
 - "Grup_XX_Sintaxi_R.r" o igual però amb extensió "Rmd" per a la sintaxi
 - "Grup_XX_Memoria.pdf" per a la memòria (*altres extensions com .doc o .docx o .rtf també acceptades*)

Sent "XX" el número del grup en 2 dígits, per exemple 01, 02 ... 12

Com ara <Grup_01_Memoria.pdf>

Qualsevol document adicional ha de començar amb el text "Grup_XX_"

- Podeu usar Markdown o alternatives, però en aquest cas passeu igualment el fitxer de sintaxi a banda i vull veure les respostes al que es demana en "net" a la memòria. Pregunteu si no ho veieu clar...

Pràctica 1 – Part-1 - Discussió

2

2.2 Punts a seguir:

1. Importació de dades: Lectura de les dades en el sistema de programari estadístic escollit
2. Qualitat de les dades: veure si les dades estan preparades i son vàlides per a l'anàlisi estadística: vigileu, valors extrems, discrepàncies aparents, *missing values*. En cas contrari, penseu i discutiu internament estratègies a seguir.
3. Comparació de les característiques basals (panel demo) dels dos grups: useu les proves estadístiques més adients en cada tipus de variable. Discutiu internament quina prova seria més adient. Useu el paquet **compareGroups**
4. Discussió sobre el possible disseny de l'estudi
5. Codi de programació ben comentat per facilitar seguir-lo

Pràctica 1 – Part-1 - Discussió

3

2.3 Memòria parcial

Prepareu una petita memòria **resumida** amb el contingut dels punts anteriors. Es **suficient amb incloure una justificació raonada** de la vostra visió respecte a cada punt i la sintaxi (en el cas que sigui aplicable)

La sintaxi usada per la preparació de les dades i l'anàlisi estadística haurà d'anar al final de la memòria. Recordeu d'incloure els comentaris i les (sub-)seccions que calgui per identificar bé els punts claus i els apartats del guió i les preguntes fetes

1.2 Lliuraments de pràctiques (aplica en tots els casos posteriors)

Quan s'obri l'activitat de lliurament, llavors haureu de lliurar la pràctica seguint les instruccions de sota.

Es **penalitzarà 0.5 punts** per a cada desviació sobre les instruccions donades:

- S'ha de fer usant el lliurament de tasques identificat en el Campus Virtual
- Poseu els **noms** i els **NIUs** de tots els integrants del grup a cada document.
- Cal usar la següent **nomenclatura** en el lliurament:
 - Sempre sense accents, ni 'ñ' ni espais en blanc
 - Els espais en blanc s'han de substituir amb el guió baix: "-"
 - "Grup_XX_Sintaxi_R.r" o igual però amb extensió "Rmd" per a la sintaxi
 - "Grup_XX_Memoria.pdf" per a la memòria (*altres extensions com .doc o .docx o .rtf també acceptades*)

Sent "XX" el número del grup en 2 dígits, per exemple 01, 02 ... 12

Com ara <Grup_01_Memoria.pdf>

Pràctica 1 – Part-1 - Discussió

4

Conclusió

- Deixeu la memòria “neta de sintaxi” amb només *outputs* “nets” i la vostra redacció
 - Com a molt la sintaxi al final, no pel mig. No poseu el log (warnings, etc...)
- Poseu la sintaxi en un fitxer a banda
 - (ex: <Grup_01_Sintaxi_R.R>)

Pràctica 1 – Part-1 - Discussió

5

5

Índex

1. Importació de dades: Lectura de les dades en el sistema de programari estadístic escollit
2. Qualitat de les dades:
 - valors extrems
 - discrepàncies aparents
 - *missing values*
 - En cas contrari, estratègies a seguir.
3. Comparació de les característiques basals (panel demo) dels dos grups
4. Discussió sobre el possible disseny de l'estudi i la millor anàlisi a aplicar-hi

Pràctica 1 – Part-1 - Discussió

6

6

Importació

```
# --- Import data from SAS -----
# Key point: 'catalog_file' allows R to resolve SAS formats into labels.
demo <- read_sas(
  data_file = "uab_demo2.sas7bdat",
  catalog_file = "formats.sas7bcat"
) %>%
  as_tibble() %>%
  # Convert SAS labelled variables to factor using their value labels
  mutate(across(where(is.labelled), as_factor)) %>%
  # Treat empty strings as missing (NA) BEFORE any factor conversion of character
  mutate(across(where(is.character), ~ na_if(., "")))
```

Pràctica 1 – Part-1 - Discussió

7

7

```
#####
# Recode binary 0/1 variables to "No"/"Yes" (for nicer tables)
#####
demo <- demo %>%
  mutate(
    # Other fracture risk factors (0/1 -> No/Yes)
    OthRiskFract = factor(as.character(OthRiskFract),
      levels = c("0", "1"),
      labels = c("No", "Yes")),
    # Number of drugs >= 4 (0/1 -> No/Yes)
    CountActualGE4 = factor(as.character(CountActualGE4),
      levels = c("0", "1"),
      labels = c("No", "Yes"))
  )
```

Pràctica 1 – Part-1 - Discussió

8

8

```
# --- Variable-specific recoding -----
# IMPORTANT: avoid converting everything to factor blindly.
# Recode only what you need for the analyses.
#-----
# If NFractura should be numeric for analyses, make it numeric explicitly.
# (Sometimes it may come in as a factor after as_factor() if it had labels.)
demo <- demo %>%
  mutate(
    NFractura = suppressWarnings(as.numeric(as.character(NFractura))),
    # Categorical version used in descriptive tables / modelling
    NFracturaCat = case_when(
      is.na(NFractura) ~ NA_character_,
      NFractura == 0 ~ "0",
      NFractura == 1 ~ "1",
      NFractura >= 2 ~ ">=2"
    ) %>% factor(levels = c("0", "1", ">=2")),
    # Continuous version (redundant if NFractura already numeric, but explicit)
    NFracturaCont = NFractura
  )
# If you want to enforce factors for a few key variables (even if SAS labels fail),
# do it explicitly:
demo <- demo %>%
  mutate(across(
    c(Grup, Smoker, ALCOHOL, tipus_diabetis, OthRiskFract, CountActualGE4),
    ~ as.factor(.x)
  ))
```

Pràctica 1 – Part-1 - Discussió

9

9

```
#####
# Variable labels (metadata)
# Using attr(x, "label") is fine; it behaves like SAS variable labels in many
# workflows (e.g., some table packages can display them).
#####
attr(demo$PatNo, "label") <- "Subject identifier"
attr(demo$Grup, "label") <- "Group. 0: Control, 1: Case"
attr(demo$Edat, "label") <- "Age (years)"
attr(demo$Sexe, "label") <- "Sex. F: Female, M: Male"
attr(demo$ServeiAlta, "label") <- "Hospital discharge department"
attr(demo$PES, "label") <- "Weight (kg)"
attr(demo$TALLA, "label") <- "Height (cm)"
attr(demo$IMC, "label") <- "BMI (kg/m^2)"
attr(demo$ALCOHOL, "label") <- "Alcohol habit (0/1/2)"
attr(demo$Smoker, "label") <- "Smoking status (0/1/2)"
attr(demo$Hipogonad, "label") <- "Hypogonadism"
attr(demo$Artritis_reumatoide, "label") <- "Rheumatoid arthritis"
attr(demo$Fractura, "label") <- "Previous fracture"
attr(demo$NFractura, "label") <- "Number of previous fractures"
attr(demo$FX_familia, "label") <- "Family history of fractures"
attr(demo$Diabetis, "label") <- "Diabetes"

.....
```

Pràctica 1 – Part-1 - Discussió

10

10

```
#####
# Variable lists
# Goal:
# - Define sets of variables to be treated as factors vs numeric
# - Optionally define a subset of binary (0/1) factor variables
#####
# All variables except the first one (often an ID such as PatNo)
ListAll <- names(demo)[-1]
# Define numeric variables by name (more robust than using positions)
# NOTE: add/remove variable names here as needed
ListNum <- c("Edat", "PES", "TALLA", "IMC", "NFracturaCont")
# Everything else (in ListAll) will be treated as factor/categorical
ListFactor <- setdiff(ListAll, ListNum)
# Optional: binary (0/1) factor variables (edit this vector as needed)
# Tip: keep this by NAME, not by position, to avoid errors if columns move.
List01 <- c(
  "Hipogonad", "Artritis_reumatoide", "Fractura", "FX_familia", "Diabetis",
  "Densitometries", "Osteoporosi", "neoplasia", "HiperTiroidisme",
  "Malnutricio", "Malabsorcio", "Malaltia_Hep_Cro", "OthRiskFract",
  "CountActualGE4"
)
```

Pràctica 1 – Part-1 - Discussió

11

11

```
#####
# (A) Value labels / factor levels
# Goal:
# - Ensure key categorical variables have readable labels AND correct ordering.
# Notes:
# - If variables were imported from SAS with formats, they may already be factors.
# - Therefore we convert via as.character() -> numeric when needed to avoid
#   mismatched levels.
#####
# Apply labels to multi-level categorical variables
demo <- demo %>%
  mutate(
    tipus_diabetis = factor(as.character(tipus_diabetis), levels = c("0", "1", "2"),
      labels = c("No", "Type 1", "Type 2")),
    ALCOHOL = factor(as.character(ALCOHOL), levels = c("0", "1", "2"),
      labels = c("No", "Light", "Moderate")),
    Smoker = factor(as.character(Smoker), levels = c("0", "1", "2"),
      labels = c("No", "Active", "Former"))
  )
```

Pràctica 1 – Part-1 - Discussió

12

12

Índex

1. Importació de dades: Lectura de les dades en el sistema de programari estadístic escollit
2. Qualitat de les dades:
 - o valors extrems
 - o discrepàncies aparents
 - o *missing values*
 - o En cas contrari, estratègies a seguir.
3. Comparació de les característiques basals (panel demo) dels dos grups
4. Discussió sobre el possible disseny de l'estudi i la millor anàlisi a aplicar-hi

Pràctica 1 – Part-1 - Discussió

13

13

2. Qualitat de les dades

Pràctica 1 – Part-1 - Discussió

14

14

2. Qualitat de les dades: veure si les dades estan preparades i son vàlides per a l'anàlisi estadística: vigileu, valors extrems, discrepàncies aparents, *missing values*. En cas contrari, penseu i discutiu internament estratègies a seguir.

Pràctica 1 – Part-1 - Discussió

15

15

Descriptiva

```
##      PatNo      Grup      Edat      Sexe
##  Min.   : 1.0    Min.   :0.0000   Min.   :51.00   Length:408
## 1st Qu.:102.8    1st Qu.:0.0000   1st Qu.:78.00   Class :character
## Median :204.5    Median :0.0000   Median :84.00   Mode  :character
## Mean   :204.5    Mean   :0.3333   Mean   :82.05
## 3rd Qu.:306.2    3rd Qu.:1.0000   3rd Qu.:88.00
## Max.   :408.0    Max.   :1.0000   Max.   :95.00
##                                     NA's :42
## ServeiAlta      PES      TALLA      IMC
## Length:408      Min.   : 38.50   Min.   :134.0   Min.   :17.90
## Class :character 1st Qu.: 57.10   1st Qu.:147.6   1st Qu.:25.41
## Mode  :character Median : 67.50   Median :153.0   Median :28.09
## Mean   : 67.39   Mean   :153.7   Mean   :28.82
## 3rd Qu.: 74.55   3rd Qu.:160.0   3rd Qu.:31.73
## Max.   :107.00   Max.   :179.0   Max.   :55.00
## NA's :253      NA's :286      NA's :286
## ALCOHOL      Smoker      Hipogonad Artritis_reumatoide
## Min.   :0.00000   Min.   :0.0000   Min.   :0   Min.   :0.000000
## 1st Qu.:0.00000   1st Qu.:0.0000   1st Qu.:0   1st Qu.:0.000000
## Median :0.00000   Median :0.0000   Median :0   Median :0.000000
## Mean   :0.07843   Mean   :0.1887   Mean   :0   Mean   :0.009804
## 3rd Qu.:0.00000   3rd Qu.:0.0000   3rd Qu.:0   3rd Qu.:0.000000
## Max.   :2.00000   Max.   :2.0000   Max.   :0   Max.   :1.000000
##
```

summary(uab)

Pràctica 1 – Part-1 - Discussió

16

16

```
##      PatNo      Grup      Edat      Sexe
##      0          0          42          0
##      ServeiAlta PES      TALLA      IMC
##      0          253      286      286
##      ALCOHOL      Smoker      Hipogonad Artritis_reumatoide
##      0          0          0          0
##      Fractura      NFractura      FX_familia      Diabetis
##      0          0          0          0
##      tipus_diabetis Densitometries      Osteoporosi      neoplasia
##      0          0          0          0
##      HiperTiroidisme Malnutricio      Malabsorcio      Malaltia_Hep_Cro
##      0          0          0          0
##      OthRiskFract CountActualGE4
##      0          0
##      apply(is.na(datos), 2, sum)

##      PatNo      Grup      Edat      Sexe
##      Mode :logical Mode :logical Mode :logical Mode :logical
##      FALSE:408 FALSE:408 FALSE:366 FALSE:408
##      TRUE :42
##      ServeiAlta PES      TALLA      IMC
##      Mode :logical Mode :logical Mode :logical Mode :logical
##      FALSE:408 FALSE:165 FALSE:122 FALSE:122
##      TRUE :253 TRUE :286 TRUE :286
##      ALCOHOL      Smoker      Hipogonad Artritis_reumatoide
##      Mode :logical Mode :logical Mode :logical Mode :logical
##      FALSE:408 FALSE:408 FALSE:408 FALSE:408
##      summary(is.na(dades))
```

Pràctica 1 – Part-1 - Discussió 17

17

- Els valors faltants de les edats i sexe els podríem **imputar** tenint en compte l'edat i sexe del seu cas o control respectiu, ja que agafen persones de la mateixa edat i sexe per cada cas-control.

- ...hi ha casos que tenen el **IMC mal calculat**, pel que també s'hauria de **recalcular**.

Pràctica 1 – Part-1 - Discussió

18

18


```
## Variable type: factor
## skim_variable n_missing complete_rate top_counts
1 Grup 0 1 0: 272, 1: 136
2 Sexe 29 0.929 F: 300, M: 79, emp: 0
3 ServeiAlta 0 1 MDU: 225, TRA: 134, CGU: 31, TOU: 13
4 ALCOHOL 0 1 0: 379, 1: 26, 2: 3
5 Smoker 0 1 Non: 362, For: 31, Act: 15
6 Hipogonad 0 1 No: 408
7 Artritis_reumatoide 0 1 No: 404, Si: 4
8 Fractura 0 1 No: 296, Si: 112
9 NFractura 0 1 0: 296, 1: 95, 2: 15, 6: 1
10 FX_familia 0 1 No: 408
11 Diabetis 0 1 No: 281, Si: 127
12 tipus_diabetis 0 1 No : 281, Tip: 125, Tip: 2
13 Densitometries 0 1 No: 390, Si: 18
14 Osteoporosi 0 1 No: 374, Si: 34
15 neoplasia 0 1 No: 358, Si: 50
16 HiperTiroidisme 0 1 No: 400, Si: 8
17 Malnutricio 0 1 No: 401, Si: 7
18 Malabsorcio 0 1 No: 407, Si: 1
19 Malaltia_Hep_Cro 0 1 No: 397, Si: 11
20 OthRiskFract 0 1 0: 334, 1: 74
21 CountActualGE4 0 1 1: 314, 0: 94

## Variable type: numeric
## skim_variable n_missing complete_rate mean sd p0 p25 p50 p75 p100 hist
1 PatNo 0 1 204. 118. 1 103. 204. 306. 408
2 Edat 42 0.897 82.0 8.84 51 78 84 88 95
3 PES 253 0.380 67.4 13.1 38.5 57.1 67.5 74.5 107
4 TALLA 286 0.299 154. 8.47 134 148. 153 160 179
5 IMC 286 0.299 28.8 5.62 17.9 25.4 28.1 31.7 55
6 NFracturaCont 0 1 0.338 0.689 0 0 0 1 7
```

Pràctica 1 – Part-1 - Discussió 19

19


pairs(demo2[c(2:5)])




Pràctica 1 – Part-1 - Discussió

20


20




21






22



23



24



Descripció de les dades:

Com que les dades tenen **missing values**, comprovem quants casos complets tenim i creem una nova base de dades amb **només aquests casos**. S'observen valors buits també a la variable **sexe**, per tant, els passem a **NA**'s.

Un cop mirats quants casos complets tenim, veiem que la gran majoria dels missing pertanyen a les variables **pes, talla i IMC**; preiem que són **MNAR** per tant, creem una nova variable factor, que podria ser rellevant en el model, on **si** pertany a que hi ha missing values en aquell individu en alguna de les variables, i **no** altrament.

Pràctica 1 – Part-1 - Discussió

30

Discrepancies

```
table(demo$Diabetis,demo$tipus_diabetis) # diabetis ok

##
##      no Tipus 1 Tipus 2
## no 281      0      0
## si   0      2     125

table(demo$Fractura,demo$NFractura) # fractures ok

##
##      0      1      2+
## no 296      0      0
## si   0     95     17
```

Pràctica 1 – Part-1 - Discussió

31

31

IMC

```
which(dades$IMC == dades$PES/(dades$TALLA*100)^2)

## integer(0)

which(dades$IMC != dades$PES/(dades$TALLA*100)^2)

## [1] 1 2 6 7 13 19 22 25 31 32 37 41 42 46 49 51 52 54
## [19] 62 69 72 78 83 91 96 99 101 102 106 109 111 115 116 118 119
## [37] 123 133 143 144 145 147 149 151 152 157 160 162 164 166 167 169 171 176
## [55] 179 180 184 189 192 205 206 209 216 217 226 228 229 230 233 234 241 247
## [73] 248 252 253 254 263 267 268 269 276 279 283 286 287 288 291 292 293 296
## [91] 304 305 307 313 314 315 317 322 327 328 332 335 342 344 348 352 357 358
## [109] 361 365 371 379 386 389 392 393 396 401 402 403 405 407
```

Pràctica 1 – Part-1 - Discussió

32

32

```
> IMC=demo$PES/(demo$TALLA/100)^2
> IMC<-round(IMC[!is.nan(IMC)],2)
> IMC2<-round(demo$IMC[!is.nan(demo$IMC)],2)
>
> IMC_comp<-data.frame(IMC,IMC2,IMC2-IMC)
>
> summary(IMC_comp)
```

```
##      IMC      IMC2      IMC2...IMC
## Min. :17.90 Min. :17.90 Min. : -0.7700
## 1st Qu.:25.34 1st Qu.:25.41 1st Qu.: 0.0000
## Median :28.09 Median :28.09 Median : 0.0000
## Mean :28.52 Mean :28.82 Mean : 0.2931
## 3rd Qu.:31.43 3rd Qu.:31.73 3rd Qu.: 0.0000
## Max. :43.37 Max. :55.00 Max. :31.1900
```


Pràctica 1 – Part-1 - Discussió

33

33

Extrems


```
par(mfrow=c(2,2), mar = c(5, 5, 2, 2))
boxplot(demo$Edat, ylab = "Edat (any)")
boxplot(demo$PES, ylab = "Pes (kg)")
boxplot(demo$TALLA, ylab = "Talla (cm)")
boxplot(demo$IMC, ylab = expression(paste("Índex de Massa Corporal (", kg/m^2, ")")))
```




Pràctica 1 – Part-1 - Discussió

34


34




35



36



38



39

Conclusió qualitat

- Discrepàncies aparents ?
- Missings
 - Estratègies possibles
 - Aclariments per solucionar les dades
 - Exclusió pacients
 - Imputació

Pràctica 1 – Part-1 - Discussió

41

41

Índex

1. Importació de dades: Lectura de les dades en el sistema de programari estadístic escollit
2. Qualitat de les dades:
 - valors extrems
 - discrepàncies aparents
 - *missing values*
 - En cas contrari, estratègies a seguir
3. Comparació de les característiques basals (panel demo) dels dos grups
4. Discussió sobre el possible disseny de l'estudi i la millor anàlisi a aplicar-hi

Pràctica 1 – Part-1 - Discussió

42

42

3. Comparació de les característiques basals

Pràctica 1 – Part-1 - Discussió

43

43

```

## ----- Summary of results by groups of 'Grup'-----
##
##   var      N  p.value  method  selection
## 1 Edat      366 0.931   continuous normal ALL
## 2 PES       155 0.098*   continuous normal ALL
## 3 TALLA     122 0.262   continuous normal ALL
## 4 IMC       122 0.091*   continuous normal ALL
## 5 Sexe      379 1.000   categorical    ALL
## 6 ServeiAlta 408 <0.001** categorical    ALL
## 7 ALCOHOL   408 0.197   categorical    ALL
## 8 Smoker    408 0.756   categorical    ALL
## 9 Hipogonad 408 .       categorical    ALL
## 10 Artritis_reumatoide 408 1.000 categorical    ALL
## 11 Fractura  408 <0.001** categorical    ALL
## 12 NFractura 408 <0.001** categorical    ALL
## 13 FX_familia 408 .       categorical    ALL
## 14 Diabetis  408 0.473   categorical    ALL
## 15 tipus_diabetis 408 0.433 categorical    ALL
## 16 Densitometries 408 0.201 categorical    ALL
## 17 Osteoporosi 408 0.006** categorical    ALL
## 18 neoplasia 408 0.311 categorical    ALL
## 19 HiperTiroidisme 408 0.449 categorical    ALL
## 20 Malnutricio 408 0.690 categorical    ALL
## 21 Malabsorcio 408 1.000 categorical    ALL
## 22 Malaltia_Hep_Cro 408 0.517 categorical    ALL
## 23 OthRiskFract 408 0.751 categorical    ALL
## 24 CountActualGE4 408 0.967 categorical    ALL
## -----
## Signif. codes:  0 '***' 0.05 '**' 0.1 '*' 1

```

Pràctica 1 – Part-1 - Discussió

44

44

```
library(compareGroups)
tabla<-compareGroups(Grup~,data = uab, include.miss = TRUE)
```

-----Summary descriptives table by 'Grup'-----

	[ALL] N=408	0 N=272	1 N=136	p.overall	N
## PatNo	204 (118)	205 (118)	204 (118)	0.989	408
## Edat	82.0 (8.84)	82.1 (8.80)	82.0 (8.97)	0.931	366
## Sexe				0.988	408
## F	29 (7.11%)	19 (6.99%)	10 (7.35%)		
## M	300 (73.5%)	200 (73.5%)	100 (73.5%)		
## Serveialta:	79 (19.4%)	53 (19.5%)	26 (19.1%)	<0.001	408
## COURG	31 (7.60%)	31 (11.4%)	0 (0.00%)		
## GOURG	2 (0.49%)	2 (0.74%)	0 (0.00%)		
## MDURG	225 (55.1%)	225 (82.7%)	0 (0.00%)		
## MED	2 (0.49%)	0 (0.00%)	2 (1.47%)		
## PSURG	1 (0.25%)	1 (0.37%)	0 (0.00%)		
## TOURG	13 (3.19%)	13 (4.78%)	0 (0.00%)		
## TRA	134 (32.8%)	0 (0.00%)	134 (98.5%)		
## PES	67.4 (13.1)	68.5 (13.7)	65.0 (11.6)	0.098	155
## TALLA	154 (8.47)	154 (8.70)	152 (7.83)	0.262	122
## IMC	28.8 (5.62)	29.3 (5.84)	27.5 (4.90)	0.091	122
## ALCOHOL	0.08 (0.30)	0.08 (0.29)	0.07 (0.31)	0.818	408
## Smoker	0.19 (0.55)	0.19 (0.57)	0.18 (0.53)	0.747	408
## Artritis_reumatoide	0.01 (0.10)	0.01 (0.10)	0.01 (0.09)	0.705	408
## Fractura	0.27 (0.45)	0.20 (0.40)	0.43 (0.50)	<0.001	408
## NFractura	0.34 (0.69)	0.25 (0.64)	0.51 (0.75)	0.001	408
## Diabetes	0.31 (0.46)	0.30 (0.46)	0.34 (0.47)	0.413	408
## tipus diabetic	0.62 (0.92)	0.59 (0.91)	0.68 (0.95)	0.370	408
## Densitometries	0.04 (0.21)	0.03 (0.18)	0.07 (0.25)	0.169	408
## Osteoporosi	0.08 (0.28)	0.06 (0.23)	0.14 (0.35)	0.011	408
## neoplasia	0.12 (0.33)	0.14 (0.34)	0.10 (0.30)	0.218	408
## Hipertensidisme	0.02 (0.14)	0.01 (0.12)	0.03 (0.17)	0.367	408
## Malnutricio	0.02 (0.13)	0.01 (0.12)	0.02 (0.15)	0.615	408
## Malabsorcio	0.00 (0.05)	0.00 (0.06)	0.00 (0.00)	0.318	408
## Malaltia_Hep_Cro	0.03 (0.16)	0.02 (0.15)	0.04 (0.19)	0.427	408
## OthRiskFract	0.18 (0.39)	0.19 (0.39)	0.17 (0.38)	0.647	408
## CountActualIGe4	0.77 (0.42)	0.77 (0.42)	0.76 (0.43)	0.869	408

45

Discussió comparabilitat

- Descriptiva
 - N %
 - Median [P25-P75].... Mean (SD)
- Proves estadístiques
 - Fisher's exact test (ji-quadrat)
 - Mann-Whitney U test (t-Student)

Pràctica 1 – Part-1 - Discussió

47

47

```
library(compareGroups)
tabla<-compareGroups(Grup~,data = uab, include.miss = TRUE)
```

-----Summary descriptives table by 'Grup'-----

	[ALL] N=408	0 N=272	1 N=136	p.overall	N
## PatNo	204 (118)	205 (118)	204 (118)	0.989	408

Possible values in methods statement are:

- 1: forces analysis as normal-distributed
- 2: forces analysis as continuous non-normal
- 3: forces analysis as categorical
- NA: performs a Shapiro-Wilks test to decide between normal or non-normal

If the method argument is stated as NA for a variable, then a Shapiro-Wilk test for normality is used to decide if the variable is normal or non-normal distributed. To change the significance threshold:

```
compareGroups(group ~ age + smoke + waist + hormo, data = predimed,
method = c(waist = NA), alpha = 0.01)
```

## Diabetes	0.31 (0.46)	0.30 (0.46)	0.34 (0.47)	0.413	408
## tipus diabetic	0.62 (0.92)	0.59 (0.91)	0.68 (0.95)	0.370	408
## Densitometries	0.04 (0.21)	0.03 (0.18)	0.07 (0.25)	0.169	408
## Osteoporosi	0.08 (0.28)	0.06 (0.23)	0.14 (0.35)	0.011	408
## neoplasia	0.12 (0.33)	0.14 (0.34)	0.10 (0.30)	0.218	408
## Hipertensidisme	0.02 (0.14)	0.01 (0.12)	0.03 (0.17)	0.367	408
## Malnutricio	0.02 (0.13)	0.01 (0.12)	0.02 (0.15)	0.615	408
## Malabsorcio	0.00 (0.05)	0.00 (0.06)	0.00 (0.00)	0.318	408
## Malaltia_Hep_Cro	0.03 (0.16)	0.02 (0.15)	0.04 (0.19)	0.427	408
## OthRiskFract	0.18 (0.39)	0.19 (0.39)	0.17 (0.38)	0.647	408
## CountActualIGe4	0.77 (0.42)	0.77 (0.42)	0.76 (0.43)	0.869	408

48

	[ALL] N=408	Control N=272	Cas N=136	p.overall
## Edat	82.0 (8.84)	82.1 (8.80)	82.0 (8.97)	0.931
## Sexe				0.988
## F	29 (7.11%)	19 (6.99%)	10 (7.35%)	
## M	300 (73.5%)	200 (73.5%)	100 (73.5%)	
## Serveialta:	79 (19.4%)	53 (19.5%)	26 (19.1%)	<0.001
## COURG	31 (7.60%)	31 (11.4%)	0 (0.00%)	
## GOURG	2 (0.49%)	2 (0.74%)	0 (0.00%)	
## MDURG	225 (55.1%)	225 (82.7%)	0 (0.00%)	
## MED	2 (0.49%)	0 (0.00%)	2 (1.47%)	
## PSURG	1 (0.25%)	1 (0.37%)	0 (0.00%)	
## TOURG	13 (3.19%)	13 (4.78%)	0 (0.00%)	
## TRA	134 (32.8%)	0 (0.00%)	134 (98.5%)	
## PES	67.4 (13.1)	68.5 (13.7)	65.0 (11.6)	0.098
## TALLA	154 (8.47)	154 (8.70)	152 (7.83)	0.262
## IMC	28.8 (5.62)	29.3 (5.84)	27.5 (4.90)	0.091
## ALCOHOL:				0.197
## No	379 (92.9%)	251 (92.3%)	128 (94.1%)	
## Light	26 (6.37%)	20 (7.35%)	6 (4.41%)	
## Moderate	3 (0.74%)	1 (0.37%)	2 (1.47%)	
## Smoker:				0.756
## No	362 (88.7%)	241 (88.6%)	121 (89.0%)	
## Active	15 (3.68%)	9 (3.31%)	6 (4.41%)	
## Former	31 (7.60%)	22 (8.09%)	9 (6.62%)	
## Hipogonad: No	408 (100%)	272 (100%)	136 (100%)	
## Artritis_reumatoide:				1.000
## No	404 (99.0%)	269 (98.9%)	135 (99.3%)	
## Yes	4 (0.98%)	3 (1.10%)	1 (0.74%)	
## Fractura:				<0.001
## No	296 (72.5%)	218 (80.1%)	78 (57.4%)	
## Yes	112 (27.5%)	54 (19.9%)	58 (42.6%)	
## NFractura:				<0.001
## 0	296 (72.5%)	218 (80.1%)	78 (57.4%)	
## 1	95 (23.3%)	44 (16.2%)	51 (37.5%)	
## 2	15 (3.68%)	9 (3.31%)	6 (4.41%)	
## 6	1 (0.25%)	0 (0.00%)	1 (0.74%)	
## 7	1 (0.25%)	1 (0.37%)	0 (0.00%)	

Pràctica 1 – Part-1 - Discussió

49

49

	[ALL] N=408	Control N=272	Cas N=136	p.overall
Edat	84.0 [78.0;88.0]	84.0 [78.0;88.0]	84.0 [78.0;88.0]	1.000
Sexe:				1.000
F	300 (79.2%)	200 (79.1%)	100 (79.4%)	
M	79 (20.8%)	53 (20.9%)	26 (20.6%)	
ServeiAlta:				<0.001
CGURG	31 (7.60%)	31 (11.4%)	0 (0.00%)	
GOURG	2 (0.49%)	2 (0.74%)	0 (0.00%)	
MDURG	225 (55.1%)	225 (82.7%)	0 (0.00%)	
MED	2 (0.49%)	0 (0.00%)	2 (1.47%)	
PSURG	1 (0.25%)	1 (0.37%)	0 (0.00%)	
TOURG	13 (3.19%)	13 (4.78%)	0 (0.00%)	
TRA	134 (32.8%)	0 (0.00%)	134 (98.5%)	
PES	67.5 [57.1;74.5]	68.5 [59.0;76.7]	65.0 [57.0;71.0]	0.326
TALLA	153 [148;160]	154 [148;160]	152 [147;159]	0.689
IMC	28.1 [25.4;31.7]	28.7 [25.5;32.1]	27.4 [24.7;29.3]	0.427
ALCOHOL:				0.491
No	379 (92.9%)	251 (92.3%)	128 (94.1%)	
Light	26 (6.37%)	20 (7.35%)	6 (4.41%)	
Moderate	3 (0.74%)	1 (0.37%)	2 (1.47%)	
Smoker:				0.978
No	362 (88.7%)	241 (88.6%)	121 (89.0%)	
Active	15 (3.68%)	9 (3.31%)	6 (4.41%)	
Former	31 (7.60%)	22 (8.09%)	9 (6.62%)	
Hipogonad: No	408 (100%)	272 (100%)	136 (100%)	
Artritis_reumatoide:				1.000
No	404 (99.0%)	269 (98.9%)	135 (99.3%)	
Yes	4 (0.98%)	3 (1.10%)	1 (0.74%)	
Fractura:				<0.001
No	296 (72.5%)	218 (80.1%)	78 (57.4%)	
Yes	112 (27.5%)	54 (19.9%)	58 (42.6%)	
NFractura:				<0.001
0	296 (72.5%)	218 (80.1%)	78 (57.4%)	
1	95 (23.3%)	44 (16.2%)	51 (37.5%)	
2+	17 (4.17%)	10 (3.68%)	7 (5.15%)	

50

	0	1	p.overall
Sexe:	19 (6.99%)	10 (7.35%)	0.988
Sexe: F	200 (73.5%)	100 (73.5%)	NA
Sexe: M	53 (19.5%)	26 (19.1%)	NA
ServeiAlta: CGURG	31 (11.4%)	0 (0.00%)	<0.001
ServeiAlta: GOURG	2 (0.74%)	0 (0.00%)	NA
ServeiAlta: MDURG	225 (82.7%)	0 (0.00%)	NA
ServeiAlta: MED	0 (0.00%)	2 (1.47%)	NA
ServeiAlta: PSURG	1 (0.37%)	0 (0.00%)	NA
ServeiAlta: TOURG	13 (4.78%)	0 (0.00%)	NA
ServeiAlta: TRA	0 (0.00%)	134 (98.5%)	NA
ALCOHOL: 0	251 (92.3%)	128 (94.1%)	0.197
ALCOHOL: 1	20 (7.35%)	6 (4.41%)	NA
ALCOHOL: 2	1 (0.37%)	2 (1.47%)	NA
Smoker: 0	241 (88.6%)	121 (89.0%)	0.756
Smoker: 1	9 (3.31%)	6 (4.41%)	NA
Smoker: 2	22 (8.09%)	9 (6.62%)	NA
Hipogonad: 0	272 (100%)	136 (100%)	.
Artritis_reumatoide: 0	269 (98.9%)	135 (99.3%)	1.000
Artritis_reumatoide: 1	3 (1.10%)	1 (0.74%)	NA
Fractura: 0	218 (80.1%)	78 (57.4%)	<0.001
Fractura: 1	54 (19.9%)	58 (42.6%)	NA

Pràctica 1 – Part-1 - Discussió

51

50

51

Table 1: Summary descriptives table by groups of 'Grup'

	[ALL] N=408	Control N=272	Caso N=136	p.overall
Edat	82.0 (8.84)	82.1 (8.80)	82.0 (8.97)	1.000
Sexe:				1.000
F	300 (79.2%)	200 (79.1%)	100 (79.4%)	
M	79 (20.8%)	53 (20.9%)	26 (20.6%)	
ServeiAlta:				<0.001
CGURG	31 (7.60%)	31 (11.4%)	0 (0.00%)	
GOURG	2 (0.49%)	2 (0.74%)	0 (0.00%)	
MDURG	225 (55.1%)	225 (82.7%)	0 (0.00%)	
MED	2 (0.49%)	0 (0.00%)	2 (1.47%)	
PSURG	1 (0.25%)	1 (0.37%)	0 (0.00%)	
TOURG	13 (3.19%)	13 (4.78%)	0 (0.00%)	
TRA	134 (32.8%)	0 (0.00%)	134 (98.5%)	
PES	67.4 (13.1)	68.5 (13.7)	65.0 (11.6)	0.361
TALLA	154 (8.47)	154 (8.70)	152 (7.83)	0.640
IMC	28.8 (5.62)	29.3 (5.84)	27.5 (4.90)	0.361
ALCOHOL:				0.553
No	379 (92.9%)	251 (92.3%)	128 (94.1%)	
Light	26 (6.37%)	20 (7.35%)	6 (4.41%)	
Moderate	3 (0.74%)	1 (0.37%)	2 (1.47%)	
Smoker:				0.978
No	362 (88.7%)	241 (88.6%)	121 (89.0%)	
Active	15 (3.68%)	9 (3.31%)	6 (4.41%)	
Former	31 (7.60%)	22 (8.09%)	9 (6.62%)	
Hipogonad: No	408 (100%)	272 (100%)	136 (100%)	.
Artritis_reumatoide:				1.000
No	404 (99.0%)	269 (98.9%)	135 (99.3%)	
Sí	4 (0.98%)	3 (1.10%)	1 (0.74%)	

52

52

FiIVar_Lab	FiIVal_Lab	0 (n=272) n (%)	1 (n=136) n (%)	TOTAL (n=408) n (%)	p-value
NFractura	0	218 (80.1%)	78 (57.4%)	296 (72.5%)	<.0001
NFractura	1	44 (16.2%)	51 (37.5%)	95 (23.3%)	
NFractura	2	9 (3.3%)	6 (4.4%)	15 (3.7%)	
NFractura	6	0 (0.0%)	1 (0.7%)	1 (0.2%)	
NFractura	7	1 (0.4%)	0 (0.0%)	1 (0.2%)	
NFractura	TOTAL	272 (100.0%)	136 (100.0%)	408 (100.0%)	
NFractura	Missing	0	0	0	
NFractura	N	272	136	408	<.0001
NFractura	Mean(SD)	0.25 (0.64)	0.51 (0.75)	0.34 (0.69)	
NFractura	Median(P25,P75)	0.00 (0.00 , 0.00)	0.00 (0.00 , 1.00)	0.00 (0.00 , 1.00)	

Pràctica 1 – Part-1 - Discussió

53

53

Conclusió comparabilitat

- Prior history of fracture
- Osteoporosi
- Servei alta Hospitalària
- Pes (+/-)...

Pràctica 1 – Part-1 - Discussió

54

54

Índex

1. Importació de dades: Lectura de les dades en el sistema de programari estadístic escollit
2. Qualitat de les dades:
 - valors extrems
 - discrepàncies aparents
 - *missing values*
 - En cas contrari, estratègies a seguir.
3. Comparació de les característiques basals (panel demo) dels dos grups
4. Discussió sobre el possible disseny de l'estudi i la millor anàlisi a aplicar-hi

Pràctica 1 – Part-1 - Discussió

56

56

4. Discussió disseny

Pràctica 1 – Part-1 - Discussió

57

57

Alguns comentaris

- En quant a l'anàlisi descriptiu de variables contínues es podria utilitzar la mitjana, mediana, desviació estàndard i interval de confiança del 95%.
- Per a la descripció de variables categòriques, el nombre i percentatge de pacients per categoria de resposta.

Pràctica 1 – Part-1 - Discussió

58

58

Alguns comentaris

- *Caldrà fer una selecció de les variables que volem incloure al multivariable*
- Segurament escolliríem entre (??):
 - pes, IMC, serveiAlta, **fractura, NFractura, osteoporosi**
- Mètodes de selecció de subconjunts (com stepwise o regsubstet)??

Pràctica 1 – Part-1 - Discussió

59

59

Alguns comentaris

- **Volem veure quins fàrmacs augmenten la probabilitat de fractura ossia, caldrà**
 - Per tal d'arribar a aquest punt, hem de saber quines variables causen més diferències entre casos i controls.
 - Volem que aquestes siguin lo mínimes possibles per poder aplicar regressió logística, que pot avaluar múltiples exposicions
 - ...quantificar la força d'associació entre l'esdeveniment d'interès o malaltia i les exposicions prèvies de manera independent, per a evitar que un factor condicioni l'efecte d'un altre

Pràctica 1 – Part-1 - Discussió

60

60

EL disseny de l'estudi no és l'adquat per tal de poder extreure unes bones conclusions. El plantejament de fer un cas-control no ajuda a determinar si els medicaments causen una pèrdua de densitat òssea. **El que nosaltres proposariem com a disseny adient és fer un estudi de cohorts.** En separariem a persones d'entre 50 i 90 anys en dos grups, en un posariem els que prenen medicaments i a l'altre els que no. Al final de l'estudi comprobariem si el fet de prendre medicaments causa més trencadures d'òs que els que no en prenen.

Les fractures, i per consegüent el **NFractures** són significatives a la variable Cas, igual que la **Osteoporosi**. Això és bastant evident, ja que l'estudi tracta d'aquestes variables com a base principal de l'objectiu. Per tant, tot i ser significatives, aquestes variables no ens donen cap informació.

Troblem que l'estudi, per a ser un estudi realment eficaç, ens falta informació per contrastar l'hipòtesi d'aquest, ja que les medicacions per a diferents malalties no són iguals, o no porten els mateixos components, i a la base de dades només tenim una variable que compti la medicació que pren el pacient, sense valorar de quina malaltia és.

Pràctica 1 – Part-1 - Discussió

61

61

L'article presenta un estudi observacional **descriptiu**, retrospectiu de casos i controls de base hospitalària

El disseny de casos i controls és un disseny molt òptim pel fet que ja estudiem casos de persones fracturades, però **no permet calcular cap tipus de prevalença ni incidència**, només **Odds Ratios**.

Però sí: prevalença us de fàrmacs en casos i controls

...s'hauria de fer un **disseny transversal** però no només unicèntric sinó de diferents centres de tota Catalunya per poder aplicar els resultats a tota la població d'estudi

...un disseny **més robust**, el disseny de **cohorts** seria el més desitjable si es disposa dels recursos necessaris.

....el temps d'observació fins que apareguin les fractures **pot ser molt llarg**.

Pràctica 1 – Part-1 - Discussió

62

62

2.4 Rebalanceig de les dades

2:1 ... => ??

...t-Student per mirar si és significatiu o no i per a les variables factor farem un test Chi-quadrat

Si, però...

Pràctica 1 – Part-1 - Discussió

63

63

El disseny es tracta d'un cas-control, el qual és un estudi observacional analític on es divideix la mostra en dos grups: el cas, el qual està format pels individuals malalts (o sobre els quals s'aplica el tractament), i el control, el qual està format per individus sans (o que no reben el tractament). Una limitació comuna dels estudis cas-control és el possible biaix en la selecció de la mostra. En fer una taula descriptiva, hem vist que la mostra està ben equilibrada pel que fa a l'edat (mitjana de 82.1 pel grup 0, i 82.0 pel grup 1) i el sexe (aprox. 79% de dones i 21% d'homes pels dos grups, amb la resta missing).

Donades les dades, creiem que el disseny s'ha vist corromput ja que falten molts valors en les variables identificadores sexe, alçada i pes, fet que no s'hauria de produir ja que són variables fàcils i imprescindibles de recollir per part de l'investigador.

factores de risc en situacions on els esdeveniments són poc freqüents. Encara que els estudis de casos i controls poden indicar associacions, és fonamental tenir en compte que per establir una relació causal directa seria necessari un disseny experimental com un assaig clínic aleatori.

Pràctica 1 – Part-1 - Discussió

64

64

Valors perduts

1. **Eliminar registres** amb massa valors perduts per evitar biaixos.
2. **Imputar valors** (per exemple, mitjana o regressió) per mantenir la mida de la mostra.
3. **Deixar els NA** si no afectaven l'anàlisi principal.

Punts forts del disseny:

- És adequat per estudiar malalties rares com la fractura de maluc.
- Permet estudiar múltiples factors de risc alhora.

Limitacions:

- Biaix de selecció: els pacients provenen d'un entorn hospitalari, i això pot no ser representatiu de la població general.
- Confusió per factors com edat i comorbiditats: algunes diferències poden ser degudes a altres causes no mesurades en l'estudi.

Els resultats mostren una associació entre fractura i altres factors clínics, però cal un anàlisi més profund per establir causalitat.

Pràctica 1 – Part-1 - Discussió

65

65

A continuació es realitza un compareGroups per tal de comparar les variables entre el grup de casos i el grup de controls. Volem analitzar si hi ha diferències significatives entre aquests per a cada variable. Les variables, segons quin tipus siguin, es tracten de diferent manera, s'apliquen diferents tests i com a conseqüència hipòtesis.

En el cas que la variable sigui contínua amb distribució Normal, s'analitza amb una ANOVA:

$$H_0 : \mu_{\text{cas}} = \mu_{\text{control}}$$

$$H_1 : \mu_{\text{cas}} \neq \mu_{\text{control}}$$

En cas de que la variable sigui contínua però no segueixi una distribució Normal, s'analitza amb un Kruskal-Wallis test:

$$H_0 : \text{mediana}_{\text{cas}} = \text{mediana}_{\text{control}}$$

$$H_1 : \text{mediana}_{\text{cas}} \neq \text{mediana}_{\text{control}}$$

Per últim, en el cas que la variable sigui categòrica, s'analitza amb un test de Chi-quadrat (si totes les cel·les tenen suficients observacions) o el test exacte de Fisher (si hi ha poques dades en alguna cel·la).

$$H_0 : \text{distribució}_{\text{casos}} = \text{distribució}_{\text{controls}}$$

$$H_1 : \text{distribució}_{\text{casos}} \neq \text{distribució}_{\text{controls}}$$

Pràctica 1 – Part-1 - Discussió

66

66