

Entrega 2 - M.Bayes

Iker Fernández Cabanillas

2026-03-24

Exercici 1:

En un curs amb 120 alumnes, 17 suspenen el primer parcial.

De cara l'examen final:

- Quin és l'interval de credibilitat de la proporció θ d'aprovar amb un prior no informatiu?

```
n=120
x=103

###Beta (1,1)
alpha_post1=1+x ;alpha_post1
```

```
## [1] 104
```

```
beta_post1 =1+(n - x) ;beta_post1
```

```
## [1] 18
```

```
ic1=qbeta(c(0.025, 0.975), alpha_post1, beta_post1);ic1
```

```
## [1] 0.7846072 0.9093874
```

- I amb un prior Beta amb $\alpha = 40$, $\beta = 1$?

```
###Beta(40,1)
alpha_post2=40+x ;alpha_post2
```

```
## [1] 143
```


```
beta_post2 =1+(n - x) ;beta_post2
```

```
## [1] 18
```

```
ic2=qbeta(c(0.025, 0.975), alpha_post2, beta_post2);ic2
```

```
## [1] 0.8353388 0.9319463
```

```
###Gràfic
theta=seq(0, 1, length.out = 1000)
plot(theta, dbeta(theta, alpha_post1, beta_post1), type = "l",
     col = "#ff1245", lwd = 2, ylab = "Densitat", xlab = expression(theta),
     main = "Distribucions posteriors")
lines(theta, dbeta(theta, alpha_post2, beta_post2), col = "#BB9", lwd = 2)
legend("topleft", legend = c("Prior no inf. Beta(1,1)", "Prior Beta(40,1)"),
     col = c("#ff1245", "#BB9"), lwd = 2)
```



Per tant, segons els nostres resultats, podem observar que sense prior informativa, és a dir, basant-se molt en les dades, l'interval conté valors una mica més petits que amb la prior optimista ($\text{beta}(40,1)$), la qual al incorporar una informació prèvia molt favorable, desplaça la distribució posterior cap a la dreta.

Exercici 2:

Suposem que teniu una distribució prèvia $\text{Beta}(4, 4)$ sobre la probabilitat θ que una moneda doni una “cara” quan es llença. La moneda es llença deu vegades de manera independent i les “cares” apareixen menys de 3 vegades.

No us diuen quantes cares s'han vist, només que el nombre és inferior a 3.

- Calculeu la vostra densitat posterior exacta (fins a una constant de proporcionalitat) per a θ i dibuixeu-la.

En aquest cas, com que el número d'èxits no ens ho donen, només que és inferior a 3:

Escribim la Likelihood per a una binomial en aquest cas:

$$P(X = k|\theta) = \binom{10}{k} \theta^k (1 - \theta)^{10-k}$$

$$P(X < 3|\theta) = \sum_{k=0}^3 \binom{10}{k} \theta^k (1 - \theta)^{10-k}$$

Per tant, la likelihood queda com:

$$L(\theta) = (1 - \theta)^{10} + 10\theta(1 - \theta)^9 + 45\theta^2(1 - \theta)^8$$


Calculem la posterior:

Posterior $\propto$ *Likelihood* $\cdot$ *prior*

$$\pi(\theta|X < 3) \propto [(1 - \theta)^{10} + 10\theta(1 - \theta)^9 + 45\theta^2(1 - \theta)^8] \cdot (\theta^3(1 - \theta)^3)$$

Això ho resoldrem i graficarem usant R:

```
theta=seq(0, 1, length.out = 1000)
prior=dbeta(theta, 4, 4)
likelihood=dbinom(0,10,theta)+dbinom(1, 10, theta)+dbinom(2, 10, theta)
posterior=likelihood*prior
plot(theta, posterior, type = "l", col = "darkgreen", lwd = 2,main = "Posterior",
      xlab = expression(theta), ylab = "Densitat")
```



Exercici 4:

Es fa un estudi de la probabilitat θ de què una dona entre 60 i 69 anys doni positiu en càncer so té un historial familiar amb casos de càncer. A l'estudi participen 300 dones amb aquestes característiques, de les quals 14 donen positiu.

- Calcula el likelihood $\mathcal{L}(X|\theta)$

$$X \sim \text{Binomial}(300, \theta) L(\theta|x) = \binom{300}{14} \theta^{14} (1 - \theta)^{286} \propto L(\theta|x) = \theta^{14} (1 - \theta)^{286}$$

Segons un expert, la seva experiència en el cap indica que aquesta probabilitat és menor del %5.

- Fes servir un prior uniforme de 0 a 5% per calcular la densitat posteriori.

Si tenim que $\theta < 5$, $\theta \sim \text{Uniforme}(0, 0.05)$

$$p(\theta) = \frac{1}{0.05} = 20 \text{ si } \theta \in [0, 0.05]$$

aplicant Bayes:

$$p(\theta|x) \propto L(\theta) \cdot p(\theta) \propto \theta^{14} (1 - \theta)^{286} \cdot \mathbb{I}_{[0, 0.05]}$$

És a dir, trunquem la Beta en la probabilitat donada per l'expert.

- Calcula el valor estimat i l'interval de credibilitat centrat del 95% per a θ , per tant:

```
theta=seq(0, 0.05, length.out = 10000)

likelihood=theta^14*(1-theta)^286

prior=dunif(theta,0,0.05)

posterior_raw=likelihood*prior

###Normalitzem
delta=theta[2]-theta[1]
constante=sum(posterior_raw)*delta
posterior=posterior_raw/constante

media_post=sum(theta*posterior)*delta ; media_post
```

```
## [1] 0.04052616
```

```
cdf=cumsum(posterior)*delta
ic_l=theta[which(cdf >= 0.025)[1]]
ic_h=theta[which(cdf >= 0.975)[1]]
paste("[",ic_l,",",ic_h,"]")
```

```
## [1] "[ 0.0260576057605761 , 0.0495749574957496 ]"
```

Exercici 6:

Volem calibrar una balança de precisió fent una sèrie de mesures amb un objecte calibrat.

Fes la inferència Bayesiana de σ^2 fent servir la mesura dels pesos:

```
w = c(2.64, 2.67, 2.65, 2.67, 2.65) # g
```

```
w = c(2.64, 2.67, 2.65, 2.67, 2.65)
```

- Assumeix que la massa de l'objecte calibrat és $\mu = 2.6g$ i calcula la seva precisió σ^2 fent servir un prior $\pi(\sigma^2) \propto 1/\sigma^4$.

```
mu=2.6

n=length(w)
S=sum((w-mu)^2)

alpha=n/2+1;alpha
```

```
## [1] 3.5
```

```
beta =S/2;beta
```

```
## [1] 0.0082
```

- Calcula l'estimació puntual i l'interval per una credibilitat del 95%

```
post_mean=beta/(alpha-1);post_mean
```

```
## [1] 0.00328
```

```
post_mo=beta/(alpha+1);post_mo
```

```
## [1] 0.001822222
```

```
ci_95=c(
  lower=1/qgamma(0.975, shape=alpha, rate=beta),
  upper=1/qgamma(0.025, shape=alpha, rate=beta))
ci_95
```

```
##      lower      upper
## 0.001024183 0.009704893
```

Exercici 7:

- Demuestra que el prior de Jeffreys per la distribució de Poisson és:

$$\pi_J(\lambda) \propto \frac{1}{\sqrt{\lambda}}$$

Per a $X \sim \text{Poisson}(\lambda)$, la log-versemblança és:

$$\ell(\lambda) = -\lambda + x \log \lambda - \log x!$$

Derivades:

$$\frac{\partial \ell}{\partial \lambda} = -1 + \frac{x}{\lambda} \implies \frac{\partial^2 \ell}{\partial \lambda^2} = -\frac{x}{\lambda^2}$$

Informació de Fisher:

$$I(\lambda) = -E \left[\frac{\partial^2 \ell}{\partial \lambda^2} \right] = \frac{E[X]}{\lambda^2} = \frac{\lambda}{\lambda^2} = \frac{1}{\lambda}$$

Prior de Jeffreys:

$$\pi_J(\lambda) \propto \sqrt{I(\lambda)} = \sqrt{\frac{1}{\lambda}} = \frac{1}{\sqrt{\lambda}}$$

- Calcula el prior de Jeffreys per a una distribució normal amb σ^2 coneguda.

Per a $X \sim N(\mu, \sigma^2)$ amb σ^2 constant, la log-versemblança és:

$$\ell(\mu) = C - \frac{(x - \mu)^2}{2\sigma^2}$$

Derivades:

$$\frac{\partial \ell}{\partial \mu} = \frac{x - \mu}{\sigma^2} \implies \frac{\partial^2 \ell}{\partial \mu^2} = -\frac{1}{\sigma^2}$$

Informació de Fisher:

$$I(\mu) = -E \left[-\frac{1}{\sigma^2} \right] = \frac{1}{\sigma^2}$$

Prior de Jeffreys:

$$\pi_J(\mu) \propto \sqrt{I(\mu)} = \sqrt{\frac{1}{\sigma^2}} = \frac{1}{\sigma}$$