

Guía de Resolución — Métodos Bayesianos

Primer Parcial 2024-2025 · Recetas paso a paso para cada tipo de ejercicio

EJERCICIO 1 — Distribución Posterior + Estimaciones Puntuales

Contexto: Tienes un modelo paramétrico $f(x|\theta)$, una prior $\pi(\theta)$ y una muestra de datos. El objetivo es encontrar la distribución posterior $f(\theta|X)$ y dar estimaciones puntuales.

Receta general (válida para cualquier modelo)

1	Escribe la verosimilitud	Multiplica la función del modelo para todas las observaciones: $L(X \theta) = \prod f(x_i \theta)$ Simplifica agrupando potencias. Ignora constantes que no dependan de θ (usa el símbolo $\propto$).
2	Escribe la prior $\pi(\theta)$	Si es Uniforme $[0,1] \rightarrow \pi(\theta) = 1$ (constante, no afecta). Si es Beta(a,b) $\rightarrow \pi(\theta) \propto \theta^{a-1}(1-\theta)^{b-1}$. Si te dan media y varianza, primero calcula a y b (ver apartado b).
3	Multiplica y reconoce la forma	$f(\theta X) \propto L(X \theta) \cdot \pi(\theta)$ Agrupa potencias de θ y $(1-\theta)$. Compara con la forma de una distribución conocida (Beta, Gamma, etc.).
4	Identifica los parámetros	Si obtienes $\theta^{A-1}(1-\theta)^{B-1} \rightarrow$ posterior es Beta(A, B) . Si obtienes $\lambda^{A-1}e^{-B\lambda} \rightarrow$ posterior es Gamma(A, B) .
5	Estimaciones puntuales	Media: $E(\theta X) = a/(a+b)$ para Beta · a/b para Gamma Moda: $(a-1)/(a+b-2)$ para Beta · $(a-1)/b$ para Gamma

 **Truco clave:** Para la Geométrica, $L(X|\theta) = (1-\theta)^{(\sum x_i - n)} \cdot \theta^n$. Con prior Uniforme $\rightarrow$ Beta(n+1, $\sum x_i - n + 1$). Con prior Beta(a,b) $\rightarrow$ Beta(n+a, $\sum x_i - n + b$).

Apartado (b) — Encontrar hiperparámetros de una Beta a partir de media y varianza

1	Plantea el sistema	$E(\theta) = a/(a+b) = \text{valor dado}$ $\text{Var}(\theta) = ab / [(a+b)^2(a+b+1)] = \text{valor dado}$
2	Despeja b en función de a	De la media: $b = a \cdot (1-\mu)/\mu$ donde μ es la media dada.
3	Sustituye en la varianza	Sustituye b en la ecuación de la varianza y resuelve para a. Luego calcula b.

⚠ **Ojo:** Una vez tienes a y b de la prior, la posterior se actualiza sumando: $a_{\text{post}} = a_{\text{prior}} + n$ · (contribución de datos), $b_{\text{post}} = b_{\text{prior}} + (\text{contribución de datos})$. Para la Geométrica: $a_{\text{post}} = a + n$, $b_{\text{post}} = b + \sum x_i - n$.

Apartado (c) — Prior de Jeffreys

1	Log-verosimilitud	Calcula $\ell(\theta) = \log f(x \theta)$ para UNA observación.
2	Segunda derivada	Deriva dos veces respecto a θ : $d^2\ell/d\theta^2$
3	Información de Fisher	$I(\theta) = -E[d^2\ell/d\theta^2]$. Sustituye $E[X]$ por su valor conocido.
4	Prior de Jeffreys	$\pi_J(\theta) \propto \sqrt{I(\theta)}$
5	¿Propia o impropia?	Calcula $\int \pi_J(\theta) d\theta$. Si diverge $\rightarrow$ impropia. Usa comparación con integrales conocidas (ej: $\int 1/\theta d\theta = \infty$).

Jeffreys para modelos comunes:

- $\text{Poisson}(\lambda)$: $\pi_J(\lambda) \propto 1/\sqrt{\lambda}$
- $\text{Geométrica}(\theta)$: $\pi_J(\theta) \propto 1/(\theta\sqrt{1-\theta})$
- $\text{Binomial}(\theta)$: $\pi_J(\theta) \propto \theta^{-1/2} (1-\theta)^{-1/2} \sim \text{Beta}(1/2, 1/2)$



EJERCICIO 2 — Distribución Predictiva Prior

Contexto: Tienes un modelo $f(x|\theta)$ y una prior $\pi(\theta)$. El objetivo es calcular la distribución marginal de una nueva observación integrando θ :

$$p(x_{\text{new}}) = \int f(x_{\text{new}} | \theta) \cdot \pi(\theta) d\theta$$

Receta general

1	Escribe el modelo para x_{new}	$f(x_{\text{new}} \theta)$ con la función del modelo dado.
2	Escribe la prior $\pi(\theta)$	Si te dan media y b fijo (ej: Beta(a,3) con E=0.4), primero calcula a: $a/(a+b) = \text{media} \rightarrow$ despeja a.
3	Multiplica y agrupa en θ	Saca fuera de la integral todo lo que NO dependa de θ . Dentro queda solo una expresión en θ .
4	Reconoce la integral como una Beta	Si dentro tienes $\theta^{(A-1)}(1-\theta)^{(B-1)}$, la integral vale: $\int_0^1 \theta^{(A-1)}(1-\theta)^{(B-1)} d\theta = \Gamma(A)\Gamma(B)/\Gamma(A+B)$
5	Escribe el resultado final	Sustituye la integral por su valor en Gammas y simplifica.
6	Evalúa en un punto concreto	Sustituye x_{new} y r por los valores pedidos. Usa $\Gamma(n) = (n-1)!$ para enteros.



Truco clave: La integral siempre se resuelve reconociendo la forma de una Beta dentro. El "truco" es identificar los exponentes de θ y $(1-\theta)$ para saber A y B, y luego aplicar la fórmula de la función Beta: $B(A,B) = \Gamma(A)\Gamma(B)/\Gamma(A+B)$.



Recuerda: $\Gamma(n) = (n-1)!$ solo para enteros positivos. Para calcular numéricamente, simplifica las fracciones de factoriales antes de multiplicar.

Ejemplo rápido (del examen)

Modelo BN(r, θ), prior Beta(2,3), se pide $p(x_{\text{new}}=10)$ con r=3:

$$p(10) = C(9, 2) \cdot [\Gamma(5) / (\Gamma(3)\Gamma(2))] \cdot \Gamma(5)\Gamma(10) / \Gamma(15) = 0.04316$$

EJERCICIO 3 — Factor de Bayes (Contraste de Hipótesis Bayesiano)

Contexto: Quieres comparar dos hipótesis H_0 vs H_1 usando los datos. El Factor de Bayes mide cuánto apoyan los datos a H_0 frente a H_1 .

Receta general

1	Construye la posterior	Verosimilitud $\times$ Prior $\rightarrow$ identifica la distribución posterior. Para Poisson con Jeffreys: $f(\lambda X) \sim \text{Gamma}(\sum x_i + 1/2, n)$
2	Calcula $P(H_0 X)$ y $P(H_1 X)$	Son las probabilidades de cada región bajo la posterior: $P(H_0 X) = P(\lambda \leq c X) = F(c) \rightarrow$ valor de la tabla dada $P(H_1 X) = P(\lambda > c X) = 1 - F(c)$
3	Calcula el Factor de Bayes	$BF_{H_0} = P(H_0 X) / P(H_1 X)$ (Esto es válido cuando $P(H_0) = P(H_1) = 0.5$, que es el caso del examen)
4	Interpreta el resultado	Mira la tabla de interpretación abajo. Si BF_{H_0} es pequeño $\rightarrow$ evidencia contra $H_0 \rightarrow$ mira $1/BF_{H_0} = BF_{H_1}$.
5	Conclusión	Responde a la pregunta del enunciado en términos del problema real.

 **Importante:** El Factor de Bayes solo coincide con $P(H_0|X)/P(H_1|X)$ cuando las probabilidades a priori son iguales ($P(H_0)=P(H_1)=0.5$). Si fueran distintas, habría que ajustar.

Tabla de interpretación del Factor de Bayes

$BF_{H_1} = 1/BF_{H_0}$	Interpretación	Decisión
1 – 3	Evidencia débil contra H_0	No concluyente
3 – 20	Evidencia positiva contra H_0	Cierta tendencia a H_1
20 – 150	Evidencia fuerte contra H_0	Rechazar H_0 
> 150	Evidencia muy fuerte contra H_0	Rechazar H_0 con certeza 

Ejemplo del examen (Poisson)

1	Posterior	$\sum x_i = 42, n = 10 \rightarrow f(\lambda X) \sim \text{Gamma}(42.5, 10)$
2	Probabilidades	$P(H_0 X) = F(3) = \text{pgamma}(3, 42.5, 10) = 0.0181$ $P(H_1 X) = 1 - 0.0181 = 0.9819$
3	Factor de Bayes	$BF_{H_0} = 0.0181/0.9819 \approx 0.018 \rightarrow BF_{H_1} \approx 54$
4	Conclusión	

$BF_{H_1} = 54 \rightarrow$ Evidencia fuerte contra $H_0 \rightarrow$ Sí contratar
publicidad 



RESUMEN — Distribuciones conjugadas más importantes

Modelo	Prior conjugada	Posterior	Jeffreys
Geométrica(θ)	Beta(a, b)	Beta(a+n, b+ $\sum x_i$ -n)	$\propto 1/(\theta\sqrt{1-\theta})$ — impropia
Poisson(λ)	Gamma(a, b)	Gamma(a+ $\sum x_i$, b+n)	$\propto 1/\sqrt{\lambda}$ — impropia
Binomial(θ)	Beta(a, b)	Beta(a+ $\sum x_i$, b+n- $\sum x_i$)	Beta(1/2, 1/2) — propia
Normal(μ) σ^2 conocida	Normal(μ_0 , σ_0^2)	Normal actualizada	$\propto 1$ — impropia



RESUMEN — Fórmulas clave

Concepto	Fórmula
Posterior (regla de Bayes)	$f(\theta X) \propto L(X \theta) \cdot \pi(\theta)$
Media Beta(a,b)	$a / (a+b)$
Moda Beta(a,b)	$(a-1) / (a+b-2)$
Varianza Beta(a,b)	$ab / [(a+b)^2(a+b+1)]$
Media Gamma(a,b)	a/b
Moda Gamma(a,b)	$(a-1)/b$
Información de Fisher	$I(\theta) = -E[d^2\ell/d\theta^2]$
Prior de Jeffreys	$\pi_J(\theta) \propto \sqrt{I(\theta)}$
Predictiva prior	$p(x_{\text{new}}) = \int f(x_{\text{new}} \theta) \cdot \pi(\theta) d\theta$
Factor de Bayes (priors iguales)	$BF_{H_0} = P(H_0 X) / P(H_1 X)$
Integral Beta	$\int_0^1 \theta^{A-1}(1-\theta)^{B-1} d\theta = \Gamma(A)\Gamma(B)/\Gamma(A+B)$
Función Gamma (enteros)	$\Gamma(n) = (n-1)!$



Estrategia general para cualquier ejercicio bayesiano:

1. Identifica el modelo y escribe la verosimilitud $L(X|\theta)$
2. Elige/calcula la prior $\pi(\theta)$
3. Multiplica: $f(\theta|X) \propto L \cdot \pi$
4. Reconoce la forma (Beta, Gamma, Normal...)
5. Extrae parámetros y calcula lo que pidan (media, moda, factor de Bayes, predictiva...)