

Modelització de dades complexes

Grau d'Estadística Aplicada UAB

Tema 1: Introducció a les xarxes Bayesianes

Llista 3: Bloc D

1. Estem interessats a estimar la proporció de fumadors a la terrassa d'estiu d'un bar, diguem-ne θ . Hem decidit apuntar si els clients fumen o no. Tenim la informació relativa als 10 clients que hi ha a la terrassa de la manera següent:

$$\{1, 2, 2, 2, 2, 1, 2, 2, 2, 1\}$$

on “1” significa que el client fuma, i “2” que no fuma.

Es demana trobar l'estimador de la màxima versemblança (EMV) de θ a partir d'aquesta informació.

2. Agafem una mostra de 100 individus que han estat fumant dos o més paquets de cigarretes diàries al llarg dels darrers 10 anys. Per a cadascun d'ells, li mesurem la pressió sistòlica (X) i prenem nota de en quin d'aquests intervals es troba:

$$\leq 100, \quad 101 - 120, \quad 121 - 140, \quad 141 - 160 \quad \text{or} \quad \geq 161,$$

i obtenim els resultats següents:

Pressió sistòlica (interval)	# individus en aquest interval
≤ 100	2
1001 - 120	15
121 - 140	23
141 - 160	25
≥ 161	35

Fem servir la notació:

$$\theta_1 = P(X \leq 100)$$

$$\theta_2 = P(101 \leq X \leq 120)$$

$$\theta_3 = P(121 \leq X \leq 140)$$

$$\theta_4 = P(141 \leq X \leq 160)$$

$$\theta_5 = P(X \geq 161)$$

Es demana trobar els estimadors pel mètode de la màxima versemblança (EMV) de θ_i , $i = 1, \dots, 5$, a partir d'aquesta informació.

3. Considerar les xarxes Bayesianes següents:

Xarxa Bayesiana A: $V = \{X, Y\}$, $E = \{(X, Y)\}$, i


Xarxa Bayesiana B: $V = \{X, Y\}$, $E = \{(Y, X)\}$,

on tant X com Y són variables aleatòries booleanes. X pren valors x_1 i x_2 , mentre que la variable Y pren els valors y_1 i y_2 . Es demana:

- (a) Especifiqueu els paràmetres per a cadascuna de les dues xarxes Bayesianes.
- (b) Trobeu l'estimador de la màxima versemblança (EMV) pels paràmetres de cadascuna de les xarxes Bayesianes, a partir del conjunt de dades D següent:

Case	X	Y
1	x1	y1
2	x1	y1
3	x1	y1
4	x1	y1
5	x1	y1
6	x1	y2
7	x2	y1
8	x2	y1
9	x2	y2
10	x2	y2

- (c) Per a cadascuna de les dues xarxes Bayesianes, estimeu $P(X = x_1)$ i $P(Y = y_1)$ a partir dels estimadors EMV obtinguts a l'apartat (b), i compareu els seus valors per a les dues xarxes Bayesianes.
- (d) Si tenim l'evidència que $X = x_1$, quina és la predicció per a la variable Y (i amb quin nivell de confiança), usant cadascuna de les dues xarxes Bayesianes?
4. Considereu la xarxa Bayesiana següent, on les tres variables són binàries i prenen els valors 1 i 0:



- (a) A partir de la base de dades D donada per la taula següent, calculeu l'estimador EMV del vector de paràmetres $\theta = (\theta_{11}, \theta_{21}, \theta_{31}, \theta_{32}, \theta_{33}, \theta_{34})$.

Case	X	Y	Z
1	1	1	1
2	1	1	0
3	1	1	0
4	1	0	1
5	0	1	1
6	0	1	0
7	0	0	1
8	0	0	1
9	0	0	0
10	0	0	0

Estimeu també la probabilitat $P(Z = 1)$.

- (b) Supposeu ara que la base de dades disponible és incompleta, com es mostra a la taula següent,

Case	X	Y	Z
1	?	1	1
2	1	1	0
3	1	1	0
4	1	0	?
5	0	1	1
6	0	1	0
7	0	0	1
8	0	?	1
9	0	0	0
10	0	0	0

Volem aplicar el mètode *Expectation Maximization (EM)* per a estimar els paràmetres. Si comencem amb les estimacions inicials dels paràmetres donades per:

$$\theta^0 = (\theta_{11}^0 = 0.3, \theta_{21}^0 = 0.6, \theta_{31}^0 = 0.4, \theta_{32}^0 = 0.6, \theta_{33}^0 = 0.8, \theta_{34}^0 = 0.7),$$

es demana:

- Trobeu la funció de versemblança per a aquesta estimació inicial dels paràmetres, a partir de la base de dades incompletes.
 - Obtenir la distribució empírica esperada per a les variables X , Y i Z , corresponent a les completacions de la base de dades incompleta i les corresponents probabilitats basades en les estimacions inicials dels paràmetres θ^0 .
 - Utilitzeu la distribució empírica esperada trobada a l'apartat anterior per a trobar les estimacions dels paràmetres corresponents a la iteració 1, $\hat{\theta}^1$.
 - Trobeu el valor de la funció de versemblança per a la primera iteració de les estimacions del paràmetre, $\hat{\theta}^1$, a partir de la base de dades incompletes, i comparar amb el que s'ha obtingut a i).
- (c) Repetiu l'apartat (b) però ara a partir de la base de dades incompleta de la tabla siguiente:

Case	X	Y	Z
1	?	?	1
2	1	1	0
3	1	1	0
4	1	0	1
5	0	1	1
6	0	1	0
7	0	0	1
8	0	0	1
9	0	0	0
10	0	0	0

5. Carregueu la base de dades [datos_generados_ejercicio.5.rdata](#) amb R. Llavors, tindreu un *data frame* de 500 casos amb 3 variables: X , Y i Z . Es demana aprendre

els paràmetres del model, la part gràfica del qual ve donada per la figura que surt a l'exercici 4, usant el paquet **bnlearn** de R, a partir de les dades.

Observació: **bnlearn** no accepta valors faltants (“NA”), per la qual cosa primer s’han d’ometre els casos amb “NA” (dels 500 casos inicials, ens quedarem amb 420).