

WINE QUALITY

1. Descripció de la Base de Dades

Per a la realització d'aquesta pràctica, s'ha seleccionat la base de dades "Wine Quality", referent a mostres de vi blanc de la variant portuguesa *Vinho Verde* (nord de Portugal). Aquesta base de dades s'ha obtingut del repositori UCI.

La base de dades està formada per 4899 casos i 12 variables. A més, no presenta valors perduts, el que facilita l'anàlisi.

Les 12 variables que componen el conjunt de dades es divideixen de la següent manera per a la nostra anàlisi:

Variables d'entrada:

- *fixed acidity*: Acidesa fixa del vi (concentració d'àcids no volàtils, en g/dm³)
- *volatile acidity*: Acidesa volàtil (concentració d'àcid acètic, en g/dm³). Valors alts poden donar sabor a vinagre.
- *citric acid*: Àcid cítric (en g/dm³). En petites quantitats afegeix frescor i sabor al vi.
- *residual sugar*: Sucre residual (en g/dm³). Quantitat de sucre que queda després de la fermentació.
- *chlorides*: Clorurs (en g/dm³). Quantitat de sal al vi.
- *free sulfur dioxide*: Diòxid de sofre lliure (en mg/dm³). Forma lliure del SO₂, actua com a conservant i antioxidant.
- *total sulfur dioxide*: Diòxid de sofre total (en mg/dm³). Suma de les formes lliure i lligada del SO₂.
- *density*: Densitat del vi (en g/cm³). Relacionada amb el contingut d'alcohol i sucre.
- *pH*: Nivell d'acidesa del vi (escala 0-14). La majoria de vins blancs es troben entre 3.0 i 3.5.
- *sulphates*: Sulfats (en g/dm³). Additiu que contribueix als nivells de SO₂ i actua com a antimicrobià.
- *alcohol*: Percentatge d'alcohol en volum (% vol).

Variables de sortida:

- *quality*: Puntuació de qualitat del vi (3-9), basada en avaluació sensorial per experts, etiquetades en Baixa [3,4,5] - Mitjana [6] - Alta [7,8,9].

2. Objectiu i Tasca de Classificació

L'objectiu principal és modelitzar la qualitat del vi a partir de les seves propietats fisicoquímiques. Es tracta d'una tasca de classificació multiclasse, on intentem predir la classe `quality` per classificar els vins en les diferents puntuacions.

Metodologia a seguir:

1. **Preprocessament:** discretitzar les 11 variables d'entrada. S'avaluarà l'agrupació de `quality` en tres categories (com "Baixa", "Mitjana" i "Alta"), ja que hi ha poques instàncies en puntuacions extremes
2. **Aprenentatge del model:** construcció de dos classificadors bayesians, un **Naive Bayes** (assumeix independència entre les variables fisicoquímiques) i un **Tree Augmented Naive Bayes** (permet detectar interaccions entre les variables).
3. **Validació:** avaluar el comportament del model a partir del k-fold cross-validation. Com es tracta de dades no balancejades i multiclasse, a més de la precisió global (accuracy) es calcularan altres mesures de rendiment per determinar quin classificador té més èxit reconeixent minories.