

UNIVERSITAT AUTÒNOMA DE BARCELONA

Grau en Estadística Aplicada
Modelització de Dades Complexes

Wine Quality: Anàlisi de Classificadors Bayesians

Aplicats a la qualitat del vi blanc “Vinho Verde”

Autors:

Iker Fernández Cabanillas	(1704341)
Enola Garcia Carbó	(1708253)
Carlos Torras Rovira	(1703430)

Índex

1	Introducció i Context de la Base de Dades	2
1.1	Origen i Descripció del Dataset	2
1.2	Tasca de Classificació i Variable Objectiu	2
2	Preprocessament i Preparació de les Dades	4
2.1	Anàlisi Exploratori Inicial	4
2.2	Mètode de Discretització (Hartemink)	4
2.2.1	Funcionament	4
2.2.2	Configuracions	5
3	Metodologia: Models de Classificació Bayesians	6
3.1	Model Base: Naive Bayes (NB)	6
3.2	Model Avançat: Tree-Augmented Naive Bayes (TAN)	7
4	Validació i Resultats	8
4.1	Metodologia de Validació (K-Fold Cross-Validation)	8
4.2	Comparativa de Discretització: 6 intervals vs 17 intervals	8
4.2.1	Resultats	8
4.3	Comparativa d'Algoritmes: Naive Bayes vs TAN (17 breaks)	9
4.3.1	Resultats	9
4.3.2	Mètriques del model	9
4.4	Anàlisi i Interpretació de l'Estructura Apresta (TAN)	9
5	Predicció de Noves Dades	11
5.1	Entrenament del Model Final	11
5.2	Disseny de Perfils Sintètics i Mapeig d'Evidències	11
5.3	Resultats de la Predicció i Insights Enològics	12
6	Conclusions	13

1 Introducció i Context de la Base de Dades

1.1 Origen i Descripció del Dataset

En aquest projecte, hem decidit treballar amb una base de dades extreta del repositori de l'UCI Machine Learning titulada "*Wine Quality*" [1]. Per a l'estudi, hem optat per treballar específicament amb el dataset que conté dades sobre vi blanc, referents a mostres de vi "Vinho Verde" procedents de la regió del nord de Portugal.

Aquesta base de dades està formada per 4899 observacions (mostres de vi) i 12 variables en total. Per una banda, comptem amb 11 variables que actuen com a predictores (de caràcter fisicoquímic i propietats de la composició de cada mostra).

Una breu descripció de les variables predictores utilitzades:

- **Acidesa fixa (fixed acidity):** Mesurada en g/dm^3 d'àcid tàrtric, representa els àcids naturals del vi que no s'evaporen fàcilment.
- **Acidesa volàtil (volatile acidity):** Mesurada en g/dm^3 d'àcid acètic; un excés indica alteració bacteriana (vinagre).
- **Àcid cítric (citric acid):** Mesurat en g/dm^3 , aporta frescor i notes cítriques al perfil del vi.
- **Sucre residual (residual sugar):** Quantitat de sucre que queda després de la fermentació (g/dm^3).
- **Clorurs (chlorides):** Quantitat de sal present al vi, mesurada en g/dm^3 de clorur sòdic.
- **Diòxid de sofre lliure (free sulfur dioxide):** Forma activa del sulfit (SO_2) que protegeix el vi de l'oxidació i dels microorganismes (mg/dm^3).
- **Diòxid de sofre total (total sulfur dioxide):** Suma del SO_2 lliure i el lligat a altres components (mg/dm^3).
- **Densitat (density):** Mesurada en g/cm^3 , reflecteix el cos o la consistència líquida del vi. Determinada per un equilibri oposat: el sucre residual la fa augmentar (fa el vi més pesat), mentre que l'alcohol la fa disminuir (fa el vi més lleuger).
- **pH:** Mesura de l'acidesa o alcalinitat a una escala logarítmica.
- **Sulfats (sulphates):** Additiu que actua com a antioxidant i antimicrobià (g/dm^3 de sulfat de potassi).
- **Alcohol:** Graduació alcohòlica de la mostra expressada en percentatge de volum (% vol).

1.2 Tasca de Classificació i Variable Objectiu

La variable marcada com a variable objectiu de l'estudi és la qualitat del vi. Aquesta variable està expressada en forma d'una puntuació assignada per un panell d'experts després de trobar la mitjana de les puntuacions assignades per cadascun al realitzar la cata de cada cas. Aquesta puntuació es presenta en el dataset com a una nota numèrica discreta que pren valors entre el 0 i el 10, tot i que per aquesta mostra, totes les puntuacions mitjanes s'han trobat entre el 3 i el 9.

Per tal d'evitar un fragmentament excessiu de les dades que malbaratés de forma severa la capacitat d'aprenentatge de la nostra xarxa bayesiana a l'hora de modelar, hem optat per fer una recodificació de la variable *quality*. Aquesta nova estructura de la variable otorga tres possibles classes ordinals a la variable objectiu, que s'estructuren millor tenint en compte la distribució original de la qualitat dels vins i faciliten la tasca de classificació.

1. **Baixa:** Agrupa els vins amb puntuacions originals inferiors o iguals a 5 (valors 3, 4 i 5). Representa el 33.5% de la mostra total, amb un volum de 1.640 casos.
2. **Mitjana:** Correspon exactament als vins amb una puntuació original de 6. Aquesta és la classe majoritària de la base de dades, representant el 44.9% del total amb 2.198 observacions.
3. **Alta:** Agrupa els vins de gamma superior amb puntuacions iguals o superiors a 7 (valors 7, 8 i 9). Representa la classe minoritària, constituint el 21.6% restant de la mostra amb 1.061 casos.

De tota manera, la nova partició de classes segueix mantenint un desequilibri important, ja que a prop de la meitat dels casos se'ls hi otorga la categoria **Mitjana** (44.9%). Aquest factor, per tant, afecta tant al procés d'avaluació del model com al de validació, ja que aquesta probabilitat *a priori* de la classe central farà que el nostre classificador tendeixi de forma natural a veure's influenciat.

2 Preprocessament i Preparació de les Dades

2.1 Anàlisi Exploratori Inicial

Previ al disseny i selecció de models probabilístics, s'ha dut a terme un anàlisi i exploració inicial de les variables predictores presentades. La característica més rellevant d'aquest dataset és la enorme disparitat de naturaleses, ordres de magnitud i escales dels nostres predictors, tot i que al tractar-se d'un conjunt de variables que mesuren quantitats químiques, totes elles mostren valors numèrics continus.

Cada una de les variables està mesurada d'una forma diferent, contem amb variables on les concentracions es representen en (g/dm³) mentre que d'altres ho fan en (mg/dm³) o (g/cm³). Inclús hi ha casos més excepcionals com ara el pH, el qual es representa en una escala logarítmica inversa de la concentració d'ions d'hidrògen.

Com en aquest treball treballem amb xarxes bayesianes, les quals queden exemptes dels conflictes que poden originar arrel d'aquesta col·lisió d'escales, al dur a terme la discretització corresponent, es tractarà de definir uns intervals tals que respectin el comportament de cada variable junt amb la seva variabilitat original.

També, durant aquest procés exploratori inicial hem trobat correlacions lineals fortes entre els predictors, cal destacar la relació inversament proporcional entre l'alcohol i la densitat o la dependència entre el diòxid de sofre lliure i el total, entre d'altres. Els dos exemples mencionat tenen molt sentit intuïtiu ja que el càlcul d'aquestes magnituds recau directament en el valor que pren l'altre. La hipòtesi fonamental del Naive Bayes estàndard es basa precisament en la independència absoluta dels predictors, i al veure que variables predictores semblen estar bastant correlacionades entre elles, ens fa pensar que a priori la implementació de models de major complexitat com ara un *Tree-Augmented Naive Bayes* (TAN), pot estar justificat i de fet pot ser una estratègia interessant a seguir en la construcció del model.

2.2 Mètode de Discretització (Hartemink)

Per tal de poder utilitzar les xarxes bayesianes, vam haver de discretitzar les dades, en el nostre cas, van ser totes les predictores ja que totes les variables predictives eren contínues.

Fent una petita cerca al `help` de la funció `discretize()`, vam observar els possibles mètodes de discretització. Considerant **Hartemink** la millor opció, ja que teòricament era el que millor representava les dades després de discretitzar-les.

2.2.1 Funcionament

Hartemink és un procés iteratiu, el qual es basa en minimitzar la pèrdua d'informació. Per tant, aquest ens demana uns breaks inicials (ibreaks) i uns finals (breaks), també demana el mètode per fer la partició inicial, el qual hem optat per una partició igual amb `quantile`, per últim requeria d'un criteri de decisió, el qual va ser MI (Mutual information), com era el seleccionat per defecte, no ho vam haver d'especificar.

Amb tot això, el procés consisteix en una primera partició de les dades amb el nombre d'ibreaks corresponent, que posteriorment, aniria col·lapsant fins arribar al nombre final de breaks que li demanem, tot això, calculant la MI de cada unió d'intervals executant el que menys pèrdua d'informació generi.

2.2.2 Configuracions

Per optimitzar aquest pas, es van plantejar i analitzar de manera reflexiva dues estratègies diferenciades:

- Opció 1 (Configuració Estàndard): Definició de 6 breaks bàsics combinats amb 60 ibreaks. Aquesta opció redueix de manera dràstica la mida de les taules CPT, disminuint el cost computacional, però corre el risc de fusionar fenòmens químics completament diferents dins d'una mateixa categoria.

- Opció 2 (Configuració d'Alta Resolució): Augment de la granularitat a 17 breaks estructurals i 170 ibreaks obtenint així un nivell de detall en les variables molt alt, que podria fer que el model detectés petits detalls que marquen la diferència, clarament, comporta un major cost computacional.

3 Metodologia: Models de Classificació Bayesians

L'objectiu d'aquesta fase és construir una xarxa probabilística que ens permeti predir la variable classe (quality) a partir de les covariables fisicoquímiques. Per aconseguir-ho, s'implementaran dos models amb complexitats i restriccions en la connectivitat entre covariables diferents: el model *Naive Bayes* (NB) i *Tree-Augmented Naive Bayes* (TAN).

La implementació d'aquests models i el preprocessament de les dades s'ha dut a terme mitjançant l'entorn de R, usant les llibreries `bnlearn` [2] i `gRain` [3]. Utilitzem la primera per estimar els paràmetres i permetre l'aprenentatge estructural de la xarxa bayesiana. Més endavant, el model que demostrï ser més òptim es migrarà a `gRain` mitjançant la funció `as.grain()`, permetent-nos realitzar inferència eficient de la qualitat del vi al introduir les característiques químiques de nous vins com a evidència.

3.1 Model Base: Naive Bayes (NB)

El model classificador *Naive Bayes* imposa una estricta condició sobre les connexions entre les variables predictores. Dictamina una independència condicional absoluta entre elles, on **quality** actua com a node pare de totes elles en una estructura on les variables predictores únicament es relacionen amb les que han de predir.

Aquesta simplificació redueix dràsticament l'espai de cerca i, en termes matemàtics, permet que la probabilitat conjunta d'una classe C donats els atributs $X_1, X_2, \dots, X_n$ es factoritzi com:

$$P(C | X_1, \dots, X_n) \propto P(C) \prod_{i=1}^n P(X_i | C)$$

Tot i la seva simplicitat estructural, el Naive Bayes sovint ofereix un punt de partida robust per a la classificació.




Figura 1: Estructura Naive Bayes

3.2 Model Avançat: Tree-Augmented Naive Bayes (TAN)

Per altra banda, la complexitat aparent del model més avançat, el *Tree-Augmented Naive Bayes* esdevé com a conseqüència de una relaxació en la restricció que presenta el model base. Aquesta arquitectura permet que els nodes predictors es connectin entre si formant un arbre inferior. Aquest algorisme cerca l'arbre d'expansió màxima connectant les variables predictors en funció de la seva informació mútua condicional. Tot i que el model passa a ser capaç de capturar interdependències químiques reals, també rep un augment molt gran en quant al cost computacional del procés.




Figura 2: Estructura Tree Augmented Naive Bayes

4 Validació i Resultats

4.1 Metodologia de Validació (K-Fold Cross-Validation)

Per avaluar el rendiment i la capacitat de generalització dels models Naive Bayes (NB) i Tree-Augmented Naive Bayes (TAN), s'ha implementat un procés de validació creuada de 10 particions (10-fold cross-validation). Aquesta tècnica divideix el conjunt de dades en 10 subconjunts d'aproximadament la mateixa mida, utilitzant-ne 9 per a l'entrenament del model i 1 per a la prova en cada iteració, permetent així que cada instància s'utilitzi exactament un cop per a l'avaluació.

Per dur a terme aquesta avaluació de manera rigorosa i adaptar-la al context específic del problema, s'ha dissenyat la funció pròpia `metriques_clasificacio`. Aquesta funció computa de forma automatitzada mètriques clau com l'Accuracy, l'F1-Macro, el MCC (Matthews Correlation Coefficient) i el MAE (Mean Absolute Error). L'ús d'aquestes mètriques combinades, en lloc de basar-nos únicament en una d'elles (com podria ser l'Accuracy), permet fer front al desbalanceig de les classes i respectar el caràcter ordinal de la variable target (`quality`).

4.2 Comparativa de Discretització: 6 intervals vs 17 intervals

Abans de fer la comparativa de models i decidir-ne un, vam haver de fer la comparativa entre les dues opcions de discretització (6 vs 17 breaks). Fent així una comparació del Naive Bayes de 6 breaks contra el Naive Bayes de 17 breaks i el Tree Augmented Naive Bayes de 6 breaks contra el Tree Augmented Naive Bayes de 17 breaks.

Per tal de validar els resultats obtinguts per la funció `metriques_clasificacio`, vam guardar els resultats de cada mètrica a tots els folds, per fer seguidament un test de diferències que segons la normalitat d'aquestes diferències, mitjançant el test de Shapiro-Wilk serà un T-Test aparellat (Normalitat) o un Test de Wilcoxon aparellat

4.2.1 Resultats

Mètrica	NB (6 breaks)	NB (17 breaks)	Guany	P-value Norm.	P-value
Accuracy	0.5302	0.5427	+0.0125 (+1.25%)	0.6515422	0.01723269
F1-Score	0.5304	0.5431	+0.0127 (+1.27%)	0.8045245	0.02031217
MCC	0.2891	0.308	+0.0189 (+1.89%)	0.5733131	0.01831445
MAE	0.5157	0.5027	-0.013 (-1.3%)	0.9802494	0.02043548

Taula 1: Comparativa de rendiment per Naive Bayes (6 vs 17 breaks)

Mètrica	TAN (6 breaks)	TAN (17 breaks)	Guany	P-value Norm.	P-value
Accuracy	0.5807	0.6376	+0.0569 (+5.69%)	0.862966	0.00003083
F1-Score	0.5831	0.6328	+0.0497 (+4.97%)	0.918433	0.000052714
MCC	0.3525	0.4293	+0.0768 (+7.68%)	0.873117	0.000042123
MAE	0.4357	0.3922	-0.0435 (-4.35%)	0.256082	0.00011687

Taula 2: Comparativa de rendiment per Tree-Augmented Naive Bayes (6 vs 17 breaks)

Com podem observar a la taula 1, el Naive Bayes de 17 breaks es superior en totes les mètriques, i després de fer els test de normalitat, els quals han resultat no significatius, per tant, totes les diferències són normals. Fent el T-Test de dades parellades, tenim que totes les diferències són significatives i per tant els 17 breaks al Naive Bayes són superiors al 6 breaks segons els test.

Per altra banda, si ens fixem la taula 2, observem una notable millora a totes les mètriques del model amb 17 breaks, tenint també normalitat a totes les diferències (P-value no significatiu) i podent dir que els 17 breaks són millors significativament al model Tree Augmented Naive Bayes, ja que els P-valors de totes les mètriques són molt significatius.

Per tant, podem concloure que els 17 breaks amb 170 ibreaks són una millor configuració que els 6 breaks amb 60 ibreaks, obtenint una significancia estadística notable en totes les mètriques provades, i per tant aquesta serà la nostra configuració final.

4.3 Comparativa d'Algoritmes: Naive Bayes vs TAN (17 breaks)

Un cop ja tenim la configuració final, passem a comparar els dos models, el Naive Bayes de 17 breaks i el Tree Augmented Naive Bayes de 17 breaks.

4.3.1 Resultats

Mètrica	NB (17 breaks)	TAN (17 breaks)	Guany	P-value Norm.	P-value
Accuracy	0.5427	0.6376	+0.0949 (+9.49%)	0.4265237	0.0000001615
F1-Score	0.5431	0.6328	+0.0897 (+8.97%)	0.9584563	0.0000007833
MCC	0.308	0.4293	+0.1213 (+12.13%)	0.6624016	0.0000004921
MAE	0.5027	0.3922	-0.1105 (-11.05%)	0.7831556	0.0000003962

Taula 3: Comparativa final de models (configuració de 17 breaks)

Com podem apreciar a la taula 3, totes les Mètriques del Tree Augmented Naive Bayes són notablement millors que les del Naive Bayes, amb unes diferències bastant marcades. No obstant, vam haver de fer els tests corresponents per tal de verificar-ho. Els quals començant per la normalitat tenim que totes les diferències són normals i posteriorment, aplicant el T-Test per dades parellades, obtenint uns P-valors molt significatius, amb això, corroborem aquesta gran millora del model Tree Augmented Naive Bayes i podem concloure que aquest model és millor que el Naive Bayes i que serà el nostre model final per fer les prediccions adients.

4.3.2 Mètriques del model

Per la part del rendiment del model, en termes general, tenim un model acceptable i relativament bo, ja que obtenim un **accuracy** proper a 2/3, amb això sabem que el model prediu millor que l'atzar (1/3) i que no es guia només pel desequilibri (44.9% de la classe majoritària), per la part de l'F1 i el MCC, també tenim uns valors bastant bons, amb un 0.6328 a l'F1 i un MCC de 0.4293, i per últim quant al MAE, tenim un resultat prou bo, 0.3922, aquest ens diu, que quan el model falla, aquest ho fa desviant-se en 0.3922 esglaons, per tant, el model no té molts errors greus (predit = baixa, real=alta), sinó que, normalment, el model té errors petits, fallant de baixa a mitjana o de mitjana a alta.

4.4 Anàlisi i Interpretació de l'Estructura Apresta (TAN)

Un cop seleccionat el model Tree-Augmented Naive Bayes (TAN) com el classificador òptim per a l'estudi, és fonamental analitzar l'estructura de la xarxa bayesiana apresada per comprendre quines relacions i dependències s'han establert entre les variables fisicoquímiques sota la condició de la variable classe **quality**. A diferència del model Naive Bayes, que imposa una independència absoluta, l'algorisme en el TAN reconeix i connecta aquells predictors que comparteixen una alta informació mútua condicional.

La figura 3 mostra el graf acíclic dirigit (DAG) resultant de l'aprenentatge estructural, on s'observen de forma visual les fletxes de connexió de les diferents valorsables.




Figura 3: Estructura de la xarxa Tree-Augmented Naive Bayes (TAN) apresa.

L'anàlisi de la significació estadística de les interaccions reflectides en el graf revela que tots els p-valors associats a les fletxes de connexió de l'arbre són molt baixos, fet que demostra la robustesa i la rellevància de les dependències estructurals identificades de forma empírica pel model.

Dins d'aquestes, els predictors que manifesten una dependència estadística més forta i els p-valors més baixos en relació amb el seu node pare dins de l'arbre són els següents:

- **Densitat (*density*):** Presenta el p-valor més baix de tot el model (1.59×10^{-123}). Això reflecteix que la densitat és una variable altament interconnectada amb la resta de components de la xarxa. En termes enològics, la densitat d'un vi actua com a indicador directe de l'equilibri físic entre el contingut de sucres residuals (que n'augmenten la densitat) i el grau d'alcohol etílic generat durant la fermentació (que la redueix per sota de la densitat de l'aigua).
- **Acidesa volàtil (*volatile acidity*):** Registra un p-valor de 7.12×10^{-85} respecte al seu node pare, evidenciant una forta associació condicional. Aquesta variable quantifica els àcids en estat gasós del vi, principalment l'àcid acètic. L'arquitectura del model captura aquesta dada com a crucial ja que nivells elevats d'acidesa volàtil són els responsables directes de dotar al vi d'un gust o aroma avinagrat (defecte greu).
- **Àcid cítric (*citric acid*):** Mostra un p-valor de 7.05×10^{-67} . Dins de la química del vi, l'àcid cítric hi juga un paper fonamental com a agent potenciador, aportant una sensació de frescor i vivacitat, fet que altera profundament la percepció qualitativa del producte final i justifica el seu pes rellevant dins la xarxa d'aprenentatge.

Aquesta solidesa en els p-valors valida la decisió de relaxar la restricció d'independència del Naive Bayes, confirmant que el model TAN no només aporta una major exactitud predictiva, sinó que construeix una representació coherent i estadísticament significativa de les interaccions químiques que defineixen la qualitat del vi blanc.

5 Predicció de Noves Dades

5.1 Entrenament del Model Final

Un cop hem determinat quin dels nostres models ofereix un millor rendiment de forma estadística significativa (*Tree Augmented Naïve Bayes*; 17 breaks), després de validar el comportament dels classificadors avaluats gràcies a un procés de validació creuada, es el moment de entrenar el model definitiu.

Prèviament, a la fase de validació s’ha fragmentat el dataset per comprovar la capacitat de generalització del model, però per l’entrenament del model final fem servir la totalitat de les dades amb la intenció de maximitzar l’eficiència de les estimacions dels paràmetres. D’aquesta manera, les taules de probabilitat condicional de la nostra taula contindran la màxima informació possible a partir de les dades.

Per tal de realitzar les prediccions de forma eficient, el model final s’ha transformat mitjançant la funció `as.grain()` de la llibreria `gRain`, la qual compila la xarxa bayesiana en una estructura de *junction tree* (arbre d’unió). D’aquesta manera s’agrupen les variables i s’eliminen estructures de bucles, fent que la nova evidència (casos nous) viatgi per les branques de l’arbre fins trobar la distribució de probabilitat final de la qualitat.

5.2 Disseny de Perfils Sintètics i Mapeig d’Evidències

Per tal d’avaluar realment com es comporta la nostra xarxa en una situació de predicció de perfils fora de la base de dades, hem decidit crear 7 perfils diferents i posar-los a prova amb el nostre model. Aquests perfils han estat creats de forma sintètica mirant de replicar amb la major exactitud possible perfils reals de vins comercials. Per fer això, per a cinc dels nostres casos nous, els hem assignat valors a les covariables fisicoquímiques replicant els vins reals, junt amb dos perfils extrems dissenyats a mode de control.

- **Verdejo Joven / Estilo Pescadito:** Perfils de vins comercials estàndard, frescos, lleugers i d’acidesa equilibrada.
- **Chardonnay Criança:** Vi de perfil més robust, caracteritzat per una baixa acidesa fixa i una graduació alcohòlica elevada (13.5% vol).
- **Blanco Semidulce:** Vi amb una concentració críticament alta de sucre residual (18.5 g/dm³) i, en conseqüència, una densitat límit (0.9990 g/cm³).
- **Blanco Atlántico:** Perfil d’alta acidesa (pH molt baix de 2.98) i marcat caràcter salí reflectit en uns clorurs elevats.
- **Vino Picado:** Control negatiu que simula un vi malmès per oxidació bacteriana, presentant un valor extrem d’acidesa volàtil (1.10 g/dm³) i carència total de sulfits protectors. Un vi inconsistent, desbalancejat i amb aroma a vinagre.
- **Balance Top:** Control positiu construït idealment a partir de la combinació dels valors òptims del dataset històric.

El model bayesià només accepta variables categòriques i per tant, a cada observació de cada perfil nou se li implementa un algorisme de mapeig el qual assigna a cada valor continu un interval basant-se en l’observació del nostre model inicial més propera a la nova minimitzant la distància absoluta. D’aquesta manera els nous casos passen a estar quadrats amb el sistema d’interval de Hartemink creats en el preprocessament.

$$x_{\text{disc}} = \arg \min_i |x_{\text{nou}} - X_i| \quad (1)$$

5.3 Resultats de la Predicció i Insights Enològics

S'introdueix l'evidència a la xarxa obtenint els següents resultats mitjançant la propagació de probabilitats:

Taula 4: Resultats de la inferència exacta sobre els perfils sintètics (Model TAN, 17 breaks).

Perfil del Vi	Predicció Final	P(Baixa)	P(Mitjana)	P(Alta)
Verdejo_Joven	Mitjana	0.0120	0.9333	0.0547
Estilo_Pescadito	Mitjana	0.0000	1.0000	0.0000
Chardonnay_Criança	Alta	0.0011	0.0869	0.9120
Blanco_Semidulce	Mitjana	0.0009	0.9991	0.0000
Blanco_Atlántico	Mitjana	0.0009	0.9989	0.0002
Vino_Picado	Baixa	0.9992	0.0008	0.0000
Balance_Top	Alta	0.0000	0.3495	0.6505

L'anàlisi de les distribucions de probabilitat posteriors (*posterior distributions*) ens permet extreure conclusions i resultats estadístics o enològics crucials:

1. **Efecte d'alta determinació (Overconfidence):** En general veiem que el nostre model confia amb força en les seves prediccions, és a dir que per a les classes guanyadores els hi otorga una probabilitat molt alta, en molts casos superior del 99%. Crida l'atenció que per a un perfil concret (*Pescadito*) trobem que el model otorga una probabilitat de 1 a que pertanyi a la classe *Mitjana*. Aquesta certesa absoluta, podria semblar un error al codi, però realment no té perquè. Hem de recordar que és un comportament esperable tenint en compte que al aplicar una discretització tant fina que divideix les variables en 17 intervals diferents, la possibilitat que existeixi una combinació d'intervals que quedi absolutament aïllada és possible (presència nul·la de vins que formen part de la classe alta o baixa).
2. **Robustesa dels perfils de control:** Ambdós perfils que hem creat que no s'ajusten a perfils reals, sinó que son combinacions de vins que hem considerat com al vi ideal i la seva contrapartida, han estat classificats de forma esperada.
3. **Tendència prior:** Amb una mostra nova tant reduïda com aquesta ja podem comprovar la forta influència que exerceix el desbalanceig de la mostra inicial, ja que provoca que el model tendeixi a predir com a qualitat més probable la *Mitjana*. De fet si no contem els casos que hem creat específicament per mirar de caure als extrems, tots els casos nous menys el cas del *Chardonnay*, el model prediu que la classe més probable es la *Mitjana*.
4. **Variables clau inferides:** Mitjançant l'aplicació de funcions tipus `arc.strength` per mesurar la força i la penalització teòrica de la informació en les dependències de la xarxa, el model revela quins components determinen directament la decisió final de la classe. El graf construït (Figura 3) assenyalava empíricament la densitat, l'acidesa volàtil i l'àcid cítric com els principals eixos vertebradors estadístics que influeixen sobre els tastadors en puntuar el vi.

6 Conclusions

- **Selecció del model:** L'estructura Tree-Augmented Naive Bayes (TAN) combinada amb una discretització de 17 intervals s'ha consolidat com el model més precís i estadísticament significatiu. Aquesta configuració permet capturar eficaçment les complexitats i interaccions químiques subjacents que determinen la qualitat del vi.
- **Limitacions detectades (Biaix de classes):** El conjunt de dades original presenta una forta concentració de mostres en les qualitats mitjanes. Aquest desbalanceig representa la limitació més crítica de l'estudi, ja que indueix un biaix en l'aprenentatge del model, reduint la seva sensibilitat i capacitat per classificar correctament els vins situats als extrems (qualitats baixes i altes).
- **Ajust de llindars:** En un intent per mitigar els efectes del desbalanceig de classes, s'han dut a terme proves fixant llindars de decisió específics per a cada categoria. Malgrat això, aquesta modificació post-processament no ha aportat millores significatives en el rendiment global ni en les mètriques d'avaluació del model.
- **Possibles millores:** Per tal de dotar el model d'una major robustesa predictiva en futures iteracions, es proposa l'aplicació de tècniques de generació de dades sintètiques com SMO-TE o estratègies d'oversampling per equilibrar les classes minoritàries. Addicionalment, seria recomanable explorar i comparar el rendiment d'aquests resultats amb altres models de classificació.

Ús d'Intel·ligència Artificial

Per a la realització d'aquest treball, s'ha utilitzat l'eina Gemini exclusivament en tasques de suport acadèmic permeses per la normativa de l'assignatura. Concretament, s'ha emprat per a la correcció ortogràfica, el suport en l'estructuració de fragments de codi en R, la formatació del document final en format LaTeX, i com a eina de cerca d'informació per obtenir els valors realistes de les covariables fisicoquímiques en el disseny dels perfils sintètics de nous vins.

L'ús d'aquesta tecnologia ha facilitat la depuració tècnica, la cerca de referències i la redacció formal, però en cap cas ha pres decisions analítiques.

Referències

- [1] Cortez, P., Cerdeira, A., Almeida, F., Matos, T., & Reis, J. (2009). *Wine Quality* [Dataset]. UCI Machine Learning Repository. Disponible a: <https://doi.org/10.24432/C56S3T>
- [2] Scutari, M. (2014). *bnlearn: Bayesian network structure learning, parameter learning and inference* (Versió 3.6) [Manual de paquet d'R]. Disponible a: <http://www.bnlearn.com/>
- [3] Højsgaard, S. (2015). *Package 'gRain': Graphical Independence Networks* (Versió 1.2-4) [Manual de paquet d'R]. Disponible a: <http://people.math.aau.dk/~sorenh/software/gR/>