

Modelització de Dades Complexes
Grau en Estadística Aplicada (GEA) UAB
PAC1: treball amb R en grup

Llegiu detingudament aquest document

DESCRIPCIÓ

El treball, **EN GRUPS DE TRES ALUMNES**, consistirà en:

1. Agafar una base de dades adient per a fer classificació, d'un repositori de bases de dades per a machine learning com ara el repositori UCI, que en té més de 600 bases diferents:

<https://archive.ics.uci.edu/datasets>

triant “Task: Classification”,

o el repositori Kaggle, amb més de 3000 per a fer classificació:

<https://www.kaggle.com/datasets>

IMPORTANT: La base de dades ha de tenir com a màxim 15 000 casos i 50 variables. Per a excepcions, parleu amb mi primer.

2. Fer un document explicatiu de la base de dades i de quina tasca de classificació es preten fer amb ella.
3. Elaborar un script d'R (**fitxer .R**) que

- a) Carregui la base de dades i faci el “preprocessing” (neteja de valors incorrectes, recodificacions, discretització de variables contínues, selecció de variables,...).
Prepari la base de dades per a construir un classificador Bayesià (conventint els NAs en una nova categoria, per exemple “Desconegut” si cal).

- b) Aprengui un classificador bayesià, que serà una xarxa Bayesiana, a partir del paquet d'R **bnlearn** i la **validi**. Haureu de considerar al menys dos classificadors diferents, com per exemple un **Naive Bayes**, i un **Augmented Naive**. Els classificadors s'han de **validar** (fent servir **k-fold cross-validation**) i **comparar** fent servir els tests d'hipòtesis estadístiques adients.

Per a fer les prediccions dels valors de la variable classe per als casos dels conjunts de validació, passeu prèviament la xarxa Bayesiana construïda amb el paquet **bnlearn** a partir dels conjunts d'entrenament, a format **gRain**.

Com a mesura bàsica de comportament dels classificadors en el procés de validació i comparació entre ells, es farà servir l'*accuracy*, però es valorarà positivament el càlcul d'altres mesures (precisió, sensibilitat, F-score, ... depenent de si la classificació és binària, multi-classe o bé ordinal). Haureu d'escollir entre els classificadors que hagueu considerat a partir de la validació.

- c) Un cop validat el model (i escollit d'entre els possibles el “millor” en algun sentit), aprengui el classificador bayesià final a partir de tota la base de dades, per a fer la predicció de la classe de nous casos i predigui la classe d'alguns casos que us semblin interessants, a partir de les seves característiques o *features*.

IMPORTANT: Es penalitzarà carregar paquets (llibreries) de R si no s'indica en un comentari a l'script per a què es fa servir (quines funcions del paquet s'utilitzen). **No es permet l'ús de les funcions `confusionMatrix` i `createFolds` del paquet `caret`, per exemple, o funcions similars, ni fer servir la llibreria `tidyverse`.**

4. Presentar un fitxer .zip amb la **base de dades**, el **document explicatiu de la base de dades**, l'script de R, i un **informe amb els resultats**:
- Del *preprocessing* de la base de dades.
 - Del procés de validació del model (i comparativa entre els models considerats).
 - De la construcció del model final per a fer prediccions i de les prediccions pels casos que trieu com a més representatius o interessants.

AVALUACIÓ

L'avaluació d'aquesta tasca tindrà en compte diferents aspectes, tots i cadascun d'ells indispensables per a que la prova puntui:

- i) A les classes de pràctiques que s'indicaran, dedicarem una part de la classe a comentar amb tots els grups els avenços que aneu fent setmana a setmana, i les dificultats amb què us aneu trobant. La participació pro-activa en aquestes sessions de tots els membres del grup serà tinguda en compte per a l'avaluació del PAC1.
- ii) També s'avaluarà el fitxer .zip esmentat anteriorment, que s'haurà d'entregar dins el plaç que es determini, a través del campus virtual.
- iii) Finalment, cada grup haurà de fer una petita exposició de **15 minuts** davant de la resta de companys i de la professora, tot explicant de manera resumida el més destacat del seu treball.

En aquesta exposició hauran de participar **tots** els membres de cada grup en l'explicació del seu treball, i hauran de contestar les preguntes que la professora els formuli.

IMPORTANT: Per a tenir nota del treball, heu d'estar (i participar) a la presentació del vostre grup, i també a les presentacions de la resta de grups. Llevat de causa justificada degudament, l'absència en alguna de les sessions de presentacions dels treballs comporta no tenir nota del PAC1.

DATES IMPORTANTS

- **Dimecres 4 de març de 2026, 23:59 hores.**

Data límit per a haver-me enviat un correu a Rosario.Delgado@uab.cat, un dels membres del grup, dient quins seran els seus components, que han de ser tres.

- **Dimecres 25 de març de 2026, de 15:00 a 17:00 hores.**

Comencen les sessions de pràctiques en què treballarem el PAC1 i cada grup hauria de tenir, abans de començar la classe, una base de dades triada per a fer el seu treball (i alguna de reserva per si de cas).

Comentarem totes les bases de dades a classe i descartarem les que no siguin adequades.

A partir d'aquest moment, ja podreu començar a fer el treball.

- **Resta de sessions de pràctiques:**

Les sessions de pràctiques amb ordinador (treball en grup amb R) seran en horari de 17:00 a 19:00 hores els dilluns següents de 2026:

20-abril

27-abril

4-maig

11-maig.

- **Presentacions de treballs a l'aula:**

Les presentacions dels treballs es faran al llarg dels dies

18-maig de 2026, de 17:00 a 19:00 hores

20-maig de 2026, de 15:00 a 17:00 hores.

- **Divendres 5 de juny de 2026, 23:59 hores.**

Data límit per a entregar el fitxer .zip a través d'una tasca del campus virtual.

Sempre que no es pugui justificar degudament, l'incompliment de plaços d'entrega i/o la no assistència a les sessions de pràctiques, que són d'assistència obligada, tindran una penalització a la nota del PAC1 que podria arribar al 100% de la nota.

ÚS DE L'IA: Per a aquesta assignatura, es permet l'ús de tecnologies d'Intel·ligència Artificial (IA) exclusivament en tasques de suport, com la cerca bibliogràfica o d'informació, la correcció de textos o les traduccions. L'estudiant haurà d'identificar clarament quines parts del seu treball (PAC1) han estat generades amb aquesta tecnologia, especificar les eines emprades i incloure una reflexió crítica sobre com aquestes han influït en el procés i el resultat final de l'activitat. La no transparència de l'ús de la IA en aquesta activitat avaluable es considerarà falta d'honestedat acadèmica i pot comportar una penalització parcial o total en la nota de l'activitat, o sancions majors en casos de gravetat.