

MODELITZACIÓ DE DADES COMPLEXES

WINE QUALITY

Anàlisi de Classificadors Bayesians aplicats a la qualitat del vi blanc "Vinho Verde"

Iker Fernández
(1704341)

Carlos Torras
(1703430)

Enola Garcia
(1708253)

| Índex de Continguts

01

Introducció i Dataset

Origen de les dades del repositori UCI i exploració inicial.

02

Discretització de Dades

Mètode Hartemink i comparativa de configuracions.

03

Classificadors

Avaluació dels models

04

Validació i Resultats

Comparació dels models

05

Predicció noves dades

Avaluació del model final per nous conjunts de dades

| El Dataset: Vinho Verde



Origen UCI

Base de dades del repositori UCI
Machine Learning amb 4.899
mostres de vi blanc.



11 Predictors


Variables fisicoquímiques: Acidesa,
àcid cítric, sucre, clorurs, diòxid de
sofre, pH, sulfats, Alcohol, etc.



Variable Classe

Qualitat sensorial puntuada de 0 a
10, agrupada en tres nivells
ordinals.

| Variable Classe: Qualitat



- Baixa [3, 4, 5]:33.5% (1.640 casos)
- Mitjana [6]:44.9% (2.198 casos)
- Alta [7, 8, 9]:21.6% (1.060 casos)

| Discretització

Hem comparat dues configuracions del mètode Hartemink:



Opció 1: Estàndard

breaks=6, ibreaks=60


- ✓ Interpretació més senzilla.
- ✓ Molt baix cost computacional.
- ✗ Menor resolució en variables amb biaix.














Opció 2: Alta Resolució

breaks=20, ibreaks=200


- ★ Millor rendiment predictiu.
- ✓ Captura matissos subtils.
- ✓ Més cost computacional pero assumible



**Dades NO
discretitzades**



breaks=6



| Models de Classificació



Naive Bayes

Estructura de control. Assumeix independència absoluta dels atributs donada la classe. Robust però teòricament limitat.




Tree Augmented Naive (TAN)

Estructura avançada. Relaxa la hipòtesi d'independència creant un arbre de dependències entre els predictors.


| Arquitectura: Naïve Bayes

Implementat amb `naive.bayes()` de bnlearn:



| Tree-Augmented Naive Bayes

Implementat amb `tree.bayes()` de bnlearn:



Comparativa de Rendiment per decidir la discretització final

Mètrica	Naive Bayes (6 breaks)	Naive Bayes (20 breaks)	Guany	P-value Normalitat	P-value
Accuracy	0.5302	0.5427	+0.0125 +1.25%	0.03880151	0.008737536
F1-Score (Macro)	0.5304	0.5431	+0.0127 +1.27%	0.126246	0.011480199
MCC	0.2891	0.3073	+0.0182 +1.82%	0.4968791	0.014949204

Comparativa de Rendiment per decidir la discretització final

Mètrica	TAN (6 breaks)	TAN (20 breaks)	Guany	P-value Normalitat	P-value
Accuracy	0.5807	0.6315	+0.0508 +5.08%	0.03267338	0.002929688
F1-Score (Macro)	0.5831	0.6249	+0.0418 +4.18%	0.003131208	0.002929688
MCC	0.3525	0.4169	+0.0644 +6.44%	0.01865351	0.002929688

Perquè coincideixen els pvalors?

En comparar 20 vs 6 breaks, el model superior guanya en **10 de 10 folds**.

La probabilitat que això passi per pur atzar és:

$$P(X = 10) = \left(\frac{1}{2}\right)^{10} = 0.000976 \longrightarrow p_{\text{adj}} = 3 \times 0.000976 = 0.00293$$

| Discretització

Hem comparat dues configuracions del mètode Hartemink:



Opció 1: Estàndard

breaks=6, ibreaks=60

- ✓ Interpretació més senzilla.
- ✓ Molt baix cost computacional.
- ✗ Menor resolució en variables amb biaix.

SELECCIONAT



Opció 2: Alta Resolució

breaks=20, ibreaks=200

- ★ Millor rendiment predictiu.
- ✓ Captura matissos subtils.
- ✓ Més cost computacional pero assumible

Resultat: La configuració 20/200 redueix la pèrdua d'informació i permet xarxes més precises.

Comparativa de Rendiment per decidir el model final

Mètrica	NB (20 breaks)	TAN (20 breaks)	Guany	P-value Normalitat	P-value
Accuracy	0.5427	0.6315	0.0888 +8.88%	0.6940936	2.830364e-06
F1-Score (Macro)	0.5431	0.6249	+0.0818 +8.18%	0.2879725	7.428279-06
MCC	0.3073	0.4169	+0.1096 +10.96%	0.6252734	1.689616e-05

| Significació Estadística

P-value
< 0.05

P-value (Paired T-Test) = 0.0000009434546

Conclusions Sòlides

L'anàlisi de les diferències d'accuracy entre els 10 folds ens permet concloure:


- ✓ L'estructura Augmented millora realment la capacitat de predicció.

Hipòtesi Nul·la (H_0):

$$H_0: \mu_{TAN20} \leq \mu_{NB20}$$


Tree-Augmented Naive Bayes amb totes les dades i 20 breaks (Model final)

Implementat amb `tree.bayes()` de bnlearn:



Influències del Model: Determinants de Qualitat

Amb la funció `arc.strength()` s'han obtingut les dependències entre les variables al model:



Influències del Model: Determinants de Qualitat

Qualitat

```
graph TD; Qualitat[Qualitat] --> Densitat[1. Densitat]; Qualitat --> Acidesa[2. Acidesa volàtil]; Qualitat --> Acid[3. Àcid cítric];
```

1. Densitat

Valor d'influència

p-valor: 1.59e-123

2. Acidesa volàtil

Valor d'influència

p-valor: 7.12e-85

3. Àcid cítric

Valor d'influència

p-valor: 7.05e-67

| Aplicació: Nous Casos

Verdejo Jove

Sec, fresc, amb acidesa equilibrada i graduació alcohòlica moderada.

Estil Pescaito

Lleuger, suau, amb poc alcohol i subtil duresa agradable.

Chardonnay Criança

Amb cos, madur, baixa acidesa i alta graduació alcohòlica.

Blanc Semidolç

Golós, amb molt de sucre residual i poc alcohol.

Blanc Atlàntic

Perfil molt fresc, amb acidesa elèctrica, pH baix i toc salí.

Ví Picat

Totalment defectuós, oxidat, descompensat i amb olor de vinagre.

Balanç Ideal

Combinació perfecta de paràmetres òptims que maximitza la qualitat.

Resultats de les prediccions amb els nous casos

Resultats obtinguts en introduir els **7 perfils sintètics** com a evidència a la xarxa **Tree-Augmented Naive (TAN)**:

Perfil del Vi	Descripció Química Clau	Predicció Qualitat	Prob baixa	Prob mitjana	Prob alta
Verdejo Jove	Alcohol 12.5% Sucre 1.5 (Sec) Acidesa equilibrada	MITJANA	0.027	0.9399	0.0330
Estilo Pescadito	Alcohol 9.5% Sucre 6.0 Vi lleuger i suau	MITJANA	0.00	1.00	0.00
Chardonnay Criança	Alcohol 13.5% Baixa acidesa fixa Vi amb cos	ALTA	0.00	0.0420	0.9580
Blanco Semidulce	Sucre 16.5 (Molt alt) Alcohol 10.0% Densitat 0.999	BAIXA	0.4553	0.5447	0.00
Blanco Atlántico	pH 2.98 (Àcid) Clorurs alts Perfil salí i fresc	MITJANA	0.1626	0.7044	0.1330
Vino Picado	Volàtil 1.10 (Vinagre) pH 3.82 Sense sulfits	BAIXA	0.9840	0.0160	0.00
Balance Top	Combinació perfecta de paràmetres òptims del dataset	ALTA	0.0020	0.2416	0.7564

| Conclusions i possibles millores

Model Seleccionat

El model TAN amb 20 breaks és el més precís i estadísticament significatiu.



Limitació Crítica

Qualitat desbalancejada: El dataset presenta una forta concentració en qualitats mitjanes.



Ajust de Llindars de Decisió

Intents de fixar llindars per classe, però **sense millores** significatives.



Millores Futures

- SMOTE / Oversampling
- Altres models de classificació



Preguntes?

Moltes gràcies per la vostra atenció.



Vinho Verde Project



bnlearn + gRain