

Tema 1

Introducció a les xarxes Bayesianes

Bloc A) Introducció a l'assignatura

Bloc B) Conceptes preliminars i definicions bàsiques

Bloc C) Inferència amb XBs

Bloc D) Aprenentatge de XBs: paràmetres


Bloc E) Aprenentatge de XBs: estructura

Tema 1. Bloc B)

Conceptes preliminars i definicions bàsiques

- 1.1 Un exemple introductori
- 1.2 Independència Condicional
- 1.3 La Condició de Markov
- 1.4 Definició de Xarxa Bayesiana
- 1.5 El “Markov Blanket” i la “d-separació”
- 1.6 Prognosi i Diagnosi: el Naive Bayes

Coronavirus (COVID-19)



Existeixen diferents tipus de tests comercialitzats per al diagnòstic de la malaltia COVID-19, provocada pel virus SARS-CoV-2:

- De detecció d'antígens,
- De detecció d'anticossos,
- De detecció d'ARN

PANBIO™ COVID-19 IgG/IgM RAPID TEST DEVICE

SCALE UP COVID-19 ANTIBODY TESTING

An *in vitro* diagnostic rapid test for the qualitative detection of IgG and IgM antibodies to SARS-CoV-2 in human serum, plasma, venous and fingerstick whole blood.

Intended to be used as an aid in the diagnosis of SARS-CoV-2 infection. The product may be used in any laboratory and non-laboratory environment that meets the requirements specified in the Instructions for Use and local regulation. The test provides preliminary test results. Negative results will not preclude SARS-CoV-2 infection, and they cannot be used as the sole basis for treatment or other management decisions. The test is not intended to be used as a donor screening test for SARS-CoV-2.

For professional use only. Product not available in all countries.

Please check with your local sales representative regarding availability in your area.



*Cassette design may vary

- Antibody tests are important to confirm that an infection has occurred.
- Quickly scale up COVID-19 coronavirus testing.
- Make testing more widely available.
- Decentralized testing can help to alleviate overcrowding in hospitals.
- Time to result: 10 - 20 minutes.
- Simple fingerstick blood sample.

RELATED LINKS

[Panbio COVID-T402 Product S](#)

[Panbio COVID-T402 Product Q](#)

[Panbio COVID-T402 Product Q](#)

PANBIO™ COVID-19 IgG/IgM RAPID TEST DEVICE



OVERVIEW

BENEFITS

HELPFUL DOCUMENTS

RELATED PRODUCTS

- ✓ **Fingerstick Whole Blood**
 - Sensitivity: 96.2%
 - Specificity: 100.0%
- ✓ **Venous Whole Blood***
 - Sensitivity: 96.0%
 - Specificity: 95.8%
 - *EDTA, heparin or sodium citrate can be used as anticoagulants
- ✓ **Plasma* / Serum****
 - Sensitivity: 97.8%
 - Specificity: 92.8%
 - *EDTA, heparin or sodium citrate can be used as anticoagulants
 - **Based on matrix equivalency studies

ELISA (de l'anglès, Enzyme-Linked ImmunoSorbent Assay) és una tècnica bioquímica que es basa en marcar els antígens/anticossos amb un enzim i afegir un substrat específic que, en interaccionar amb l'enzim, produirà un color visible a simple vista i quantificable mitjançant l'ús d'un espectrofotòmetre o un colorímetre, detectant la presència de l'antigen/anticòs i quantificant-la.

1.1 Un exemple introductori

Test 1: Venous Whole Blood test (de sang sencera venosa)

✓ **true positive rate** (*sensitivity*)

$$P(\text{ELISA} = + / \text{anticossos} = \text{sí}) = 0.960$$

✓ **true negative rate** (*specificity*)

$$P(\text{ELISA} = - / \text{anticossos} = \text{no}) = 0.958$$

Test 2: Plasma/Serum test (de plasma/serum)

✓ **true positive rate** (*sensitivity*)

$$P(\text{ELISA} = + / \text{anticossos} = \text{sí}) = 0.978$$

✓ **true negative rate** (*specificity*)

$$P(\text{ELISA} = - / \text{anticossos} = \text{no}) = 0.928$$

Quin dels dos tests és millor?

1.1 Un exemple introductori

Si a la població la prevalença de persones amb anticossos és $P(\text{anticossos} = \text{sí}) = 0.05$ (5%), vol dir que “a priori”, el risc que té qualsevol individu de la població de tenir anticossos és 5%.

Per a comparar els dos tests, calcularem el risc “a posteriori” de tenir anticossos per a un individu de la població qualsevol, donada l’evidència que el test li ha donat positiu:

$$P(\text{anticossos} = \text{sí} / \text{ELISA} = +) = ?$$

Calcularem aquesta probabilitat fent servir la **Fórmula de Bayes**:

$$P(\text{anticossos} = \text{sí} / \text{ELISA} = +) = \frac{P(\text{ELISA} = + / \text{anticossos} = \text{sí}) P(\text{anticossos} = \text{sí})}{P(\text{ELISA} = +)}$$

Per a calcular la probabilitat del denominador, farem servir la

Fórmula de la Probabilitat Total:

1.1 Un exemple introductori

$$P(\text{ELISA} = +) = P(\text{ELISA} = + / \text{anticossos} = \text{sí}) P(\text{anticossos} = \text{sí}) \\ + P(\text{ELISA} = + / \text{anticossos} = \text{no}) P(\text{anticossos} = \text{no})$$

Amb el test 1: Venous Whole Blood test:

sensitivity = 0.960, specificity = 0.958

$$P(\text{ELISA} = +) = P(\text{ELISA} = + / \text{anticossos} = \text{sí}) P(\text{anticossos} = \text{sí}) \\ + P(\text{ELISA} = + / \text{anticossos} = \text{no}) P(\text{anticossos} = \text{no}) \\ = 0.960 \times 0.05 + (1 - 0.958) \times (1 - 0.05) = 0.0879$$

I per la Fórmula de Bayes:

$$P(\text{anticossos} = \text{sí} / \text{ELISA} = +) = \frac{P(\text{ELISA} = + / \text{anticossos} = \text{sí}) P(\text{anticossos} = \text{sí})}{P(\text{ELISA} = +)} \\ = \frac{0.960 \times 0.05}{0.0879} = 0.54608$$

És a dir, que aproximadament 55 persones de cada 100 que han donat positiu en el test de sang sencera venosa, tenen anticossos (és el **Valor Predictiu Positiu** del test), i no només depèn de les característiques del test (sensibilitat i especificitat), sinó també de la prevalença a la població $P(\text{anticossos} = \text{sí}) = 0.05$ (5%).

1.1 Un exemple introductori

$$P(\text{ELISA} = +) = P(\text{ELISA} = + / \text{anticossos} = \text{sí}) P(\text{anticossos} = \text{sí}) \\ + P(\text{ELISA} = + / \text{anticossos} = \text{no}) P(\text{anticossos} = \text{no})$$

Amb el test 2: Plasma/serum test:

sensitivity = 0.978, specificity = 0.928

$$P(\text{ELISA} = +) = P(\text{ELISA} = + / \text{anticossos} = \text{sí}) P(\text{anticossos} = \text{sí}) \\ + P(\text{ELISA} = + / \text{anticossos} = \text{no}) P(\text{anticossos} = \text{no}) \\ = 0.978 \times 0.05 + (1 - 0.928) \times (1 - 0.05) = 0.1173$$

I per la Fórmula de Bayes:

$$P(\text{anticossos} = \text{sí} / \text{ELISA} = +) = \frac{P(\text{ELISA} = + / \text{anticossos} = \text{sí}) P(\text{anticossos} = \text{sí})}{P(\text{ELISA} = +)} \\ = \frac{0.978 \times 0.05}{0.1173} = 0.4169$$

És a dir, que aproximadament 42 persones de cada 100 que han donat positiu en el test de plasma/sèrum, tenen anticossos (Valor Predictiu Positiu del test).

El VPP del test de plasma/sèrum per a aquesta població és menor que el del test de sang sencera venosa i, per tant, és millor aquest últim!!

1.1 Un exemple introductori

Encara que no ens ha calgut per a portar a terme els càlculs, podríem haver fet servir el següent model probabilístic per a representar les relacions entre les dues variables que afecten el fenomen de la detecció d'anticossos: el resultat del test (ELISA) i tenir o no anticossos. És una **xarxa Bayesiana amb dos nodes**.



$$P(\text{anticossos} = \text{sí}) = 0.05$$

$$P(\text{ELISA} = +/\text{anticossos} = \text{sí}) = 0.96$$

$$P(\text{anticossos} = \text{no}) = 0.95$$

$$P(\text{ELISA} = -/\text{anticossos} = \text{sí}) = 0.04$$

(probabilitats **a priori**)

$$P(\text{ELISA} = +/\text{anticossos} = \text{no}) = 0.042$$

$$P(\text{ELISA} = -/\text{anticossos} = \text{no}) = 0.958$$

(probabilitats **condicionades**)

A partir de les probabilitats a priori (la distribució del node/variable “anticossos”, i de les probabilitats condicionades del node/variable “ELISA” a “anticossos”, hem calculat les probabilitats a posteriori fent servir la Fórmula de Bayes:

$$P(\text{anticossos} = \text{sí}/\text{ELISA} = +) = 0.54608$$

1.2 Independència Condicional

Sigui $(\Omega, \mathcal{A}, P)$ un espai de probabilitat.

Siguin **A**, **B** i **C** conjunts de variables aleatòries discretes sobre aquest espai de probabilitat.

Definició: Es diu que **A** i **B** són **condicionalment independents donat el conjunt C** si per a qualssevol variables A, B i C , a **A**, **B** i **C**, respectivament, i per a qualssevol valors dels suports d'aquestes variables, diguem a, b i c , sempre que $P(C = c) \neq 0$ es compleix que els esdeveniments $A = a$ i $B = b$ són independents condicionats a l'esdeveniment $C = c$. És a dir:

$$P(A = a, B = b / C = c) = P(A = a / C = c) P(B = b / C = c)$$

Equivalentment:

$$P(A = a / B = b, C = c) = P(A = a / C = c) \text{ si } P(B = b, C = c) \neq 0$$

Notació:

$$I_P(A, B / C)$$

Conèixer el valor de la variable C ens diu tot el que necessitem sobre A , de manera que conèixer B no ens fa guanyar res, ja sigui perquè B no té cap influència sobre A , o perquè coneixent C , B ja no pot aportar cap informació rellevant sobre A .

1.2 Independència Condicional

Un exemple:



Llencem dos daus perfectes, un de color blau i un de color vermell. Naturalment, els resultats dels dos daus són independents entre sí.

Considerem les variables aleatòries (sobre l'espai de probabilitat associat al llançament dels dos daus, amb 36 casos possibles simètrics). És a dir, si

A="resultat del dau blau", **B**="resultat del dau vermell".

Aleshores, les variables **A** i **B** són independents.

Sigui **C**="la suma de resultats dels dos daus".

Ens preguntem:

Continuen sent **A** i **B** independents, si condicionem a **C**?

si agafem $a = 1$, $b = 3$, $c = 4$, tenim que:

$$P(A = a / B = b, C = c) = P(A = 1 / B = 3, C = 4) = 1$$

$$P(A = a / C = c) = P(A = 1 / C = 4) = P(B = 3) = 1/6 \neq 1$$

I, per tant, encara que **A** i **B** són independents,
NO són condicionalment independents, donada **C**.


1.3 La Condició de Markov

Definicions

Un **graf dirigit** és un (V, E) , amb V un conjunt finit d'elements anomenats **nodes**, i E és un conjunt de parells ordenats d'elements de V , anomenats **arcs dirigits** o **fletxes**.

Exemple: $V=\{A,B,C,D\}$, $E=\{(A,B), (B,C), (B,D)\}$

Suposició: hi ha com a molt un arc ordenat entre dos nodes.



Un **camí** del node X a l' Y és un conjunt de fletxes que els connecten.

Exemple: un camí de A a D és $\{(A,B), (B,D)\}$.


1.3 La Condició de Markov

Definicions

Un **graf dirigit** és un (V, E) , amb V un conjunt finit d'elements anomenats **nodes**, i E és un conjunt de parells ordenats d'elements de V , anomenats **arcs dirigits** o **fletxes**.

Exemple: $V=\{A,B,C,D\}$, $E=\{(A,B), (B,C), (B,D)\}$


Suposició: hi ha com a molt un arc ordenat entre dos nodes.



Un **camí** del node X a l' Y és un conjunt de fletxes que els connecten.

Exemple: un camí de A a D és $\{(A,B), (B,D)\}$.

Un **cicle dirigit** és un camí d'un node a ell mateix. Un graf dirigit (V,E) es diu **acíclic** (**directed acyclic graph, DAG**) si no conté cicles.




1.3 La Condició de Markov

Definicions

Un **graf dirigit** és un (V, E) , amb V un conjunt finit d'elements anomenats **nodes**, i E és un conjunt de parells ordenats d'elements de V , anomenats **arcs dirigits** o **fletxes**.

Exemple: $V=\{A,B,C,D\}$, $E=\{(A,B), (B,C), (B,D)\}$

Suposició: hi ha com a molt un arc ordenat entre dos nodes.



Un **camí** del node X a l' Y és un conjunt de fletxes que els connecten.

Exemple: un camí de A a D és $\{(A,B), (B,D)\}$.

Un **cicle dirigit** és un camí d'un node a ell mateix. Un graf dirigit (V,E) es diu **acíclic** (**directed acyclic graph, DAG**) si no conté cicles.

A un DAG, el node X és un **“pare”** del node Y si hi ha una fletxa de X a Y . I es diu que Y és un **“fill”** of X . Si hi ha un camí de X a Y , X és un **“ancestre”** de Y , i Y un **“descendent”** de X .

A és un node **“arrel”**, ja que no té pares. C i D són **“fulles”** perquè no tenen fills. B és un **“intermedi”** (ni arrel ni fulla).

Definició

Sigui $\Gamma = (\mathbf{V}, \mathbf{E})$ un **graf dirigit (DAG)**, amb $\mathbf{V}$ un conjunt finit de variables aleatòries (discretes) sobre el mateix espai de probabilitat $(\Omega, \mathcal{A}, P)$, representades per **nodes**, i $\mathbf{E}$ un conjunt d'**arcs dirigits** o **fletxes** entre les variables aleatòries.

Aleshores, diem que la parella (Γ, P) satisfà la **Condició de Markov** si per a cada $X \in \mathbf{V}$, $\{X\}$ és independent del conjunt dels nodes que no són descendents seus, que denotem per $ND(X)$, condicionalment al conjunt dels seus pares, que denotem per $PA(X)$.

Això s'expressa: $I_P(\{X\}, ND(X) / PA(X))$


i tenint en compte que els pares estan inclosos en els no-descendents,

equivalentment: $I_P(\{X\}, ND(X) \setminus PA(X) / PA(X))$

Si X és un node arrel, aleshores $PA(X) = \emptyset$ i la **Condició de Markov** diu, simplement, que $\{X\}$ sigui independent de $ND(X)$, sense condicionar.

1.3 La Condició de Markov

Exemple:




Les variables del DAG estan definides al mateix espai de probabilitat $(\Omega, \mathcal{A}, P)$. La parella formada per aquest DAG i per la probabilitat P compleix la **Condició de Markov** si per a cadascun dels nodes (variables) es compleix el següent: és independent dels seus no-descendents (que no són pares seus), condicionalment als seus pares.

Per exemple, pel node X , la **Condició de Markov** ens diu que X és independent de ND_1 i ND_2 , condicionalment als pares $\{P_1, P_2\}$.

1.3 La Condició de Markov

Un altre exemple:




$V = \{X, Y, Z, W, V\}$,
 $E = \{(X, Y), (X, Z), (Y, W), (Z, W), (Z, V)\}$
 $\Gamma = (V, E)$ és un DAG

Una probabilitat P amb aquest DAG compleix la **Condició de Markov** si per a cada node del DAG es compleix el següent:

Node	Pares del node	No-descendents	Independència condicional
X	Conjunt buit	Conjunt buit	(cap condició)
Y	X	Z, V	Y i {Z, V} són independents, condicionant a X
Z	X	Y	Z i Y són independents, condicionant a X
W	Y, Z	X, V	W i {X, V} són independents, condicionant a {Y, Z}
V	Z	X, Y, W	V i {X, Y, W} són independents, condicionant a Z

1.3 La Condició de Markov

Com a exemple final, considerem que $V=\{A, B, C\}$, i tenim 3 DAGs que verifiquen la **Condició de Markov** amb probabilitats respectives P_1, P_2, P_3 .



v-estructura:


A i B no són independents condicionant a C

$$\cancel{I_{P_1}(A, B / C)}$$

(es diu que C és un “**collider**” de A i B, ja que ve influenciada per les dues)

1.3 La Condició de Markov

Com a exemple final, considerem que $V=\{A, B, C\}$, i tenim 3 DAGs que verifiquen la **Condició de Markov** amb probabilitats respectives P_1, P_2, P_3 .




v-estructura:


A i B no són independents condicionant a C

$$\cancel{I_{P_1}(A, B / C)}$$

(es diu que C és un “**collider**” de A i B, ja que ve influenciada per les dues)



Aquests dos DAGs, que NO són v-estructura, porten a que A i B sí són independents condicionant a C!




$$I_{P_2}(A, B / C)$$

$$I_{P_3}(A, B / C)$$

1.3 La Condició de Markov

Com a exemple final, considerem que $V=\{A, B, C\}$, i tenim 3 DAGs que verifiquen la **Condició de Markov** amb probabilitats respectives P_1, P_2, P_3 .




v-estructura:

A i B no són independents condicionant a C

$$\cancel{I_{P_1}(A, B / C)}$$


(es diu que C és un “**collider**” de A i B, ja que ve influenciada per les dues)



Aquests dos DAGs, que NO són v-estructura, porten a que A i B sí són independents condicionant a C!

$$I_{P_2}(A, B / C)$$

$$I_{P_3}(A, B / C)$$



Si estudiem si A influencia B, per exemple, C seria un “**confounder**” ja que influencia tant A com B, causant una relació (associació) espúria entre elles.

Teorema 1: (Theorem 1.4, Neapolitan, 2004)

Sigui $\Gamma = (\mathbf{V}, \mathbf{E})$ un **graf dirigit (DAG)**, amb $\mathbf{V}$ un conjunt finit de variables aleatòries (discretes) sobre el mateix espai de probabilitat $(\Omega, \mathcal{A}, P)$. Suposem que $\mathbf{V} = \{X_1, \dots, X_n\}$, i denotem per $S(X_i)$ el suport de la variable X_i , $i = 1, \dots, n$.

Si la parella (Γ, P) compleix la **Condició de Markov**, aleshores la funció de probabilitat del vector aleatori $(X_1, \dots, X_n)$ coincideix el producte de les probabilitats de cada node condicionades als seus pares, sempre que aquestes probabilitats tinguin sentit.

Formalment, si $x_i \in S(X_i)$, $i = 1, \dots, n$, tenim que

$$P(X_1 = x_1, \dots, X_n = x_n) = \prod_{i=1}^n P(X_i = x_i / PA(X_i))$$


on la notació $P(X_i = x_i / PA(X_i))$ fa referència a la probabilitat que la variable X_i prengui el valor $x_i \in S(X_i)$, condicionat pels valors que prenen les variables que siguin els seus pares en el DAG a l'esdeveniment $\{X_1 = x_1, \dots, X_n = x_n\}$.

1.3 La Condició de Markov

$$P(X_1 = x_1, \dots, X_n = x_n) = \prod_{i=1}^n P(X_i = x_i / PA(X_i))$$

Aquesta expressió s'anomena "Regla de la Cadena".

Idea: El que ens diu el Teorema 1 és que si tenim una parella formada per un DAG Γ , y la probabilitat P de l'espai de probabilitat en el que estan definides les variables del DAG, aleshores,



1.3 La Condició de Markov

Exemple: Tenim N atletes que poden, o no, estar dopats. Considerem l'espai de probabilitat: $(\Omega = \{\text{atletes}\}, \mathcal{A} = \mathcal{P}(\Omega), P)$ on P correspon a la distribució uniforme discreta (assigna probabilitat $1/N$ a cada atleta). Definim les variables:

X_1 = atleta dopat: sí/no


X_2 = resultat test de sang de dopatge: + / -

X_3 = resultat test d'orina de dopatge: + / -

- ✓ Els dos tests NO són independents (si un dóna +, és més probable que l'altre també).
- ✓ Però sí ho són si coneixem si l'atleta és dopat o no:

$$I_P(X_2, X_3 / X_1)$$

Per tant, aquest DAG juntament amb P compleix la Condició de Markov.



Aleshores, es compleix la Regla de la Cadena i, per tant, podem calcular:

$$P(X_1 = x_1, X_2 = x_2, X_3 = x_3) = P(X_3 = x_3 / X_1 = x_1) P(X_2 = x_2 / X_1 = x_1) P(X_1 = x_1)$$

1.3 La Condició de Markov

Exemple: Tenim els següents 13 objectes. Considerem l'espai de probabilitat:

$$(\Omega = \{\text{objectes}\}, \mathcal{A} = \mathcal{P}(\Omega), P)$$


amb P la probabilitat distribució uniforme discreta (assigna probabilitat $1/13$ a cadascun dels 13 objectes). Definim les variables L , S i C .



Variable	Valor
L (Lletra)	A
	B
S (Forma)	Quadrat
	Rodona
C (Color)	Negre
	Blanc

I considerem el DAG:

$$\Gamma_1 = (V, E), \text{ amb } V = \{L, S, C\}$$
$$E = \{(C, L), (C, S)\}$$



Node	Pares del node	No-descendents	Independència condicional
L	C	S	L i S són independents, condicionant a C
S	C	L	idem
C	Conjunt buit	Conjunt buit	(cap condició)

Per tant, (Γ_1, P) compleix la **Condició de Markov** si L i S són independents, condicionant a C , això és, si: $P(L, S / C) = P(L / C) P(S / C)$

1.3 La Condició de Markov

Anem a comprovar si (Γ_1, P) compleix la Condició de Markov:

$$P(L, S / C) = P(L / C) P(S / C) ??$$



Dist. conjunta de L i S , condicionada a C =Negre

Si C = Negre	A	B	
Quadrat	2/9	4/9	2/3
Rodona	1/9	2/9	1/3
	1/3	2/3	

Dist. conjunta de L i S , condicionada a C =Blanc

Si C = Blanc	A	B	
Quadrat	1/4	1/4	1/2
Rodona	1/4	1/4	1/2
	1/2	1/2	

Acabem de veure que (Γ_1, P) **sí** compleix la Condició de Markov. Aleshores, per Teorema 1, a més, tenim que es compleix la Regla de la Cadena, és a dir,

$$P(L, S, C) = P(L / C) P(S / C) P(C)$$


1.3 La Condició de Markov

Per tant, per a calcular la probabilitat conjunta de L , S i C , fem servir:

$$P(L, S, C) = P(L / C) P(S / C) P(C)$$



Distribucions
condicionals (CPTs) de
 L i S respecte de C :



Negre	Blanc
9/13	4/13

Distribució marginal del node
“arrel” C .

L	A	B
Si C = Negre	1/3	2/3
Si C = Blanc	1/2	1/2

S	Quadrat	Rodona
Si C = Negre	2/3	1/3
Si C = Blanc	1/2	1/2

Distribució conjunta de
 L , S i C : $2^3 - 1 = 8 - 1 = 7$
valors.

CPTs: $1 + 2 + 2 = 5$ valors.

Sabem (per Laplace) que $P(C = \text{Negre}, L = A, S = \text{Quadrat}) = \mathbf{2/13}$ (anàlogament les altres 7 probabilitats conjuntes). També la podem calcular per la **Regla de la Cadena**:

$$P(C = \text{Negre}, L = A, S = \text{Quadrat}) = P(L = A / C = \text{Negre})$$


$$P(S = \text{Quadrat} / C = \text{Negre}) P(C = \text{Negre}) = \frac{1}{3} \times \frac{2}{3} \times \frac{9}{13} = \frac{2}{13}$$

1.3 La Condició de Markov

Fixada la probabilitat P , NO tots els DAGs compleixen la [Condició de Markov](#) amb ella! Veiem un exemple:



Sigui $V=\{L,S,C\}$, com abans, i $E=\{(L,C), (S,C)\}$
Considerem el DAG $\Gamma_2=(V, E)$



Node	Pares del node	No-descendents	Independència condicional
L	Conjunt buit	S	L i S són independents
S	Conjunt buit	L	idem
C	L, S	Conjunt buit	(cap condició)

Per tal que el parell (Γ_2, P) compleixi la [Condició de Markov](#), s'hauria de verificar que L i S fossin variables independents (sense condicionar). Ho són?
NO!!! Per exemple:

$$P(L = A, S = \text{Quadrat}) = \frac{3}{13}$$

$$P(L = A) P(S = \text{Quadrat}) = \frac{5}{13} \times \frac{8}{13} = \frac{3}{13} \times \frac{40}{39} \neq \frac{3}{13}$$

1.3 La Condició de Markov

Hem vist que (Γ_2, P) **NO** compleix la Condició de Markov. El Teorema 1 diu que si la compleix, aleshores es compleix la Regla de la Cadena. Però si no es compleix, el Teorema 1 no ens diu res! De tota manera, podem veure si es compleix o no...





La Regla de la Cadena es compleix si:

$$P(L, S, C) = P(C / L, S) P(L) P(S)$$

Veurem que en aquest cas **NO** es compleix!!

A	B
5/13	8/13



Quadrat	Rodona
8/13	5/13

C	Negre	Blanc
Si L=A, S=Quadrat	2/3	1/3
Si L=A, S=Rodona	1/2	1/2
Si L=B, S=Quadrat	4/5	1/5
Si L=B, S=Rodona	2/3	1/3

$$P(L = A, S = \text{Quadrat}, C = \text{Negre}) = \frac{2}{13}$$

$$P(C = \text{Negre} / L = A, S = \text{Quadrat}) P(L = A) P(S = \text{Quadrat}) = \frac{2}{3} \times \frac{5}{13} \times \frac{8}{13} = \frac{2}{13} \times \frac{40}{39} \neq \frac{2}{13}$$

1.3 La Condició de Markov


Recordem que el Teorema 1 ens diu que si tenim un DAG on els nodes representen variables en un espai de probabilitat $(\Omega, \mathcal{A}, P)$, i la parella formada pel DAG i la probabilitat P verifiquen la **Condició de Markov**, aleshores es compleix la **Regla de la Cadena** i, per tant, la distribució de probabilitat conjunta de les variables del DAG es pot calcular com el producte de les probabilitats condicionades de cada node als seus pares (i les marginals dels nodes arrel).

A la pràctica, donat el DAG, el que fem és determinar les distribucions condicionades de cada node als seus pares (i les marginals dels nodes arrel), normalment estimant-les a partir d'una base de dades. Quan fem això, suposem que les variables del DAG estan definides a un mateix espai de probabilitat, diguem $(\Omega, \mathcal{A}, Q)$ i podem definir una distribució conjunta de les variables a partir de les distribucions condicionades, mitjançant la Regla de la Cadena, i a partir d'ella, trobar quina és la probabilitat Q de l'espai de probabilitat. Exemple:




Espai de probabilitat:

$(\Omega = \{\text{objectes}\}, \mathcal{A} = \mathcal{P}(\Omega), Q), Q = ?$



1.3 La Condició de Markov


Si podem estimar, d'alguna manera, a partir d'una base de dades, per exemple, les probabilitats condicionades de cada node als seus pares, i les distribucions marginals dels nodes arrels (CPTs):



Definim la distribució conjunta de les variables L , S i C , per la **Regla de la Cadena**:

$$Q(L, S, C) = Q(C / L, S) Q(L) Q(S)$$

1.3 La Condició de Markov



$$Q(L, S, C) = Q(C / L, S) Q(L) Q(S)$$


$Q(L = A, S = Quadrat, C = Negre) =$

$$Q(C = Negre / L = A, S = Quadrat) Q(L = A) Q(S = Quadrat) = \frac{2}{3} \times \frac{5}{13} \times \frac{8}{13} = \frac{80}{507}$$

I anàlogament calculem les altres 7 probabilitats conjuntes (n'hi ha $2^3 = 8$).

1.3 La Condició de Markov

A	B
5/13	8/13



Quadrat	Rodona
8/13	5/13

C	Negre	Blanc
Si L=A, S=Quadrat	2/3	1/3
Si L=A, S=Rodona	1/2	1/2
Si L=B, S=Quadrat	4/5	1/5
Si L=B, S=Rodona	2/3	1/3

$$Q(L, S, C) = Q(C / L, S) Q(L) Q(S)$$

La distribució de probabilitat conjunta de les variables L , S i C que obtenim a partir de les CPTs, és:

L	S	C	$Q(L, S, C)$
A	Quadrat	Negre	80/507
A	Quadrat	Blanc	40/507
A	Rodona	Negre	25/338
A	Rodona	Blanc	25/338
B	Quadrat	Negre	256/845
B	Quadrat	Blanc	64/845
B	Rodona	Negre	80/507
B	Rodona	Blanc	40/507

1.3 La Condició de Markov


A partir d'aquesta distribució de probabilitat conjunta de les variables L , S i C , *quina seria la probabilitat Q ?*

Espai de probabilitat:

$(\Omega = \{\text{objectes}\}, \mathcal{A} = \mathcal{P}(\Omega), Q), Q = ?$

Per a determinar Q només cal trobar el seu valor sobre cada objecte de Ω , ja que els elements de $\mathcal{A}$ són unions d'objectes.

L	S	C	$Q(L, S, C)$
A	Quadrat	Negre	80/507
A	Quadrat	Blanc	40/507
A	Rodona	Negre	25/338
A	Rodona	Blanc	25/338
B	Quadrat	Negre	256/845
B	Quadrat	Blanc	64/845
B	Rodona	Negre	80/507
B	Rodona	Blanc	40/507



Per la taula tenim que $Q(\{\text{Ob}_1, \text{Ob}_2\}) = 80/507$. Per simetria: $Q(\text{Ob}_1) = Q(\text{Ob}_2) = 40/507$

$Q(\{\text{Ob}_3, \text{Ob}_4, \text{Ob}_5, \text{Ob}_6\}) = 256/845 \implies Q(\text{Ob}_3) = Q(\text{Ob}_4) = Q(\text{Ob}_5) = Q(\text{Ob}_6) = 64/845$
 $Q(\text{Ob}_7) = 25/338$


$Q(\{\text{Ob}_8, \text{Ob}_9\}) = 80/507 \implies Q(\text{Ob}_8) = Q(\text{Ob}_9) = 40/507$

$Q(\text{Ob}_{10}) = 40/507$ $Q(\text{Ob}_{12}) = 25/338$

$Q(\text{Ob}_{11}) = 64/845$ $Q(\text{Ob}_{13}) = 40/507$


1.3 La Condició de Markov

A	B
5/13	8/13



Quadrat	Rodona
8/13	5/13

C	Negre	Blanc
Si L=A, S=Quadrat	2/3	1/3
Si L=A, S=Rodona	1/2	1/2
Si L=B, S=Quadrat	4/5	1/5
Si L=B, S=Rodona	2/3	1/3



Espai de probabilitat associat, a partir de fer servir la **Regla de la Cadena** i de les CPTs:

$$(\Omega = \{13 \text{ objectes}\}, \mathcal{A} = \mathcal{P}(\Omega), Q)$$

On Q ve determinada per la següent assignació de probabilitats a cada element de Ω :




La probabilitat inicial P venia determinada per la següent assignació de probabilitats:




1.3 La Condició de Markov

A	B
5/13	8/13



Quadrat	Rodona
8/13	5/13

C	Negre	Blanc
Si L=A, S=Quadrat	2/3	1/3
Si L=A, S=Rodona	1/2	1/2
Si L=B, S=Quadrat	4/5	1/5
Si L=B, S=Rodona	2/3	1/3



Hem vist que (Γ_2, P) **NO** compleix la Condició de Markov.

A partir de les CPTs, hem definit una nova probabilitat Q .

Teorema 2: (Theorem 1.5, Neapolitan, 2004)

En aquestes circumstàncies,
la parella (Γ_2, Q) compleix la Condició de Markov!

En particular, això ens diu que $P \neq Q$ ja que (Γ_2, P) no compleix la Condició de Markov, mentre que (Γ_2, Q) sí la compleix! (a banda, hem vist que donen probabilitats diferents als 13 elements.

1.3 La Condició de Markov

COMPTE!! La probabilitat Q no té perquè quedar completament determinada per la **Regla de la Cadena** i de les CPTs!!!

Per la taula tenim: $Q(\{Ob_1, Ob_2\}) = 80/507$


$Q(\{Ob_3, Ob_4, Ob_5, Ob_6\}) = 256/845$

$Q(\{Ob_8, Ob_9\}) = 80/507$


$Q(Ob_7) = 25/338$ $Q(Ob_{10}) = 40/507$ $Q(Ob_{11}) = 64/845$

$Q(Ob_{12}) = 25/338$ $Q(Ob_{13}) = 40/507$

L	S	C	Q(L, S, C)
A	Quadrat	Negre	80/507
A	Quadrat	Blanc	40/507
A	Rodona	Negre	25/338
A	Rodona	Blanc	25/338
B	Quadrat	Negre	256/845
B	Quadrat	Blanc	64/845
B	Rodona	Negre	80/507
B	Rodona	Blanc	40/507



La següent assignació de probabilitats també és possible i dona una Q diferent de l'anterior, però igualment compatible amb la **Regla de la Cadena**, el DAG i les CPTs!!





1.3 La Condició de Markov

Distribució conjunta de probabilitat de les variables L , S i C :



Espai de probabilitat:

$(\Omega = \{\text{objectes}\}, \mathcal{A} = \mathcal{P}(\Omega), \text{probabilitat})$

L	S	C	Q(L, S, C)
A	Quadrat	Negre	80/507
A	Quadrat	Blanc	40/507
A	Rodona	Negre	25/338
A	Rodona	Blanc	25/338
B	Quadrat	Negre	256/845
B	Quadrat	Blanc	64/845
B	Rodona	Negre	80/507
B	Rodona	Blanc	40/507


P													
	1/13	1/13	1/13	1/13	1/13	1/13	1/13	1/13	1/13	1/13	1/13	1/13	1/13
Q													
	40/507	40/507	64/845	64/845	64/845	64/845	25/338	40/507	40/507	40/507	64/845	25/338	40/507
Q'													
	20/507	50/507	50/845	50/845	50/845	106/845	25/338	10/507	70/507	40/507	64/845	25/338	40/507

1.3 La Condició de Markov

P													
	1/13	1/13	1/13	1/13	1/13	1/13	1/13	1/13	1/13	1/13	1/13	1/13	1/13
Q													
	40/507	40/507	64/845	64/845	64/845	64/845	25/338	40/507	40/507	40/507	64/845	25/338	40/507
Q'													
	20/507	50/507	50/845	50/845	50/845	106/845	25/338	10/507	70/507	40/507	64/845	25/338	40/507


$(\Omega = \{\text{objectes}\}, \mathcal{A} = \mathcal{P}(\Omega), P)$

Les variables L i S són independents condicionant a C
 (Γ_1, P) compleix la CM



$(\Omega = \{\text{objectes}\}, \mathcal{A} = \mathcal{P}(\Omega), Q)$

Les variables L i S són independents
 (Γ_2, Q) compleix la CM




$(\Omega = \{\text{objectes}\}, \mathcal{A} = \mathcal{P}(\Omega), Q')$

(Γ_2, Q') compleix la CM

1.3 La Condició de Markov

A	B
5/13	8/13





Quadrat	Rodona
8/13	5/13

C	Negre	Blanc
Si $L=A$, $S=Quadrat$	2/3	1/3
Si $L=A$, $S=Rodona$	1/2	1/2
Si $L=B$, $S=Quadrat$	4/5	1/5
Si $L=B$, $S=Rodona$	2/3	1/3




Donat el DAG Γ_2 , a partir de les CPTs, hem definit una nova probabilitat Q tal que la parella (Γ_2, Q) (**Teorema 2**) que, a més, hem vist que no és única!!

Per tant, a partir del DAG sabem com trobar la probabilitat.
Però la mateixa probabilitat la podem obtenir amb diferents DAGs!!
Vegem-ho amb un exemple:




1.3 La Condició de Markov



Definim la probabilitat conjunta per a cada DAG, a partir de la **Regla de la Cadena**:

$$\begin{aligned} Q(A, B, C) &= P(C/A, B) P(A) P(B) \\ &= \frac{P(A, B / C) P(C)}{P(A, B)} P(A) P(B) \\ &= P(A, B / C) P(C) = P(A / B, C) P(B / C) P(C) \end{aligned}$$




$$Q'(A, B, C) = P(A / B, C) P(B / C) P(C)$$

Veiem, doncs, que $Q = Q'$, és a dir, que dos DAGs clarament diferents ens donen la mateixa probabilitat!!


1.3 La Condició de Markov

Podem definir un ordre en el conjunt dels nodes $V = \{A, B, C\}$, que formen un DAG, que s'anomena **ordre ancestral**. En aquest ordre, que no és únic, cap node pot precedir a un dels seus pares. Veiem que els dos DAGs tenen diferents **ordres ancestrals**:



Ordre ancestral:

- A, B, C
- També possible: B, A, C




Ordre ancestral:

- C, B, A (cap més possibilitat)

Veiem que els ordres són clarament diferents, però tanmateix els dos DAGs ens generen la mateixa probabilitat tal que la parella (DAG, probabilitat) compleix la Condició de Markov!!

1.3 La Condició de Markov

Si tornem a l'exemple on $V=\{A, B, C\}$, i tenim 3 DAGs que verifiquen la **Condició de Markov** amb probabilitats respectives P_1, P_2, P_3 .




v-estructura:

A i B no són independents condicionant a C


$$P_1(A, B / C) \neq P_1(A / C) P_1(B / C)$$

$$P_1(A, B, C) = P_1(C / A, B) P_1(A) P_1(B)$$



A i B sí són independents condicionant a C

$$P_2(A, B / C) = P_2(A / C) P_2(B / C)$$




$$P_3(A, B / C) = P_3(A / C) P_3(B / C)$$

Veiem que $P_1 \neq P_2, P_1 \neq P_3$.


1.3 La Condició de Markov

Si tornem a l'exemple on $V=\{A, B, C\}$, i tenim 3 DAGs que verifiquen la **Condició de Markov** amb probabilitats respectives P_1, P_2, P_3 .



$$\begin{aligned} P_2(A, B, C) &= P_2(B / C) P_2(C / A) P_2(A) \\ &= P_2(B / C) P_2(A / C) P_2(C) \end{aligned}$$

Fórmula de Bayes




$$P_3(A, B, C) = P_3(B / C) P_3(A / C) P_3(C)$$

Per tant, els dos DAGs són **EQUIVALENTS**, ja que representen la mateixa probabilitat conjunta de les variables A, B i C, obtinguda a partir de les CPTs, amb la mateixa fórmula!!

P_2 i P_3 són **compatibles!!**


1.3 La Condició de Markov

Si tornem a l'exemple on $V=\{A, B, C\}$, i tenim 3 DAGs que verifiquen la **Condició de Markov** amb probabilitats respectives P_1, P_2, P_3 .



$$\begin{aligned} P_2(A, B, C) &= P_2(B / C) P_2(C / A) P_2(A) \\ &= P_2(B / C) P_2(A / C) P_2(C) \end{aligned}$$

Fórmula de Bayes



$$P_3(A, B, C) = P_3(B / C) P_3(A / C) P_3(C)$$


Per tant, els dos DAGs són **EQUIVALENTS**, ja que representen la mateixa probabilitat conjunta de les variables A, B i C, obtinguda a partir de les CPTs, amb la mateixa fórmula!!

P_2 i P_3 són **compatibles!!**

El que importa, en realitat, és la **DISTRIBUCIÓ CONJUNTA** de les variables, i els dos DAGs porten a la mateixa distribució conjunta.

1.3 La Condició de Markov

SI a les fletxes del DAG els hi donem una **interpretació causal** (que **NO** tenen per què tenir), aleshores una **v-estructura** correspon a **dues causes independents que tenen un mateix efecte**.



Exemple: tant la pluja P, com el reg automàtic R, produeixen el mateix efecte de gespa mullada M. Si el reg està programat de manera automàtica cada tres dies, faci el temps que faci, és evident que P i R són independents.

Si fixem un valor de M diem que M ha sigut **inicialitzada** (*instantiated*).

Això genera **DEPENDÈNCIA** entre les variables P i R, que eren independents!

Per què? Perquè cadascuna de les dues causes explica l'ocurrència de l'efecte, fent que l'altra causa sigui menys probable si és present, o més probable si és absent.


Si M=sí, vol dir que la gespa és mullada. Si sabem que el reg no ha funcionat (R=no), aleshores és més probable que hagi plogut (P=sí), i viceversa.

Aquest tipus de dependència generat entre les dues causes independents d'un efecte comú, quan aquest s'inicialitza, es coneix com **selection bias**.

1.3 La Condició de Markov

¿Què passa quan el que tenim no són dues causes independents d'un efecte comú, sinó dos efectes d'una mateixa causa comuna?

Exemple: el refredat pot causar esternuts i mal de gola, i cap d'aquests efectes pot ser causa de l'altre. Fem servir aquest DAG que, per la **Condició de Markov**, ens donarà que E i M són independents condicionant a R. És a dir, que si sabem que la persona està refredada, o que no ho està, tenir esternuts i tenir mal de gola són independents.




Compte! Si no condicionem a R, aleshores E i M **NO** són independents: si sabem que una persona té esternuts, és més probable que estigui refredada i, per tant, també que tingui mal de gola!

Idea: si no condicionem per R, hi ha un “pont” entre E i M que passa per R, a través del qual circula la informació entre E i M, de tal manera que s’influeixen l’un a l’altre. En canvi, si condicionem per R, “tanquem el pont” i ja no es poden influir, esdevenint independents.


1.3 La Condició de Markov

Important! La situació és just al contrari que amb la **v-estructura**, en la qual és quan condicionem per l'efecte comú (inicialitzem) que “obrim el pont” i generem dependència entre les causes comunes, mentre que en cas contrari, son independents.



Què passaria si hagués una altra causa comuna dels dos efectes “amagada” (no considerada al model)? En aquest cas, encara que condicionem per la causa coneguda, els dos efectes **no** serien independents!!

Encara que coneguem el valor de R, E i M **no** seran independents: si una persona no està refredada però sabem que té esternuts, això incrementa la probabilitat de tenir una al·lèrgia A, i això a la vegada la probabilitat de tenir mal de gola.



Aleshores, la **Condició de Markov no es compleix!**

1.4 Definició de Xarxa Bayesiana

Definició:

Sigui $\Gamma = (V, E)$ un **graf dirigit (DAG)**, amb V un conjunt finit de variables aleatòries (discretes) sobre el mateix espai de probabilitat $(\Omega, \mathcal{A}, P)$, representades per **nodes**, i E un conjunt d'**arcs dirigits** o **fletxes** entre les variables aleatòries.

Aleshores, diem que la parella (Γ, P) és una **Xarxa Bayesiana** si satisfà la **Condicció de Markov**.

- Pel Teorema 1, la distribució conjunta de les variables del DAG Γ d'una xarxa Bayesiana (Γ, P) , és el producte de les probabilitats condicionades de cada node als seus pares (**Regla de la Cadena**) (respecte la probabilitat P).

1.4 Definició de Xarxa Bayesiana

Definició:

Sigui $\Gamma = (V, E)$ un **graf dirigit (DAG)**, amb V un conjunt finit de variables aleatòries (discretes) sobre el mateix espai de probabilitat $(\Omega, \mathcal{A}, P)$, representades per **nodes**, i E un conjunt d'**arcs dirigits** o **fletxes** entre les variables aleatòries.

Aleshores, diem que la parella (Γ, P) és una **Xarxa Bayesiana** si satisfà la **Condició de Markov**.

- Pel Teorema 2, si tenim un DAG $\Gamma = (V, E)$, on les variables aleatòries (discretes) de V són definides a un espai $(\Omega, \mathcal{A}, P)$ i coneixem les distribucions condicionades (CPTs) de cada node als seus pares al DAG, aleshores, podem definir una probabilitat Q a $(\Omega, \mathcal{A})$ mitjançant la **Regla de la Cadena**, a partir de les CPTs, de tal manera que (Γ, Q) serà una **Xarxa Bayesiana** (complirà la **Condició de Markov**), com hem fet a l'exemple.
- El que és important és la distribució de probabilitat conjunta de les variables de V , que s'obté fent servir la **Regla de la Cadena**, i no tant la probabilitat Q , encara que a partir d'una s'obté l'altra.

1.4 Definició de Xarxa Bayesiana

Definició:

Sigui $\Gamma = (V, E)$ un **graf dirigit (DAG)**, amb V un conjunt finit de variables aleatòries (discretes) sobre el mateix espai de probabilitat $(\Omega, \mathcal{A}, P)$, representades per **nodes**, i E un conjunt d'**arcs dirigits** o **fletxes** entre les variables aleatòries.

Aleshores, diem que la parella (Γ, P) és una **Xarxa Bayesiana** si satisfà la **Condicció de Markov**.

És així com es construeixen les Xarxes Bayesianes a la pràctica:

- ✓ es troba el DAG i les CPTs,
- ✓ i amb això ja tindríem la **Xarxa Bayesiana**, que és la parella formada pel DAG i la probabilitat obtinguda a partir de les CPTs fent servir la **Regla de la Cadena**.
- ✓ Fent un abús de llenguatge, direm que tenim una **Xarxa Bayesiana** si tenim un DAG i les CPTs.

1.4 Definició de Xarxa Bayesiana

Des d'un punt de vista pràctic, és un gran estalvi fer servir les CPTs per a representar la Xarxa Bayesiana, juntament amb el DAG, per comptes de la distribució de probabilitat conjunta de les variables del DAG. Exemple:

A	P(A)
false	0.6
true	0.4


Distribució marginal
del node arrel A

A	B	P(B/A)
false	false	0.01
false	true	0.99
true	false	0.7
true	true	0.3

Els paràmetres de la Xarxa Bayesiana són les probabilitats (no redundants, ja que sabem que algunes de les probabilitats han de sumar 1) de les CPTs.

B	C	P(C/B)
false	false	0.4
false	true	0.6
true	false	0.9
true	true	0.1

La distribució conjunta de A, B, C i D té $2^4 = 16$ probabilitats, de les quals 1 és redundant, per tant, són $16 - 1 = \mathbf{15}$ probabilitats a calcular/emmagatzemar.



B	D	P(D/B)
false	false	0.02
false	true	0.98
true	false	0.05
true	true	0.95

És un gran estalvi!

Total paràmetres de la Xarxa Bayesiana:
 $1 \text{ (de A)} + 2 \text{ (de B)} + 2 \text{ (de C)} + 2 \text{ (de D)} = \mathbf{7}$

1.4 Definició de Xarxa Bayesiana

Si tenim una Xarxa Bayesiana amb n variables Booleanes (que prenen només dos valors: true/false) o binàries (que prenen dos valors diferents, per exemple 0/1), aleshores:

- La distribució de probabilitat conjunta de les variables del DAG necessita de calcular/emmagatzemar $2^n - 1$ probabilitats.
- Si cada node del DAG té com a màxim k pares, aleshores el nombre de probabilitats a les CPTs seran, com a molt, 2^{k+1} , de les quals només la meitat són no redundants i s'han de calcular/emmagatzemar: 2^k , de manera que el nombre de paràmetres seria, com a molt $n 2^k$.

Per exemple, si $n = 30$, $k = 3$ (hi ha 30 nodes binaris o Booleans a la Xarxa Bayesiana, i cadascun té un màxim de 3 pares en el DAG, aleshores:

- Distribució conjunta de les 30 variables, tenim $2^n - 1 = 1073741823$ probabilitats no redundants.
- Paràmetres de la Xarxa Bayesiana (probabilitats no redundants de les CPTs): com a màxim $n 2^k = 240$.

Podem veure l'estalvi tan important en càlcul i en espai d'emmagatzematge que aconseguim gràcies al Teorema 2.


1.5 El “Markov Blanket” i la “d-separació”

Tenint en compte la **Condició de Markov** que compleix una **xarxa Bayesiana**, per definició, per a fer qualsevol inferència (o sigui, per a calcular qualsevol probabilitat) sobre un node objectiu (*target*), només ens haurem de fixar en els nodes “relacionats” amb ell en el DAG, que són:

- els seus pares,
- els seus fills,
- els altres pares dels seus fills.


El conjunt format per aquest conjunt de nodes, donat un node objectiu, s'anomena **“Markov Blanket”** del node.

Així podem fer selecció de variables (*feature selection*).



Es diu que A i els nodes que **no** pertanyen al seu **“Markov Blanket”** es troben **“d-separats”**.

1.5 El “Markov Blanket” i la “d-separació”



El concepte de “**d-separació**” és més complex en general, però en el cas particular del “**Markov Blanket**” (**MB**), el que vol dir és:

Donat el node objectiu A, i qualsevol node que no pertanyi al seu **MB**. Per a qualsevol camí entre aquest node i A, existeix un node en el **MB** de A tal que forma part del camí.

Exemples:

1. H no pertany al **MB** de A.
Hi ha un camí entre H i A.
Existeix un node del **MB** de A que forma part del camí: E.
2. G no pertany al **MB** de A.
Hi ha dos camins entre A i G.
Existeix un node del **MB** de A que forma part de cada camí: B i C.

1.6 Prognosi i Diagnosi: el Naive Bayes

Exemple:

Estem investigant la relació entre diferents comorbiditats i variables demogràfiques, i el desenvolupament d'una malaltia degenerativa. Tenim les variables:

- **Malaltia degenerativa (M)**: Sí, No

Variables demogràfiques:

- **Edat (E)**: <18, 18-35, 35-44, 45-60, >60
- **Sexe (S)**: Home, Dona

Comorbiditats:


- **Diabetis (D)**: Sí, No
- **Hipertensió (H)**: Sí, No
- **Cardiopatia (C)**: Sí, No

Tenim una base de dades amb aquestes variables, recollides per a un conjunt de pacients (casos o “*instances*”).

La natura de les pròpies variables ens poden suggerir com s'han de relacionar entre elles. El més habitual és aprendre a partir de les dades l'estructura que les relaciona (DAG) en el context del model que volem construir per a les relacions de dependència entre elles: xarxa Bayesiana. Però podem aprendre diferents tipus d'estructura.

Xarxa Bayesiana de tipus “prognosi”


Una aproximació de tipus **prognosi** seria una xarxa Bayesiana amb un DAG tal que les variables demogràfiques i les comorbiditats estan a dalt, i la variable Malaltia degenerativa està a baix.



Les variables que poden afectar la variable d'interès M es troben a sobre seu, són les comorbiditats. I les variables demogràfiques que poden afectar les comorbiditats, es troben a dalt de tot.

Xarxa Bayesiana de tipus “diagnosi”


Una aproximació de tipus **diagnosi** seria una xarxa Bayesiana amb un DAG tal que les variables demogràfiques i les comorbiditats estan a baix, i la variable Malaltia degenerativa està a dalt de tot.



Les variables que poden afectar la variable d'interès **M** es troben a sota seu, són les comorbiditats. I les variables demogràfiques que poden afectar les comorbiditats, es troben a baix de tot. És un tipus diferent d'estructura però que codifica les mateixes relacions de dependència entre les variables del model.

Xarxa Bayesiana de tipus “Naive Bayes”


És un tipus molt utilitzat de xarxa Bayesiana de tipus “diagnosi”, amb un DAG en el qual només hi ha fletxa de la variable target a totes i cadascuna de les altres variables del model, diguem “variables d’evidència”, i cap més. És, doncs, un tipus de xarxa Bayesiana amb estructura (DAG) fix, que no s’aprèn de les dades.



Aquest seria el DAG, i els paràmetres de la Xarxa Bayesiana serien: les probabilitats condicionades de cada variable evidència a la variable M , i les probabilitats marginals de la variable M .

Aleshores, un cop tenim la Xarxa Bayesiana, podem calcular la probabilitat a posteriori de $M = \text{sí}$, per exemple, donades unes evidències: $E_1=e_1, \dots, E_k=e_k$, fent servir la **Fórmula de Bayes**.

1.6 Prognosi i Diagnosi: el Naive Bayes



M	P(M)
sí	0.1
no	0.9

Els paràmetres de la xarxa Bayesiana són les probabilitats de la variable M, i de les variables E_1 i E_2 condicionades a M.

Els tindrem d'alguna manera:

- ✓ per coneixement expert, o
- ✓ estimant els valors a partir d'una base de dades.

La probabilitat **a priori** d'estar malalt és

$$P(M = \text{sí}) = 0.1,$$

que és la prevalença de la malaltia a la població.

M	E_1	$P(E_1/M)$
sí	sí	0.8
no	sí	0.3

M	E_2	$P(E_2/M)$
sí	sí	0.6
no	sí	0.5


Quina és la probabilitat **a posteriori** d'estar malalt si sabem que $E_1 = \text{sí}$, $E_2 = \text{no}$, per exemple?

$$\begin{aligned} P(M = \text{sí} / E_1 = \text{sí}, E_2 = \text{no}) &= \frac{P(E_1 = \text{sí}, E_2 = \text{no} / M = \text{sí}) P(M = \text{sí})}{P(E_1 = \text{sí}, E_2 = \text{no})} \\ &= \frac{P(E_1 = \text{sí}, E_2 = \text{no} / M = \text{sí}) P(M = \text{sí})}{P(E_1 = \text{sí}, E_2 = \text{no} / M = \text{sí}) P(M = \text{sí}) + P(E_1 = \text{sí}, E_2 = \text{no} / M = \text{no}) P(M = \text{no})} \end{aligned}$$

I fent servir la **condició de Markov**, que ens diu que E_1 i E_2 són independents condicionant a M, el numerador és:

$$P(E_1 = \text{sí} / M = \text{sí}) P(E_2 = \text{no} / M = \text{sí}) P(M = \text{sí}) = 0.8 \times (1 - 0.6) \times 0.1 = 0.032$$

1.6 Prognosi i Diagnosi: el Naive Bayes



M	P(M)
sí	0.1
no	0.9

La probabilitat **a priori** d'estar malalt és
 $P(M = \text{sí}) = 0.1$,
que és la prevalença de la malaltia a la població.

M	E ₁	P(E ₁ /M)
sí	sí	0.8
no	sí	0.3

M	E ₂	P(E ₂ /M)
sí	sí	0.6
no	sí	0.5

El numerador és:

$$P(E_1 = \text{sí} / M = \text{sí}) P(E_2 = \text{no} / M = \text{sí}) P(M = \text{sí}) = 0.8 \times (1 - 0.6) \times 0.1 = 0.032$$


I el segon sumand del denominador,

$$P(E_1 = \text{sí} / M = \text{no}) P(E_2 = \text{no} / M = \text{no}) P(M = \text{no}) = 0.3 \times (1 - 0.5) \times 0.9 = 0.135$$

$$\text{Per tant, } P(M = \text{sí} / E_1 = \text{sí}, E_2 = \text{no}) = \frac{0.032}{0.032 + 0.135} = \frac{0.032}{0.167} \approx 0.19162$$

És a dir, que la probabilitat d'estar malalt passar de ser 0.1 a priori, a ser 0.19162, quasi el doble, a posteriori, donada l'evidència del pacient.

1.6 Prognosi i Diagnosi: el Naive Bayes



Risc de patir la malaltia

Risc a priori
10%

Risc a posteriori
20%

Evidència:
 $E_1 = \text{sí}, E_2 = \text{no}$

- Les **xarxes Bayesianes** són una metodologia de l'Aprenentatge Automàtic Supervisat, que és un subcamp de la Intel·ligència Artificial que es caracteritza per ser **de caixa blanca**.
- Una **xarxa Bayesiana** és una parella formada per un DAG i una probabilitat que verifiquen la **condició de Markov**.
- La **condició de Markov** implica la **Regla de la Cadena**.
- Donat un DAG, si definim una probabilitat a partir de les CPTs i de la **Regla de la Cadena**, la parella formada pel DAG i la probabilitat és una **xarxa Bayesiana**.
- En l'**ordre ancestral** a un DAG, cap node precedeix a cap dels seus pares.
- S'anomena "**selection bias**" la dependència que es genera a una **v-estructura** entre els pares, quan es fixa un valor concret del seu fill en comú.
- El **Markov Blanket** associat a un node target d'un DAG és el conjunt de nodes format pels seus pares, els seus fills, i els altres pares dels seus fills. El node target i els nodes que no formen part del **Markov Blanket** es troben **d-separats**.
- Hi ha estructures de xarxa Bayesiana (DAGs) de tipus **prognosi** i de tipus **diagnosi**.
- El **Naive Bayes** és una xarxa Bayesiana de tipus diagnosi d'estructura fixa. Hi ha independència entre les variables d'evidència condicionant per la variable target.