

Tema 1

Introducció a les xarxes Bayesianes

Bloc A) Introducció a l'assignatura

Bloc B) Conceptes preliminars i
definicions bàsiques

Bloc C) Inferència amb XBs

Bloc D) Aprenentatge de XBs: paràmetres

Bloc E) Aprenentatge de XBs: estructura

Tema 1. Bloc C)

Inferència amb XBs

1.7 La inferència Bayesiana

1.8 Inferència exacta

1.9 Inferència aproximada

- a) Logic Sampling (LS)
- b) Likelihood Weighting (LW)
- c) Kullback-Leibler (KL) divergence

1.10 Un exemple de cinema: Armageddon

1.7 La inferència Bayesiana

Quan introduïm una evidència (una peça d'informació relativa a unes quantes variables) i la fem servir per a actualitzar (*update*) les probabilitats associades a una altra variable diferent mitjançant algun model predictiu, es diu que fem “**propagació**”, “**inferència**” o “**belief updating**”.

Es diu que fem “**inferència Bayesiana**” quan fem servir una xarxa Bayesiana (XB) com a model predictiu per a calcular la probabilitat *a posteriori* que una variable de la xarxa prengui un determinat valor, condicionant per l'evidència que es té sobre altres variables de la xarxa, és a dir, quan calculem:

$$P(X / E)$$


X = La variable que ens interessa
(variable de consulta o “*query*”)


E = Les variables de l'evidència
(evidence)

(les variables de la xarxa que no són ni *X* ni *E*, es tracten com a **no observades**)

1.7 La inferència Bayesiana

- ✓ Fer **inferència exacta** només és factible amb xarxes Bayesianes petites i mitjanes. A l'exemple introductori (ELISA) de l'apartat 1.1 vam veure, com a aplicació estàndard de la **Fórmula de Bayes**, com realitzar inferències Bayesianes amb una xarxa bayesiana de dos nodes.
- ✓ La **inferència exacta** amb xarxes Bayesianes grans triga molt de temps (problema computacionalment complex).
- ✓ En aquest cas, recorrem a tècniques **d'inferència aproximada** que són molt més ràpides i donen força bons resultats.
No cal que us preocupeu pels algorismes d'inferència aproximada, que explicarem però que estan implementats en diversos paquets que fan inferència Bayesiana aproximada (LS a **bnlearn::rbn**).

1.8 Inferència Exacta




Considerem aquesta XB en la qual les 4 variables X, Y, Z i W són binàries.

Les relacions d'independència condicional de la Condició de Markov són

Node	Pares	No desc.	Independència Condicional
X	$\emptyset$	$\emptyset$	$\emptyset$
Y	X	$\emptyset$	$\emptyset$
Z	Y	X	Z i X, donada Y
W	Z	X, Y	W i {X, Y}, donada Z

Aleshores, en primer lloc, les probabilitats *a priori* o **marginals** (sense condicionar) de totes les variables es poden calcular utilitzant **Fórmula de la Probabilitat Total** així:

1.8 Inferència Exacta



$$\begin{aligned} P(y_1) &= P(y_1/x_1) P(x_1) + P(y_1/x_2) P(x_2) \\ &= 0.9 \times 0.4 + 0.8 \times 0.6 = 0.84 \end{aligned}$$


$$\begin{aligned} P(z_1) &= P(z_1/y_1) P(y_1) + P(z_1/y_2) P(y_2) \\ &= 0.7 \times 0.84 + 0.4 \times 0.16 = 0.652 \end{aligned}$$

$$\begin{aligned} P(w_1) &= P(w_1/z_1) P(z_1) + P(w_1/z_2) P(z_2) \\ &= 0.5 \times 0.652 + 0.6 \times 0.348 = 0.5348 \end{aligned}$$

Tingueu en compte que el càlcul de cada variable requereix informació del seu pare.

Podem considerar aquest mètode un message-passing algorithm en el qual cada node passa al seu fill un missatge necessari per calcular les probabilitats del fill.

1.8 Inferència Exacta




Suposem ara que X s'inicialitza per a x_1 . Com que la condició de Markov implica que cada variable és condicionalment independent de X donat el seu pare, podem calcular les probabilitats condicionades per a les variables restants utilitzant la [Fórmula de la Probabilitat Total](#).

$$P(y_1/x_1) = 0.9$$

$$\begin{aligned} P(z_1/x_1) &= P(z_1/y_1, x_1) P(y_1/x_1) + P(z_1/y_2, x_1) P(y_2/x_1) \\ &= P(z_1/y_1) P(y_1/x_1) + P(z_1/y_2) P(y_2/x_1) \\ &= 0.7 \times 0.9 + 0.4 \times 0.1 = 0.67 \end{aligned}$$

$$\begin{aligned} P(w_1/x_1) &= P(w_1/z_1, x_1) P(z_1/x_1) + P(w_1/z_2, x_1) P(z_2/x_1) \\ &= P(w_1/z_1) P(z_1/x_1) + P(w_1/z_2) P(z_2/x_1) \\ &= 0.5 \times 0.67 + 0.6 \times (1 - 0.67) = 0.533 \end{aligned}$$

1.8 Inferència Exacta



Aquest exemple mostra com podem utilitzar la **propagació descendent** (*downward propagation*) de missatges per a calcular les probabilitats condicionades de variables descendents de la variable inicialitzada.

Inicialitzada: $X=x1$


Calculades: $P(y1/x1)=0.9$

$P(z1/x1)=0.67$

$P(w1/x1)=0.533$

Podem calcular probabilitats condicionades de variables ascendents de la variable inicialitzada?

1.8 Inferència Exacta




Suposem ara, en canvi, que és **W** que s'inicialitza, per **w1** (i cap altra variable). Podem utilitzar la **propagació ascendent** (*upward propagation*) de missatges per a calcular les probabilitats condicionades de les variables ascendents de la variable instanciada.

Primer, usem la **Fórmula de Bayes** per a calcular:

$$\begin{aligned} P(z_1/w_1) &= \frac{P(w_1/z_1) P(z_1)}{P(w_1)} \\ &= \frac{0.5 \times 0.652}{0.5348} = 0.6096 \end{aligned}$$

1.8 Inferència Exacta



X	P(X)
x1	0.4

X	Y	P(Y/X)
x1	y1	0.9
x2	y1	0.8

Y	Z	P(Z/Y)
y1	z1	0.7
y2	z1	0.4

Z	W	P(W/Z)
z1	w1	0.5
z2	w1	0.6

W=w1

Per a calcular $P(y_1/w_1)$, de nou apliquem la [Fórmula de Bayes:](#)

$$P(y_1/w_1) = \frac{P(w_1/y_1) P(y_1)}{P(w_1)}$$

Però encara no podem completar aquest càlcul perquè no coneixem $P(w_1/y_1)$. Podem obtenir aquest valor mitjançant la propagació descendent de la manera següent:


$$\begin{aligned} P(w_1/y_1) &= P(w_1/z_1) P(z_1/y_1) + P(w_1/z_2) P(z_2/y_1) \\ &= 0.5 \times 0.7 + 0.6 \times 0.3 = 0.53 \end{aligned}$$

$$\begin{aligned} P(w_1/y_2) &= P(w_1/z_1) P(z_1/y_2) + P(w_1/z_2) P(z_2/y_2) \\ &= 0.5 \times 0.4 + 0.6 \times 0.6 = 0.56 \end{aligned}$$

(també calculem $P(w_1/y_2)$ perquè para X ho necessitem)

1.8 Inferència Exacta

Aleshores, usant que $P(w_1/y_1)=0.53$,



W=w1

$$P(y_1/w_1) = \frac{P(w_1/y_1) P(y_1)}{P(w_1)}$$
$$= \frac{0.53 \times 0.84}{0.5348} \approx 0.83246$$


Finalment, calculem:

$$P(x_1/w_1) = \frac{P(w_1/x_1) P(x_1)}{P(w_1)}$$

$$P(w_1/x_1) = P(w_1/y_1) P(y_1/x_1) + P(w_1/y_2) P(y_2/x_1)$$
$$= 0.53 \times 0.9 + 0.56 \times 0.1 = 0.533$$

$$P(x_1/w_1) = \frac{P(w_1/x_1) P(x_1)}{P(w_1)}$$
$$= \frac{0.533 \times 0.4}{0.5348} \approx 0.39865$$

1.8 Inferència Exacta



Aquest exemple mostra com podem utilitzar la propagació ascendent de missatges per a calcular les probabilitats condicionades de les variables ascendents de la variable inicialitzada.

Inicialitzada: $W=w1$

Calculades: $P(z1/w1)=0.6096$

$P(y1/w1) \cong 0.83246$


$P(w1/x1) \cong 0.39865$

$W=w1$

Com podem tornar les cantonades en un arbre?

1.8 Inferència Exacta

Considereu aquesta XB a la qual cada v.a. és binària.



Suposeu que W s'inicialitza w1.

Primer podem calcular $P(y1/w1)$ i $P(x1/w1)$ mitjançant l'**algorisme de propagació ascendent**, i després $P(z1/w1)$ i $P(t1/w1)$ mitjançant l'**algorisme de propagació descendent**.

1.9 Inferència Aproximada

En general, la inferència exacta a les xarxes bayesianes és computacionalment complexa quan les xarxes són grans (o xarxes densament connectades), i s'han d'utilitzar algorismes aproximats.

Un enfocament per a la inferència aproximada per a xarxes multi-connectades és la **simulació estocàstica**, que utilitza la xarxa per a generar un gran nombre de casos a partir de la distribució de la probabilitat de la xarxa, que al seu torn s'utilitzen per a estimar la probabilitat *a posteriori* que ens interessi (la d'un node de consulta “*query*” donada l'evidència). A mesura que es generen més casos, l'estimació convergeix cap a la probabilitat exacta (per la Llei dels Grans Nombres).

A a la pràctica, si l'evidència a la qual es condiona no és massa improbable ($P(E)$ no és massa petita), l'aproximació convergeix bastant ràpidament!

1.9 a) Logic Sampling (LS)

L'algoritme més simple que farem servir és Logic Sampling (LS) (Henrion, 1988).

Aquest algorisme genera un cas seleccionant aleatòriament valors per a cada node, ponderats per la probabilitat d'aquest valor. Els nodes es recorren des dels nodes arrel fins a les fulles, de manera que a cada pas la probabilitat de ponderació és la probabilitat a priori o la corresponent a la CPT dels valors seleccionats dels pares.

Quan s'han visitat tots els nodes, tenim un “cas” (o “*instance*”) nou, és a dir, una realització de tots els nodes de la XB.

Per a estimar $P(X=x_i / E=e)$ calculem la proporció de casos en què tant $X=x_i$ com $E=e$ són certs dintre dels casos en què $E=e$ és cert.

Així, després de la generació de cada cas, aquestes combinacions es comptabilitzen, segons correspongui.

Problema: si l'evidència $E=e$ és poc probable, la majoria dels casos s'han de descartar, ja que no contribueixen al recompte.

Logic Sampling (LS) Algorithm

Initialization:

- Create a count variable $\text{Count}(xi,e)$ and a count variable $\text{Count}(e)$.
- Initialize both count variables to 0.

For each round of simulation:

1. For all root nodes:
Randomly choose a value for it, weighting the choice by the priors.
2. Loop:
Choose values randomly for children, using the conditional probabilities given the known values of the parents.
Until all the leaves are reached.
3. Update run counts:
If the case includes $E=e$, $\text{Count}(e) \leftarrow \text{Count}(e)+1$
If the case includes $X=xi$ and $E=e$, $\text{Count}(xi,e) \leftarrow \text{Count}(xi,e)+1$

Current estimate for the posterior probability:


$$P(X=xi / E=e) = \text{Count}(xi,e) / \text{Count}(e)$$

1.9 a) Logic Sampling (LS)

Exemple:

Les dues “causes” de C (S i B) comparteixen un pare comú, M .

Considereu aquesta XB en què cada v.a. només té dos valors possibles, és a dir, és binària (T/F).



1.9 a) Logic Sampling (LS)

Anem a veure com seria una ronda de simulació de l'algorisme LS per a l'estimació de $P(M=T / H=T)$ i de $P(M=F / H=T)$.

- M és l'únic node arrel, amb probabilitat *a priori* $P(M=T)=0.2$.
El generador de nombres aleatoris produeix un valor entre 0 i 1; si el nombre és > 0.2 , seleccionem F. En cas contrari, T. Suposem que hem seleccionat F.
- A continuació, s'han de triar els valors dels fills S i B, utilitzant els valors de les CPT $P(S=T / M=F)=0.20$ i $P(B=T / M=F)=0.05$, anàlogament.
Suposem que hem triat aleatòriament els valors $S=T$ i $B=F$.
- Finalment, cal triar anàlogament els valors de C i H ponderats amb les probabilitats $P(C=T / M=F, S=T, B=F) = P(C=T / S=T, B=F)=0.80$ i $P(H=T / M=F, S=T, B=F) = P(H=T / B=F)=0.60$.
Suposem que els valors triats han estat $C=F$ i $H=T$.
- Aleshores, el “cas” complet per a aquesta ronda de simulació és:
 $M=F, S=T, B=F, C=F$ i $H=T$
- Aquest cas afegiria un 1 a la variable de recompte $\text{Count}(H=T)$, un 1 a $\text{Count}(M=F, H=T)$, però no a $\text{Count}(M=T, H=T)$.

1.9 b) Likelihood Weighting (LW)

És una modificació de l'algoritme LS
(Fung and Chang, 1989; Shachter and Peot, 1989).

Aquest algorisme resol el problema que provoca tenir una evidència poc probable a l'algorisme LS, ja que sempre utilitza tots els casos generats, mentre que l'algorisme LS, només aquells en què els nodes de la evidència E prenen el valor que interessa (que seran pocs si aquest valor és poc probable).

Però en lloc d'afegir un 1 al recompte d'execucions (variable comptador corresponent), fa servir les CPT per al node (o nodes) d'evidència per a determinar la probabilitat d'aquesta evidència (o aquesta combinació d'evidències) condicionant a l'estat del(s) pare(s), i és aquesta probabilitat (que no és 1 sinó un nombre entre 0 i 1) la que s'afegeix a la variable comptador.

Likelihood Weighting (LW) Algorithm

Initialization:

- Create a count variable $\text{Count}(x_i, e)$ and a count variable $\text{Count}(e)$
- Initialize both count variables to 0.

For each round of simulation:

1. For all root nodes:

 If a root is the evidence node E ,

 Choose $E=e$, and assign $\text{likelihood}(E=e) \leftarrow P(E=e)$

 Else

 Randomly choose a value for it, weighting the choice by the priors.

2. Loop:

 If a child is the evidence node E ,

 Choose $E=e$, and $\text{likelihood}(E=e) \leftarrow P(E=e / \text{chosen parents values})$

 Else

 Choose values randomly for children, using the conditional probabilities given the known values of the parents.

Until all the leaves are reached.

3. Update run counts:

Since the case necessarily includes $E=e$,

$$\text{Count}(e) \leftarrow \text{Count}(e) + \text{likelihood}(E=e)$$

If the case, moreover, includes $X=x_i$,

$$\text{Count}(x_i, e) \leftarrow \text{Count}(x_i, e) + \text{likelihood}(E=e)$$

Current estimate for the posterior probability:

$$P(X=x_i / E=e) = \text{Count}(x_i, e) / \text{Count}(e)$$

Nota: si l'evidència $E=e$ és una “combinació d'evidències” formada per $\{E_1=e_1, \dots, E_n=e_n\}$, els passos 1. i 2. són iguals, fent-los per a cada $j=1, \dots, n$. L'única diferència és al pas 3:

3. Update run counts:

Since the case necessarily includes $E_1=e_1, \dots, E_n=e_n$,

$$\text{Count}(e) \leftarrow \text{Count}(e) + \prod_j \text{likelihood}(E_j=e_j)$$

If the case, moreover, includes $X=x_i$,

$$\text{Count}(x_i, e) \leftarrow \text{Count}(x_i, e) + \prod_j \text{likelihood}(E_j=e_j)$$

1.9 b) Likelihood Weighting (LW)

El mateix exemple, revisitat:

Anem a veure com seria una ronda de simulació de l'algorisme LW per a estimar $P(C=T / B=T)$, per exemple.

- Trieu un valor per a M (l'únic node arrel) amb $P(M=T)=0.2$ com a probabilitat *a priori*, com amb LS. Suposem que triem $M=F$.
- A continuació, s'han de triar els valors del fill S, utilitzant el valor de la CPT, $P(S=T / M=F)=0.20$. Suposem que s'escull $S=T$.
- B és un node d'evidència, que s'ha de fixar en el valor evidència que és T, és a dir, agafem $B=T$. Com que $P(B=T / M=F)=0.05$, aquest cas que estem generant compta com a 0.05 d'un cas complet.
- Finalment, cal triar el valor de C ponderat amb la probabilitat $P(C=T / M=F, S=T, B=T) = P(C=T / S=T, B=T)=0.80$. Suposem $C=T$. (tingueu en compte que en aquest cas no cal triar un valor per al node H).
- Hem completat una ronda i generat un cas amb una probabilitat de 0.05 que a més de $B=T$, també té $C=T$ donat $B=T$ i, per tant, tant $\text{Count}(B=T)$ com $\text{Count}(C=T, B=T)$ s'incrementen en 0.05.

1.9 c) Kullback-Leibler (KL) divergence

Per avaluar el rendiment d'un algorisme d'inferència aproximada particular, o per a comparar algorismes, utilitzem una mesura de la qualitat de la solució en instant determinat: **la divergència de Kullback-Leibler**, que només es pot aplicar quan la xarxa és tal que es pot calcular la probabilitat *a posteriori* exacta.

DEFINICIÓ: La divergència Kullback-Leibler de la probabilitat a posteriori (actualitzada) per a un node de consulta X donada una evidència $E=e$ és

$$KL(P(X/E=e), P'(X/E=e)) = \sum_{x_i} P(X=x_i/E=e) \log \frac{P(X=x_i/E=e)}{P'(X=x_i/E=e)}$$

on $P(X=x_i / E=e)$ es calcula mitjançant un algorisme exacte, i $P'(X=x_i / E=e)$ mitjançant l'algorisme aproximat que es vol avaluar.

DEFINICIÓ: La divergència Kullback-Leibler de la probabilitat a posteriori (actualitzada) per a un node de consulta X donada una evidència E=e és

$$KL(P(X/E=e), P'(X/E=e)) = \sum_{x_i} P(X=x_i/E=e) \log \frac{P(X=x_i/E=e)}{P'(X=x_i/E=e)}$$

on $P(X=x_i / E=e)$ es calcula mitjançant un algorisme exacte,
i $P'(X=x_i / E=e)$ mitjançant l'algorisme aproximat que es vol avaluar.

PROPIETAT: La divergència de Kullback-Leibler és no-negativa, podria ser $+\infty$ i és $=0$ si i només si per a tot x_i ,

$$P(X=x_i/E=e) = P'(X=x_i/E=e)$$

OBSERVACIONS:

- $KL(P, P')$ és el valor esperat de la diferència logarítmica entre P i P', respecte a la probabilitat P.
- Es defineix amb les convencions $0 \log(0) = 0$ i $0 \log(0/0) = 0$.
- És asimètrica.
- És **finita** si P és absolutament contínua respecte a P' ($P \ll P'$), és a dir, si es compleix la propietat següent:

Per a qualsevol esdeveniment A, si $P'(A)=0$, aleshores $P(A)=0$.

1.9 c) Kullback-Leibler (KL) divergence

PROPIETAT: La divergència de Kullback-Leibler és no-negativa, podria ser $+\infty$ i és $= 0$ si i només si per a tot x_i ,

$$P(X = x_i/E = e) = P'(X = x_i/E = e)$$

Prova:

Denote $g(x) = \frac{P(X = x/E = e)}{P'(X = x/E = e)} \in [0, +\infty]$ and $\varphi(t) = t \log(t)$. Then,

$$\begin{aligned} KL(P(X/E = e), P'(X/E = e)) &= \sum_{x_i} P(X = x_i/E = e) \log \frac{P(X = x_i/E = e)}{P'(X = x_i/E = e)} \\ &= \sum_{x_i} \varphi(g(x_i)) P'(X = x_i/E = e). \end{aligned} \quad (1)$$

By Taylor's development around 1, since $\varphi(1) = 0$,

$$\begin{aligned} \varphi(g(x)) &= \varphi(1) + (g(x) - 1) \varphi'(1) + \frac{1}{2} (g(x) - 1)^2 \varphi''(h(x)) \\ &= (g(x) - 1) \varphi'(1) + \frac{1}{2} (g(x) - 1)^2 \varphi''(h(x)) \end{aligned} \quad (2)$$

where $h(x)$ lies between $g(x)$ and 1 (then, $h(x) \in (0, +\infty)$).

1.9 c) Kullback-Leibler (KL) divergence

Therefore, by (2),

$$\begin{aligned} & \sum_{x_i} \varphi(g(x_i)) P'(X = x_i/E = e) = \\ & \sum_{x_i} \left((g(x_i) - 1) \varphi'(1) + \frac{1}{2} (g(x_i) - 1)^2 \varphi''(h(x_i)) \right) P'(X = x_i/E = e) = \\ & \sum_{x_i} (g(x_i) - 1) \varphi'(1) P'(X = x_i/E = e) + \\ & \sum_{x_i} \frac{1}{2} (g(x_i) - 1)^2 \varphi''(h(x_i)) P'(X = x_i/E = e) = \\ & \sum_{x_i} \frac{1}{2} (g(x_i) - 1)^2 \varphi''(h(x_i)) P'(X = x_i/E = e), \end{aligned} \tag{3}$$

since

$$\begin{aligned} & \sum_{x_i} (g(x_i) - 1) \varphi'(1) P'(X = x_i/E = e) = \\ & \varphi'(1) \sum_{x_i} g(x_i) P'(X = x_i/E = e) - \varphi'(1) \sum_{x_i} P'(X = x_i/E = e) = \\ & \varphi'(1) \times 1 - \varphi'(1) \times 1 = 0, \end{aligned}$$

1.9 c) Kullback-Leibler (KL) divergence

which is a consequence of the fact that

$$\sum_{x_i} g(x_i) P'(X = x_i/E = e) = \sum_{x_i} P(X = x_i/E = e) = \sum_{x_i} P'(X = x_i/E = e) = 1.$$

By replacing (3) into (1), and taking into account that $\varphi''(t) = 1/t$, which is > 0 because $t \in (0, +\infty)$, we have that


$$KL(P(X/E = e), P'(X/E = e)) = \sum_{x_i} \frac{1}{2} (g(x_i) - 1)^2 \varphi''(h(x_i)) P'(X = x_i/E = e) \geq 0 \quad \square$$

Sovint, avaluar el rendiment d'un algorisme d'inferència aproximada particular, o comparar el rendiment de dos algorismes d'inferència aproximada, implica representar la divergència KL en funció del nombre d'iteracions.

Mitjançant aquest procediment s'ha vist experimentalment que:

1. L'algorisme LW té una convergència més ràpida en comparació amb l'algorisme LS.
2. Els mètodes de simulació estocàstica funcionen millor quan la variable d'evidència E està més a prop dels nodes arrel.

1.10 Un exemple de cinema: Armageddon



Quan es tracta de [quantificar el risc](#) associat a algun fenomen, les tècniques tradicionals no són vàlides i les xarxes Bayesianes són una metodologia que pot resultar molt útil.

Armageddon és el títol d'una pel·lícula de desastres de ciència-ficció nord-americana de 1998, dirigida per Michael Bay i protagonitzada per Bruce Willis, Ben Affleck i Liv Tyler.


La pel·lícula explica la història d'un grup de perforadors enviats per la NASA per a intentar aturar un meteorit gegant en un curs de col·lisió contra la Terra.

La probabilitat de col·lisió efectiva del meteorit contra la Terra, de conseqüències molt greus, és alta.

Per això la humanitat s'enfrontava a un risc realment enorme (l'Armageddon bíblic)!

1.10 Un exemple de cinema: Armageddon

Per a trobar un model que ens permeti fer una avaluació de riscos en l'exemple de l'**Armageddon**, farem servir una XB que construïm *ad hoc*.



Considerem variables binàries amb valors “T” (true) o “F” (false). “Pèrdua massiva de vides” significa la pèrdua d'almenys el 80% de la població mundial: l'Armageddon.

L'avaluació del risc serà la probabilitat a posteriori que trobem amb la XB, donada una evidència E, de la variable “Pèrdua massiva de vides”. Abans hem de donar les probabilitats del model, que representen la **força** de les relacions entre les variables.

1.10 Un exemple de cinema: Armageddon

Els valors de probabilitat que donem són simples i venen motivats pel sentit comú i la intuïció.



Marginal

F	0.001
T	0.999

CPT “Impacte contra la Terra”

Meteorit en curs de col·lisió	F		T	
Explotar el meteorit	F	T	F	T
F	1.0	1.0	0.0	0.8
T	0.0	0.0	1.0	0.2

CPT “Pèrdua massiva de vides”

Impacte contra la Terra	F		T	
Població sota terra	F	T	F	T
F	1.0	1.0	0.0	0.4
T	0.0	0.0	1.0	0.6

Meteorit en curs de col·lisió

Explotar el meteorit

Impacte contra la Terra

Població sota terra

Pèrdua massiva de vides

Marginal

F	0.99
T	0.01

Marginal

F	0.70
T	0.30

1.10 Un exemple de cinema: Armageddon

Un cop s'han donat les probabilitats inicials (Marginals *a priori* i CPTs), es pot fer servir la XB per a obtenir totes les mesures de risc que es necessitin, trobant les probabilitats *a posteriori* de “Pèrdua massiva de vides” condicionant a les evidències que es tingui.



Marginal	
F	0.001
T	0.999

CPT “Impacte contra la Terra”

Meteorit en curs de col·lisió	F		T	
Explotar el meteorit	F	T	F	T
F	1.0	1.0	0.0	0.8
T	0.0	0.0	1.0	0.2

CPT “Pèrdua massiva de vides”

Impacte contra la Terra	F		T	
Població sota terra	F	T	F	T
F	1.0	1.0	0.0	0.4
T	0.0	0.0	1.0	0.6

Meteorit en curs de col·lisió

Explotar el meteorit

Impacte contra la Terra

Població sota terra

Pèrdua massiva de vides

Marginal	
F	0.99
T	0.01

Marginal	
F	0.70
T	0.30

1.10 Un exemple de cinema: Armageddon

Primer podem calcular la probabilitat inicial (*a priori*) de T="Pèrdua massiva de vida" (el risc *a priori*): **0.872087**

Ara podem comparar dos escenaris:

1. Bruce i el seu equip no aconsegueixen fer explotar el meteorit. En aquest escenari, el risc d'Armageddon és: **0.87912**
2. Bruce i el seu equip tenen èxit i aconsegueixen fer explotar el meteorit. En aquest escenari, el risc d'Armageddon és: **0.175824**



Observem que el risc d'Armageddon baixa de gairebé 0.88 quan els perforadors no aconsegueixen fer explotar el meteorit, a menys de 0.18 quan ho poden fer.

Aquesta disminució tan gran de les possibilitats de tenir una gran pèrdua de vides explica clarament per què mereixia un intent tan desesperat.

1.10 Un exemple de cinema: Armageddon

L'exemple de l'Armageddon amb gRain

Primer definim les variables i els seus valors, l'estructura i els paràmetres (CPT i marginals):

```
#  
library(gRain)  
#  
tf<-c("false","true")  
#  
# And specify the CPTs:  
#  
Node.Meteor.on.collission.course<-cptable(~ node.Meteor.on.collission.course,  
                                           values=c(0.001,0.999),levels=tf)  
  
Node.Explode.meteor<-cptable(~ node.Explode.meteor, values=c(0.99,0.01), levels=tf)  
  
Node.Move.people.underground<-cptable(~ node.Move.people.underground, values=c(0.70,0.30),  
                                         levels=tf)  
  
##  
Node.Meteor.strikes.Earth<-cptable(~ node.Meteor.strikes.Earth + node.Explode.meteor +  
                                     node.Meteor.on.collission.course,  
                                     values=c(1,0,1,0,0,1,8,2), levels=tf)  
## values=c(1,0,1,0,0,1,1,0), levels=tf)  
  
Node.Loss.of.life<-cptable(~ node.Loss.of.life + node.Move.people.underground +  
                             node.Meteor.strikes.Earth,  
                             values=c(1,0,1,0,0,1,4,6), levels=tf)
```

1.10 Un exemple de cinema: Armageddon

Segon, creem la xarxa Bayesiana: Armageddon.net

```
#  
# Create an intermediate representation of the CPTs:  
#  
plist<-compileCPT(list(Node.Meteor.on.collission.course,Node.Explode.meteor,  
                        Node.Move.people.underground,  
                        Node.Meteor.strikes.Earth, Node.Loss.of.life))  
  
plist  
  
plist$node.Meteor.on.collission.course  
plist$node.Explode.meteor  
plist$node.Move.people.underground  
plist$node.Meteor.strikes.Earth  
plist$node.Loss.of.life  
#  
#  
# Create network:  
#  
Armageddon.net<-grain(plist)|  
summary(Armageddon.net)  
plot(Armageddon.net)  
#
```

1.10 Un exemple de cinema: Armageddon

En tercer lloc, fem servir la xarxa Bayesiana per a obtenir les marginals de totes les variables.

```
#  
# The marginal probability of each variable (EXACT!!!):  
#  
querygrain(Armageddon.net,nodes=c("node.Meteor.on.collision.course",  
                                   "node.Explode.meteor",  
                                   "node.Meteor.strikes.Earth",  
                                   "node.Move.people.underground",  
                                   "node.Loss.of.life"),  
           type="marginal")  
"
```

Finalment, introduïm les evidències i calculem les probabilitats a posteriori de T.

```
#  
Armageddon.net.fail<-setEvidence(Armageddon.net,nodes=c("node.Explode.meteor"), states=c("false"))  
  
marg.fail=querygrain(Armageddon.net.fail,nodes=c("node.Loss.of.life"), type="marginal")  
marg.fail  
#  
#  
#  
Armageddon.net.success<-setEvidence(Armageddon.net,nodes=c("node.Explode.meteor"), states=c("true"))  
  
marg.success=querygrain(Armageddon.net.success,nodes=c("node.Loss.of.life"), type="marginal")  
marg.success|  
#
```

1.10 Un exemple de cinema: Armageddon

Podem comparar diferents escenaris. Per exemple, amb la CPT següent:

CPT “Impacte contra la Terra”

Meteorit en curs de col·lisió	F		T	
Explotar el meteorit	F	T	F	T
F	1.0	1.0	0.0	0.8
T	0.0	0.0	1.0	0.2

obteníem que si Bruce i el seu equip aconseguixen fer explotar el meteorit, el risc d’Armageddon $P(\text{“Pèrdua massiva de vides”} = T)$ és: **0.175824**



Què hauria passat si, en el seu lloc, haguéssim fet server aquesta altra CPT?

CPT “Impacte contra la Terra”

Meteorit en curs de col·lisió	F		T	
Explotar el meteorit	F	T	F	T
F	1.0	1.0	0.0	1.0
T	0.0	0.0	1.0	0.0

En aquest cas, hauríem obtingut que si Bruce i el seu equip fan explotar el meteorit, el risc d’Armageddon és 0!! (clar, és el més lògic!!)


1.10 Un ejemplo de cinema: Armageddon

... de cinema?

La NASA estrella con éxito la nave Dart contra el asteroide Dimorphos en una misión histórica para proteger la Tierra

Jonathan Amos
Corresponsal de Ciencia, BBC


27 septiembre 2022



NASA/JHU-APL

Ilustración del impacto entre Dart y Dimorphos.

La misión de la NASA impactará contra la miniluna del asteroide



Fuente: NASA, Laboratorio de Física Aplicada de la Universidad Johns Hopkins

BBC