

Tema 1

Introducció a les xarxes Bayesianes

Bloc A) Introducció a l'assignatura

Bloc B) Conceptes preliminars i
definicions bàsiques

Bloc C) Inferència amb XBs

Bloc D) Aprenentatge de XBs: paràmetres

Bloc E) Aprenentatge de XBs: estructura

Tema 1. Bloc D)

Aprenentatge de XBs: paràmetres

1.11 Aprenentatge de paràmetres

1.12 L'aproximació MLE

1.13 Dades faltants: l'algorisme EM

1.14 Aprenentatge de paràmetres amb **bnlearn**

1.11 Aprenentatge de paràmetres

Fins ara hem assumit que coneixíem les distribucions de probabilitat condicionades i les distribucions marginals dels nodes pares (paràmetres) de les xarxes bayesianes que hem presentat.

Però no ens ha preocupat com els hem aconseguit!

A la pràctica es poden obtenir o bé:

- A partir de la opinió subjectiva d'un expert en la matèria (difícil en el cas de les xarxes grans, amb molts nodes i/o connexions).
- A partir de dades.

Un cop s'especifica un model (XB) amb els seus paràmetres hom està en condicions d'avaluar el seu ajustament a les dades observades, s'hagin fet servir o no per a aprendre el model.

Una manera d'aprendre (estimar) els paràmetres és triar-los de manera que el corresponent model sigui el que millor s'ajusti a les dades. És el mètode **MLE (Estimació de la Màxima Versemblança)**.

1.12 L'aproximació MLE


L'Estimació de la Màxima Versemblança (MLE) és un enfocament estàndard per a l'estimació i inferència de paràmetres en Estadística.

Considerat una de les aportacions més importants a l'Estadística del segle XX. Va ser obra d'un sol home, **Sir Ronald Aylmer Fisher** (1890-1962), però no va ser gens senzill fer-ho: entre 1912 i 1922, va produir tres justificacions diferents!



Fisher el 1912,
amb 20 anys.

Amb la seva calculadora
a Whittingehame Lodge,
el 1952, 40 anys després.



1.12 L'aproximació MLE

Sigui (Γ, P) una XB amb $\Gamma=(V, E)$ i $V=\{X_1, \dots, X_n\}$.

Suposem que les v.a. siguin totes discretes (XB estàndards)

Sigui $\mathbf{x}=(x_1, \dots, x_n)$ un vector de dades que és la realització de les v.a. $X_1, \dots, X_n$, i sigui $D=\{\mathbf{x}_1, \dots, \mathbf{x}_M\}$ un conjunt de M vectors de dades (cada vector de dades s'anomena *“cas”* o *“instance”*).

L'objectiu ara és identificar la població (és a dir, la distribució de probabilitat conjunta P) que és més probable que hagi generat les dades observades.

Associat a la distribució de probabilitat conjunta P hi ha un vector de paràmetres θ . El MLE de θ és el valor de θ tal que el model amb aquest vector de paràmetres és el que és més probable que hagi generat el conjunt de dades D .

La funció de versemblança

Donat el conjunt de dades d'entrenament, $D=\{\mathbf{x}_1, \dots, \mathbf{x}_M\}$, que consisteix on M casos, la funció de versemblança es defineix per:

$$L(\theta) = P(D/\theta) = \prod_{i=1}^M P(\mathbf{x}_i/\theta)$$

És a dir, la versemblança de que D estigui generat pel model amb paràmetre (vector) θ , és el producte de les probabilitats d'observar cada cas $\mathbf{x}_i$, donat el model.

Estimador de la Màxima Versemblança (MLE)

S'estima θ per $\theta_{MLE} = \arg \max_{\theta} \ln L(\theta)$, i aleshores s'aproxima la probabilitat d'un nou cas $\mathbf{x}$, donat el conjunt de dades d'entrenament D , com $P(\mathbf{x} / D) \approx P(\mathbf{x} / \theta_{MLE})$

MLE **no** assumeix cap distribució a priori dels paràmetres θ .

Un exemple molt simple:


Sigui (Γ, P) una XB amb $\Gamma=(V, E)$ i $V=\{X_1, \dots, X_n\}$ (suposem que les v.a. són discretes). Per simplicitat, agafem $n=2$.


Il·lustrarem l'ús del mètode MLE d'aprenentatge de paràmetres en una XB amb aquest exemple en el què les dues variables X_1 i X_2 són binàries i prenen els valors 0 i 1.

Anàlogament es faria si prenguessin més valors.

Els paràmetres no redundants d'aquesta XB són 3:

θ_{11} , θ_{21} i θ_{22} , i el vector de paràmetres és: $\theta=(\theta_{11}, \theta_{21}, \theta_{22})$





Sigui $\mathbf{x}=(x_1,x_2)$ un vector de dades corresponent a les v.a. X_1, X_2 (o sigui, que és una realització del vector (X_1, X_2)), i sigui $D=\{\mathbf{x}_1,\dots,\mathbf{x}_M\}$ un conjunt de M vectors de dades diferents (“casos”).

L'objectiu és identificar la població (és a dir, la distribució de probabilitat conjunta) que és més probable que hagi generat les dades observades.

No assumim cap distribució a priori del paràmetre θ .

L'estimador MLE de θ és el valor (vector) que és més probable que hagi generat el conjunt de dades D .

Donades les dades observades, $D=\{\mathbf{x}_1, \dots, \mathbf{x}_M\}$, que consisteixen en M casos, la [funció de versemblança](#) associada a D i al model (XB) amb vector de paràmetres θ és:

$$\begin{aligned}
 L(\theta) &= P((X_1^1, X_2^1) = (x_1^1, x_2^1), \dots, (X_1^M, X_2^M) = (x_1^M, x_2^M) / \theta) \\
 &= \prod_{i=1}^M P((X_1^i, X_2^i) = (x_1^i, x_2^i) / \theta) \\
 &= \prod_{i=1}^M P(X_1^i = x_1^i / \theta) P(X_2^i = x_2^i / X_1^i = x_1^i, \theta) \\
 &= \prod_{i=1}^M \theta_{11}^{x_1^i} (1 - \theta_{11})^{1-x_1^i} \theta_{21}^{x_2^i x_1^i} (1 - \theta_{21})^{(1-x_2^i) x_1^i} \\
 &\quad \theta_{22}^{x_2^i (1-x_1^i)} (1 - \theta_{22})^{(1-x_2^i) (1-x_1^i)} \\
 &= \theta_{11}^{s_{11}} (1 - \theta_{11})^{t_{11}} \theta_{21}^{s_{21}} (1 - \theta_{21})^{t_{21}} \theta_{22}^{s_{22}} (1 - \theta_{22})^{t_{22}}
 \end{aligned}$$

És a dir,

$$L(\theta) = \theta_{11}^{s_{11}} (1 - \theta_{11})^{t_{11}} \theta_{21}^{s_{21}} (1 - \theta_{21})^{t_{21}} \theta_{22}^{s_{22}} (1 - \theta_{22})^{t_{22}}$$

on:

$$\theta = (\theta_{11}, \theta_{21}, \theta_{22})$$

s_{11} = number of cases for which $X_1 = 1$

t_{11} = number of cases for which $X_1 = 0$

s_{21} = number of cases for which $X_2 = 1$ and $X_1 = 1$

t_{21} = number of cases for which $X_2 = 0$ and $X_1 = 1$

s_{22} = number of cases for which $X_2 = 1$ and $X_1 = 0$

t_{22} = number of cases for which $X_2 = 0$ and $X_1 = 0$

Note that $s_{11} + t_{11} = M$

$$s_{21} + t_{21} + s_{22} + t_{22} = M$$

$$\ln(L(\theta)) = s_{11} \ln(\theta_{11}) + t_{11} \ln(1 - \theta_{11}) + s_{21} \ln(\theta_{21}) + t_{21} \ln(1 - \theta_{21}) \\ + s_{22} \ln(\theta_{22}) + t_{22} \ln(1 - \theta_{22})$$

$$\frac{\partial \ln(L(\theta))}{\partial \theta_{11}} = \frac{s_{11}}{\theta_{11}} - \frac{t_{11}}{1 - \theta_{11}} = 0 \Rightarrow \hat{\theta}_{11} = \frac{s_{11}}{s_{11} + t_{11}} = \frac{s_{11}}{M}$$

$$\frac{\partial \ln(L(\theta))}{\partial \theta_{21}} = \frac{s_{21}}{\theta_{21}} - \frac{t_{21}}{1 - \theta_{21}} = 0 \Rightarrow \hat{\theta}_{21} = \frac{s_{21}}{s_{21} + t_{21}} \quad \text{if } s_{21} + t_{21} > 0$$

$$\frac{\partial \ln(L(\theta))}{\partial \theta_{22}} = \frac{s_{22}}{\theta_{22}} - \frac{t_{22}}{1 - \theta_{22}} = 0 \Rightarrow \hat{\theta}_{22} = \frac{s_{22}}{s_{22} + t_{22}} \quad \text{if } s_{22} + t_{22} > 0$$

Per a comprovar que $\hat{\theta} = (\hat{\theta}_{11}, \hat{\theta}_{21}, \hat{\theta}_{22})$ és l'estimador MLE,

hem de trobar la matriu Hessiana:

$$H(\ln(L(\theta))) = \begin{pmatrix} \frac{\partial^2 \ln(L(\theta))}{\partial \theta_{11}^2} & \frac{\partial^2 \ln(L(\theta))}{\partial \theta_{11} \partial \theta_{21}} & \frac{\partial^2 \ln(L(\theta))}{\partial \theta_{11} \partial \theta_{22}} \\ \frac{\partial^2 \ln(L(\theta))}{\partial \theta_{21} \partial \theta_{11}} & \frac{\partial^2 \ln(L(\theta))}{\partial \theta_{21}^2} & \frac{\partial^2 \ln(L(\theta))}{\partial \theta_{21} \partial \theta_{22}} \\ \frac{\partial^2 \ln(L(\theta))}{\partial \theta_{22} \partial \theta_{11}} & \frac{\partial^2 \ln(L(\theta))}{\partial \theta_{22} \partial \theta_{21}} & \frac{\partial^2 \ln(L(\theta))}{\partial \theta_{22}^2} \end{pmatrix} \quad \text{i calcular les derivades segones:}$$

$$H(\ln(L(\theta))) = \begin{pmatrix} -\frac{s_{11}}{\theta_{11}^2} - \frac{t_{11}}{(1-\theta_{11})^2} & 0 & 0 \\ 0 & -\frac{s_{21}}{\theta_{21}^2} - \frac{t_{21}}{(1-\theta_{21})^2} & 0 \\ 0 & 0 & -\frac{s_{22}}{\theta_{22}^2} - \frac{t_{22}}{(1-\theta_{22})^2} \end{pmatrix}$$

La matriu Hessiana és una matriu definida negativa per a tots els possibles valors de θ_{11} , θ_{21} i θ_{22} .

Aleshores, $L(\theta)$ aconseguix arribar a un màxim local (que, de fet, és un màxim **GLOBAL**) a $\hat{\theta} = (\hat{\theta}_{11}, \hat{\theta}_{21}, \hat{\theta}_{22})$.

Aleshores,

$$\theta_{MLE} = \hat{\theta} = \left(\frac{s_{11}}{M}, \frac{s_{21}}{s_{21} + t_{21}}, \frac{s_{22}}{s_{22} + t_{22}} \right)$$

En general:

Els paràmetres de la xarxa bayesiana són de la forma:

$$\theta_{x/u} = P(X=x / PA(X)=u)$$

on X representa qualsevol node de V i $PA(X)$ és el conjunt de nodes de V que són pares de X . Suposem que tots els paràmetres estan ben definits.

Sigui θ el vector de paràmetres, les components del qual són els paràmetres del model, i sigui $L(\theta | D)$ la funció de versemblança associada al vector de paràmetres i al conjunt de dades disponibles D .

Aleshores, l'estimador MLE és el valor de (vector) que maximitza la funció de versemblança (equivalentment, el seu logaritme), és a dir,

$$\theta^{MLE} = \operatorname{argmax}_{\theta} L(\theta | D) = \operatorname{argmax}_{\theta} \log(L(\theta | D)) .$$

TEOREMA 3 (Th. 17. 1 Darwiche, 2009)

Si D , el conjunt de dades disponibles (seran les dades d'entrenament), està compost per M casos **complets** (sense valors faltants), aleshores l'estimador MLE de θ , θ^{MLE} , verifica que les seves components s'obtenen a partir de la **funció de distribució empírica**, és a dir,

$$\theta_{x/u}^{MLE} = \# D(x,u) / \# D(u)$$

on $\# D(x,u)$ és el cardinal del conjunt de casos de D per als quals $X = x$ i $PA(X) = u$, mentre que $\# D(u)$ és el cardinal de conjunt de casos de D per als quals simplement $PA(X) = u$.

Pel Teorema 3, doncs, si el conjunt de dades d'entrenament està compost únicament per **complets**, l'estimador MLE de θ , θ^{MLE} , **EXISTEIXS I ÉS ÚNIC !**

TEOREMA 4 (Th. 17.2 Darwiche, 2009)

Si D , el conjunt de dades disponibles (les dades d'entrenament), està compost per M casos **complets** (sense valors faltants), aleshores l'estimador MLE de θ , θ^{MLE} , minimitza la divergència de Kullback-Leibler entre la distribució de probabilitat empírica P^* que assigna a un esdeveniment la seva freqüència relativa al conjunt D , i la distribució de probabilitat P_θ associada a la XB (la distribució de probabilitat conjunta de les variables aleatòries de V implementada en la XB), amb vector de paràmetres θ , és a dir,

$$\begin{aligned}\theta^{MLE} & \left(= \operatorname{argmax}_{\theta} L(\theta | D) \right) \\ & = \operatorname{argmin}_{\theta} \operatorname{KL}(P^*, P_\theta)\end{aligned}$$

1.13 Dades faltants: l'algorisme EM

Fins ara hem considerat conjunts de dades en què es registra cada valor de cada variable en cada cas, és a dir, a les quals els casos són sempre **complets**.

A continuació considerem el cas en què alguns valors d'alguns casos de la base de dades podrien ser desconeguts, per simples **omissions aleatòries** a causa de problemes d'enregistrament o per algun error similar.

L'estimador MLE que fem servir quan tots els casos són **complets** té una sèrie de propietats molt interessants:

- és únic,
- és asimptòticament Normal, i
- maximitza la probabilitat d'observar amb el model les dades que realment hem observat (maximitza la funció de versemblança).

I la corresponent estimació per al vector de paràmetres θ es pot calcular fàcilment a partir d'un conjunt de dades.

Però què passa si tenim **dades faltants** (casos incomplets)?

L'algorisme **EM** ([*Expectation Maximization*](#)) és un procediment iteratiu per a trobar el MLE amb dades faltants, desenvolupat per Nan McKenzie Laird (1943) i James Ware, de la Universitat de Harvard.

Nan Laird és una matemàtica i estadística estatunidenca, emèrita en bioestadística a la Harvard School of Public Health. Va ser la primera dona en guanyar el [**International Prize in Statistics**](#) (considerat el premi més important, el "Nobel", en Estadística).

Es dedica especialment a l'anàlisi de les dades longitudinals i la seva aplicació a la medicina i la psicologia, que segueix activa en la investigació a dia d'avui.



Va presentar l'algorisme EM per a trobar el MLE amb dades incompletes a l'article: [*"Maximum Likelihood from Incomplete Data via the EM Algorithm"*](#), amb A.P. Dempster i D.B. Rubin, al *Journal of the Royal Statistical Society, Series B (Methodological)*, vol. 39(1), pp. 1-38, **1977** (fa més de 45 anys!). Té més de **60 000** cites a Google Scholar!!!



James Hutchinson Ware (1941-2016), va ser un bioestadístic i també professor a la Harvard School of Public Health. Entre altres coses, va ser president de la Eastern North America Region de la International Biometric Society.

Entre molts altres treballs, va ser co-autor, juntament amb la Nan Laird, de l'article publicat a la revista *Biometrics* l'any **1982**:

“Random Effects Models for Longitudinal Data”,
considerat un clàssic en el camp de la bioestadística.

Expectation Maximization (EM)

- És un mètode que cerca estimacions MLE del paràmetre a partir de dades incompletes, basat en la cerca local que comença amb algunes estimacions inicials i després les va millorant iterativament fins que es compleix alguna condició d'aturada.
- Aquest mètode és generalment més costós que el mètode per a dades completes (és el preu a pagar per no tenir tots els casos complets!) i, naturalment, no es pot garantir que s'acabi trobant les estimacions MLE.

Expectation Maximization (EM)

La idea del mètode EM és la següent:

1. primer es “completen” els casos incomplets del conjunt de dades, és a dir, fem **imputació**, però d’una manera determinada, i
2. després s’utilitzen aquestes dades “completades” per a trobar els estimadors MLE com quan tots els casos eren complets.

Amb l’algorisme EM es garanteix que en cada pas del procediment iteratiu, la versemblança del model amb la nova estimació del vector de paràmetres per a les dades originals no és inferior que amb l’anterior estimació.

I així es va iterant, repetint el procediment, fins que es compleixi alguna condició de convergència que el faci aturar.

Tornem a l'exemple que teníem:



$$\theta_{11} = P(X_1 = 1)$$

$$\theta_{21} = P(X_2 = 1 \mid X_1 = 1)$$

$$\theta_{22} = P(X_2 = 1 \mid X_1 = 0)$$

El nostre objectiu és trobar estimacions MLE pels paràmetres θ_{11} , θ_{21} i θ_{22} , a partir del següent conjunt de dades incompletes

$D = \{\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3, \mathbf{x}_4, \mathbf{x}_5\}$ ($M=5$)

Cas	X_1	X_2
1	1	1
2	1	?
3	1	1
4	1	0
5	0	?

Això és, tenim les dades:

$\mathbf{x}_1=(1,1)$, $\mathbf{x}_2=(1,?)$, $\mathbf{x}_3=(1,1)$, $\mathbf{x}_4=(1,0)$, $\mathbf{x}_5=(0,?)$

Suposem a més que comencem amb les

estimacions inicials $\theta_{11}^0 = 0.25$, $\theta_{21}^0 = 0.80$, $\theta_{22}^0 = 0.40$

La funció de versemblança de la XB amb aquests valors dels paràmetres per al conjunt de dades D és:

$$\begin{aligned}
L(\theta^0/D) &= \prod_{i=1}^{M=5} P(\mathbf{x}_i/\theta^0) \\
&= P_{\theta^0}(X_1 = 1, X_2 = 1) P_{\theta^0}(X_1 = 1) P_{\theta^0}(X_1 = 1, X_2 = 1) P_{\theta^0}(X_1 = 1, X_2 = 0) P_{\theta^0}(X_1 = 0) \\
&= (\theta_{21}^0 \theta_{11}^0) \times \theta_{11}^0 \times (\theta_{21}^0 \theta_{11}^0) \times ((1 - \theta_{21}^0) \theta_{11}^0) \times (1 - \theta_{11}^0) \\
&= 0.80 \times 0.25 \times 0.25 \times 0.80 \times 0.25 \times 0.20 \times 0.25 \times 0.75 \\
&= 0.000375
\end{aligned}$$

Tingueu en compte que si tots els casos fossin complets, cada terme d'aquest producte es podria avaluar mitjançant la regla de la cadena per a xarxes Bayesianes. En canvi, en aquest cas (dades incompletes), avaluar els termes d'aquest producte generalment requereix fer inferència a la XB.

Per exemple, imagineu que un cas fos $x=(?,0)$. Aleshores, el terme corresponent en el producte de la funció de versemblança seria:

$$\begin{aligned}
P_{\theta^0}(X_2 = 0) &= P_{\theta^0}(X_2 = 0/X_1 = 1) P_{\theta^0}(X_1 = 1) + P_{\theta^0}(X_2 = 0/X_1 = 0) P_{\theta^0}(X_1 = 0) \\
&= (1 - \theta_{21}^0) \times \theta_{11}^0 + (1 - \theta_{22}^0) \times (1 - \theta_{11}^0) \\
&= 0.20 \times 0.25 + 0.60 \times 0.75 = 0.5
\end{aligned}$$

Cas	X_1	X_2
1	1	1
2	1	?
3	1	1
4	1	0
5	0	?

En primer lloc, hem de completar el conjunt de dades incompletes **D**, i després l'utilitzarem per a estimar els paràmetres com amb l'enfocament MLE amb dades completes.

En aquest cas, hi ha quatre completacions possibles:

Cas	X_1	X_2
1	1	1
2	1	1
3	1	1
4	1	0
5	0	1

Cas	X_1	X_2
1	1	1
2	1	1
3	1	1
4	1	0
5	0	0

Cas	X_1	X_2
1	1	1
2	1	0
3	1	1
4	1	0
5	0	1

Cas	X_1	X_2
1	1	1
2	1	0
3	1	1
4	1	0
5	0	0

Encara que no sabem quina d'aquestes completacions és la correcta, podem calcular la probabilitat de cada completació a partir del conjunt inicial de paràmetres que tenim:

Completacions			
Cas	X_1	X_2	$P_0(\cdot / x_i)$
1	1	1	1
2	1	1	$P_0(X_2=1/X_1=1)=\theta_{21}=0.80$
2	1	0	$P_0(X_2=0/X_1=1)=1-\theta_{21}=0.20$
3	1	1	1
4	1	0	1
5	0	1	$P_0(X_2=1/X_1=0)=\theta_{22}=0.40$
5	0	0	$P_0(X_2=0/X_1=0)=1-\theta_{22}=0.60$

Probabilitat de les variables amb valors faltants en el cas x_i , sota θ_0 .

A partir d'aquesta taula podem obtenir una distribució empírica esperada per a les variables X_1 i X_2 :

Completacions			
Cas	X_1	X_2	$P_o(/ x_i)$
1	1	1	1
2	1	1	0.80
2	1	0	0.20
3	1	1	1
4	1	0	1
5	0	1	0.40
5	0	0	0.60

Distribució empírica esperada

X_1	X_2	
1	1	0.56
1	0	0.24
0	1	0.08
0	0	0.12
		+1

$$(1+0.80+1)/5=0.56$$

$$(0.20+1)/5=0.24$$

$$0.40/5=0.08$$

$$0.60/5=0.12$$

I ara podem utilitzar aquesta distribució empírica esperada per a estimar els paràmetres de la manera següent:

$$\hat{\theta}_{11}^1 = 0.56 + 0.24 = 0.80$$

$$\hat{\theta}_{21}^1 = \frac{0.56}{0.56 + 0.24} = \frac{0.56}{0.80} = 0.7$$

$$\hat{\theta}_{22}^1 = \frac{0.08}{0.08 + 0.12} = \frac{0.08}{0.20} = 0.4$$

$$\begin{aligned}
L(\theta^1/D) &= \prod_{i=1}^{M=5} P(\mathbf{x}_i/\theta^1) \\
&= P_{\theta^1}(X_1 = 1, X_2 = 1) P_{\theta^1}(X_1 = 1) P_{\theta^1}(X_1 = 1, X_2 = 1) P_{\theta^1}(X_1 = 1, X_2 = 0) P_{\theta^1}(X_1 = 0) \\
&= (\theta_{21}^1 \theta_{11}^1) \times \theta_{11}^1 \times (\theta_{21}^1 \theta_{11}^1) \times ((1 - \theta_{21}^1) \theta_{11}^1) \times (1 - \theta_{11}^1) \\
&= 0.70 \times 0.80 \times 0.80 \times 0.70 \times 0.80 \times 0.30 \times 0.80 \times 0.20 \\
&= 0.01204224 \text{ (} > L(\theta^0/D) = 0.000375 \text{)}
\end{aligned}$$

Per tant, les noves estimacions tenen una versemblança més alta que les inicials amb les quals vam començar:

Iteration	$i = 0$	$i = 1$
θ_{11}^i	0.25	0.80
θ_{21}^i	0.80	0.70
θ_{22}^i	0.40	0.40
$L(\theta^i/D)$	0.000375	0.01204224

I ara podem tornar a calcular la probabilitat de cada completació a partir de la nova estimació dels paràmetres que tenim:

Completacions			
Cas	X_1	X_2	$P_1(\cdot / x_i)$
1	1	1	1
2	1	1	$P_1(X_2=1/X_1=1)=\theta_{21}=0.70$
2	1	0	$P_1(X_2=0/X_1=1)=1-\theta_{21}=0.30$
3	1	1	1
4	1	0	1
5	0	1	$P_1(X_2=1/X_1=0)=\theta_{22}=0.40$
5	0	0	$P_1(X_2=0/X_1=0)=1-\theta_{22}=0.60$

Probabilitat de les variables amb valors faltants en el cas x_i , sota θ_1 .

A partir d'aquesta taula podem obtenir una nova distribució empírica esperada per a les variables X_1 i X_2 :

Completacions			
Cas	X_1	X_2	$P_1(/ x_i)$
1	1	1	1
2	1	1	0.70
2	1	0	0.30
3	1	1	1
4	1	0	1
5	0	1	0.40
5	0	0	0.60

Distribució empírica esperada

X_1	X_2	
1	1	0.54
1	0	0.26
0	1	0.08
0	0	0.12
		+1

$$(1+0.70+1)/5=0.54$$

$$(0.30+1)/5=0.26$$

$$0.40/5=0.08$$

$$0.60/5=0.12$$

I ara podem utilitzar aquesta distribució empírica esperada per trobar la nova estimació dels paràmetres:

$$\hat{\theta}_{11}^2 = 0.54 + 0.26 = 0.80$$

$$\hat{\theta}_{21}^2 = \frac{0.54}{0.54 + 0.26} = \frac{0.54}{0.80} = 0.675$$

$$\hat{\theta}_{22}^2 = \frac{0.08}{0.08 + 0.12} = \frac{0.08}{0.20} = 0.40$$

$$\begin{aligned}
 L(\theta^2/D) &= \prod_{i=1}^{M=5} P(\mathbf{x}_i/\theta^2) \\
 &= P_{\theta^2}(X_1 = 1, X_2 = 1) P_{\theta^2}(X_1 = 1) P_{\theta^2}(X_1 = 1, X_2 = 1) P_{\theta^2}(X_1 = 1, X_2 = 0) P_{\theta^2}(X_1 = 0) \\
 &= (\theta_{21}^2 \theta_{11}^2) \times \theta_{11}^2 \times (\theta_{21}^2 \theta_{11}^2) \times ((1 - \theta_{21}^2) \theta_{11}^2) \times (1 - \theta_{11}^2) \\
 &= 0.675 \times 0.80 \times 0.80 \times 0.675 \times 0.80 \times 0.325 \times 0.80 \times 0.20 \\
 &= 0.01213056 (> L(\theta^1/D) = 0.01204224)
 \end{aligned}$$

I les noves estimacions ens donaran un model amb una versemblança no menor que les anteriors...

Iteration	$i = 0$	$i = 1$	$i = 2$
θ_{11}^i	0.25	0.80	0.80
θ_{21}^i	0.80	0.70	0.675
θ_{22}^i	0.40	0.40	0.40
$L(\theta^i/D)$	0.000375	0.01204224	0.01213056

Augmentant versemblança

Iteration	$i = 0$	$i = 1$	$i = 2$
$\theta_{11}^i = P(X_1 = 1)$	0.25	0.80	0.80
θ_{21}^i	0.80	0.70	0.675
θ_{22}^i	0.40	0.40	0.40
$L(\theta^i/D)$	0.000375	0.01204224	0.01213056
$P(X_2 = 1)$	0.5	0.64	0.62

$$\begin{aligned}
 P(X_2 = 1) &= P(X_2 = 1/X_1 = 1) P(X_1 = 1) + P(X_2 = 1/X_1 = 0) P(X_1 = 0) \\
 &= \theta_{21} \theta_{11} + \theta_{22} (1 - \theta_{11})
 \end{aligned}$$

Nota: l'algorisme acaba després d'un nombre prefixat d'iteracions, o bé quan les diferències entre avaluacions successives de la funció de versemblança (o del logaritme de la funció de versemblança) siguin molt petites (< un **llindar** fix).

Aquest algorisme es coneix com l'algorisme

“ML-EM (Maximum Likelihood Expectation Maximization)”.

- ✓ Converteix a un **màxim local** de la funció de versemblança, però l'algorisme pot convergir a diferents estimacions dels paràmetres (amb diferents versemblances) depenent de les estimacions inicials θ_0 .
- ✓ Per tant, no és estrany executar l'algorisme diverses vegades, començant amb estimacions diferents en cada iteració (potser escollides aleatòriament) i després retornant les millors estimacions trobades en totes les iteracions (versemblança més gran).
- ✓ Se sap que l'algorisme EM convergeix molt lentament si la proporció de dades faltants és bastant gran, encara que es pot modificar per a fer-lo més ràpid.

1.14 Aprenentatge de paràmetres amb bnlearn

Recordeu que hem vist que existeixen diferents maneres de crear una XB amb **bnlearn**. Concretament, a partir d'un objecte de classe **bn** que només té l'estructura, crearem un objecte de classe **bn.fit** que a més té els paràmetres, o sigui, crearem la XB:

1. Expert-driven approach: en què els paràmetres són especificats per l'usuari mitjançant la funció **custom.fit()**, que pren un objecte de classe **bn** que codifica l'estructura d'una xarxa, i una llista amb els paràmetres, que són les probabilitats de les distribucions condicionades dels nodes als seus pares, i les marginals dels nodes arrel.

Per a seguir aquest enfocament, és preferible el paquet **gRain** de R!

2. Data-driven approach: aprenent els paràmetres de la XB a partir d'un conjunt de dades, utilitzant la funció **bn.fit()** a la qual se li ha d'introduir una estructura (un objecte de classe **bn**).
3. Hybrid approach: combina els dos anteriors, utilitzant l'operador d'assignació a un objecte de classe **bn.fit**, que el que fa es reemplaçar alguns valors dels paràmetres pels valors que li introduïm.


Ho veurem amb un exemple:

Considerem la XB que té aquest DAG (estructura). Les variables X_1 i X_2 són booleans (pren valors true/false). Els paràmetres són:

$$\theta_{11} = P(X_1 = \text{true}) = 0.25$$

$$\theta_{21} = P(X_2 = \text{true} / X_1 = \text{true}) = 0.80$$

$$\theta_{22} = P(X_2 = \text{true} / X_1 = \text{false}) = 0.40$$




Hem generat un conjunt aleatori de 500 casos a partir de la XB (seguint la distribució de probabilitat conjunta P donada per la CPT de X_2 condicionada a X_1 , i la distribució de probabilitat de X_1 , per la Regla de la Cadena).

Aquest conjunt de dades s'anomena: “[Ejemplo_1.rdata](#)” i quan el carregueu amb R tindreu un dataframe de nom “**ejemplo_1**”.

Si haguéssim oblidat els valors dels paràmetres, podríem aplicar la metodologia per a l'aprenentatge de paràmetres implementada al paquet **bnlearn** per aprendre els paràmetres a partir de les dades (i després podem comparar amb els valors reals!).

Amb **bnlearn**, primer hem de crear un objecte de classe **bn** amb l'estructura gràfica de la xarxa bayesiana (el DAG). En aquest cas, el crearem “a mà”. Al bloc E veurem com aprendre'l a partir de les dades.



```
library(bnlearn)
library(Rgraphviz)
# Now we create a empty network:
names<-c("X1","X2")
net=empty.graph(names)
net
class(net)
# we see that “net” is a bn object.
```

Now introduce the arrows:

```
arcs(net,ignore.cycles=TRUE)=  
matrix(c("X1","X2"), ncol=2, byrow=TRUE,  
dimnames=list(c(),c("from","to")))
```

#

net

The graph:

```
plot1<-graphviz.plot(net)
```

```
plot1
```

```
#####
```

Alternatively, we could introduce arrows in this way:


```
mat=matrix(c(0,1,0,0),nrow=2,byrow=TRUE,  
dimnames=list(nodes(net),nodes(net)))
```

```
mat
```

```
net2=empty.graph(names)
```

```
amat(net2)=mat
```

```
all.equal(net,net2)
```



```
# Or even...
```

```
net3=empty.graph(names)
```

```
# or
```

```
net3=empty.graph(nodes(net))
```

```
#
```

```
net3=set.arc(net3, "X1","X2")
```

```
all.equal(net,net3)
```

```
#####
```

```
# Now we load the data randomly generated from the Bayesian  
network: data frame “ejemplo_1”.
```

```
# We estimate the probabilities constructing an object bn.fit:
```

```
net.estimated=bn.fit(net, ejemplo_1, method="mle")
```


```
net.estimated
```

```
class(net.estimated)
```

```
# We can save coefficients in a list named “coef”:
```

```
coef<-coefficients(net.estimated)
```

```
str(coef)
```



```
> coef[1]
```

```
$X1
```

```
      false   true
```

```
0.042 0.740 0.218
```

Normalizing



X_1	False (0)	True (1)
	0.7724425887	$\theta_{11} = 0.2275574113$

```
> #
```

```
> coef[2]
```

```
$X2
```

```
      X1
```

```
X2
```

```
      false
```

```
      true
```

```
0.00000000 0.04324324 0.05504587
```

```
false 0.28571429 0.54594595 0.16513761
```

```
true  0.71428571 0.41081081 0.77981651
```

Normalizing



$X_1 \rightarrow$ $X_2 \downarrow$	False (0)	True (1)
False (0)	0.5706214712	0.1747572782
True (1)	$\theta_{22} = 0.4293785288$	$\theta_{21} = 0.8252427218$

```

# Estimations of the parameters are, then, by normalizing:
# theta_11=P(X1=true)=
theta_11=coef$X1[3]/(1-coef$X1[1])
# theta_21=P(X2=true/X1=true)
theta_21=coef$X2[3,3]/(1-coef$X2[1,3])
# theta_22=P(X2=true/X1=false)
theta_22=coef$X2[3,2]/(1-coef$X2[1,2])
#
theta<-cbind(theta_11,theta_21,theta_22)
theta
#
#
P_X2_true<-theta_21*theta_11+theta_22*(1-theta_11)
P_X2_true
#
#

```

```

> theta
      theta_11  theta_21  theta_22
true 0.2275574 0.8252427 0.4293785

```

```

> P_X2_true
      true
0.5194604

```

Avaluant l'aprenentatge de paràmetres amb **bnlearn**

Parameters	Actual values	bnlearn
$\theta_{11} = P(X_1 = \text{true})$	0.25	0.2275574113 (−0.0224425887)
$\theta_{21} = P(X_2 = \text{true}/X_1 = \text{true})$	0.80	0.8252427218 (+0.0252427218)
$\theta_{22} = P(X_2 = \text{true}/X_1 = \text{false})$	0.40	0.4293785288 (+0.0293785288)
$P(X_2 = 1)$	0.5	0.5194603598 (+0.0194603598)