

Tema 1

Introducció a les xarxes Bayesianes

Bloc A) Introducció a l'assignatura

Bloc B) Conceptes preliminars i
definicions bàsiques

Bloc C) Inferència amb XBs

Bloc D) Aprenentatge de XBs: paràmetres

Bloc E) Aprenentatge de XBs: estructura.

Optimització estocàstica.

Tema 1. Bloc E)

Aprenentatge de XBs: estructura

1.15 Aprenentatge d'estructura

1.16 Score-based structure learning

1.17 L'algorisme Greedy Search-and-Score.
Optimització estocàstica.

1.18 Score-based structure learning amb **bnlearn**

1.15 Aprenentatge d'estructura

Fins ara hem assumit que coneixem l'estructura d'una XB i ens hem preocupat d'estimar els valors dels seus paràmetres. El nostre enfocament per a aquesta estimació ha estat buscar estimacions **MLE**, és a dir, les que maximitzin la probabilitat d'observar el conjunt de dades donat.

Ara suposarem que l'estructura en sí és desconeguda, que és el més habitual, i presentarem alguns mètodes per aprendre-la a partir d'un conjunt de dades determinat. Un cop aprenem el DAG a partir de les dades, podem aprendre els paràmetres. El resultat serà una XB que podrem utilitzar per fer inferència.

L'estructura d'una XB pot ser determinada per raonaments (*expert knowledge*), o construïda formalment per consideracions del camp d'estudi al qual faci referència el problema. Això no és el que farem aquí: el que farem serà utilitzar un algorisme que ens permeti trobar la “millor” estructura, en algun sentit, a partir de les dades disponibles. Aquesta és la tasca de l'aprenentatge d'estructura ([structure learning](#)).

Chickering (1996) va demostrar que l'aprenentatge de l'estructura d'una XB és computacionalment complex (se'n diu: **NP-hard**). Només caldrà considerar el nombre de DAGs possibles per a un nombre determinat de nodes, i això ja ens indicarà com és de difícil el problema (veurem que per a 10 nodes, per exemple, n'hi ha aproximadament $4,2 \times 10^{18}$ DAGs possibles!).

A causa de la complicació computacional, no és factible trobar una solució òptima quan busquem “el” DAG d’una XB, i per això s'utilitzen mètodes heurístics, és a dir, que no garanteixen donar una solució òptima, tot i que sí una solució que pot ser prou satisfactòria per als nostres propòsits.

Basant-nos només en dades (*data-driven methods*), els mètodes d'aprenentatge d'estructures (heurístics) solen caure en una d'aquestes quatre categories principals:

- A. “Score-based” (també anomenats “Search-and-score”), que utilitzen una funció de puntuació (*score*) i l'algorisme intenta trobar l'estructura (DAG) que la maximitza.
- B. “Constraint-based”, que fan servir tests d'hipòtesis d'independència condicional. Les relacions d'independència que es troben entre les variables proporcionen les restriccions que el DAG hauria de satisfer.
- C. *Hybrid methods*, que utilitzen mètodes tipus B. per reduir l'espai de cerca de DAGs, i una funció de puntuació (mètode A) per a trobar el pseudo-òptim en l'espai més petit.
- D. “Dynamic programming”.

Ens centrem en usar *dades completes*. Tractar dades incompletes és similar pel que fa als mètodes A., que són els que farem servir, però és molt més exigent computacionalment.

Suficiència

El comportament o rendiment (*performance*) de la XB obtinguda dependrà dels algoritmes d'aprenentatge (o entrenament), tant de l'estructura com dels paràmetres, i això dependrà de la *suficiència* de la part de la base de dades que fem servir per a l'aprenentatge (*the training data set*).

Però no podem saber a priori si la nostra base de dades, amb la seva *mida* (nombre de casos) és o no *suficient*, ja que el fet que ho sigui depèn de:

- a. el nombre de nodes (variables),
- b. la “mida del domini”, i
- c. les distribucions de probabilitat subjacents.

Si bé el nombre de nodes es coneix des de l'inici, a partir de la formulació del problema, la “mida del domini” i les distribucions de probabilitat subjacents solen ser desconegudes a priori.

1.16 Score-based structure learning (Search-and-score)

En l'aprenentatge de l'estructura basat en una funció puntuació (*score*) , assignem una puntuació a un DAG, en funció de com s'ajusta el DAG a les dades (d'entrenament). És a dir, avaluem la ajust d'una estructura de xarxa candidata (DAG) mitjançant una funció de puntuació.

Cada estructura de xarxa candidata té associada una estimació dels seus paràmetres per MLE que es fa servir per a estimar la seva puntuació. Si les dades són incompletes, s'ha d'utilitzar l'algoritme EM. En canvi, si les dades són completes, això es pot fer comptant casos i normalitzant els recomptes, i és molt més senzill, com ja vam veure.

Es poden utilitzar diferents funcions de puntuació. Introduïrem en primer lloc el **Bayesian Information Criterion (BIC)**.

Recordatori de notacions (i alguna de nova):

- $\Gamma=(V, E)$ és un DAG, amb $V=\{X_1,\dots,X_n\}$ v.a. discretes.
- $x=(x_1,\dots,x_n)$ és un cas (vector de dades, corresponent a una realització de les v.a. $X_1,\dots,X_n$).
- $D=\{\mathbf{x}_1,\dots,\mathbf{x}_M\}$ és un conjunt de M casos diferents. És la base de dades, que assumirem que es fa servir per a entrenament (training data set).
- θ és el vector de paràmetres associat al model, és a dir, associat al DAG (que és el que marca quants i quins són els paràmetres). Si volem fer palès que depèn del DAG, ho denotem així: θ^Γ .
- θ_{MLE} és l'estimador MLE del vector de paràmetres.
- d denota la “dimensió” de Γ , és a dir, el nombre de paràmetres no-redundants (la dimensió del vector θ^Γ). És la “mida del domini”. Aleshores, d és una mesura de la complexitat de la XB amb el DAG Γ .

Recordeu que la probabilitat d'observar els M casos de la base de dades D amb el model que té per DAG Γ , i per vector de paràmetres θ^Γ , que és la [funció de versemblança](#) L , és el producte de les probabilitats que el vector $(X_1, \dots, X_n)$ sigui igual a cadascun dels casos $\mathbf{x}_i = (x_1^i, \dots, x_n^i)$, donades pel model, és a dir:

$$\begin{aligned} L^D(\theta^\Gamma) &= P(D/\theta^\Gamma) = \prod_{i=1}^M P(\mathbf{x}_i/\theta^\Gamma) \\ &= \prod_{i=1}^M P(X_1^i = x_1^i, \dots, X_n^i = x_n^i/\theta^\Gamma) \end{aligned}$$

where $\mathbf{x}_i = (x_1^i, \dots, x_n^i)$ is the i -th case of D
and $(X_1^i, \dots, X_n^i)$ is a copy of $(X_1, \dots, X_n)$.

La funció de versemblança reflecteix com de bé el model prediu les dades que realment observem quan utilitzem les estimacions MLE com a valors per als paràmetres del model. Aleshores:

per què no fer servir la [funció de versemblança](#) L com a *score* a maximitzar en l'aprenentatge d'estructura?

Proposició (Corollary 12 Darwiche 2009):

Si obtenim un DAG Γ^* a partir d'un DAG Γ afegint-hi algun arc dirigit, aleshores es compleix que:

$$L^D(\theta_{MLE}^{\Gamma^*}) \geq L^D(\theta_{MLE}^{\Gamma})$$

- Conseqüència: Si simplement busquem una estructura de xarxa que maximitzi la funció de versemblança com a *score*, acabariem amb una xarxa completament connectada (quan la introducció d'un arc dirigit més no és possible sense la introducció de cicles tancats, cosa que no es pot fer).
- Problemes que sen deriven:
 - Aquest seria un model massa complex que no es podria interpretar fàcilment. A més, pel [principi de la navalla d'Occam](#) (*Occam's razor*): entre dos models competidors amb prediccions similars, el més simple és preferible.
 - El model tindria molts paràmetres per a estimar (molt **complex**), que poden ser excessius en comparació amb les dades disponibles (domini de mida gran que implica **no suficiència** de la base de dades).
 - Fins i tot en el cas que tinguéssim prou dades, tindrem sobre-ajustament (**overfitting**): mal comportament predictiu del model per a nou casos que no formen part de les dades fetes servir per a l'entrenament del model.

The Bayesian Information Criterion (BIC) score

- Solució: Fer servir un altre *score*, diferent de la funció de versemblança L , però basat en ella, que penalitzi per complexitat.
En primer lloc introduïm el **Bayesian Information Criterion (BIC) score**:

$$BIC(\Gamma, D) = \ln \left(L^D(\theta_{MLE}^\Gamma) \right) - \frac{d}{2} \ln(M)$$

(G. Schwarz, “Estimating the dimension of a model”.
Annals of Statistics, vol. 6, pp. 461–464, 1978)

La funció *score* BIC és intuïtivament interessant perquè està formada per:

- ✓ el log-likelihood (logaritme de la funció de versemblança), que és un terme que mostra com de bé el model s'ajusta a les dades quan el vector de paràmetres del model és igual a la seva estimació MLE, i
- ✓ un terme que penalitza per complexitat.

The Akaike Information Criterion (AIC) score

Alternativament al BIC, podem fer servir també el **Akaike Information Criterion (AIC) score**:

$$AIC(\Gamma, D) = \ln \left(L^D(\theta_{MLE}^\Gamma) \right) - d$$

(H. Akaike, “A new look at the statistical model identification”.
IEEE Transactions on Automatic Control, vol. 19, pp. 716–723, 1974)


La funció *score* AIC penalitza menys per complexitat que el BIC *score* si M és suficientment gran (de fet, sempre que $M > 7$, ja que $\ln(7) = 1.94591 < 2$, mentre que $\ln(8) = 2.079442 > 2$).
Per tant, l'ús de l'AIC com a funció de puntuació dóna lloc a DAGs més connectats que els obtinguts mitjançant l'*score* BIC.

Un exemple


Suposem que només tenim dues variables X_1 i X_2 , cadascuna pren només dos valors: 0 i 1.

En aquest cas, com que tenim molt poques variables, podem calcular la nostra funció *score* de manera exhaustiva per a **tots** els DAG possibles, que són tres. En general n'hi ha molts i no es pot fer aquesta cerca exhaustiva.


A continuació, seleccionarem el(s) DAG(s) amb l'*score* més alt.



DAG Γ_1




DAG Γ_2



DAG Γ_3

Quins són els paràmetres de cadascun dels DAGs?





DAG	Parameters	θ^Γ
Γ_1	$\theta_{11}^{\Gamma_1} = P(X_1 = 1)$	$\theta_{21}^{\Gamma_1} = P(X_2 = 1)$
Γ_2	$\theta_{11}^{\Gamma_2} = P(X_1 = 1)$	$\theta_{21}^{\Gamma_2} = P(X_2 = 1 / X_1 = 1)$ $\theta_{22}^{\Gamma_2} = P(X_2 = 1 / X_1 = 0)$
Γ_3	$\theta_{11}^{\Gamma_3} = P(X_1 = 1 / X_2 = 1)$ $\theta_{12}^{\Gamma_3} = P(X_1 = 1 / X_2 = 0)$	$\theta_{21}^{\Gamma_3} = P(X_2 = 1)$

Ara calcularem $BIC(\Gamma_1, D)$, $BIC(\Gamma_2, D)$ i $BIC(\Gamma_3, D)$ i triarem el(s) DAG(s) amb el valor més alt, on D és el conjunt de dades d'entrenament.

Suposem que la nostra base de dades d'entrenament **D** és la de la taula (amb M=8 casos).

Cas	X_1	X_2
1	1	1
2	1	1
3	1	1
4	1	1
5	1	0
6	0	1
7	0	1
8	0	0



DAG Γ_1

Per al DAG Γ_1 , $d=2$, i la funció de versemblança és:

$$\begin{aligned}
 L^D(\theta^{\Gamma_1}) &= P((X_1^1, X_2^1) = (x_1^1, x_2^1), \dots, (X_1^M, X_2^M) = (x_1^M, x_2^M) / \theta^{\Gamma_1}) \\
 &= \prod_{i=1}^M P((X_1^i, X_2^i) = (x_1^i, x_2^i) / \theta^{\Gamma_1}) \\
 &= \prod_{i=1}^M P(X_1^i = x_1^i / \theta^{\Gamma_1}) P(X_2^i = x_2^i / \theta^{\Gamma_1}) \\
 &= \prod_{i=1}^M (\theta_{11}^{\Gamma_1})^{x_1^i} (1 - \theta_{11}^{\Gamma_1})^{1-x_1^i} (\theta_{21}^{\Gamma_1})^{x_2^i} (1 - \theta_{21}^{\Gamma_1})^{(1-x_2^i)} \\
 &= (\theta_{11}^{\Gamma_1})^{s_{11}} (1 - \theta_{11}^{\Gamma_1})^{t_{11}} (\theta_{21}^{\Gamma_1})^{s_{21}} (1 - \theta_{21}^{\Gamma_1})^{t_{21}}
 \end{aligned}$$

És a dir,

$$L^D(\theta^{\Gamma_1}) = (\theta_{11}^{\Gamma_1})^{s_{11}} (1 - \theta_{11}^{\Gamma_1})^{t_{11}} (\theta_{21}^{\Gamma_1})^{s_{21}} (1 - \theta_{21}^{\Gamma_1})^{t_{21}}$$

on

$$\theta^{\Gamma_1} = (\theta_{11}^{\Gamma_1}, \theta_{21}^{\Gamma_1})$$

s_{11} = number of cases in D for which $X_1 = 1$

t_{11} = number of cases in D for which $X_1 = 0$

s_{21} = number of cases in D for which $X_2 = 1$

t_{21} = number of cases in D for which $X_2 = 0$

Note that $s_{11} + t_{11} = s_{21} + t_{21} = M$

$$\ln(L^D(\theta^{\Gamma_1})) = s_{11} \ln(\theta_{11}^{\Gamma_1}) + t_{11} \ln(1 - \theta_{11}^{\Gamma_1}) + s_{21} \ln(\theta_{21}^{\Gamma_1}) + t_{21} \ln(1 - \theta_{21}^{\Gamma_1})$$

$$\frac{\partial \ln(L^D(\theta^{\Gamma_1}))}{\partial \theta_{11}^{\Gamma_1}} = \frac{s_{11}}{\theta_{11}^{\Gamma_1}} - \frac{t_{11}}{1 - \theta_{11}^{\Gamma_1}} = 0 \Rightarrow \theta_{11,MLE}^{\Gamma_1} = \frac{s_{11}}{s_{11} + t_{11}} = \frac{s_{11}}{M}$$

$$\frac{\partial \ln(L^D(\theta^{\Gamma_1}))}{\partial \theta_{21}^{\Gamma_1}} = \frac{s_{21}}{\theta_{21}^{\Gamma_1}} - \frac{t_{21}}{1 - \theta_{21}^{\Gamma_1}} = 0 \Rightarrow \theta_{21,MLE}^{\Gamma_1} = \frac{s_{21}}{s_{21} + t_{21}} = \frac{s_{21}}{M}$$

La matriu Hessiana és definida negativa per a tots els possibles valors de $\theta^{\Gamma_1}_{11}$ i $\theta^{\Gamma_1}_{21}$.


$$H(\ln(L(\theta))) = \begin{pmatrix} -\frac{s_{11}}{\theta_{11}^2} - \frac{t_{11}}{(1-\theta_{11})^2} & 0 \\ 0 & -\frac{s_{21}}{\theta_{21}^2} - \frac{t_{21}}{(1-\theta_{21})^2} \end{pmatrix}$$

Aleshores, $L^D(\theta^{\Gamma_1})$ arriba a un màxim local (que, de fet, és un màxim global) a:

$$\theta^{\Gamma_1}_{11,MLE} = \frac{s_{11}}{s_{11} + t_{11}} = \frac{s_{11}}{M}$$

$$\theta^{\Gamma_1}_{21,MLE} = \frac{s_{21}}{s_{21} + t_{21}} = \frac{s_{21}}{M}$$

Cas	X_1	X_2
1	1	1
2	1	1
3	1	1
4	1	1
5	1	0
6	0	1
7	0	1
8	0	0



$s_{11}=5, t_{11}=3, s_{21}=6, t_{21}=2$


$$\theta^{\Gamma_1}_{MLE} = \left(\frac{s_{11}}{M}, \frac{s_{21}}{M} \right) = \left(\frac{5}{8}, \frac{6}{8} \right)$$

Aleshores,

$$\begin{aligned} L^D(\theta_{MLE}^{\Gamma_1}) &= (\theta_{11,MLE}^{\Gamma_1})^{s_{11}} (1 - \theta_{11,MLE}^{\Gamma_1})^{t_{11}} (\theta_{21,MLE}^{\Gamma_1})^{s_{21}} (1 - \theta_{21,MLE}^{\Gamma_1})^{t_{21}} \\ &= \left(\frac{5}{8}\right)^5 \left(\frac{3}{8}\right)^3 \left(\frac{6}{8}\right)^6 \left(\frac{2}{8}\right)^2 = 5.5594245067 \times 10^{-5} \end{aligned}$$

i el valor de la funció *score* **Bayesian Information Criterion (BIC)** pel DAG Γ_1 és:

$$\begin{aligned} BIC(\Gamma_1, D) &= \ln(L^D(\theta_{MLE}^{\Gamma_1})) - \frac{d}{2} \ln(M) \\ &= -9.791187062 - \frac{2}{2} \ln(8) = -11.8706286 \end{aligned}$$



DAG Γ_2

Per al DAG Γ_2 , $d=3$, i la funció de versemblança és:

$$\begin{aligned}
 L^D(\theta^{\Gamma_2}) &= P((X_1^1, X_2^1) = (x_1^1, x_2^1), \dots, (X_1^M, X_2^M) = (x_1^M, x_2^M) / \theta^{\Gamma_2}) \\
 &= \prod_{i=1}^M P((X_1^i, X_2^i) = (x_1^i, x_2^i) / \theta^{\Gamma_2}) \\
 &= \prod_{i=1}^M P(X_1^i = x_1^i / \theta^{\Gamma_2}) P(X_2^i = x_2^i / X_1^i = x_1^i, \theta^{\Gamma_2}) \\
 &= \prod_{i=1}^M (\theta_{11}^{\Gamma_2})^{x_1^i} (1 - \theta_{11}^{\Gamma_2})^{1-x_1^i} (\theta_{21}^{\Gamma_2})^{x_2^i x_1^i} (1 - \theta_{21}^{\Gamma_2})^{(1-x_2^i)x_1^i} \\
 &\quad (\theta_{22}^{\Gamma_2})^{x_2^i (1-x_1^i)} (1 - \theta_{22}^{\Gamma_2})^{(1-x_2^i)(1-x_1^i)} \\
 &= (\theta_{11}^{\Gamma_2})^{s_{11}} (1 - \theta_{11}^{\Gamma_2})^{t_{11}} (\theta_{21}^{\Gamma_2})^{s_{21}} (1 - \theta_{21}^{\Gamma_2})^{t_{21}} (\theta_{22}^{\Gamma_2})^{s_{22}} (1 - \theta_{22}^{\Gamma_2})^{t_{22}}
 \end{aligned}$$

on

$$\theta^{\Gamma_2} = (\theta_{11}^{\Gamma_2}, \theta_{21}^{\Gamma_2}, \theta_{22}^{\Gamma_2})$$

s_{11} = number of cases in D for which $X_1 = 1$

t_{11} = number of cases in D for which $X_1 = 0$

s_{21} = number of cases in D for which $X_2 = 1$ and $X_1 = 1$

t_{21} = number of cases in D for which $X_2 = 0$ and $X_1 = 1$

s_{22} = number of cases in D for which $X_2 = 1$ and $X_1 = 0$

t_{22} = number of cases in D for which $X_2 = 0$ and $X_1 = 0$

Note that $s_{11} + t_{11} = M$, $s_{21} + t_{21} = s_{11}$, $s_{22} + t_{22} = t_{11}$

$$\begin{aligned} \ln(L^D(\theta^{\Gamma_2})) &= s_{11} \ln(\theta_{11}^{\Gamma_2}) + t_{11} \ln(1 - \theta_{11}^{\Gamma_2}) + s_{21} \ln(\theta_{21}^{\Gamma_2}) + t_{21} \ln(1 - \theta_{21}^{\Gamma_2}) \\ &\quad + s_{22} \ln(\theta_{22}^{\Gamma_2}) + t_{22} \ln(1 - \theta_{22}^{\Gamma_2}) \end{aligned}$$

$$\frac{\partial \ln(L^D(\theta^{\Gamma_2}))}{\partial \theta_{11}^{\Gamma_2}} = \frac{s_{11}}{\theta_{11}^{\Gamma_2}} - \frac{t_{11}}{1 - \theta_{11}^{\Gamma_2}} = 0 \Rightarrow \theta_{11,MLE}^{\Gamma_2} = \frac{s_{11}}{s_{11} + t_{11}} = \frac{s_{11}}{M}$$

$$\frac{\partial \ln(L^D(\theta^{\Gamma_2}))}{\partial \theta_{21}^{\Gamma_2}} = \frac{s_{21}}{\theta_{21}^{\Gamma_2}} - \frac{t_{21}}{1 - \theta_{21}^{\Gamma_2}} = 0 \Rightarrow \theta_{21,MLE}^{\Gamma_2} = \frac{s_{21}}{s_{21} + t_{21}} = \frac{s_{21}}{s_{11}}$$

$$\frac{\partial \ln(L^D(\theta^{\Gamma_2}))}{\partial \theta_{22}^{\Gamma_2}} = \frac{s_{22}}{\theta_{22}^{\Gamma_2}} - \frac{t_{22}}{1 - \theta_{22}^{\Gamma_2}} = 0 \Rightarrow \theta_{22,MLE}^{\Gamma_2} = \frac{s_{22}}{s_{22} + t_{22}} = \frac{s_{22}}{t_{11}}$$


Podem comprovar que la matriu Hessiana és definida negativa per a tots els possibles valors de $\theta^{\Gamma_2}_{11}$, $\theta^{\Gamma_2}_{21}$ i $\theta^{\Gamma_2}_{22}$. Aleshores, $L^D(\theta^{\Gamma_2})$ assoleix un màxim local, que de fet és global, a

$$\theta^{\Gamma_2}_{11,MLE} = \frac{s_{11}}{s_{11} + t_{11}} = \frac{s_{11}}{M}$$

$$\theta^{\Gamma_2}_{21,MLE} = \frac{s_{21}}{s_{21} + t_{21}} = \frac{s_{21}}{s_{11}}$$

$$\theta^{\Gamma_2}_{22,MLE} = \frac{s_{22}}{s_{22} + t_{22}} = \frac{s_{22}}{t_{11}}$$

Cas	X_1	X_2
1	1	1
2	1	1
3	1	1
4	1	1
5	1	0
6	0	1
7	0	1
8	0	0



$s_{11}=5$, $t_{11}=3$,
 $s_{21}=4$, $t_{21}=1$,
 $s_{22}=2$, $t_{22}=1$


$$\theta^{\Gamma_2}_{MLE} = \left(\frac{s_{11}}{M}, \frac{s_{21}}{s_{11}}, \frac{s_{22}}{t_{11}} \right) = \left(\frac{5}{8}, \frac{4}{5}, \frac{2}{3} \right)$$

Aleshores,

$$\begin{aligned} L^D(\theta^{\Gamma_2}) &= (\theta_{11}^{\Gamma_2})^{s_{11}} (1 - \theta_{11}^{\Gamma_2})^{t_{11}} (\theta_{21}^{\Gamma_2})^{s_{21}} (1 - \theta_{21}^{\Gamma_2})^{t_{21}} (\theta_{22}^{\Gamma_2})^{s_{22}} (1 - \theta_{22}^{\Gamma_2})^{t_{22}} \\ &= \left(\frac{5}{8}\right)^5 \left(\frac{3}{8}\right)^3 \left(\frac{4}{5}\right)^4 \left(\frac{1}{5}\right)^1 \left(\frac{2}{3}\right)^2 \left(\frac{1}{3}\right)^1 = 6.103515625 \times 10^{-5} \end{aligned}$$

i la funció de *score* **Bayesian Information Criterion (BIC)** per al DAG Γ_2 és:

$$\begin{aligned} BIC(\Gamma_2, D) &= \ln(L^D(\theta_{MLE}^{\Gamma_2})) - \frac{d}{2} \ln(M) \\ &= -9.704060528 - \frac{3}{2} \ln(8) = -12.82322284 \end{aligned}$$



DAG Γ_3

Per al DAG Γ_3 , $d=3$, i la funció de versemblança és:

$$\begin{aligned}
 L^D(\theta^{\Gamma_3}) &= P((X_1^1, X_2^1) = (x_1^1, x_2^1), \dots, (X_1^M, X_2^M) = (x_1^M, x_2^M) / \theta^{\Gamma_3}) \\
 &= \prod_{i=1}^M P((X_1^i, X_2^i) = (x_1^i, x_2^i) / \theta^{\Gamma_3}) \\
 &= \prod_{i=1}^M P(X_1^i = x_1^i / X_2^i = x_2^i, \theta^{\Gamma_3}) P(X_2^i = x_2^i / \theta^{\Gamma_3}) \\
 &= \prod_{i=1}^M (\theta_{11}^{\Gamma_3})^{x_1^i x_2^i} (1 - \theta_{11}^{\Gamma_3})^{(1-x_1^i) x_2^i} (\theta_{12}^{\Gamma_3})^{x_1^i (1-x_2^i)} (1 - \theta_{12}^{\Gamma_3})^{(1-x_1^i)(1-x_2^i)} \\
 &\quad (\theta_{21}^{\Gamma_3})^{x_2^i} (1 - \theta_{21}^{\Gamma_3})^{(1-x_2^i)} \\
 &= (\theta_{11}^{\Gamma_3})^{s_{11}} (1 - \theta_{11}^{\Gamma_3})^{t_{11}} (\theta_{12}^{\Gamma_3})^{s_{12}} (1 - \theta_{12}^{\Gamma_3})^{t_{12}} (\theta_{21}^{\Gamma_3})^{s_{21}} (1 - \theta_{21}^{\Gamma_3})^{t_{21}}
 \end{aligned}$$

on

$$\theta^{\Gamma_3} = (\theta_{11}^{\Gamma_3}, \theta_{12}^{\Gamma_3}, \theta_{21}^{\Gamma_3})$$

s_{11} = number of cases in D for which $X_1 = 1$ and $X_2 = 1$

t_{11} = number of cases in D for which $X_1 = 0$ and $X_2 = 1$

s_{12} = number of cases in D for which $X_1 = 1$ and $X_2 = 0$

t_{12} = number of cases in D for which $X_1 = 0$ and $X_2 = 0$

s_{21} = number of cases in D for which $X_2 = 1$

t_{21} = number of cases in D for which $X_2 = 0$

Note that $s_{11} + t_{11} = s_{21}$, $s_{12} + t_{12} = t_{21}$, $s_{21} + t_{21} = M$

$$\begin{aligned} \ln(L^D(\theta^{\Gamma_3})) &= s_{11} \ln(\theta_{11}^{\Gamma_3}) + t_{11} \ln(1 - \theta_{11}^{\Gamma_3}) + s_{12} \ln(\theta_{12}^{\Gamma_3}) + t_{12} \ln(1 - \theta_{12}^{\Gamma_3}) \\ &\quad + s_{21} \ln(\theta_{21}^{\Gamma_3}) + t_{21} \ln(1 - \theta_{21}^{\Gamma_3}) \end{aligned}$$

$$\frac{\partial \ln(L^D(\theta^{\Gamma_3}))}{\partial \theta_{11}^{\Gamma_3}} = \frac{s_{11}}{\theta_{11}^{\Gamma_3}} - \frac{t_{11}}{1 - \theta_{11}^{\Gamma_3}} = 0 \Rightarrow \theta_{11,MLE}^{\Gamma_3} = \frac{s_{11}}{s_{11} + t_{11}} = \frac{s_{11}}{s_{21}}$$

$$\frac{\partial \ln(L^D(\theta^{\Gamma_3}))}{\partial \theta_{12}^{\Gamma_3}} = \frac{s_{12}}{\theta_{12}^{\Gamma_3}} - \frac{t_{12}}{1 - \theta_{12}^{\Gamma_3}} = 0 \Rightarrow \theta_{12,MLE}^{\Gamma_3} = \frac{s_{12}}{s_{12} + t_{12}} = \frac{s_{12}}{t_{21}}$$

$$\frac{\partial \ln(L^D(\theta^{\Gamma_3}))}{\partial \theta_{21}^{\Gamma_3}} = \frac{s_{21}}{\theta_{21}^{\Gamma_3}} - \frac{t_{21}}{1 - \theta_{21}^{\Gamma_3}} = 0 \Rightarrow \theta_{21,MLE}^{\Gamma_3} = \frac{s_{21}}{s_{21} + t_{21}} = \frac{s_{21}}{M}$$


I la matriu Hessiana és definida negativa per a tots els possibles valors dels paràmetres $\theta^{\Gamma_3}_{11}$, $\theta^{\Gamma_3}_{12}$ i $\theta^{\Gamma_3}_{21}$. Aleshores, $L^D(\theta^{\Gamma_3})$ assoleix un màxim local (que és de fet global) a

$$\theta^{\Gamma_2}_{11,MLE} = \frac{s_{11}}{s_{11} + t_{11}} = \frac{s_{11}}{M}$$

$$\theta^{\Gamma_2}_{21,MLE} = \frac{s_{21}}{s_{21} + t_{21}} = \frac{s_{21}}{s_{11}}$$

$$\theta^{\Gamma_2}_{22,MLE} = \frac{s_{22}}{s_{22} + t_{22}} = \frac{s_{22}}{t_{11}}$$

Cas	X_1	X_2
1	1	1
2	1	1
3	1	1
4	1	1
5	1	0
6	0	1
7	0	1
8	0	0



$s_{11}=4$, $t_{11}=2$,
 $s_{12}=1$, $t_{12}=1$,
 $s_{21}=6$, $t_{21}=2$

$$\theta^{\Gamma_3}_{MLE} = \left(\frac{s_{11}}{s_{21}}, \frac{s_{12}}{t_{21}}, \frac{s_{21}}{M} \right) = \left(\frac{4}{6}, \frac{1}{2}, \frac{6}{8} \right)$$

Aleshores,

$$\begin{aligned} L^D(\theta^{\Gamma_3}) &= (\theta_{11}^{\Gamma_3})^{s_{11}} (1 - \theta_{11}^{\Gamma_3})^{t_{11}} (\theta_{12}^{\Gamma_3})^{s_{12}} (1 - \theta_{12}^{\Gamma_3})^{t_{12}} (\theta_{21}^{\Gamma_3})^{s_{21}} (1 - \theta_{21}^{\Gamma_3})^{t_{21}} \\ &= \left(\frac{4}{6}\right)^4 \left(\frac{2}{6}\right)^2 \left(\frac{1}{2}\right)^1 \left(\frac{1}{2}\right)^1 \left(\frac{6}{8}\right)^6 \left(\frac{2}{8}\right)^2 = 6.103515625 \times 10^{-5} \end{aligned}$$

I el **BIC** score per al DAG Γ_3 pren aquest valor:

$$\begin{aligned} BIC(\Gamma_3, D) &= \ln(L^D(\theta_{MLE}^{\Gamma_3})) - \frac{d}{2} \ln(M) \\ &= -9.704060528 - \frac{3}{2} \ln(8) = -12.82322284 \end{aligned}$$

Observeu que, tot i que les dades eren més probables (més gran la funció de versemblança) amb el model (XB) que té per DAG Γ_2 o Γ_3 , finalment “guanya” el DAG Γ_1 fent servir el criteri de la funció de puntuació Bayesian Information Criterion (BIC) perquè és menys complex que els altres dos.

DAG	$\ln \left(L^D(\theta_{MLE}^\Gamma) \right)$	d	BIC
Γ_1	-9.791187062	2	-11.8706286
Γ_2	-9.704060528	3	-12.82322284
Γ_3	-9.704060528	3	-12.82322284

On resideix el problema amb aquest procediment?

Hem vist amb l'exemple que quan no hi ha moltes variables, podem calcular el valor de la funció *score* de manera exhaustiva per a tots els DAGs possibles i seleccionar el(s) DAG(s) amb la puntuació més alta.

Tanmateix, quan el nombre de variables no és petit, és un problema computacionalment inviable, ja que el nombre de DAGs que contenen n nodes ve donat per la recurrència següent. **S'han hagut de desenvolupar algorismes heurístics de cerca de DAGs pseudo-òptims!**

$$f(n) = \begin{cases} 1 & \text{if } n = 0 \\ 1 & \text{if } n = 1 \\ \sum_{i=1}^n (-1)^{i+1} \binom{n}{i} 2^{i(n-i)} f(n-i) & \text{if } n \geq 2 \end{cases}$$

(Robinson, R.W., "Counting Unlabelled Acyclic Diagrams", in C.H.C. Little (Ed.): Lecture Notes in Mathematics, 622: Combinatorial Mathematics V, Springer-Verlag, New York, 1977.)

El nombre de possibles DAGs amb n nodes, per a $n = 1, 2, 3, \dots$ és:

1, 3, 25, 543, 29281, 3781503, 1138779265, 783702329343,
1213442454842881, 4175098976430598143,...

(successió A003024 al OEIS, On-Line Encyclopedia of Integer Sequences).

1.17 L'algorisme Greedy Search-and-Score.

Optimització Estocàstica

En aquesta subsecció presentem un algorisme heurístic per a la selecció de models que cerca sobre els possibles DAGs, donada una base de dades que es fa servir per a l'aprenentatge (per tant, donades les v.a. que són els nodes dels DAGs), és a dir, en el qual l'espai de cerca està format per tots els possibles DAGs amb els nodes donats.

Concretament, l'espai de cerca és el conjunt de tots els possibles DAGs que contenen n nodes, on n és el nombre de variables aleatòries de la base de dades.

L'objectiu és trobar un DAG dins d'aquest espai amb la puntuació (*score*) màxima, on el nostre criteri o funció de puntuació podria ser el BIC o qualsevol altra.

Per a fixar idees, ens centrem en l'*score* BIC.

Recordeu que el BIC *score* és, per definició:

$$BIC(\Gamma, D) = \ln (L^D(\theta_{MLE}^\Gamma)) - \frac{d}{2} \ln(M)$$

El logaritme de la funció de versemblança es pot expressar així:

$$\ln (L^D(\theta_{EML}^\Gamma)) = \sum_{i=1}^n \sum_{j=1}^{q_i} \sum_{k=1}^{r_i} N_{ijk} \ln \left(\frac{N_{ijk}}{N_{ij}} \right)$$

(R. R. Bouckaert, “Belief networks construction using the minimum description length principle”. Lecture Notes in Computer Science, 747:41–48, 1993)

I el terme “d”, la dimensió, que es fa servir en el terme que penalitza, d’aquesta manera:

$$d = \sum_{i=1}^n (r_i - 1) q_i$$

Aleshores, podem re-escriure:

$$BIC(\Gamma, D) = \sum_{i=1}^n g(\{X_i, PA_{X_i}\}, D)$$

amb

$$g(\{X_i, PA_{X_i}\}, D) = \sum_{j=1}^{q_i} \sum_{k=1}^{r_i} N_{ijk} \ln \left(\frac{N_{ijk}}{N_{ij}} \right) - \frac{(r_i - 1) q_i}{2} \ln(M)$$

on

n is the number of variables $\{X_1, \dots, X_n\}$

r_i is the number of states of variable X_i , $i = 1, \dots, n$

q_i is the number of possible configurations of the parent set PA_{X_i} on the DAG Γ

(therefore, $q_i = \prod_{j: X_j \in PA_{X_i}} r_j$)

ω_{ij} ($j = 1, \dots, q_i$) represents a configuration of PA_{X_i}

N_{ijk} is the number of instances in the data set D where the variable X_i takes its k -th value and the set of variables PA_{X_i} have the configuration ω_{ij}

$N_{ij} = \sum_{k=1}^{r_i} N_{ijk}$ is the number of instances in the data set D where the variables in PA_{X_i} have their j -th configuration ω_{ij}

És a dir, tenim la propietat següent, molt útil:

Propietat: El BIC *score* és *descomposable*. Això vol dir que la puntuació total es pot calcular com la suma de les puntuacions locals dels nodes del DAG:

$$BIC(\Gamma, D) = \sum_{i=1}^n g(\{X_i, PA_{X_i}\}, D)$$

On la puntuació local per a cada node X_i depèn només dels valors de dades de X_i i dels seus nodes pares PA_{X_i} :

$$g(\{X_i, PA_{X_i}\}, D) = \sum_{j=1}^{q_i} \sum_{k=1}^{r_i} N_{ijk} \ln \left(\frac{N_{ijk}}{N_{ij}} \right) - \frac{(r_i - 1) q_i}{2} \ln(M)$$

Això fa que sigui fàcil calcular l'efecte d'una simple modificació a l'estructura de la xarxa (com ara afegir o eliminar un arc dirigit).

Observeu que si X_i és un [node arrel](#), aleshores,

$PA_{X_i} = \emptyset$ and $q_i = 1$ by convention. Then, $j = 1$, and

N_{i1k} is the number of instances in the data set D where the variable X_i takes its k -th value, and

$N_{i1} = \sum_{k=1}^{r_i} N_{i1k} = M$, the number of instances in the data set D . Then,

$$g(\{X_i, PA_{X_i}\}, D) = g(\{X_i\}, D) = \sum_{k=1}^{r_i} N_{i1k} \ln\left(\frac{N_{i1k}}{M}\right) - \frac{(r_i - 1)}{2} \ln(M)$$

Quan un algorisme de cerca d'un DAG òptim en algun sentit només necessita re-calcular localment uns quants valors de la puntuació (*score*) del DAG trobat en un pas, per a determinar la puntuació del DAG corresponent al pas següent, diem que l'algorisme té una actualització local de la puntuació (*local scoring updating*). Un tal algorisme és, per motius obvis, considerablement més eficient que un que no ho és.

L'algorisme **Greedy Search-and-score** amb la funció score BIC, és *local scoring updating* i realitza una cerca d'un DAG que acabarà sent pseudo-òptim a través de l'espai de possibles estructures de xarxa. Els operadors utilitzats per a realitzar aquesta cerca, donat un DAG candidat en el pas actual, per a considerar els possibles DAGs candidats al pas següent, són:

- afegir-hi un arc dirigit
- eliminar un arc dirigit, i
- invertir un arc dirigit.

I totes les operacions estan subjectes a la restricció que el DAG resultant no contingui cap cicle.


L'algorisme Greedy Search-and-score a partir d'un conjunt de dades D

1. Comença amb un DAG sense arcs dirigits (buit).
2. A cada pas de la cerca, de tots aquells DAGs “en les proximitats” del DAG del pas actual (és a dir, el conjunt de DAGs Γ' obtinguts del DAG actual Γ aplicant un dels operadors), triem “avariciosament” el que maximitza el $BIC(\Gamma', D)$.
3. Ens aturem quan cap operació augmenta aquesta puntuació.

Local scoring updating: Per a avaluar l'efecte d'un canvi al DAG Γ que involucra un determinat node X_i per a donar lloc a un altre DAG Γ' , el valor de $BIC(\Gamma', D)$ es pot obtenir a partir del de $BIC(\Gamma, D)$, de la manera següent:

- ✓ re-avaluar $g(\{X_i, PA(X_i)\}, D)$, si el que s'ha fet és afegir o treure un arc dirigit que va cap a X_i ,
- ✓ re-avaluar $g(\{X_i, PA(X_i)\}, D)$ i $g(\{X_j, PA(X_j)\}, D)$ si el que hem fet és canviar la direcció d'un arc dirigit entre X_i i X_j .

Actualització de l'score després d'un canvi local



Problema (amb l'algorisme Greedy-search-and-score):

podria aturar-se en una solució candidata que maximitzi localment la funció objectiu (l'*score*) en lloc de maximitzar-la globalment.

Pseudo-solucions:

- **iterated hill-climbing algorithm:** La cerca local es fa fins a obtenir un màxim local. Aleshores, l'estructura actual es pertorba aleatòriament i es repeteix el procés: a partir d'aquest nou DAG s'inicia una nova cerca d'un màxim local. El procés es repeteix diverses vegades. Finalment, s'agafa el màxim de tots els màxims locals.
- **random-restart hill-climbing algorithm:** Fa el mateix que l'anterior, però comença cada vegada en un DAG diferent escollit aleatòriament.
- **Tabu search:** És un *iterated-hill climbing algorithm* modificat que manté una llista de les últimes k estructures visitades, i torna a alguna d'elles només si tots els DAGs als quals es pot anar des de l'actual són pitjors.
- **Simulated annealing:** És un altre algorisme que aborda aquest problema però permet que el valor de la puntuació en alguns passos disminueixi, és a dir, que empitjori temporalment, i després torna a millorar, per tal d'escapar de l'atracció d'un màxim local.
- **Genetic algorithms:** pertorben els DAGs (fan “mutacions”) a través de diverses generacions d'estructures (passos), i mantenen les “mutacions” que porten a millors puntuacions. Estan inspirats en les regles de l'evolució darwiniana.

Tots aquest són **algorismes d'Optimització Estocàstica**.

L'**Optimització Estocàstica** fa referència als problemes d'optimització (màxim o mínim de funcions objectiu) quan o bé a la funció objectiu, o bé al mateix algorisme, hi intervé l'atzar (hi ha una component aleatòria).

En el nostre cas, els algorismes d'Optimització Estocàstica fan servir l'atzar com a part del procediment de cerca de l'òptim: l'aleatorietat es fa servir com a estratègia per a millorar l'oportunitat de trobar un òptim global o un millor òptim local.

Per exemple, en l'**iterated hill-climbing algorithm**, el càlcul de la funció score a maximitzar depèn de la distribució de probabilitat tant del model en cada pas, com en el pas següent. A més, després d'arribar a un màxim local, l'estructura es pertorba aleatòriament per a començar de nou el procés, i això es va repetint (**multi-restart strategy**) per a millorar les possibilitats d'arribar a un màxim global.

De fer servir l'aleatorietat (*randomness*) a l'algorisme de cerca se'n diu "**fer cerca heurística**" (*heuristic search*), ja que el procediment pot acabar a un òptim o no, a diferència d'un procediment analític.

Consideracions sobre els **algorismes d'Optimització Estocàstica**:

1. La seva pròpia natura estocàstica fa que cada repetició (*run*) de l'algorisme sigui diferent, ja que tindrà diferents punts inicials per a fer la cerca, de manera que pot donar com a resultat un pseudo-òptim diferent.
2. Encara que es pot fixar la font d'aleatorietat fixant la llavor aleatòria (*seed*), això només interessa fer-ho per a petites demostracions, ja que no permet captar la aleatorietat inherent al propi algorisme.
3. Al contrari, l'algorisme s'ha d'executar diferents vegades (*runs*) sense fixar la llavor, precisament per a poder “controlar” l'aleatorietat. Amb dos objectius:
 - a) Avaluar el resultat final de l'algorisme que estem utilitzant.
 - b) Comparar algorismes diferents (i poder triar el “millor”).

Els algorismes es comparen a partir de la qualitat relativa dels seus resultats, que per a ser mesurada requereix:

- repetir les execucions dels algorismes canviant la font d'aleatorietat (sense fixar la llavor!), i
- calcular una mesura o mètrica de comportament.

Després, les mitjanes de les mètriques obtingudes amb les diferents execucions, pels diferents algorismes, es poden comparar estadísticament.

1.18 Score-based structure learning amb bnlearn

Com en el cas de l'aprenentatge de paràmetres, existeixen diferents aproximacions per a l'aprenentatge (o entrenament) de l'estructura (DAG) d'una XB.

Amb el paquet **bnlearn**, el que fem és crear una estructura que és un objecte de **bn**.

1. Expert-driven approach: l'estructura (objecte de classe **bn**) és especificada per l'usuari, com ja havíem fet. Després, podem aprendre els paràmetres per a crear un objecte de **bn.fit**, com hem vist al Bloc D.
2. Data-driven approach: s'aprèn l'estructura a partir d'una base de dades d'entrenament fent servir la funció **hc()**, que implementa l'algorisme **iterated hill-climbing (hc)**, i construeix i guarda un objecte de classe **bn**.

3. Hybrid approach: combina les dues aproximacions anteriors (fa servir les llistes “**black**” i “**white**” a la funció **hc()** per a introduir quins són els arcs prohibits i obligats, respectivament, que s’imposen com a restricció quan s’aprèn l’estructura).

Més concretament, es pot fer servir

whitelist=nom1



Com a argument dins la funció **hc()**, on “nom1” és un dataframe amb dues columnes (etiquetades opcionalment com “from” i “to”) que conté la informació del conjunt d’arcs dirigits **que s’han d’incloure necessàriament** al, així com també es pot fer servir

blacklist=nom2

Pels arcs dirigits que està **prohibit incloure** al DAG.

L'exemple revisitat

En l'exemple anterior, teníem dues variables binàries que prenen valors 1 i 0, i el conjunt de dades "d'entrenament" **D**, que ara hem d'introduir a R per a tenir un dataframe de nom "training", per exemple.



Case	X1	X2
1	1	1
2	1	1
3	1	1
4	1	1
5	1	0
6	0	1
7	0	1
8	0	0

```
> library(bnlearn)
> library(Rgraphviz)
> load("training_exemple.rdata")
> str(training)
```

```
'data.frame':  8 obs. of  2 variables:
 $ X1: Factor w/ 2 levels "1","0": 1 1 1 1 1 2 2 2
 $ X2: Factor w/ 2 levels "0","1": 2 2 2 2 1 2 2 1
```

```
> xarxa<-hc(training, score="bic")
> class(xarxa)
```

```
> class(xarxa)
[1] "bn"
```

> xarxa

Bayesian network learned via Score-based methods

model:

[X1][X2]

nodes: 2

arcs: 0

undirected arcs: 0

directed arcs: 0

average markov blanket size: 0.00

average neighbourhood size: 0.00

average branching factor: 0.00

learning algorithm: Hill-Climbing

score: BIC (disc.)


penalization coefficient: 1.039721

tests used in the learning procedure: 1

optimized: TRUE

(el que anomena “penalization coefficient” és $\ln(M)/2$)

```
> plot<-graphviz.plot(xarxa)  
> plot
```



```
> logLik(xarxa,training)
```

```
[1] -9.791187
```

```
> BIC(xarxa,training)
```

```
[1] -11.87063
```

(comparant amb l'exemple quan el vam fer “a mà”, el guanyador és el mateix DAG, Γ_1 , i els valors que ens dona [bnlearn](#) del *loglikelihood* i del BIC són els mateixos).

Un cop tenim l'estructura (“**xarxa**”, que és un objecte de classe **bn**), podem estimar paràmetres com en el Bloc D, obtenint un objecte de classe **bn.fit** que anomenem “**xarxa.estimada**”.


```
> xarxa.estimada=bn.fit(xarxa, training, method="mle")  
> xarxa.estimada
```

```
Bayesian network parameters  
  
Parameters of node X1 (multinomial distribution)  
  
Conditional probability table:  
      1      0  
0.625 0.375  
  
Parameters of node X2 (multinomial distribution)  
  
Conditional probability table:  
      0      1  
0.25 0.75
```

Un altre exemple

$P(X_1=0)$	$P(X_1=1)$	$P(X_1=2)$
0.80	0.15	0.05

X_1	$P(X_2=0 / X_1)$	$P(X_2=1 / X_1)$
0	0.30	0.70
1	0.80	0.20
2	0.99	0.01



X_1	X_2	$P(X_3=0/X_1,X_2)$	$P(X_3=1/X_1,X_2)$
0	0	0.10	0.90
0	1	0.80	0.20
1	0	0.50	0.50
1	1	0.30	0.70
2	0	0.60	0.40
2	1	0.05	0.95


X_3	$P(X_4=0/X_3)$	$P(X_4=1/X_3)$	$P(X_4=2/X_3)$
0	0.60	0.30	0.10
1	0.20	0.30	0.50

Carregueu el fitxer “**Exemple_dades_generades.rdata**”, que conté 1000 casos generats aleatòriament a partir de la xarxa Bayesiana anterior. L'utilitzarem per aprendre la XB utilitzant l'R amb el paquet **bnlearn**. El dataframe del fitxer s'anomena “**simulated.data**”.

```
> library(bnlearn)
> library(Rgraphviz)
> load("Exemple_dades_generades.rdata")
> str(simulated.data)
```

```
'data.frame':  1000 obs. of  4 variables:
 $ X1: Factor w/ 3 levels "0","1","2": 1 2 1 1 2 1 1 1 1 1 ...
 $ X2: Factor w/ 2 levels "0","1": 2 1 2 1 1 1 1 2 2 1 ...
 $ X3: Factor w/ 2 levels "0","1": 1 2 1 2 2 2 2 1 1 2 ...
 $ X4: Factor w/ 3 levels "0","1","2": 1 3 1 2 3 2 3 1 2 2 ...
```

```
> xarxa<-hc(simulated.data, score="bic")
> class(xarxa)
> xarxa
> plot<-graphviz.plot(xarxa)
> plot
```



Si compareu amb l'estructura que hem utilitzat per a generar dades, no són exactament iguals perquè alguna direcció ha canviat, i falta una fletxa, però són prou semblants.

Ara estimem els paràmetres amb el paquet **bnlearn**:

```
>xarxa.estimada=bn.fit(xarxa,simulated.data, method="mle")  
>xarxa.estimada
```

```
Bayesian network parameters
```

```
Parameters of node X1 (multinomial distribution)
```

```
Conditional probability table:
```

	0	1	2
	0.799	0.160	0.041

```
Parameters of node X2 (multinomial distribution)
```

```
Conditional probability table:
```

```
, , X3 = 0
```

	X1		
X2	0	1	2
0	0.0720339	0.8493151	1.0000000
1	0.9279661	0.1506849	0.0000000

, , X3 = 1

		X1		
X2		0	1	2
	0	0.6880734	0.8850575	1.0000000
	1	0.3119266	0.1149425	0.0000000

Parameters of node X3 (multinomial distribution)

Conditional probability table:

	0	1
	0.572	0.428

Parameters of node X4 (multinomial distribution)

Conditional probability table:

		X3	
X4		0	1
	0	0.6153846	0.2032710
	1	0.2867133	0.3317757
	2	0.0979021	0.4649533

Finalment, podem obtenir els valors de les funcions *score*:

- ✓ Log-likelihood,
- ✓ AIC,
- ✓ BIC

```
> logLik(xarxa.estimada,simulated.data)
'log Lik.' -2626.908 (df=13)
> AIC(xarxa.estimada,simulated.data)
'log Lik.' -2639.908 (df=13)
> BIC(xarxa.estimada,simulated.data)
'log Lik.' -2671.809 (df=13)
```

Com predir amb la xarxa el valor de **X4** donada l'evidència de que **X1=0** i **X2=1**, per exemple?

Farem servir el paquet **gRain** d'R per a fer-ho:

```
> library(gRain)
> xarxa.estimada.gRain<-as.grain(xarxa.estimada)
> #
> valors <- matrix(c("0","1"), nrow=1, byrow=T)
> colnames(valors)<-c("X1","X2")
> valors
```

valors és l'evidència:

```
> valors
      X1  X2
[1,] "0" "1"
```

```
> evi<-as.data.frame(valors)
> pred.classe<-predict(xarxa.estimada.gRain, response="X4",
newdata=evi, predictor=c("X1","X2"), type="class")
> pred.classe
```

```
$pred
$pred$X4
[1] "0"
```

```
$pEvidence
[1] 0.5307767
```

La predicció per a X4 donada l'evidència és "0",
i la probabilitat de l'evidència és $P(X1=0, X2=1)=0.5307...$

```
> pred.dist<-predict(xarxa.estimada.gRain, response="X4",
newdata=evi, predictor=c("X1","X2"), type="distribution")
> pred.dist
```

```
$pred
$pred$X4
      0      1      2
[1,] 0.5325622 0.2957695 0.1716684
```

```
$pEvidence
[1] 0.5307767
```

El valor "0", que és la predicció per a X4 donada l'evidència, és el que té la probabilitat més gran (criteri MAP).

Podem comparar la distribució de probabilitat predita per a X_4 condicionada a l'evidència $X_1=0$ i $X_2=1$, amb els valors reals, calculats “a mà” a partir de la XB original:

```
$pred
$pred$X4
           0           1           2
[1,] 0.5325622 0.2957695 0.1716684

$pEvidence
[1] 0.5307767
```

$$\begin{aligned} P(X_4 = 0 / X_1 = 0, X_2 = 1) &= P(X_4 = 0 / X_3 = 0) P(X_3 = 0 / X_1 = 0, X_2 = 1) \\ &\quad + P(X_4 = 0 / X_3 = 1) P(X_3 = 1 / X_1 = 0, X_2 = 1) \\ &= 0.60 \times 0.80 + 0.20 \times 0.20 = 0.52 \end{aligned}$$

$$\begin{aligned} P(X_4 = 1 / X_1 = 0, X_2 = 1) &= P(X_4 = 1 / X_3 = 0) P(X_3 = 0 / X_1 = 0, X_2 = 1) \\ &\quad + P(X_4 = 1 / X_3 = 1) P(X_3 = 1 / X_1 = 0, X_2 = 1) \\ &= 0.30 \times 0.80 + 0.30 \times 0.20 = 0.30 \end{aligned}$$

$$\begin{aligned} P(X_4 = 2 / X_1 = 0, X_2 = 1) &= P(X_4 = 2 / X_3 = 0) P(X_3 = 0 / X_1 = 0, X_2 = 1) \\ &\quad + P(X_4 = 2 / X_3 = 1) P(X_3 = 1 / X_1 = 0, X_2 = 1) \\ &= 0.10 \times 0.80 + 0.50 \times 0.20 = 0.18 \end{aligned}$$

S'assemblen bastant!!

Imaginem que volem modificar “a mà” alguna taula CPT, per exemple la de la variable X2.

```
> xarxa.estimada$X2
```

Parameters of node X2 (multinomial distribution)

Conditional probability table:

, , X3 = 0

	X1		
X2	0	1	2
0	0.0720339	0.8493151	1.0000000
1	0.9279661	0.1506849	0.0000000

, , X3 = 1

	X1		
X2	0	1	2
0	0.6880734	0.8850575	1.0000000
1	0.3119266	0.1149425	0.0000000

Suposem que condicionant a que $X_3=1$ i $X_1=2$, no volem que la probabilitat condicionada de X_2 sigui (1, 0) sinó que volem que sigui (0.9, 0.1). Veiem com canviar-la:

```
> # Guardem la CPT a modificar a "cpt.X2":  
> cpt.X2<-xarxa.estimada$X2  
  
> # Modifiquem convenientment la cpt. El "2" es refereix al valor de  
X1, i l'"1" a X3:  
> cpt.X2$prob[ , "2", "1"] <- c(0.9, 0.1)  
  
> # Fixeu-vos que "cpt.X2" és una llista, i la taula, com a tal, es troba  
a cpt.X2$prob. Fem una copia de la XB i incorporem la taula CPT de  
X2 modificada a la xarxa copia:  
> xarxa.estimada.modificada<-xarxa.estimada  
> xarxa.estimada.modificada$X2<-cpt.X2$prob  
  
> # Comprovem que ho hem fet bé:  
> xarxa.estimada.modificada$X2
```

Algunes Utilitats de bnlearn

Algunes funcions de bnlearn que poden ser útils, donat un objecte de classe “bn” (DAG), diguem “xarxa”:

the Markov blanket of A.

```
mb(xarxa, "A")
```

the neighbourhood of F.

```
nbr(xarxa, "F")
```

the arcs in the graph.

```
arcs(xarxa)
```

the nodes of the graph.

```
nodes(xarxa)
```

the adjacency matrix for the nodes of the graph.

```
amat(xarxa)
```

the parents of D.

```
parents(xarxa, "D")
```

the children of A.

```
children(xarxa, "A")
```

the root nodes of the graph.

```
root.nodes(xarxa)
```

the leaf nodes of the graph.

```
leaf.nodes(xarxa)
```

number of parameters of the Bayesian network.

```
nparams(xarxa, training.test)
```

the ancestors of D.

```
ancestors(xarxa, "D")
```

the descendants of F.

```
descendants(xarxa, "F")
```

the isolated nodes of the DAG.

```
isolated.nodes(xarxa)
```

the nodes to A.

```
incoming.arcs(xarxa, "A")
```

the nodes from A.

```
outgoing.arcs(xarxa, "A")
```

the number of arcs in the DAG.

```
narcs(xarxa)
```

the number of nodes in the DAG.

```
nnodes(xarxa)
```