

Tema 3

Validació i mètriques de comportament

3.1 Validació creuada

3.2 Taxonomia de les mètriques de classificació

3.3 Mètriques per a *hard labels*:

- a) el cas binari. Bases de dades desequilibrades
- b) el cas multi-classe nominal
- c) el cas ordinal

3.4 Mètriques a partir de probabilitats derivades de la matriu de confusió: *confusion entropy*.

3.1 Validació creuada

Recordeu que per a avaluar els classificadors (“**validar-los**”) es fan servir **mètriques**, que són mesures que quantifiquen el comportament predictiu del classificador, o sigui, com de bé fa la seva tasca de classificar.

La **validació** consisteix en el següent:

1. S’entrena (o aprèn) el model predictiu en un conjunt de dades d’entrenament,
2. Es fa servir el classificador que s’ha entrenat per a classificar els casos d’un conjunt de dades de validació (o test), com a casos nous per a ell (és a dir: no poden formar part del conjunt d’entrenament),
3. Es recull la informació relativa als encerts/errors en la classificació dels casos del conjunt de validació en forma de matriu (**matriu de confusió**),
4. Es calcula una mètrica de comportament a partir de la matriu.


Hi ha diferents tipus de validació.

Comencem per la més simple. La base de dades original es divideix en 3 conjunts:

1. Una part (aprox. un 10%) que es reservarà per a fer un test ulterior (*testing dataset*).

Del que queda, es fa una divisió:

2. La part que es dedicarà a l'entrenament del model, **T** (*training dataset*) (80%)
3. La part que es farà servir per a validar el model, **V** (*validation dataset*) (20%).



Cap dels casos del conjunt de validació (ni del conjunt de test) s'ha fet servir per a entrenar el classificador, així que pot ser considerat com un “cas nou” per a ell.

Aquest procediment s'anomena “Split-validation”.

I quan fem “Split-validation”, quina mesura del comportament predictiu del nostre classificador tenim?

Com podem comparar dos classificadors diferents per a poder triar “el millor”?

Imaginem que hem entrenat dos classificadors, i que quan els validem amb el conjunt de validació, obtenim les corresponents matrius de confusió.

MATRIU DE CONFUSIÓ (cas binari)

Matriu de confusió 2×2 :

classe observada

$$\begin{array}{c} \text{classe predita} \\ + \\ - \end{array} \begin{pmatrix} + & - \\ t_p & f_p \\ f_n & t_n \end{pmatrix}$$

t_p (*true positive*) nombre de casos del conjunt de validació de classe + correctament classificats,

t_n (*true negative*) nombre de casos del conjunt de validació de classe – correctament classificats,

f_p (*false positive*) nombre de casos del conjunt de validació de classe – erròniament classificats,

f_n (*false negative*) nombre de casos del conjunt de validació de classe + erròniament classificats,

n_+ nombre de casos del conjunt de validació de classe +, $n_+ = t_p + f_n$,

n_- nombre de casos del conjunt de validació de classe –, $n_- = f_p + t_n$,

N nombre total de casos al conjunt de validació: $N = n_+ + n_- = t_p + f_n + f_p + t_n$.

Quan la base de dades és desequilibrada (*unbalanced/imbalanced*), usualment s'agafa com a classe minoritària la classe +, i com a majoritària la classe –.

I quan fem “Split-validation”, quina mesura del comportament predictiu del nostre classificador tenim?

Com podem comparar dos classificadors diferents per a poder triar “el millor”?

Imaginem que hem entrenat dos classificadors, i que quan els validem amb el conjunt de validació, obtenim les corresponents matrius de confusió.

Classificador A:

		classe observada	
		+ (sí)	− (no)
classe predita	+ (sí)	$t_p = 6$	$f_p = 5$
	− (no)	$f_n = 4$	$t_n = 85$
		$n_+ = 10$	$n_- = 90$

Classificador B:

		classe observada	
		+ (sí)	− (no)
classe predita	+ (sí)	$t_p = 8$	$f_p = 15$
	− (no)	$f_n = 2$	$t_n = 75$
		$n_+ = 10$	$n_- = 90$

Quin sembla millor?

Una manera de comparar-los seria amb l'**accuracy**,
que és la proporció d'encerts: $(t_p + t_n)/N$

Accuracy classificador A: $(6+85)/100 = 0.91$ (**91% d'encerts**)

Accuracy classificador B: $(8+75)/100 = 0.83$ (**83% d'encerts**)

Semblaria millor (més accuracy) el model A... Sí?

Avaluació estadística del comportament dels models d'aprenentatge automàtic i comparació entre ells

La **validació** del model d'aprenentatge automàtic és essencial perquè no es pot confiar en cap progrés metodològic si els resultats no s'avaluen adequadament mitjançant mètodes vàlids i fiables.

Malauradament, els mètodes incorrectes són habituals a la literatura científica i als negocis, cosa que condueix a una selecció de models sub-òptima i a conclusions incorrectes.

El que s'ha de fer per a validar un model és provar estadísticament que funciona millor que l'atzar, calculant estimacions de les mètriques de comportament (mesures de rendiment) més adients, i donant intervals de confiança i fent tests d'hipòtesis, a partir d'una mostra.


Per a comparar dos o més models d'aprenentatge automàtic també es segueix el mateix procediment, fent tests estadístics de comparació de les mètriques triades (amb mostres amb dades aparellades).


És a dir, és imprescindible fer servir la Inferència Estadística!

Tornant a l'exemple anterior,
semblaria millor (més accuracy) el model A... Sí?
NO!!!!

Amb només un valor de l'*accuracy* del model A, i un del model B, no
podem tenir evidència estadística en favor del model A!!

Per això, per comptes de fer servir “Split-validation”, el que
utilitzarem és **k-fold cross-validation**!! (amb $k=5, 10, \dots$)





COM COMPAREM CLASSIFICADORS? ELS TESTS D'HIPÒTESIS ESTADÍSTICS

Classificador A

Model 1

$$\begin{array}{c} + \quad - \\ + \left(\begin{array}{cc} t_p & f_p \\ f_n & t_n \end{array} \right) \\ - \end{array}$$

mètrica 1

Model 2

$$\begin{array}{c} + \quad - \\ + \left(\begin{array}{cc} t_p & f_p \\ f_n & t_n \end{array} \right) \\ - \end{array}$$

mètrica 2

...

Model 10

$$\begin{array}{c} + \quad - \\ + \left(\begin{array}{cc} t_p & f_p \\ f_n & t_n \end{array} \right) \\ - \end{array}$$

mètrica 10

→ Classificador A
(mètrica 1, ..., mètrica 10)

Classificador B

Model 1

$$\begin{array}{c} + \quad - \\ + \left(\begin{array}{cc} t_p & f_p \\ f_n & t_n \end{array} \right) \\ - \end{array}$$

mètrica 1

Model 2

$$\begin{array}{c} + \quad - \\ + \left(\begin{array}{cc} t_p & f_p \\ f_n & t_n \end{array} \right) \\ - \end{array}$$

mètrica 2


...

Model 10

$$\begin{array}{c} + \quad - \\ + \left(\begin{array}{cc} t_p & f_p \\ f_n & t_n \end{array} \right) \\ - \end{array}$$

mètrica 10

→ Classificador B
(mètrica 1, ..., mètrica 10)



COM COMPAREM CLASSIFICADORS? ELS TESTS D'HIPÒTESIS ESTADÍSTICS

Classificador A

Model 1

$$+ \begin{pmatrix} t_p & f_p \\ f_n & t_n \end{pmatrix}$$

→ mètrica 1

Model 2

$$+ \begin{pmatrix} t_p & f_p \\ f_n & t_n \end{pmatrix}$$

→ mètrica 2

...

Model 10

$$+ \begin{pmatrix} t_p & f_p \\ f_n & t_n \end{pmatrix}$$

→ mètrica 10

→ Classificador A
(mètrica 1, ..., mètrica 10)

Classificador B

Model 1

$$+ \begin{pmatrix} t_p & f_p \\ f_n & t_n \end{pmatrix}$$

→ mètrica 1

Model 2

$$+ \begin{pmatrix} t_p & f_p \\ f_n & t_n \end{pmatrix}$$

→ mètrica 2

...

Model 10

$$+ \begin{pmatrix} t_p & f_p \\ f_n & t_n \end{pmatrix}$$

→ mètrica 10

→ Classificador B
(mètrica 1, ..., mètrica 10)

Classificador A – Classificador B
(diferència 1, ..., diferència 10)

Diferència: Accuracy classificador A – Accuracy classificador B

40.53, 32.91, 1.56, 28.71, 28.66,
21.67, 17.22, 28.71, 22.00, 21.43

→ **Mitjana:** 24.33969

Comparar el valor de la mètrica pels classificadors A i B,
és el mateix que fer les diferències i comparar amb 0 !


Test de normalitat (**Shapiro-Wilk**) amb
(diferència 1, ..., diferència 10)

H_0 : normalitat

H_1 : no normalitat

p-valor = P(acceptar H_1 si és falsa): **0.4322**

S'accepta H_1 si p-valor petit.



Sí

No


Test no paramètric de
comparació de medianes de
Wilcoxon
 H_1 : mediana > 0

Test paramètric de comparació
de mitjanes (t-test)
 H_1 : mitjana > 0

p-valor=0.0000213
S'accepta que té més
accuracy el classificador
A que el B, en mitjana!!

Particularment interessant és el cas $k=N$, si N és el nombre total de casos al conjunt d'entrenament. Se'n diu: **leave-one-out cross-validation (LOOCV)**. Es recomana utilitzar-lo només quan N és petit (pocs casos a la base de dades), ja que en cas contrari, és computacionalment molt costós. En aquest cas, de nou, tornem a tenir una única matriu de confusió i podem calcular només un valor (global) per a cada mètrica de comportament.

LOOCV



Finalment, a més de:

- *Split-validation*,
- *K-fold cross-validation* i
- *Leave-one-out cross-validation*,

Hi ha encara una altra manera de fer la validació, que només comentem: el bootstrap sampling.

En termes generals, el bootstrap sampling es refereix als mètodes estadístics d'utilitzar mostres de dades agafades aleatòriament de conjunts de dades més grans, per a estimar les propietats d'aquest conjunt.

Quan aquest principi s'aplica a la validació d'un model d'aprenentatge automàtic, implica la creació de diversos conjunts de dades de validació i d'entrenament seleccionats aleatòriament de la base de dades, que després s'utilitzen per a estimar la mètrica de comportament.

Finalment, es fa la mitjana dels valors obtinguts per a la mètrica de comportament amb els diferents conjunts de dades que s'han agafat aleatòriament de la base de dades, i aquesta és la estimació final.

Aleshores, què fa que el *bootstrap sampling* aplicat a la validació sigui diferent de fer servir un *k-fold cross-validation*?

Mentre que la validació creuada divideix les dades en particions separades en les quals cada exemple (cas) només pot aparèixer una vegada, el *bootstrap* permet seleccionar exemples diverses vegades mitjançant un procés de mostreig amb reposició o reemplaçament.

Això vol dir que a partir del conjunt de dades original de N exemples o casos, el *bootstrap sampling* crearà un o més conjunts de dades d'entrenament nous, que també contindran cadascun d'ells N exemples, alguns dels quals estaran repetits.

Els conjunts de dades validació respectius es construeixen agafant casos dels que no hagin estat agafats per a formar part de cadascun dels conjunts d'entrenament.

3.2 Taxonomia de les mètriques de classificació

Moltes vegades ens interessa la comparació entre diferents models per a determinar el més adequat en funció del problema en qüestió.

Per això, necessitem una eina per a comparar els models:

les **mesures de comportament (mètriques)**.

Les mètriques difereixen segons quina part de la predicció del classificador fan servir:


- **hard labels** (etiquetes predites): són les més habituals
- **distribucions empíriques** derivades de la matriu de confusió: basades en l'**entropia de Shannon**
- **distribucions de probabilitat a posteriori** proporcionades pels classificadors probabilístics (*soft labels*): els **proper scoring rules**

Idea intuïtiva:

quanta més informació fa servir la mètrica, més acurada serà l'avaluació

Suposem que hem après un classificador qualsevol.

Per exemple, un classificador bayesià (una XB d'un tipus particular: **diagnòstic**) en el qual tenim algunes característiques $A_1, \dots, A_n$, i una variable classe C , d'un conjunt de dades d'entrenament T , i que tenim un conjunt de validació V .



Aleshores, obtenim una “matriu de confusió” en la qual per columna tenim la classe observada (enregistrada), i per fila tenim la classe predita (o viceversa).

Els valors diagonals corresponen a una classificació correcta, i la resta, a errors.

3.3 Mètriques per a *hard labels*:

a) el cas binari. Bases de dades desequilibrades

		Actual class	
		P	N
Predicted class	P	TP	FP
	N	FN	TN

Mètriques basades en proporcions

M = nombre de casos en el conjunt de validació V
= (TP + FN) + (FP + TN) = P + N

where: P = Positive; N = Negative; TP = True Positive; FP = False Positive; TN = True Negative; FN = False Negative.

sensitivity, recall, hit rate, or true positive rate (TPR)

$$\text{TPR} = \frac{\text{TP}}{P} = \frac{\text{TP}}{\text{TP} + \text{FN}} = 1 - \text{FNR}$$

specificity, selectivity or true negative rate (TNR)

$$\text{TNR} = \frac{\text{TN}}{N} = \frac{\text{TN}}{\text{TN} + \text{FP}} = 1 - \text{FPR}$$

precision or positive predictive value (PPV)

$$\text{PPV} = \frac{\text{TP}}{\text{TP} + \text{FP}} = 1 - \text{FDR}$$

negative predictive value (NPV)

$$\text{NPV} = \frac{\text{TN}}{\text{TN} + \text{FN}} = 1 - \text{FOR}$$

miss rate or false negative rate (FNR)

$$\text{FNR} = \frac{\text{FN}}{P} = \frac{\text{FN}}{\text{FN} + \text{TP}} = 1 - \text{TPR}$$

fall-out or false positive rate (FPR)

$$\text{FPR} = \frac{\text{FP}}{N} = \frac{\text{FP}}{\text{FP} + \text{TN}} = 1 - \text{TNR}$$

false discovery rate (FDR)

$$\text{FDR} = \frac{\text{FP}}{\text{FP} + \text{TP}} = 1 - \text{PPV}$$

false omission rate (FOR)

$$\text{FOR} = \frac{\text{FN}}{\text{FN} + \text{TN}} = 1 - \text{NPV}$$

		Actual class	
		P	N
Predicted class	P	TP	FP
	N	FN	TN

where: P = Positive; N = Negative; TP = True Positive; FP = False Positive; TN = True Negative; FN = False Negative.

accuracy (ACC)

$$ACC = \frac{TP + TN}{P + N} = \frac{TP + TN}{TP + TN + FP + FN}$$

balanced accuracy (BA)

$$BA = \frac{TPR + TNR}{2}$$

F1 score

is the **harmonic mean** of **precision** and **sensitivity**

$$F_1 = 2 \cdot \frac{PPV \cdot TPR}{PPV + TPR} = \frac{2TP}{2TP + FP + FN}$$

$$F1 = \frac{2}{\frac{1}{precision} + \frac{1}{sensitivity}} = \frac{2}{\frac{1}{\frac{TP}{TP+FP}} + \frac{1}{\frac{TP}{TP+FN}}}$$

Puntuació F1 (*F1 score*): Com que descriu el rendiment del model en un sol valor, proporciona una manera convenient de comparar diversos models entre ells. Tanmateix, assumeix que s'ha d'assignar el mateix pes a la precisió i la sensibilitat (*recall*), un supòsit que no sempre és vàlid.

També és possible calcular la puntuació F1 utilitzant diferents pesos per a la precisió i la sensibilitat, però triar els pesos podria ser complicat en el millor dels casos i arbitrari en el pitjor.

		Actual class	
		P	N
Predicted class	P	TP	FP
	N	FN	TN

where: P = Positive; N = Negative; TP = True Positive; FP = False Positive; TN = True Negative; FN = False Negative.

Matthews correlation coefficient (MCC)

$$\text{MCC} = \frac{\text{TP} \times \text{TN} - \text{FP} \times \text{FN}}{\sqrt{(\text{TP} + \text{FP})(\text{TP} + \text{FN})(\text{TN} + \text{FP})(\text{TN} + \text{FN})}}$$

- MCC pren valors entre -1 i +1,
- +1 correspon a classificació perfecta,
- quan més gran el valor, millor.

(també veurem la Kappa de Cohen, més endavant, que és una altra mètrica basada en correlacions)

MCC: Va ser introduït per Matthews a l'article:

Matthews, B.W.: Comparison of the predicted and observed secondary structure of t4 phage lysozyme. Biochimica et Biophysica Acta(BBA)-Protein Structure 405(2),442–451(1975).

Exemple: la classificació en un conjunt de M=100 casos de validació va donar lloc a la següent matriu de confusió:

		Actual class		
		P	N	
Predicted class	P	TP 90	FP 4	94
	N	FN 5	TN 1	6
		95	5	

accuracy (ACC)

$$ACC = \frac{TP + TN}{P + N} = \frac{TP + TN}{TP + TN + FP + FN}$$

balanced accuracy (BA)

$$BA = \frac{TPR + TNR}{2}$$

F1 score

is the harmonic mean of precision and sensitivity

$$F_1 = 2 \cdot \frac{PPV \cdot TPR}{PPV + TPR} = \frac{2TP}{2TP + FP + FN}$$

Matthews correlation coefficient (MCC)

$$MCC = \frac{TP \times TN - FP \times FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}}$$

$$Acc = 91/100 = 0.91$$

$$BA = \frac{90/95 + 1/5}{2} = 0.5736842$$

$$F1 = \frac{2 \times 90}{2 \times 90 + 4 + 5} = 0.952381$$

$$MCC = \frac{90 \times 1 - 4 \times 5}{\sqrt{94 \times 95 \times 5 \times 6}} = 0.135242$$

Exemple: la classificació en un conjunt de M=100 casos de validació va donar lloc a la següent matriu de confusió:

		Actual class		
		P	N	
Predicted class	P	TP 90	FP 4	94
	N	FN 5	TN 1	6
		95	5	

$$\begin{aligned}
 Acc &= 91/100 = 0.91 \\
 BA &= \frac{90/95 + 1/5}{2} = 0.5736842 \\
 F1 &= \frac{2 \times 90}{2 \times 90 + 4 + 5} = 0.952381 \\
 MCC &= \frac{90 \times 1 - 4 \times 5}{\sqrt{94 \times 95 \times 5 \times 6}} = 0.135242
 \end{aligned}$$

El classificador ha funcionat bé en la classificació de casos positius, però no ha estat capaç de reconèixer correctament els negatius.

Les puntuacions resultants de **F1** i **Accuracy** són altes, però el valor de l'**MCC** indica que el classificador està funcionant malament (com ho faria fer la tria a l'atzar!).

A més, el valor de **BA** no és molt elevat, la qual cosa també indica que el casos negatius no s'estan classificant correctament.

Tingueu en compte que la puntuació **F1 depèn de quina classe es defineix com a classe positiva**! En l'exemple anterior, la puntuació F1 és alta perquè la classe majoritària es defineix com la classe positiva. Invertint les classes positives i negatives obtindríem $F1 = 2/11 = 0,181818... = 18,18 \%$ en lloc del **95,24 %**.

		Actual class		
		P	N	
Predicted class	P	TP 90	FP 4	94
	N	FN 5	TN 1	
		95	5	6

$$\begin{aligned}Acc &= 91/100 = 0.91 \\ BA &= \frac{90/95 + 1/5}{2} = 0.5736842 \\ F1 &= \frac{2 \times 90}{2 \times 90 + 4 + 5} = 0.952381 \\ MCC &= \frac{90 \times 1 - 4 \times 5}{\sqrt{94 \times 95 \times 5 \times 6}} = 0.135242\end{aligned}$$

La “**accuracy paradox**” és un fenomen en el que tenim una matriu de confusió que reflecteix un grau molt alt d'encert del classificador, però molt desigual en les dues classes: els casos de la classe majoritària es classifiquen molt bé, però els de la minoritària molt malament.

Seria el cas de la matriu de confusió de l'exemple: com vam veure, l'*accuracy* és alt: 91%, però l'encert de la classe minoritària és baix: 20%, és a dir, el classificador no reconeix bé els casos de la classe minoritària, però tot i així té una molt bona *accuracy*!

Això és comú a les **bases de dades (binàries) desequilibrades**, amb una classe minoritària que representa una fracció molt petita dels casos de la base de dades.

El problema del desequilibri (**unbalance/imbalance**) a les bases de dades (binàries) és molt important en classificació, ja que en aquesta situació el model de classificació dóna més pes a la classe majoritària i no és capaç de classificar bé els casos de la classe minoritària. **Què podem fer per a tractar-lo?**

1. Es pot fer servir l'**oversampling**, que és una tècnica que consisteix a augmentar de manera artificial el nombre de casos de la classe minoritària al conjunt de dades d'entrenament, per a re-equilibrar-la i millorar el rendiment dels models de l'Aprenentatge Automàtic, que tindran més dades per a entrenar-se i seran menys propensos a sobre-ajustar-se a la classe majoritària.

Això es pot fer:

- a) Duplicant mostres existents de la classe minoritària.
- b) Fent servir **SMOTE** (*Synthetic Minority Over-sampling TEchnique*), que és el mètode més utilitzat, i consisteix en generar casos sintètics de la classe minoritària a partir dels existents, fent interpolació lineal entre les característiques de diversos casos de la classe minoritària, per així generar un nou cas "intermedi" que s'assembli a ells.

Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: synthetic minority over-sampling technique. *Journal of artificial intelligence research*, 16, 321-357.

El problema amb **SMOTE** és que si les característiques no són contínues, la interpolació lineal deixa de tenir sentit (les distàncies perden el sentit amb les variables discretes i categòriques).

c) Fent servir **BOSME** (*Bayesian network-based Over-Sampling MEthod*), que és un altre mètode d'*oversampling*, en aquest cas basat en xarxes bayesianes.

A diferència de SMOTE o d'altres tècniques d'*oversampling* que generen mostres sintètiques aleatòries, BOSME utilitza una xarxa bayesiana per a modelar les relacions entre les característiques dels casos de la classe minoritària i generar mostres sintètiques coherents amb les dades originals.

En general, BOSME té com a objectiu generar mostres sintètiques més realistes i coherents amb les dades originals.

Delgado, R., & Núñez-González, J.D. (2022). Bayesian network-based over-sampling method (BOSME) with application to indirect cost-sensitive learning. *Scientific Reports*, 12(1), 8724.

2. Es pot modificar l'algorisme d'aprenentatge del classificador per tal que tingui en compte el desequilibri de la base de dades (no explicarem com).
3. Sempre s'ha de tenir en compte el desequilibri fent servir una mètrica de comportament que no només miri el comportament predictiu en general, sinó en la classe minoritària en particular, com per exemple l'**F1 score**, agafant com a classe positiva la minoritària (que és com s'acostuma a agafar), l'**MCC** o el **BA**.

Exemple (continuació): la resta de mètriques que hem vist, en aquest exemple amb M=100 casos de validació són:

		Actual class		
		P	N	
Predicted class	P	TP 90	FP 4	94
	N	FN 5	TN 1	6
		95	5	

sensitivity, recall, hit rate, or true positive rate (TPR)

$$\text{TPR} = \frac{\text{TP}}{\text{P}} = \frac{\text{TP}}{\text{TP} + \text{FN}} = 1 - \text{FNR}$$

specificity, selectivity or true negative rate (TNR)

$$\text{TNR} = \frac{\text{TN}}{\text{N}} = \frac{\text{TN}}{\text{TN} + \text{FP}} = 1 - \text{FPR}$$

precision or positive predictive value (PPV)

$$\text{PPV} = \frac{\text{TP}}{\text{TP} + \text{FP}} = 1 - \text{FDR}$$

negative predictive value (NPV)

$$\text{NPV} = \frac{\text{TN}}{\text{TN} + \text{FN}} = 1 - \text{FOR}$$

miss rate or false negative rate (FNR)

$$\text{FNR} = \frac{\text{FN}}{\text{P}} = \frac{\text{FN}}{\text{FN} + \text{TP}} = 1 - \text{TPR}$$

fall-out or false positive rate (FPR)

$$\text{FPR} = \frac{\text{FP}}{\text{N}} = \frac{\text{FP}}{\text{FP} + \text{TN}} = 1 - \text{TNR}$$

false discovery rate (FDR)

$$\text{FDR} = \frac{\text{FP}}{\text{FP} + \text{TP}} = 1 - \text{PPV}$$


false omission rate (FOR)

$$\text{FOR} = \frac{\text{FN}}{\text{FN} + \text{TN}} = 1 - \text{NPV}$$

$$\begin{aligned} \text{TPR} &= \frac{90}{95} = 0.9473684, & \text{TNR} &= \frac{1}{5} = 0.2 \\ \text{PPV} &= \frac{90}{94} = 0.9574468, & \text{NPV} &= \frac{1}{6} = 0.1666667 \end{aligned}$$

$$\begin{aligned} \text{FNR} &= 1 - \text{TPR} = 1 - 0.9473684 = 0.0526316 \\ \text{FPR} &= 1 - \text{TNR} = 1 - 0.2 = 0.8 \\ \text{FDR} &= 1 - \text{PPV} = 1 - 0.9574468 = 0.0425532 \\ \text{FOR} &= 1 - \text{NPV} = 1 - 0.1666667 = 0.8333333 \end{aligned}$$

b) el cas multi-classe nominal



Tenim r classes diferents, $r > 2$,
 $C_1, \dots, C_r$.

Aleshores, la matriu de confusió és una
matriu $r \times r$ (r files i r columnes)

Predicted class	Actual class		
	C_1	$\dots$	C_r
C_1	a_{11}	$\dots$	a_{1r}
$\vdots$	$\vdots$	$\dots$	$\vdots$
C_r	a_{r1}	$\dots$	a_{rr}


M = nombre de casos
en el conjunt de
validació V .

Predicted class	Actual class		
	C_1	$\dots$	C_r
C_1	a_{11}	$\dots$	a_{1r}
$\vdots$	$\vdots$	$\dots$	$\vdots$
C_r	a_{r1}	$\dots$	a_{rr}

Per a cadascuna de les classes C_j , $j=1,\dots,r$, podem construir (per col·lapse) a partir de la matriu de confusió una nova matriu com aquesta:

Predicted class	Actual class	
	C_j	C_j^c
C_j	TP_j	FP_j
C_j^c	FN_j	TN_j

On $C_j^c = \{C_1, \dots, C_{j-1}, C_{j+1}, \dots, C_r\}$



Mesures per a la classificació multi-classe nominal basades en una generalització de les mesures de classificació binària per a moltes classes

Average Accuracy	$\frac{\sum_{j=1}^r \frac{TP_j + TN_j}{M}}{r}$	The average per-class effectiveness of a classifier
Average Error rate =1-Average Accuracy	$\frac{\sum_{j=1}^r \frac{FP_j + FN_j}{M}}{r}$	The average per-class classification error
Average Precision	$\frac{\sum_{j=1}^r \frac{TP_j}{TP_j + FP_j}}{r}$	An average per-class agreement of the data class labels with those of the classifiers
Average Recall (sensitivity)	$\frac{\sum_{j=1}^r \frac{TP_j}{TP_j + FN_j}}{r}$	An average per-class effectiveness of a classifier to identify class labels
Average Specificity	$\frac{\sum_{j=1}^r \frac{TN_j}{FP_j + TN_j}}{r}$	An average per-class effectiveness of a classifier to identify negative class labels

Altres mesures per a classificació multi-classe nominal

- La versió multi-classe del Coeficient de Correlació de Matthews:

Gorodkin, J.: Comparing two k-category assignments by a k-category correlation coefficient. Computational biology and chemistry 28(5-6), 367–374 (2004).

$$MCC = \frac{\sum_{k,\ell,m=1}^r (a_{kk} a_{\ell m} - a_{mk} a_{k\ell})}{\sqrt{\sum_{k=1}^r \left(\left(\sum_{\ell=1}^r a_{k\ell} \right) \left(\sum_{u,v=1, u \neq k}^r a_{uv} \right) \right)} \sqrt{\sum_{k=1}^r \left(\left(\sum_{\ell=1}^r a_{\ell k} \right) \left(\sum_{u,v=1, u \neq k}^r a_{vu} \right) \right)}}$$

- La Kappa de Cohen (també es pot fer en el cas binari):

Cohen, J.: A coefficient of agreement for nominal scales. Educational and psychological measurement 20(1), 37–46 (1960).

Es va introduir en l'àmbit de la psicologia com a mesura d'acord entre dos jutges. Més tard es va generalitzar el seu ús com a mesura de comportament, per a quantificar el grau d'acord entre les classes observades i les predites.

$$\kappa = \frac{Acc - P_e}{1 - P_e} \quad \text{with} \quad P_e = \sum_{i=1}^r \frac{a_{i.} \times a_{.i}}{M^2}, \quad a_{i.} = \sum_{j=1}^r a_{ij}, \quad a_{.i} = \sum_{\ell=1}^r a_{\ell i}$$

Per a fer el càlcul en general ($r > 2$), és millor programar-ho en R!!

$$MCC = \frac{\sum_{k,\ell,m=1}^r (a_{kk} a_{\ell m} - a_{mk} a_{k\ell})}{\sqrt{\sum_{k=1}^r \left(\left(\sum_{\ell=1}^r a_{k\ell} \right) \left(\sum_{u,v=1, u \neq k}^r a_{uv} \right) \right)} \sqrt{\sum_{k=1}^r \left(\left(\sum_{\ell=1}^r a_{\ell k} \right) \left(\sum_{u,v=1, u \neq k}^r a_{vu} \right) \right)}}$$

$$\kappa = \frac{Acc - P_e}{1 - P_e} \quad \text{with} \quad P_e = \sum_{i=1}^r \frac{a_{i.} \times a_{.i}}{M^2}, \quad a_{i.} = \sum_{j=1}^r a_{ij}, \quad a_{.i} = \sum_{\ell=1}^r a_{\ell i}$$

(P_e és la probabilitat teòrica o hipotètica d'acord a l'atzar)

Comentaris:

1. Tant MCC com Kappa són mètriques **simètriques**, és a dir, aplicades a una matriu de confusió $A=(a_{ij})_{ij=1,\dots,r}$, $MCC(A)=MCC(A^T)$, i $Kappa(A)=Kappa(A^T)$.
2. Si la matriu de confusió és simètrica, aleshores MCC i Kappa coincideixen, és a dir, **$MCC(A) = Kappa(A)$** si **$A=A^T$** .
3. Però en la situació asimètrica **$A \neq A^T$** , **Kappa pot mostrar un comportament no desitjat!** (un classificador pitjor que un altre pot obtenir una puntuació Kappa més alta), cosa en la que difereix qualitativament de MCC. Això fa que **la Kappa de Cohen NO sigui una bona mesura de comportament** per a fer servir en general per a comparar classificadors.

(Delgado, R. and Tibau, X.A.: Why Cohen's Kappa should be avoided as performance measure in classification, PLoS ONE 14(9) (2019)).

Un exemple:

$$A = \begin{pmatrix} t_p = 1 & f_p = 5 \\ f_n = 5 & t_n = 1 \end{pmatrix}, \quad B = \begin{pmatrix} t_p = 1 & f_p = 20 \\ f_n = 5 & t_n = 1 \end{pmatrix}$$

$$\text{MCC} = \frac{tp \times tn - fp \times fn}{\sqrt{(tp + fp)(tp + fn)(tn + fp)(tn + fn)}}$$

$$\text{MCC}(A) = \frac{1 \times 1 - 5 \times 5}{\sqrt{6 \times 6 \times 6 \times 6}} = \frac{-24}{36} = -0.6666667$$

$$\text{MCC}(B) = \frac{1 \times 1 - 5 \times 20}{\sqrt{21 \times 6 \times 21 \times 6}} = \frac{-99}{21 \times 6} = -0.7857143$$

B reflecteix un pitjor comportament predictiu que *A*, i MCC ho recull, ja que $\text{MCC}(B) < \text{MCC}(A)$.

Un exemple:

$$A = \begin{pmatrix} t_p = 1 & f_p = 5 \\ f_n = 5 & t_n = 1 \end{pmatrix}, \quad B = \begin{pmatrix} t_p = 1 & f_p = 20 \\ f_n = 5 & t_n = 1 \end{pmatrix}$$

$$\text{MCC} = \frac{tp \times tn - fp \times fn}{\sqrt{(tp + fp)(tp + fn)(tn + fp)(tn + fn)}}$$

$$\text{MCC}(A) = \frac{1 \times 1 - 5 \times 5}{\sqrt{6 \times 6 \times 6 \times 6}} = \frac{-24}{36} = -0.6666667$$

$$\text{MCC}(B) = \frac{1 \times 1 - 5 \times 20}{\sqrt{21 \times 6 \times 21 \times 6}} = \frac{-99}{21 \times 6} = -0.7857143$$

B reflecteix un pitjor comportament predictiu que A, i MCC ho recull, ja que $\text{MCC}(B) < \text{MCC}(A)$.

En canvi Kappa no ho capta bé, ja que $\text{Kappa}(B) > \text{Kappa}(A)$.

$$\text{Kappa} = \frac{\text{Acc} - P_e}{1 - P_e}$$

$$\text{Kappa}(A) = \frac{\frac{2}{12} - \frac{1}{12^2} (6 \times 6 + 6 \times 6)}{1 - \frac{1}{12^2} (6 \times 6 + 6 \times 6)} = \frac{2 \times 12 - 2 \times 36}{12^2 - 2 \times 36} = \frac{-48}{72} = -0.6666667$$

$$\text{Kappa}(B) = \frac{\frac{2}{27} - \frac{1}{27^2} (21 \times 6 + 6 \times 21)}{1 - \frac{1}{27^2} (21 \times 6 + 6 \times 21)} = \frac{2 \times 27 - 2 \times 21 \times 6}{27^2 - 2 \times 21 \times 6} = \frac{-198}{477} = -0.4150943$$

Noteu que com que A és simètrica, $\text{Kappa}(A) = \text{MCC}(A)$.

c) el cas ordinal

Ara veurem el cas particular de les mètriques per a la classificació multi-classe, amb $r > 2$ classes, quan hi ha un ordre entre elles.

Suposem, per comoditat i sense pèrdua de generalitat, que les classes ordenades són

$$1 < 2 < \dots < r$$

(si no, es canvia l'ordre i els noms de les classes).

Com que hi ha un ordre en les classes, suposem que es considera més greu classificar un cas de la classe i com a $i+2$ o $i-2$, que classificar-lo com a $i+1$ o $i-1$.

Nota: Si treballem amb l'*accuracy*, podem equivalentment considerar

$$\text{l'Error Rate} = 1 - \text{accuracy}$$

$$\text{Error Rate} = 1 - \frac{\sum_{i=1}^r a_{ii}}{M} = \frac{1}{M} \sum_{i \neq j} a_{ij}$$

L'*accuracy* interessa que sigui gran, equivalentment, que l'Error Rate que sigui petit.

Quin és el problema? Que l'Error Rate tracta tots els errors igual, i no penalitza més els que són més greus (quan ens allunyem més predient de la classe correcta).

L'alternativa és fer servir una mètrica que penalitzi els errors de manera diferent.

MAE (Mean Absolute Error): es considera una de les millors mètriques per a classificació ordinal. Penalitza més els errors més greus, proporcionalment a la distància entre les categories. Com que també és una mesura d'error, quant més petita, millor.

$$\text{MAE} = \frac{1}{M} \sum_{i,j=1}^r a_{ij} |i - j|$$

(noteu que els termes a_{ii} no afecten el sumatori perquè $|i - i| = 0$).

Hi ha algunes variants de MAE que es fan servir:

1. Quan les mides de les classes $n_1, \dots, n_r$, són desequilibrades (típicament en aplicacions en medicina, per exemple), es calcula la **Weighted Average of Mean Absolute Error (AMAE)**, que és una mitjana ponderada de la MAE calculada per a cadascuna de les classes, que és més robusta que MAE.

$$\text{AMAE} = \frac{1}{r} \sum_{j=1}^r \text{MAE}_j, \quad \text{amb}$$

$$\text{MAE}_j = \frac{1}{n_j} \sum_{i=1}^r a_{ij} |i - j|, \quad n_j = \sum_{i=1}^r a_{ij}$$

2. També es fa servir quan les mides de les classes $n_1, \dots, n_r$, són desequilibrades, el **Maximum of Mean Absolute Error (MMAE)**, que és el màxim de la MAE calculada per a cadascuna de les classes.

$$\text{MMAE} = \max_{j=1, \dots, r} \text{MAE}_j$$

El problema amb **MAE** i les seves variants és que suposen que totes les classes són **equidistants**, cosa que no té per què ser certa quan es fa una tasca de classificació ordinal. Per exemple,

molt dolent/dolent/acceptable/bo/molt bo

és conseqüència d'una apreciació subjectiva que difícilment correspondrà a valors numèrics equidistants.

Els treballs que utilitzen aquestes mètriques assumeixen de manera explícita o implícita que “els costos de classificació errònia sempre són proporcionals a la diferència absoluta entre l'etiqueta real i la prevista”

(Waegeman, W., De Baets, B., Boullart, L. (2006) A comparison of different ROC measures for ordinal regression. In Proceedings of the CML 2006 workshop on ROC Analysis in Machine Learning).

Però aquesta suposició va en contra del principi bàsic de la falta de sentit dels valors numèrics en la classificació ordinal, més enllà del seu ordenament!

Uns exemples

$$A = \begin{pmatrix} 5 & 2 & 1 \\ 3 & 6 & 2 \\ 2 & 2 & 7 \end{pmatrix}, B = \begin{pmatrix} 5 & 4 & 1 \\ 3 & 12 & 2 \\ 2 & 4 & 7 \end{pmatrix}, C = \begin{pmatrix} 5 & 4 & 2 \\ 2 & 12 & 1 \\ 3 & 4 & 7 \end{pmatrix}$$

- Matriu A : $n_1 = 10, n_2 = 10, n_3 = 10$. $M = \sum_{j=1}^3 n_j = 30$
- Matrius B i C : $n_1 = 10, n_2 = 20, n_3 = 10$. $M = \sum_{j=1}^3 n_j = 40$

	Accuracy	Error Rate	MAE	MAE ₁	MAE ₂	MAE ₃	AMAE	MMAE
A	18/30 = 0.6	12/30 = 0.4	15/30 = 0.5	7/10 = 0.7	4/10 = 0.4	4/10 = 0.4	0.5	0.7
B	24/40 = 0.6	16/40 = 0.4	19/40 = 0.475	7/10 = 0.7	8/20 = 0.4	4/10 = 0.4	0.5	0.7
C	24/40 = 0.6	16/40 = 0.4	21/40 = 0.525	8/10 = 0.8	8/20 = 0.4	5/10 = 0.5	0.566667	0.8

Ni *accuracy* ni Error Rate detecten diferències entre A , B i C .

MAE detecta diferències entre les tres, mentre que AMAE i MMAE donen el mateix valor a A i B , i diferent (més gran) a C .

Globalment, podem dir que la millor és B , després A i després C .

El coeficient de correlació de Kendall

El coeficient de correlació de Kendall (tau de Kendall) τ_b :

per a evitar la influència d'etiquetes de classe arbitràries, com passa amb **MAE** i les seves variants, podem utilitzar una mètrica que sigui independent de l'interval que representa cada classe, i simplement avalua la relació d'ordre entre les etiquetes de classe observades i predites.

Aquest coeficient de correlació és una mesura de l'associació ordinal entre les classes observades i predites. La seva definició és:

Primer, denotem per $y_1, \dots, y_M$ i $\hat{y}_1, \dots, \hat{y}_M$, respectivament, les classes observades i les classes predites (totes són valors entre 1 i r).

Definim

$$\gamma_{\ell m} = \begin{cases} +1 & \text{si } y_\ell > y_m \\ 0 & \text{si } y_\ell = y_m \\ -1 & \text{si } y_\ell < y_m \end{cases} \quad \text{i} \quad \hat{\gamma}_{\ell m} = \begin{cases} +1 & \text{si } \hat{y}_\ell > \hat{y}_m \\ 0 & \text{si } \hat{y}_\ell = \hat{y}_m \\ -1 & \text{si } \hat{y}_\ell < \hat{y}_m \end{cases}$$

segons que les parelles d'etiquetes observades corresponents als casos $(\ell, m) \in M \times M$ estiguin en un ordre, en el contrari, o siguin iguals (empat), i el mateix a les etiquetes predites.

El coeficient de correlació de Kendall

$$\gamma_{\ell m} = \begin{cases} +1 & \text{si } y_{\ell} > y_m \\ 0 & \text{si } y_{\ell} = y_m \\ -1 & \text{si } y_{\ell} < y_m \end{cases} \quad \text{i} \quad \hat{\gamma}_{\ell m} = \begin{cases} +1 & \text{si } \hat{y}_{\ell} > \hat{y}_m \\ 0 & \text{si } \hat{y}_{\ell} = \hat{y}_m \\ -1 & \text{si } \hat{y}_{\ell} < \hat{y}_m \end{cases}$$

c és el nombre de parells concordants: $(\ell, m) \in M \times M$ tals que $\gamma_{\ell m} \hat{\gamma}_{\ell m} = +1$

d és el nombre de parells discordants: $(\ell, m) \in M \times M$ tals que $\gamma_{\ell m} \hat{\gamma}_{\ell m} = -1$

e_{obs} és el nombre de parells de classes observades empatades (però predites, no)

$(\ell, m) \in M \times M$ tals que $\gamma_{\ell m} = 0$ però $\hat{\gamma}_{\ell m} \neq 0$

e_{pred} és el nombre de parells de classes predites empatades (però observades, no)

$(\ell, m) \in M \times M$ tals que $\hat{\gamma}_{\ell m} = 0$ però $\gamma_{\ell m} \neq 0$

I aleshores, el **coeficient de correlació de Kendall τ_b** es defineix així:

$$\tau_b = \frac{c - d}{\sqrt{(c + d + e_{obs}) (c + d + e_{pred})}}$$

(si l'empat és a la vegada a les classes observades observades i predites, $\gamma_{\ell m} = \hat{\gamma}_{\ell m} = 0$, s'**ignora**)⁴⁰

Uns exemples

$$A = \begin{pmatrix} 4 & 0 & 0 & 0 \\ 0 & 6 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 3 \end{pmatrix}, B = \begin{pmatrix} 0 & 0 & 0 & 0 \\ 4 & 0 & 0 & 0 \\ 0 & 6 & 0 & 0 \\ 0 & 0 & 0 & 3 \end{pmatrix}, C = \begin{pmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 4 & 6 & 0 & 0 \\ 0 & 0 & 0 & 3 \end{pmatrix}, D = \begin{pmatrix} 0 & 2 & 0 & 0 \\ 2 & 0 & 0 & 0 \\ 2 & 4 & 0 & 1 \\ 0 & 0 & 0 & 2 \end{pmatrix}$$

- **Matriu A:** $y = 1, 1, 1, 1, 2, 2, 2, 2, 2, 2, 4, 4, 4$
 $\hat{y} = 1, 1, 1, 1, 2, 2, 2, 2, 2, 2, 4, 4, 4$

ℓ	m	1:4	5:10	11:13
1:4		$\gamma=0$ / $\hat{\gamma}=0$	$\gamma=-1$ / $\hat{\gamma}=-1$	$\gamma=-1$ / $\hat{\gamma}=-1$
5:10		$\gamma=+1$ / $\hat{\gamma}=+1$	$\gamma=0$ / $\hat{\gamma}=0$	$\gamma=-1$ / $\hat{\gamma}=-1$
11:13		$\gamma=+1$ / $\hat{\gamma}=+1$	$\gamma=+1$ / $\hat{\gamma}=+1$	$\gamma=0$ / $\hat{\gamma}=0$

$$c = \frac{1}{2} (4 \times (6 + 3) + 6 \times (4 + 3) + 3 \times (4 + 6)) = 54$$

$$d = 0$$

$$e_{obs} = 0$$

$$e_{pred} = 0$$

$$\tau_b = \frac{c - d}{\sqrt{(c + d + e_{obs})(c + d + e_{pred})}} = \frac{54}{\sqrt{54 \times 54}} = 1$$

Com que la classificació és perfecta, per a la matriu A, $\tau_b = 1$.

Uns exemples

$$A = \begin{pmatrix} 4 & 0 & 0 & 0 \\ 0 & 6 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 3 \end{pmatrix}, B = \begin{pmatrix} 0 & 0 & 0 & 0 \\ 4 & 0 & 0 & 0 \\ 0 & 6 & 0 & 0 \\ 0 & 0 & 0 & 3 \end{pmatrix}, C = \begin{pmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 4 & 6 & 0 & 0 \\ 0 & 0 & 0 & 3 \end{pmatrix}, D = \begin{pmatrix} 0 & 2 & 0 & 0 \\ 2 & 0 & 0 & 0 \\ 2 & 4 & 0 & 1 \\ 0 & 0 & 0 & 2 \end{pmatrix}$$

- Matriu B : $y = 1, 1, 1, 1, 2, 2, 2, 2, 2, 2, 4, 4, 4$
 $\hat{y} = 2, 2, 2, 2, 3, 3, 3, 3, 3, 3, 4, 4, 4$

ℓ	m	1:4	5:10	11:13
1:4		$\gamma=0$ / $\hat{\gamma}=0$	$\gamma=-1$ / $\hat{\gamma}=-1$	$\gamma=-1$ / $\hat{\gamma}=-1$
5:10		$\gamma=+1$ / $\hat{\gamma}=+1$	$\gamma=0$ / $\hat{\gamma}=0$	$\gamma=-1$ / $\hat{\gamma}=-1$
11:13		$\gamma=+1$ / $\hat{\gamma}=+1$	$\gamma=+1$ / $\hat{\gamma}=+1$	$\gamma=0$ / $\hat{\gamma}=0$

$$c = \frac{1}{2} (4 \times (6 + 3) + 6 \times (4 + 3) + 3 \times (4 + 6)) = 54$$

$$d = 0$$

$$e_{obs} = 0$$

$$e_{pred} = 0$$

$$\tau_b = \frac{c - d}{\sqrt{(c + d + e_{obs}) (c + d + e_{pred})}} = \frac{54}{\sqrt{54 \times 54}} = 1$$

Encara que la classificació **no** és perfecta, per a la matriu B , també es té que $\tau_b = 1$!

Uns exemples

$$A = \begin{pmatrix} 4 & 0 & 0 & 0 \\ 0 & 6 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 3 \end{pmatrix}, B = \begin{pmatrix} 0 & 0 & 0 & 0 \\ 4 & 0 & 0 & 0 \\ 0 & 6 & 0 & 0 \\ 0 & 0 & 0 & 3 \end{pmatrix}, C = \begin{pmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 4 & 6 & 0 & 0 \\ 0 & 0 & 0 & 3 \end{pmatrix}, D = \begin{pmatrix} 0 & 2 & 0 & 0 \\ 2 & 0 & 0 & 0 \\ 2 & 4 & 0 & 1 \\ 0 & 0 & 0 & 2 \end{pmatrix}$$

- Matriu C: $y = 1, 1, 1, 1, 2, 2, 2, 2, 2, 2, 4, 4, 4$
 $\hat{y} = 3, 3, 3, 3, 3, 3, 3, 3, 3, 3, 4, 4, 4$

ℓ	m	1:4	5:10	11:13
1:4		$\gamma=0$ / $\hat{\gamma}=0$	$\gamma=-1$ / $\hat{\gamma}=0$	$\gamma=-1$ / $\hat{\gamma}=-1$
5:10		$\gamma=+1$ / $\hat{\gamma}=0$	$\gamma=0$ / $\hat{\gamma}=0$	$\gamma=-1$ / $\hat{\gamma}=-1$
11:13		$\gamma=+1$ / $\hat{\gamma}=+1$	$\gamma=+1$ / $\hat{\gamma}=+1$	$\gamma=0$ / $\hat{\gamma}=0$

$$c = \frac{1}{2}(4 \times 3 + 6 \times 3 + 3 \times (4 + 6)) = 30$$

$$d = 0$$

$$e_{obs} = \frac{1}{2}(4 \times 6 + 6 \times 4) = 24$$

$$e_{pred} = 0$$

$$\tau_b = \frac{c - d}{\sqrt{(c + d + e_{obs})(c + d + e_{pred})}} = \frac{30}{\sqrt{(30 + 24) \times 30}} = 0.745356$$

Per a la matriu C, $\tau_b = 0.745356 < 1$, indicant que és pitjor que A i que B.

Uns exemples

$$A = \begin{pmatrix} 4 & 0 & 0 & 0 \\ 0 & 6 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 3 \end{pmatrix}, B = \begin{pmatrix} 0 & 0 & 0 & 0 \\ 4 & 0 & 0 & 0 \\ 0 & 6 & 0 & 0 \\ 0 & 0 & 0 & 3 \end{pmatrix}, C = \begin{pmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 4 & 6 & 0 & 0 \\ 0 & 0 & 0 & 3 \end{pmatrix}, D = \begin{pmatrix} 0 & 2 & 0 & 0 \\ 2 & 0 & 0 & 0 \\ 2 & 4 & 0 & 1 \\ 0 & 0 & 0 & 2 \end{pmatrix}$$

- Matriu D : $y = 1, 1, 1, 1, 2, 2, 2, 2, 2, 2, 4, 4, 4$
 $\hat{y} = 2, 2, 3, 3, 1, 1, 3, 3, 3, 3, 3, 4, 4$

ℓ	m	1:2	3:4	5:6	7:10	11	12:13
1:2		$\gamma=0 / \hat{\gamma}=0$	$\gamma=0 / \hat{\gamma}=-1$	$\gamma=-1 / \hat{\gamma}=+1$	$\gamma=-1 / \hat{\gamma}=-1$	$\gamma=-1 / \hat{\gamma}=-1$	$\gamma=-1 / \hat{\gamma}=-1$
3:4		$\gamma=0 / \hat{\gamma}=+1$	$\gamma=0 / \hat{\gamma}=0$	$\gamma=-1 / \hat{\gamma}=+1$	$\gamma=-1 / \hat{\gamma}=0$	$\gamma=-1 / \hat{\gamma}=0$	$\gamma=-1 / \hat{\gamma}=-1$
5:6		$\gamma=+1 / \hat{\gamma}=-1$	$\gamma=+1 / \hat{\gamma}=-1$	$\gamma=0 / \hat{\gamma}=0$	$\gamma=0 / \hat{\gamma}=-1$	$\gamma=-1 / \hat{\gamma}=-1$	$\gamma=-1 / \hat{\gamma}=-1$
7:10		$\gamma=+1 / \hat{\gamma}=+1$	$\gamma=+1 / \hat{\gamma}=0$	$\gamma=0 / \hat{\gamma}=+1$	$\gamma=0 / \hat{\gamma}=0$	$\gamma=-1 / \hat{\gamma}=0$	$\gamma=-1 / \hat{\gamma}=-1$
11		$\gamma=+1 / \hat{\gamma}=+1$	$\gamma=+1 / \hat{\gamma}=0$	$\gamma=+1 / \hat{\gamma}=+1$	$\gamma=+1 / \hat{\gamma}=0$	$\gamma=0 / \hat{\gamma}=0$	$\gamma=0 / \hat{\gamma}=-1$
12:13		$\gamma=+1 / \hat{\gamma}=+1$	$\gamma=+1 / \hat{\gamma}=+1$	$\gamma=+1 / \hat{\gamma}=+1$	$\gamma=+1 / \hat{\gamma}=+1$	$\gamma=0 / \hat{\gamma}=+1$	$\gamma=0 / \hat{\gamma}=0$

$$c = \frac{1}{2}((2 \times 4 + 2 \times 1 + 2 \times 2) + (2 \times 2) + (2 \times 1 + 2 \times 2) + (4 \times 2 + 4 \times 2) + (1 \times 2 + 1 \times 2) + (2 \times 2 + 2 \times 2 + 2 \times 2 + 2 \times 4)) = 32, \quad d = \frac{1}{2}(2 \times 2 + 2 \times 2 + 2 \times (2 + 2)) = 8$$

$$e_{obs} = \frac{1}{2}(2 \times 2 + 2 \times 2 + 2 \times 4 + 4 \times 2 + 1 \times 2 + 2 \times 1) = 14$$

$$e_{pred} = \frac{1}{2}(2 \times (4 + 1) + 4 \times (2 + 1) + 1 \times (2 + 4)) = 14$$

Uns exemples

$$A = \begin{pmatrix} 4 & 0 & 0 & 0 \\ 0 & 6 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 3 \end{pmatrix}, B = \begin{pmatrix} 0 & 0 & 0 & 0 \\ 4 & 0 & 0 & 0 \\ 0 & 6 & 0 & 0 \\ 0 & 0 & 0 & 3 \end{pmatrix}, C = \begin{pmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 4 & 6 & 0 & 0 \\ 0 & 0 & 0 & 3 \end{pmatrix}, D = \begin{pmatrix} 0 & 2 & 0 & 0 \\ 2 & 0 & 0 & 0 \\ 2 & 4 & 0 & 1 \\ 0 & 0 & 0 & 2 \end{pmatrix}$$

- Matriu D :

$$c = \frac{1}{2}((2 \times 4 + 2 \times 1 + 2 \times 2) + (2 \times 2) + (2 \times 1 + 2 \times 2) + (4 \times 2 + 4 \times 2) + (1 \times 2 + 1 \times 2) + (2 \times 2 + 2 \times 2 + 2 \times 2 + 2 \times 4)) = 32, \quad d = \frac{1}{2}(2 \times 2 + 2 \times 2 + 2 \times (2 + 2)) = 8$$

$$e_{obs} = \frac{1}{2}(2 \times 2 + 2 \times 2 + 2 \times 4 + 4 \times 2 + 1 \times 2 + 2 \times 1) = 14$$

$$e_{pred} = \frac{1}{2}(2 \times (4 + 1) + 4 \times (2 + 1) + 1 \times (2 + 4)) = 14$$

$$\tau_b = \frac{c - d}{\sqrt{(c + d + e_{obs})(c + d + e_{pred})}} = \frac{32 - 8}{\sqrt{(32 + 8 + 14) \times (32 + 8 + 14)}} = \frac{4}{9} \approx 0.44444$$

Per a la matriu D , $\tau_b=0.44444$, indicant que és pitjor que A , B , i C .

Uns exemples

$$A = \begin{pmatrix} 4 & 0 & 0 & 0 \\ 0 & 6 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 3 \end{pmatrix}, B = \begin{pmatrix} 0 & 0 & 0 & 0 \\ 4 & 0 & 0 & 0 \\ 0 & 6 & 0 & 0 \\ 0 & 0 & 0 & 3 \end{pmatrix}, C = \begin{pmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 4 & 6 & 0 & 0 \\ 0 & 0 & 0 & 3 \end{pmatrix}, D = \begin{pmatrix} 0 & 2 & 0 & 0 \\ 2 & 0 & 0 & 0 \\ 2 & 4 & 0 & 1 \\ 0 & 0 & 0 & 2 \end{pmatrix}$$

	Error Rate	MAE	τ_b
<i>A</i>	0	0	1
<i>B</i>	$10/13 \cong 0.77$	$10/13 \cong 0.77$	1
<i>C</i>	$10/13 \cong 0.77$	$14/13 \cong 1.08$	$1/9 \cong 0.75$
<i>D</i>	$11/13 \cong 0.85$	$13/13 = 1$	$4/9 \cong 0.44$

Aquestes i d'altres mesures per a classificació ordinal es poden trobar, per exemple, a:

Cardoso, J.S., Sousa, R. (2011). Measuring the performance of ordinal classification. *International Journal of Pattern Recognition and Artificial Intelligence*, 25(8), pp. 1173-1195

3.4 Mètriques a partir de probabilitats derivades de la matriu de confusió: *confusion entropy*

Partim d'una matriu de confusió general $r \times r$:

predit	observat					
	C_1	C_2	$\dots$	C_j	$\dots$	C_r
C_1	a_{11}	a_{12}	$\dots$	a_{1j}	$\dots$	a_{1r}
C_2	a_{21}	a_{22}	$\dots$	a_{2j}	$\dots$	a_{2r}
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$		$\vdots$
C_i	a_{i1}	a_{i2}	$\dots$	a_{ij}	$\dots$	a_{ir}
$\vdots$	$\vdots$	$\vdots$		$\vdots$	$\ddots$	$\vdots$
C_r	a_{r1}	a_{r2}	$\dots$	a_{rj}	$\dots$	a_{rr}
	$n_1 = a_{.1}$	$n_2 = a_{.2}$	$\dots$	$n_j = a_{.j}$	$\dots$	$n_r = a_{.r}$

A partir d'aquesta matriu podem definir probabilitats empíriques i definir a partir d'elles una mètrica basada en l'entropia de Shannon, que s'anomena **CEN (*Confusion Entropy*)**.

Jin-Mao Wei, Xiao-Jie Yuan, Qing-Hua Hu, Shu-Qin Wang (2010) "A novel measure for evaluating classifiers", Expert Systems with Applications, 37(5)

<https://doi.org/10.1016/j.eswa.2009.11.040>

predict	observat					
	C_1	C_2	$\dots$	C_j	$\dots$	C_r
C_1	a_{11}	a_{12}	$\dots$	a_{1j}	$\dots$	a_{1r}
C_2	a_{21}	a_{22}	$\dots$	a_{2j}	$\dots$	a_{2r}
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$		$\vdots$
C_i	a_{i1}	a_{i2}	$\dots$	a_{ij}	$\dots$	a_{ir}
$\vdots$	$\vdots$	$\vdots$		$\vdots$	$\ddots$	$\vdots$
C_r	a_{r1}	a_{r2}	$\dots$	a_{rj}	$\dots$	a_{rr}
	$n_1 = a_{.1}$	$n_2 = a_{.2}$	$\dots$	$n_j = a_{.j}$	$\dots$	$n_r = a_{.r}$

En aquest article s'introdueix una millora de la mètrica CEN, de nom MCEN (Modified Confusion Entropy):

Delgado R., Núñez-González JD. (2019) "Enhancing Confusion Entropy (CEN) for binary and multiclass classification", PLoS ONE 14(1): e0210264. <https://doi.org/10.1371/journal.pone.0210264>

Definim unes probabilitats:

$$P_{i,j}^i = \frac{a_{ij}}{a_{.i} + a_{i.} - a_{ii}}$$

Probabilitat de classificar incorrectament com pertanyent a la classe i un ítem de la classe j , $j \neq i$, condicionat a tots els ítems que pertanyen o que són classificats com pertanyent a la classe i .

A CEN aquest terme no apareix (si no es posa, la definició no és correcta).

predict	observat					
	C_1	C_2	$\dots$	C_j	$\dots$	C_r
C_1	a_{11}	a_{12}	$\dots$	a_{1j}	$\dots$	a_{1r}
C_2	a_{21}	a_{22}	$\dots$	a_{2j}	$\dots$	a_{2r}
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$		$\vdots$
C_i	a_{i1}	a_{i2}	$\dots$	a_{ij}	$\dots$	a_{ir}
$\vdots$	$\vdots$	$\vdots$		$\vdots$	$\ddots$	$\vdots$
C_r	a_{r1}	a_{r2}	$\dots$	a_{rj}	$\dots$	a_{rr}
	$n_1 = a_{.1}$	$n_2 = a_{.2}$	$\dots$	$n_j = a_{.j}$	$\dots$	$n_r = a_{.r}$

$$P_{i,j}^j = \frac{a_{ij}}{a_{.j} + a_{j.} - a_{jj}}$$

Probabilitat de classificar incorrectament com pertanyent a la classe i un ítem de la classe j , $j \neq i$, condicionat a tots els ítems que pertanyen o que són classificats com pertanyent a la classe j .

A CEN aquest terme tampoc no apareix (si no es posa, la definició no és correcta).

Aleshores, es defineix MCEN_i per a la classe i de la manera següent:

$$\text{MCEN}_i = - \sum_{j \neq i} (P_{i,j}^i \log_{2(r-1)}(P_{i,j}^i) + P_{i,j}^j \log_{2(r-1)}(P_{i,j}^j))$$

$$\text{MCEN}_i = - \sum_{j \neq i} (P_{i,j}^i \log_{2(r-1)}(P_{i,j}^i) + P_{i,j}^j \log_{2(r-1)}(P_{i,j}^j))$$

Fixeu-vos que és la suma de dos termes semblants a l'**entropia de Shannon** (recordeu AA1), fixada i , de les probabilitats corresponents a classificar incorrectament com pertanyent a la classe i un ítem de la classe j , $j \neq i$, condicionant a:

➤ tots els ítems que pertanyen o que són classificats com pertanyent a la classe i

$$P_{i,j}^i = \frac{a_{ij}}{a_{.i} + a_{i.} - a_{ii}}$$

predict	observat							
	C_1	C_2	$\cdots$	C_i	$\cdots$	C_j	$\cdots$	C_r
C_1	a_{11}	a_{12}	$\cdots$	a_{1i}	$\cdots$	a_{1j}	$\cdots$	a_{1r}
C_2	a_{21}	a_{22}	$\cdots$	a_{2i}	$\cdots$	a_{2j}	$\cdots$	a_{2r}
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\ddots$	$\vdots$	$\ddots$	$\vdots$
C_i	a_{i1}	a_{i2}	$\cdots$	a_{ii}	$\cdots$	a_{ij}	$\cdots$	a_{ir}
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\ddots$	$\vdots$	$\ddots$	$\vdots$
C_j	a_{j1}	a_{j2}	$\cdots$	a_{ji}	$\cdots$	a_{jj}	$\cdots$	a_{jr}
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\ddots$	$\vdots$	$\ddots$	$\vdots$
C_r	a_{r1}	a_{r2}	$\cdots$	a_{ri}	$\cdots$	a_{rj}	$\cdots$	a_{rr}

➤ tots els ítems que pertanyen o que són classificats com pertanyent a la classe j

$$P_{i,j}^j = \frac{a_{ij}}{a_{.j} + a_{j.} - a_{jj}}$$

predict	observat							
	C_1	C_2	$\cdots$	C_i	$\cdots$	C_j	$\cdots$	C_r
C_1	a_{11}	a_{12}	$\cdots$	a_{1i}	$\cdots$	a_{1j}	$\cdots$	a_{1r}
C_2	a_{21}	a_{22}	$\cdots$	a_{2i}	$\cdots$	a_{2j}	$\cdots$	a_{2r}
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\ddots$	$\vdots$	$\ddots$	$\vdots$
C_i	a_{i1}	a_{i2}	$\cdots$	a_{ii}	$\cdots$	a_{ij}	$\cdots$	a_{ir}
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\ddots$	$\vdots$	$\ddots$	$\vdots$
C_j	a_{j1}	a_{j2}	$\cdots$	a_{ji}	$\cdots$	a_{jj}	$\cdots$	a_{jr}
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\ddots$	$\vdots$	$\ddots$	$\vdots$
C_r	a_{r1}	a_{r2}	$\cdots$	a_{ri}	$\cdots$	a_{rj}	$\cdots$	a_{rr}

Aleshores, la mètrica MCEN es defineix com una mitjana ponderada dels valors $MCEN_i$:

$$MCEN = \sum_{i=1}^r P_i MCEN_i$$

on els pesos són:

$$P_i = \frac{a_{.i} + a_{i.} - a_{ii}}{2M - \alpha \sum_{k=1}^r a_{kk}}$$

amb

$$\alpha = \begin{cases} \frac{1}{2} & \text{si } r = 2 \\ 1 & \text{si } r > 2 \end{cases}$$

predict	observat							
	C_1	C_2	$\dots$	C_i	$\dots$	C_j	$\dots$	C_r
C_1	a_{11}	a_{12}	$\dots$	a_{1i}	$\dots$	a_{1j}	$\dots$	a_{1r}
C_2	a_{21}	a_{22}	$\dots$	a_{2i}	$\dots$	a_{2j}	$\dots$	a_{2r}
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\ddots$	$\vdots$	$\ddots$	$\vdots$
C_i	a_{i1}	a_{i2}	$\dots$	a_{ii}	$\dots$	a_{ij}	$\dots$	a_{ir}
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\ddots$	$\vdots$	$\ddots$	$\vdots$
C_j	a_{j1}	a_{j2}	$\dots$	a_{ji}	$\dots$	a_{jj}	$\dots$	a_{jr}
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\ddots$	$\vdots$	$\ddots$	$\vdots$
C_r	a_{r1}	a_{r2}	$\dots$	a_{ri}	$\dots$	a_{rj}	$\dots$	a_{rr}

Important!!

es pot demostrar, tot i que no ho farem, que $MCEN \in [0, 1]$

Cas particular: r=2 (classificació binària)

$$\text{MCEN}_1 = - (P_{1,2}^1 \log_2(P_{1,2}^1) + P_{1,2}^2 \log_2(P_{1,2}^2))$$

$$P_{1,2}^1 = \frac{f_p}{t_p + f_p + f_n} \quad P_{1,2}^2 = \frac{f_n}{t_n + f_p + f_n}$$

$$\text{MCEN}_2 = - (P_{2,1}^2 \log_2(P_{2,1}^2) + P_{2,1}^1 \log_2(P_{2,1}^1))$$

$$P_{2,1}^2 = \frac{f_n}{t_n + f_p + f_n} \quad P_{2,1}^1 = \frac{f_p}{t_p + f_p + f_n}$$

$$P_1 = \frac{t_p + f_p + f_n}{2M - \frac{1}{2}(t_p + t_n)} \quad P_2 = \frac{t_n + f_p + f_n}{2M - \frac{1}{2}(t_p + t_n)}$$

	observat	
	+	-
predit	$t_p = a_{11}$	$f_p = a_{12}$
	$f_n = a_{21}$	$t_n = a_{22}$

$$\begin{pmatrix} 6 & 0 \\ 0 & 6 \end{pmatrix}$$

$$\begin{aligned} P_{1,2}^1 &= 0 & P_{1,2}^2 &= 0 & P_{2,1}^2 &= 0 & P_{2,1}^1 &= 0 \\ \text{MCEN}_1 &= 0 & \text{MCEN}_2 &= 0 & \implies & \text{MCEN} &= 0 \end{aligned}$$

$$\begin{pmatrix} 4 & 2 \\ 2 & 4 \end{pmatrix}$$

$$\begin{aligned} P_{1,2}^1 &= \frac{2}{8} = \frac{1}{4} & P_{1,2}^2 &= \frac{2}{8} = \frac{1}{4} & \implies & \text{MCEN}_1 &= -2 \frac{1}{4} \log_2\left(\frac{1}{4}\right) = -2 \frac{1}{4} (-2) = 1 \\ P_{2,1}^2 &= \frac{2}{8} = \frac{1}{4} & P_{2,1}^1 &= \frac{2}{8} = \frac{1}{4} & \implies & \text{MCEN}_2 &= -2 \frac{1}{4} \log_2\left(\frac{1}{4}\right) = -2 \frac{1}{4} (-2) = 1 \\ P_1 &= \frac{8}{2 \times 12 - \frac{1}{2} 8} = \frac{2}{5} & P_2 &= \frac{8}{2 \times 12 - \frac{1}{2} 8} = \frac{2}{5} & \implies & \text{MCEN} &= \frac{2}{5} 1 + \frac{2}{5} 1 = \frac{4}{5} = 0.8 \end{aligned}$$

observat

+ -

$$\text{predit} \quad \left(\begin{array}{cc} t_p = a_{11} & f_p = a_{12} \\ f_n = a_{21} & t_n = a_{22} \end{array} \right)$$

$$\text{MCEN}_1 = - \left(P_{1,2}^1 \log_2(P_{1,2}^1) + P_{1,2}^2 \log_2(P_{1,2}^2) \right)$$

$$P_{1,2}^1 = \frac{f_p}{t_p + f_p + f_n} \quad P_{1,2}^2 = \frac{f_p}{t_n + f_p + f_n}$$

$$\text{MCEN}_2 = - \left(P_{2,1}^2 \log_2(P_{2,1}^2) + P_{2,1}^1 \log_2(P_{2,1}^1) \right)$$

$$P_{2,1}^2 = \frac{f_n}{t_n + f_p + f_n} \quad P_{2,1}^1 = \frac{f_n}{t_p + f_p + f_n}$$

$$P_1 = \frac{t_p + f_p + f_n}{2M - \frac{1}{2}(t_p + t_n)} \quad P_2 = \frac{t_n + f_p + f_n}{2M - \frac{1}{2}(t_p + t_n)}$$

$$\left(\begin{array}{cc} 2 & 4 \\ 4 & 2 \end{array} \right) \rightarrow$$

$$\begin{aligned} P_{1,2}^1 &= \frac{4}{10} = \frac{2}{5} & P_{1,2}^2 &= \frac{4}{10} = \frac{2}{5} \Rightarrow \text{MCEN}_1 = -2 \frac{2}{5} \log_2\left(\frac{2}{5}\right) = \frac{4}{5} (\log_2(5) - 1) \\ P_{2,1}^2 &= \frac{4}{10} = \frac{2}{5} & P_{2,1}^1 &= \frac{4}{10} = \frac{2}{5} \Rightarrow \text{MCEN}_2 = -2 \frac{2}{5} \log_2\left(\frac{2}{5}\right) = \frac{4}{5} (\log_2(5) - 1) \\ P_1 &= \frac{10}{2 \times 12 - \frac{1}{2} 4} = \frac{5}{11} & P_2 &= \frac{10}{2 \times 12 - \frac{1}{2} 4} = \frac{5}{11} \Rightarrow \text{MCEN} = \frac{8}{11} (\log_2(5) - 1) \approx 0.9614 \end{aligned}$$

$$\left(\begin{array}{cc} 0 & 6 \\ 6 & 0 \end{array} \right) \rightarrow$$

$$\begin{aligned} P_{1,2}^1 &= \frac{6}{12} = \frac{1}{2} & P_{1,2}^2 &= \frac{6}{12} = \frac{1}{2} \Rightarrow \text{MCEN}_1 = -2 \frac{1}{2} \log_2\left(\frac{1}{2}\right) = (1)(-1) = 1 \\ P_{2,1}^2 &= \frac{6}{12} = \frac{1}{2} & P_{2,1}^1 &= \frac{6}{12} = \frac{1}{2} \Rightarrow \text{MCEN}_2 = -2 \frac{1}{2} \log_2\left(\frac{1}{2}\right) = (1)(-1) = 1 \\ P_1 &= \frac{12}{2 \times 12 - \frac{1}{2} 0} = \frac{1}{2} & P_2 &= \frac{12}{2 \times 12 - \frac{1}{2} 0} = \frac{1}{2} \Rightarrow \text{MCEN} = 2 \frac{1}{2} 1 = 1 \end{aligned}$$

Un exemple amb $r=3$ (classificació multi-classe)

$$\begin{pmatrix} 10 & 0 & 0 \\ 0 & 10 & 10 \\ 10 & 0 & 0 \end{pmatrix} \rightarrow$$

$$i = 1 : P_{1,2}^1 = \frac{0}{10 + 20 - 10} = 0 \quad P_{1,2}^2 = \frac{0}{10 + 10 - 10} = 0$$

$$P_{1,3}^1 = \frac{0}{10 + 20 - 10} = 0 \quad P_{1,3}^3 = \frac{0}{10 + 10 - 0} = 0 \Rightarrow \text{MCEN}_1 = 0$$

$$i = 2 : P_{2,1}^2 = \frac{0}{10 + 20 - 10} = 0 \quad P_{2,1}^1 = \frac{0}{10 + 20 - 10} = 0$$

$$P_{2,3}^2 = \frac{10}{20 + 10 - 10} = \frac{1}{2} \quad P_{2,3}^3 = \frac{10}{10 + 10 - 0} = \frac{1}{2}$$

$$\Rightarrow \text{MCEN}_2 = -2 \frac{1}{2} \log_4\left(\frac{1}{2}\right) = (-1) \left(-\frac{1}{2}\right) = \frac{1}{2}$$

$$i = 3 : P_{3,1}^3 = \frac{10}{10 + 10 - 0} = \frac{1}{2} \quad P_{3,1}^1 = \frac{10}{10 + 20 - 10} = \frac{1}{2}$$

$$P_{3,2}^3 = \frac{0}{10 + 10 - 0} = 0 \quad P_{3,2}^2 = \frac{0}{10 + 20 - 10} = 0$$

$$\Rightarrow \text{MCEN}_3 = -2 \frac{1}{2} \log_4\left(\frac{1}{2}\right) = (-1) \left(-\frac{1}{2}\right) = \frac{1}{2}$$

$$P_1 = \frac{20}{2 \times 40 - 20} = \frac{1}{3} \quad P_2 = \frac{20}{2 \times 40 - 20} = \frac{1}{3} \quad P_3 = \frac{20}{2 \times 40 - 20} = \frac{1}{3}$$

$$\Rightarrow \text{MCEN} = \frac{1}{3} \left(0 + \frac{1}{2} + \frac{1}{2}\right) = \frac{1}{3} \approx 0.3333$$