

Entrega Remostreig

8 de maig de 2026

Aquesta entrega s'ha de realitzar en parelles. La data límit de lliurament és el pròxim **8 de maig a les 23:59h**.

Exercici 1: Bootstrap per a la comparació de la Media i la Mediana

En molts estudis biològics, com el de les mides de fòssils o nivells de lípids en sang, les dades presenten una forta asimetria cap a la dreta (heavy tails). En aquests casos, la mediana sol ser un estimador més representatiu que la mitjana. L'objectiu d'aquest exercici és utilitzar el mètode bootstrap per analitzar la precisió d'ambdós estimadors utilitzant les següents dades:

Espècie	Inferior	Mitjà	Superior
Ceratops	50	53	19
Hadro	29	51	7
Pachycephalo	2	19	1
Tyranno	1	3	2
Ornithomo	4	8	1
Sauronith	1	6	3

Considerem la mostra agregada del període **Inferior** ($n = 87$ individus repartits en les 6 espècies).

- (a) A partir de les dades de la taula per al període Inferior, calcula la mitjana ($\bar{x}$) i la mediana (M) del nombre de troballes per espècie. Comenta la diferència entre ambdós valors en funció de la dispersió de les dades.

- (b) Implementa un algorisme bootstrap amb $B = 2000$ replicacions per a:

- Estimar l'error estàndard de la mitjana, $se_{boot}(\bar{x})$.
- Estimar l'error estàndard de la mediana, $se_{boot}(M)$.

Quin dels dos estimadors presenta una variabilitat menor en aquest context?

- (c) Utilitzant les mostres bootstrap generades, calcula el biaix estimat per a la mitjana i per a la mediana:

$$\widehat{Bias}^*(\hat{\theta}) = \bar{\theta}^* - \hat{\theta}$$

on $\bar{\theta}^*$ és la mitjana de les replicacions bootstrap i $\hat{\theta}$ és l'estimador original. És algun dels dos estimadors significativament esbiaixat?

- (d) Per a la **mediana**, calcula els següents intervals de confiança al 95%:

- i. Interval Normal (basat en se_{boot}).
- ii. Interval del Percentil.

- (e) Si afegim una observació atípica (outlier) a les dades originals (per exemple, una nova espècie amb 200 troballes), quin dels dos intervals de confiança (mitjana vs. mediana) creus que patiria un desplaçament més gran?

Exercici 2: Tests de permutacions per a la comparació de poblacions

Un dels avantatges dels mètodes de remostreig és la seva capacitat per contrastar hipòtesis sense assumir la normalitat de les dades. En aquest exercici, utilitzarem la distribució permutacional per estudiar si l'abundància relativa de dinosaures va canviar significativament entre el període **Inferior** i el **Superior** segons les dades del registre fòssil.

Considerem la distància de la chi-quadrat (d_{χ^2}) com a estadístic de contrast per comparar les freqüències observades en dos períodes:

$$d_{\chi^2} = \sum_{i=1}^k \frac{(p_{i,inf} - p_{i,sup})^2}{\bar{p}_i}$$

on $p_{i,j}$ és la proporció de l'espècie i en el període j , i $\bar{p}_i$ és la proporció mitjana global.

- (a) Utilitzant les dades de la taula del Cretaci, calcula les proporcions de cada espècie per als períodes *Inferior* i *Superior*. Calcula el valor observat de l'estadístic d_{χ^2} entre aquests dos períodes.
- (b) Defineix amb precisió la hipòtesi nul·la (H_0) en el context d'un test de permutacions per a aquestes dades.
- (c) Implementa el test. Interpreta els resultats.
- (d) Representa l'histograma de la distribució permutacional de l'estadístic i marca amb una línia vermella el valor observat en l'apartat (a).

Exercici 3: Bootstrap Paramètric vs No Paramètric

En l'estudi paleontològic presentat, els recomptes d'espècies en el període **Superior** ($n = 33$ fòssils totals) es podrien modelitzar teòricament mitjançant una distribució de Poisson si assumim que les troballes ocorren de manera independent en el jaciment. L'objectiu d'aquest exercici és determinar si aquesta assumpció és vàlida i com afecta a la precisió de les nostres estimacions.

- (a) Calcula la mitjana mostral ($\hat{\lambda}$) i la variància mostral (s^2) dels recomptes del període Superior. Presenta un comentari comparant ambdós valors: es compleix la propietat d'equidispensió ($\mu = \sigma^2$) típica de la distribució de Poisson? A la vista dels resultats, creus que una Poisson és un model d'ajust adequat per a aquestes dades o hi ha evidència de sobredispersió?
- (b) Genera $B = 2000$ mostres bootstrap extraient elements amb reposició de la mostra original. Calcula l'error estàndard de la mitjana, $\hat{se}_{boot,NP}(\hat{\lambda})$.
- (c) Suposa ara que les dades segueixen estrictament una distribució $Poisson(\hat{\lambda})$, on el paràmetre s'estima amb la mitjana de la mostra original. Genera $B = 2000$ mostres simulades a partir d'aquest model i calcula l'error estàndard paramètric, $\hat{se}_{boot,P}(\hat{\lambda})$.
- (d) Calcula l'interval de confiança del 95% per a λ utilitzant el mètode del percentil per a:

- a) L'enfocament no paramètric de l'apartat (b).
- b) L'enfocament paramètric de l'apartat (c).