

Pràctica 5

Maria Cobo Ollero

26-03-2026

Introducció al Bootstrap

El **Bootstrap** és una tècnica d'inferència estadística que permet estimar la distribució d'un estadístic (com la mitjana, la variància o els coeficients d'una regressió) mitjançant el remostreig a partir de les dades originals.

La idea central és que la mostra original és la millor aproximació que tenim de la població real. Per tant, si tornem a extreure mostres d'aquesta "mostra", podem simular com variaria l'estadístic si haguéssim pres moltes mostres diferents de la població.

El mètode té sempre tres etapes fonamentals:

1. **Estimar** la distribució de la població a partir del conjunt de dades.
2. **Simular** el mostreig d'aquesta població per obtenir noves "mostres bootstrap" de la mateixa mida (n).
3. **Calcular** l'estadístic d'interès per a cada una de les simulacions.

1. Bootstrap No Paramètric

En el mètode **no paramètric**, no assumim cap forma matemàtica (com la Normal) per a les dades. Fem servir la distribució de freqüències dels n valors observats com la nostra millor estimació de la població.

Procés pas a pas:

1. Tenim una mostra original de mida n .
2. **Generem una mostra bootstrap:** Seleccionem n observacions de la mostra original **amb reposició** (`sample(dades, replace = TRUE)`). Això significa que una mateixa dada pot aparèixer diversos cops i d'altres cap.
3. Calculem l'estadístic d'interès.
4. Repetim el procés B vegades.
5. Analitzem la distribució de les B estimacions per calcular intervals de confiança o l'error estàndard.

Per què és útil? - No cal assumir que les dades segueixen una distribució normal. - És ideal per a estadístics complexos sense fórmula senzilla (com la mediana). - És molt fàcil d'aplicar computacionalment.

2. Bootstrap Paramètric

El **Bootstrap paramètric** s'utilitza quan estem disposats a assumir que les dades provenen d'una distribució coneguda (Normal, Poisson, Exponencial, etc.).

Procés pas a pas:

1. **Estimació de paràmetres:** Utilitzem les dades per estimar els paràmetres del model (per exemple, si assumim normalitat, calculem la mitjana $\hat{\mu}$ i la desviació $\hat{\sigma}$).
2. **Simulació:** En lloc de reordenar les dades originals, utilitzem un **generador de nombres aleatoris** (com `rnorm()`) per crear mostres noves basades en el patró estimat.
3. La resta del procés (càlcul de l'estadístic i repetició B vegades) és idèntic al mètode no paramètric.

Per què és útil? - Si el model teòric triat és correcte, aquest mètode és més precís que el no paramètric, especialment amb mostres petites.

Exemple 1.

Un laboratori mesura el creixement de 10 cultius cel·lulars en mil·límetres: 12, 15, 14, 11, 25, 13, 16, 14, 12, 15. L'investigador no només vol la mitjana, sinó que està interessat en la variància (la dispersió), ja que una variabilitat alta podria indicar un problema en el protocol.

Calcularem l'error estàndard de la variància mitjançant Bootstrap No Paramètric.

```
creixement <- c(12, 15, 14, 11, 25, 13, 16, 14, 12, 15)
n <- length(creixement)
B <- 1000
variancies_boot <- numeric(B)

set.seed(123)
for(i in 1:B) {
  mostra_b <- sample(creixement, size = n, replace = TRUE)
  variancies_boot[i] <- var(mostra_b)
}

# Error estàndard de la variància (desviació típica de les simulacions)
se_var <- sd(variancies_boot)
cat("La variància observada és:", var(creixement), "\n")

## La variància observada és: 15.56667

cat("L'error estàndard estimat per Bootstrap és:", se_var, "\n")
```

```
## L'error estàndard estimat per Bootstrap és: 10.02966
```

Exemple 2.

Hem mesurat el temps d'espera (en minuts) de 8 clients en una cafeteria. Les dades obtingudes són: 2, 5, 3, 8, 4, 12, 6, 7.

Volem estimar la **mitjana del temps d'espera** i calcular-ne l'error estàndard i l'interval de confiança del 95% utilitzant dues estratègies diferents:

1. **Bootstrap No Paramètric:** No assumirem res sobre la distribució dels temps.
2. **Bootstrap Paramètric:** Assumirem que els temps d'espera segueixen una **distribució Normal**.

El mètode Paramètric és més "arriscat": si el temps d'espera realment no segueix una distribució Normal (per exemple, si fos una Exponencial), l'interval seria incorrecte. El mètode No Paramètric és més "segur" perquè no s'inventa la forma de la distribució; simplement "copia" la que ja ha vist.

Començem fent el model no paramètric.

```
temps <- c(2, 5, 3, 8, 4, 12, 6, 7)
n <- length(temps)
B <- 1000
res_no_param <- numeric(B)

set.seed(123)
for(i in 1:B) {
  mostra_b <- sample(temps, size = n, replace = TRUE)
  res_no_param[i] <- mean(mostra_b)
}
```

```
ic_no_param <- quantile(res_no_param, probs = c(0.025, 0.975))
cat("IC 95% No Paramètric:", ic_no_param, "\n")
```

```
## IC 95% No Paramètric: 4.125 8.125
```

Ara ho fem però assumint que els temps d'espera segueixen una distribució Normal. En aquest cas, primer “aprenem” els paràmetres de la mostra (mitjana i desviació) i després generem dades noves seguint el model teòric de la Normal.

```
mitjana_est <- mean(temps)
sd_est <- sd(temps)

n <- length(temps)
B <- 1000
res_param <- numeric(B)

set.seed(123)
for(i in 1:B) {
  mostra_b <- rnorm(n, mean = mitjana_est, sd = sd_est) # NO utilitzem sample!
  res_param[i] <- mean(mostra_b)
}

ic_param <- quantile(res_param, probs = c(0.025, 0.975))
cat("IC 95% Paramètric:", ic_param, "\n")
```

```
## IC 95% Paramètric: 3.601351 7.996744
```

Ara mirem aquests resultats de manera gràfica.


```
par(mfrow = c(1, 2))

limit_x <- c(2, 10)


hist(res_no_param, breaks = 25, col = "skyblue", border = "white",
     xlim = limit_x, main = "Bootstrap No Paramètric",
     xlab = "Mitjana de temps", ylab = "Freqüència")
abline(v = ic_no_param, col = "blue", lwd = 2, lty = 2)
abline(v = mitjana_est, col = "red", lwd = 2)

hist(res_param, breaks = 25, col = "skyblue", border = "white",
     xlim = limit_x, main = "Bootstrap Paramètric",
     xlab = "Mitjana de temps", ylab = "Freqüència")
abline(v = ic_param, col = "blue", lwd = 2, lty = 2)
abline(v = mitjana_est, col = "red", lwd = 2)
```

Bootstrap No Paramètric



Bootstrap Paramètric



```
par(mfrow = c(1, 1))
```

Exemple 3

Volem estudiar la relació entre la potència del motor (hp) i el consum (mpg) utilitzant el conjunt de dades mtcars. El nostre objectiu és estimar el coeficient de la pendent (com afecta la potència al consum) i calcular el seu interval de confiança del 95% mitjançant bootstrap no paramètric i paramètric.

1. Model no paramètric: En aquest mètode, seleccionem files completes de la base de dades amb reposició. Això conserva la relació entre les variables però varia la mostra.

```
dades <- mtcars[, c("mpg", "hp")]
n <- nrow(dades)
B <- 1000
pendents_no_param <- numeric(B)

model_original <- lm(mpg ~ hp, data = dades)
beta_original <- coef(model_original)[2]

set.seed(123)
for(i in 1:B) {
  indexs <- sample(1:n, size = n, replace = TRUE)
  mostra_b <- dades[indexs, ]
  model_b <- lm(mpg ~ hp, data = mostra_b)
  pendents_no_param[i] <- coef(model_b)[2]
}

ic_no_param <- quantile(pendents_no_param, probs = c(0.025, 0.975))
cat("Pendent original:", beta_original, "\n")

## Pendent original: -0.06822828

cat("IC 95% No Paramètric:", ic_no_param, "\n")
```

```
## IC 95% No Paramètric: -0.1009381 -0.04783975
```

2. Model paramètric: En regressió, el mètode paramètric assumeix que el model lineal és correcte i que l'error segueix una distribució Normal. Generem noves "Y" (consums) mantenint les "X" (potència) fixes.

```
valors_ajustats <- predict(model_original)
sigma_residus <- summary(model_original)$sigma

pendents_param <- numeric(B)

set.seed(123)
for(i in 1:B) {
  residus_simulats <- rnorm(n, mean = 0, sd = sigma_residus)
  mpg_simulat <- valors_ajustats + residus_simulats
  model_b <- lm(mpg_simulat ~ dades$hp)
  pendents_param[i] <- coef(model_b)[2]
}

ic_param <- quantile(pendents_param, probs = c(0.025, 0.975))
cat("IC 95% Paramètric:", ic_param, "\n")

## IC 95% Paramètric: -0.08738745 -0.04866285
```

Ara mirem els resultats de manera gràfica:

```


par(mfrow = c(1, 2))
limit_x <- c(-0.14, -0.02)

hist(pendents_no_param, breaks = 30, col = "skyblue", border = "white",
     xlim = limit_x, main = "Regressió: No Paramètric",
     xlab = "Valor de la pendent (beta)", ylab = "Freqüència")
abline(v = quantile(pendents_no_param, c(0.025, 0.975)), col = "blue", lwd = 2, lty = 2)
abline(v = beta_original, col = "red", lwd = 2)


hist(pendents_param, breaks = 30, col = "skyblue", border = "white",
     xlim = limit_x, main = "Regressió: Paramètric",
     xlab = "Valor de la pendent (beta)", ylab = "Freqüència")
abline(v = quantile(pendents_param, c(0.025, 0.975)), col = "blue", lwd = 2, lty = 2)
abline(v = beta_original, col = "red", lwd = 2)

```

Regressió: No Paramètric



Regressió: Paramètric



```

par(mfrow = c(1, 1))

```

Exemple 4:

Tenim una mostra de 6 cotxes en un mercat de segona mà, del mateix model i any, amb els següents preus i quilòmetres totals:

```
km <- c(37388, 44758, 45833, 30862, 31705, 34010)
Price <- c(14636, 14122, 14016, 15590, 15568, 14718)
data <- data.frame(km=km, Price=Price)
data
```

```
##      km Price
## 1 37388 14636
## 2 44758 14122
## 3 45833 14016
## 4 30862 15590
## 5 31705 15568
## 6 34010 14718
```

L'objectiu d'aquest exercici és calcular els intervals de confiança (IC) bootstrap del 95% (tres mètodes) per al preu de segona mà d'un cotxe (mateix model i any) amb 50.000 km.

Els tres mètodes amb els que podem calcular els intervals de confiança són:

- Mètode del Percentil:

L'interval de confiança es calcula directament a partir dels percentils.

$$[\hat{\theta}_{0.025}^*, \hat{\theta}_{0.975}^*]$$

- Mètode Bàsic:

Aquest mètode ajusta l'interval del percentil utilitzant la fórmula:

$$[2\hat{\theta} - \hat{\theta}_{975}^*, 2\hat{\theta} - \hat{\theta}_{25}^*]$$

on $\hat{\theta}$ és el valor observat de l'estadístic.

- Mètode Estandarditzat (basat en t):

Aquest mètode calcula un IC basat en la distribució bootstrap de l'estadístic t (estadístic estandarditzat):

$$t = \frac{\hat{\theta} - \theta_0}{\hat{se}(\hat{\theta})} \xrightarrow{d} N(0, 1)$$

i l'IC es construeix de la següent manera:

$$[\hat{\theta} + t_{\alpha/2} \cdot \hat{se}(\hat{\theta}), \hat{\theta} + t_{1-\alpha/2} \cdot \hat{se}(\hat{\theta})]$$

Primer, ajustem un model de regressió lineal simple per predir el preu basat en el quilometratge:

```
model <- lm(Price ~ km)
int_coef <- summary(model)$coefficients[1]
km_coef <- summary(model)$coefficients[2]
res <- residuals(model)
```

A continuació, calculem el preu predit ($\hat{\theta}$) per a un cotxe amb 50.000 km:

```
prediction <- predict(model, newdata = data.frame(km = 50000), se.fit=T)
theta_hat <- prediction$fit
se_theta_hat <- prediction$se.fit
paste0("L'estimació de theta és: ", round(theta_hat,4))
```

```
## [1] "L'estimació de theta és: 13537.6014"
```

Per aproximar la distribució mostral de $\hat{\theta}_B$ farem un bootstrap de l'error, generant 10.000 mostres bootstrap amb reposició:

```
set.seed(123)
B <- 10000
n <- length(km)
theta_hat_B <- numeric(B)
tB <- numeric(B)

for (i in 1:B) {
  rb <- sample(res, n, replace = TRUE) # mostra dels residus
  priceB <- int_coef + km_coef * km + rb
  modelB <- lm(priceB ~ km)
  predB <- predict(modelB, newdata = data.frame(km = 50000), se.fit = TRUE)
  theta_hat_B[i] <- predB$fit
  tB[i] <- (theta_hat_B[i] - theta_hat) / predB$se.fit
}
```

Ara apliquem els diferents mètodes. Primer el mètode del Percentil, que es deriva directament dels percentils 2,5 i 97,5 de la distribució bootstrap:

```
CI_percentile <- c(as.numeric(quantile(theta_hat_B,0.025)),
                  as.numeric(quantile(theta_hat_B,0.975)))
paste0("L'interval de confiança del 95% amb el mètode del percentil és (", round(CI_percentile[1],3),",",
```

```
## [1] "L'interval de confiança del 95% amb el mètode del percentil és (13092.274,13861.72)"
```

I ara, calculem l'IC amb el mètode bàsic.

```
CI_basic <- c(as.numeric(2*theta_hat-quantile(theta_hat_B,0.975)),
             as.numeric(2*theta_hat-quantile(theta_hat_B,0.025)))
paste0("L'interval de confiança del 95% amb el mètode bàsic és (", round(CI_basic[1],3),",", round(CI_b
```

```
## [1] "L'interval de confiança del 95% amb el mètode bàsic és (13213.483,13982.929)"
```

I l'últim mètode per calcular l'IC del 95% és el mètode estandarditzat (basat en t). Utilitzant els quantils de t_B , construïm l'interval de confiança.

```
CI_standarized <- c(as.numeric(theta_hat)+quantile(tB,0.025)*se_theta_hat,
                  as.numeric(theta_hat)+quantile(tB,0.975)*se_theta_hat)
paste0("L'interval de confiança del 95% amb el mètode estandarditzat és (", round(CI_standarized[1],3),",
```

```
## [1] "L'interval de confiança del 95% amb el mètode estandarditzat és (12776.919,14326.238)"
```


Aquest interval és més ample que l'obtingut amb els altres mètodes.

Finalment, visualitzem la distribució de $\hat{\theta}_B^*$ i l'estimació original $\hat{\theta}$.

```
hist(theta_hat_B, breaks = 50,
     main = expression("Distribució de " * hat(theta)[B] ^ "*"),
     xlab = expression(hat(theta)[B] ^ "*"),
     col = "lightblue", border="white")
abline(v = theta_hat, col = "red", lwd = 2)
```



```
legend("topright", legend = expression(hat(theta)),
      lwd = 2, col = "red", cex = 0.8)
```




Ara visualitzem la distribució de $\hat{\theta}_B^*$, l'estimació original $\hat{\theta}$ i els tres IC calculats.

```
# Gràfic per al mètode Percentil
hist(theta_hat_B, breaks = 50,
     main = expression("Distribució de " * hat(theta)[B]^"*"),
     xlab = expression(hat(theta)[B]^"*"),
     col = "lightblue", border="white")
abline(v = theta_hat, col = "red", lwd = 2, lty = 2)

abline(v = CI_percentile[1], col = "blue", lwd = 2)
abline(v = CI_percentile[2], col = "blue", lwd = 2)

legend("topright", legend = c(expression(hat(theta)), " IC Percentil"),
      lwd = 2, col = c("red", "blue"), lty = 2, cex = 0.8)
```




Aquest IC és una representació raonable de la variabilitat bootstrap ($\hat{\theta}_B$). En el següent gràfic es representa l'IC calculat amb el mètode bàsic.

```
hist(theta_hat_B, breaks = 50,
     main = expression("Distribució de " * hat(theta)[B] ^ "*"),
     xlab = expression(hat(theta)[B] ^ "*"),
     col = "lightblue", border="white")
abline(v = theta_hat, col = "red", lwd = 2, lty = 2)

abline(v = CI_basic[1], col = "darkgreen", lwd = 2)
abline(v = CI_basic[2], col = "darkgreen", lwd = 2)

legend("topright", legend = c(expression(hat(theta)), " IC Bàsic"),
     lwd = 2, col = c("red", "darkgreen"), lty = 2, cex = 0.8)
```




La representació gràfica mostra clarament que l'IC bàsic és més ample que el mètode del percentil.

```
hist(theta_hat_B, breaks = 50,
     main = expression("Distribució de " * hat(theta)[B] ^ "*"),
     xlab = expression(hat(theta)[B] ^ "*"),
     col = "lightblue", border="white",
     xlim = c(12770, 14330))
abline(v = theta_hat, col = "red", lwd = 2, lty = 2)

abline(v = CI_standarized[1], col = "darkviolet", lwd = 2)
abline(v = CI_standarized[2], col = "darkviolet", lwd = 2)

legend("topright", legend = c(expression(hat(theta)), " IC Estandarditzat"),
      lwd = 2, col = c("red", "darkviolet"), lty = 2, cex = 0.8)
```



Com hem vist darrerament, aquest IC és més ample que els altres dos mètodes.

Exemple 5:

Utilitzant les dades de l'article “*Estimating the Number of HIV-Infected Injection Drug Users in Bangkok: A Capture-Recapture Method*”, estimarem el nombre d'usuaris d'opioides d'entre 20 i 29 anys. Utilitzarem els estimadors de Lincoln-Petersen i de Chapman, calculant els intervals de confiança del 95% mitjançant **bootstrap paramètric**.

L'estimador de **Lincoln-Petersen** és un mètode de captura-recaptura senzill i molt aplicat, basat en dues mostres independents.

La fórmula d'aquest estimador és:

$$\hat{N}_{LP} = \frac{n_1 \cdot n_2}{m}$$

On:

- n_1 : Mida de la primera mostra.
- n_2 : Mida de la segona mostra.
- m : Nombre d'individus recapturats en la segona mostra.

D'altra banda, l'estimador de **Chapman** és una versió corregida del biaix de l'estimador de Lincoln-Petersen, especialment útil per a poblacions petites.

La fórmula d'aquest estimador és:

$$\hat{N}_{Chapman} = \frac{(n_1 + 1)(n_2 + 1)}{m + 1} - 1$$

Aquest estimador corregeix el biaix de Lincoln-Petersen, especialment quan el nombre de recaptures (m) és petit.

Els intervals de confiança del 95% per a ambdós estimadors es calcularan mitjançant **bootstrap paramètric**, que repeteix el procediment d'estimació moltes vegades generant dades simulades basades en la distribució observada (en aquest cas, una distribució hipergeomètrica).

Primer, definim els diferents paràmetres:

```
n1 <- 1378
n2 <- 699
m <- 76
```

Calculem ambdós estimadors:

```
N_LP <- (n1 * n2) / m
N_Chapman <- ((n1 + 1) * (n2 + 1) / (m + 1)) - 1
```

Ara, volem calcular els intervals de confiança per a ambdós estimadors utilitzant el Bootstrap paramètric.

```
set.seed(123)
B <- 1000
N_LP_B <- numeric(B)
N_Chapman_B <- numeric(B)

for (i in 1:B) {
  # Simulem el nombre de recaptures (m) usant la distribució hipergeomètrica
  m_sim <- rhyper(1, n1, N_LP - n1, n2)

  N_LP_B[i] <- (n1 * n2) / m_sim
}
```

```

  N_Chapman_B[i] <- ((n1 + 1) * (n2 + 1) / (m_sim + 1)) - 1
}

```

```

IC_LP <- quantile(N_LP_B, c(0.025, 0.975))
IC_Chapman <- quantile(N_Chapman_B, c(0.025, 0.975))

```

```

cat("Estimador Lincoln-Petersen:", N_LP, "\n")

```

```

## Estimador Lincoln-Petersen: 12673.97

```

```

cat("IC del 95% per a Lincoln-Petersen:", IC_LP, "\n\n")

```

```

## IC del 95% per a Lincoln-Petersen: 10469.8 15790.52

```

```

cat("Estimador Chapman:", N_Chapman, "\n")

```

```

## Estimador Chapman: 12535.36

```

```

cat("IC del 95% per a Chapman:", IC_Chapman, "\n")

```

```

## IC del 95% per a Chapman: 10378.57 15568.35

```


Per acabar, representem l'estimador de Lincoln-Petersen amb el seu interval de confiança del 95%.

```

hist(N_LP_B, main = "Histograma de l'estimador Lincoln-Petersen",
     xlab = "Estimador Lincoln-Petersen", xlim = c(8000, 21000), col = "lightblue", border = "white")
abline(v = as.numeric(IC_LP[1]), col = "red", lwd = 2, lty = 2)
abline(v = as.numeric(IC_LP[2]), col = "red", lwd = 2, lty = 2)
abline(v = N_LP, col = "blue", lwd = 2)
legend("topright",
      legend = c("Blau = Estimador", "Vermell = IC 95%"),
      col = c("blue", "red"),
      lty = c(1, 2),
      lwd = 2,
      bty = "n",
      cex = 0.8)

```


Histograma de l'estimador Lincoln-Petersen



I l'estimador de Chapman amb el seu interval de confiança del 95%:

```
hist(N_Chapman_B, main = "Histograma de l'estimador Chapman",
     xlab = "Estimador Chapman", xlim = c(8000, 21000), col = "lightgrey", border = "white")
abline(v = as.numeric(IC_Chapman[1]), col = "red", lwd = 2, lty = 2)
abline(v = as.numeric(IC_Chapman[2]), col = "red", lwd = 2, lty = 2)
abline(v = N_Chapman, col = "blue", lwd = 2)
legend("topright",
      legend = c("Blau = Estimador", "Vermell = IC 95%"),
      col = c("blue", "red"),
      lty = c(1, 2),
      lwd = 2,
      bty = "n",
      cex = 0.8)
```

Histograma de l'estimador Chapman



Ambdós estimadors proporcionen resultats similars, amb intervals de confiança que se superposen. L'estimador de Chapman és lleugerament més fiable gràcies a la seva correcció del biaix, especialment quan el nombre de recaptures (m) és petit.

Exercici 1

Un grup d'investigadors està estudiant la capacitat d'emmagatzematge de carboni d'un bosc mediterrani. Han seleccionat una mostra aleatòria de 12 arbres i han mesurat la seva biomassa estimada (en tones). Les dades obtingudes són les següents: 1.2, 1.5, 2.8, 1.1, 0.9, 3.2, 1.8, 2.1, 1.4, 1.0, 5.2, 1.6

- 1) Calculeu la mitjana i la mediana de la mostra original.
- 2) Realitzeu un Bootstrap No Paramètric amb $B = 2000$ repeticions per estimar la distribució de la mediana.
- 3) Trobeu l'Interval de Confiança del 95% utilitzant el mètode del percentil.
- 4) Representeu gràficament la distribució de les medianes bootstrap mitjançant un histograma, marcant amb una línia vertical el valor de la mediana original.

Exercici 2

El baix pes al néixer segons gestació (SGA) és un factor de risc per a molts problemes de salut a la vida adulta. Per a tractar aquest fet, en una població de dones amb risc de patir Creixement Intrauterí Restringit (CIT), es van assignar aleatòriament a intervenció usual (control) o formació en dieta mediterrània (tractament) per a prevenir el baix pes al néixer del nadó.

Es vol calcular els estadístics que segueixen per a comparar els dos grups:

$$\text{Risk Difference (RD)} = P(SGA|\text{tractament}) - P(SGA|\text{control})$$

$$\text{Numer Needed to Treat (NNT)} = \frac{1}{|RD|}$$

Calculeu l'interval de confiança d'aquests paràmetres amb el mètode de bootstrap paramètric definint quina és l'estratègia de remostreig que feu servir. Representeu aquestes distribucions gràficament i interpreteu els resultats. Utilitzeu la base de dades anomenada "IMPACT.csv" que està al campus.

Exercici 3

La creatinina de la sang és un indicador important de la salut renal dels pacients. Volem estudiar diferents aspectes d'aquesta molècula, entre ells, si pot estar associada a problemes cardíacs.

Disposem d'una base de dades amb les següents variables:

```
library(foreign)
dades <- read.spss('CREA.sav', use.value.labels = TRUE, to.data.frame = TRUE)
head(dades)
```

```
##  EDAT SEXE CREA FE  CARDIOPATIA
## 1   67 DONA  1.1 20 NO ISQUEMICA
## 2   55 HOME  0.7 23  ISQUEMICA
## 3   81 HOME  1.2 20 NO ISQUEMICA
## 4   75 HOME  1.7 33 NO ISQUEMICA
## 5   52 HOME  1.0 18 NO ISQUEMICA
## 6   70 HOME  1.6 16 NO ISQUEMICA
```

- 1) Feu una descripció global de la mostra. Feu un gràfic de la variable creatinina.
- 2) Doneu l'estimació amb bootstrap no-paramètric del IC 95% per a la mediana de la creatinina (amb quantils i amb l'aproximació per la normal) i calculeu el seu biaix.
- 3) Existeix relació entre la creatinina en sang i el sexe de l'individu? Feu un t-test i ajusteu un model lineal. Comenteu els resultats.

- 4) Volem veure si és possible predir el valor de la creatinina en sang en funció de l'edat. Ajusteu un model lineal i feu la seva validació.
- 5) Doneu un interval de confiança del 95% per al coeficient R^2 de la regressió de l'apartat anterior mitjançant bootstrap paramètric. És possible predir bé els valors de creatinina en sang?