

Pràctica tests permutacionals

Maria Cobo Ollero

13-03-2026

```
library(readxl)
library(dplyr)
library(combinat)
```

Tests permutacionals

Els tests de permutacions són mètodes no paramètrics que ens permeten determinar la significació estadística sense assumir que les dades segueixen una distribució específica (com la normal). Es basen en la idea que, si la hipòtesi nul·la és certa, les etiquetes dels grups són intercanviables.

Aquests són els 6 punts clau per a executar un test de randomització:

1. **Definir les hipòtesis: H_0 (Hipòtesi Nul·la):** No hi ha diferències; el tractament o la variable no té efecte. H_1 (Hipòtesi Alternativa): Existeix una diferència significativa.
2. **Triar l'estadístic de contrast:** Has de seleccionar un valor (com la diferència de mitjanes) que sigui **gran** si la H_0 és falsa, i **petit** si la H_0 és certa (o viceversa).
3. **Barrejar les dades (Permutació):** Crea un nou conjunt de dades reordenant aleatòriament les observacions originals. La manera exacta de reordenar-les dependrà de la teva H_0 .
4. **Calcular l'estadístic de "mentida":** Calcula el mateix estadístic del pas 2, però fent servir les dades barrejades. Compara aquest valor amb el valor real que vas obtenir originalment.
5. **Iteració (El bucle):** Repeteix els passos 3 i 4 moltes vegades (com a mínim **1.000 vegades** és el recomanat per a obtenir robustesa).
6. **Càlcul del p-valor:** Si el teu estadístic real és més extrem (major o menor) que el **95%** dels valors obtinguts per atzar, pots rebutjar la hipòtesi nul·la amb un $p < 0.05$.

Exemple 1.

Volem fer un test permutacional per a saber si el dit índex dels nois i de les noies de la classe és igual o no.

Aquest exemple ho farem amb el fitxer *Pràctica1:Dades dits* del campus virtual.

```
dades <- read_excel("dades_ratio_dits_Remostreig_2022-23.xlsx")
head(dades)
```

```
## # A tibble: 6 x 14
##   ID Curs  sexe  altura polze index  mig anular  minut punt_pare punt_mare
##   <dbl> <chr>  <chr>  <dbl> <dbl> <dbl> <dbl>  <dbl>  <dbl>    <dbl>    <dbl>
## 1     1  2021-22 h      178    59    83    97    91    72      80      25
## 2     2  2021-22 h      178    60    75    80    74    59     NA      80
## 3     3  2021-22 h      179    64    90   100    92    70     30     70
## 4     4  2021-22 <NA>    185    65    85    97    85     6     90     85
## 5     5  2021-22 <NA>    178    55    85    90    85    75     90     90
```

```
## 6      6 2021-22 h      170    70    98   113    99   81      55      90
## # i 3 more variables: parella <chr>, punt_parella <dbl>,
## #   sensacio_periode_covid <dbl>
```

Definim les hipòtesis:

$$H_0 : \mu_{nois} = \mu_{noies}$$

$$H_1 : \mu_{nois} \neq \mu_{noies}$$

Només ens interessa quedar-nos amb la mesura del dit index i el sexe.

```
dades2 <- dades %>%
  filter(!is.na(index), sexe %in% c("h", "d")) %>%
  select(sexe, index)
head(dades2)
```

```
## # A tibble: 6 x 2
##   sexe index
##   <chr> <dbl>
## 1 h      83
## 2 h      75
## 3 h      90
## 4 h      98
## 5 h      90
## 6 h      88
```

Guardem els valors dels index separat per nois i noies, i calculem l'estadístic de contrast.

```
nois <- dades2 %>% filter(sexe == "h") %>% pull(index)
noies <- dades2 %>% filter(sexe == "d") %>% pull(index)
dif_mitjana <- mean(nois) - mean(noies)
```

Fem el test permutacional:

```
set.seed(123)
nr <- 10000
st <- numeric(nr)
n1 <- length(nois)
n2 <- length(noies)
total <- n1+n2
cnt <- 0
vect <- c(nois, noies)
for (i in 1:nr){
  d <- sample(vect, n1+n2)
  H_r <- d[1:n1]
  D_r <- d[(n1+1):total]
  st[i] <- mean(H_r) - mean(D_r)
  if(abs(st[i])>abs(dif_mitjana))
    cnt <- cnt+1
}

pvalue <- cnt/nr
print(pvalue)
```

```
## [1] 0.0083
```

Com que el p-valor és inferior a 0.05, tenim evidències suficients per rebutjar la hipòtesis nul·la, i per tant, podem dir que existeixen diferències entre les mitjanes dels índex de nois i de noies.

Ara tornem a fer el mateix test, però comparant medianes.

$$H_0 : \text{Mediana}_{nois} = \text{Mediana}_{noies}$$

$$H_1 : \text{Mediana}_{nois} \neq \text{Mediana}_{noies}$$

```
set.seed(123)
dif_mediana <- median(nois) - median(noies)
nr <- 10000
st <- numeric(nr)
n1 <- length(nois)
n2 <- length(noies)
total <- n1+n2
cnt <- 0
vect <- c(nois, noies)
for (i in 1:nr){
  d <- sample(vect, n1+n2)
  H_r <- d[1:n1]
  D_r <- d[(n1+1):total]
  st[i] <- median(H_r) - median(D_r)
  if(abs(st[i])>abs(dif_mediana))
    cnt <- cnt+1
}

pvalue <- cnt/nr
print(pvalue)
```

```
## [1] 0.0339
```

Com que el p-valor menor a 0.05, no hi ha suficient evidència per acceptar la hipòtesis nul·la, per tant, hi ha diferència de medianes.

Exemple 2

Suposem que durant un període de tres hores que va passar a l'aire lliure, una persona va registrar la temperatura, el temps que va tallar la gespa i el seu consum d'aigua. L'experiment es va dur a terme en 7 dies seleccionats aleatòriament durant l'estiu. Les dades es mostren a la taula a continuació amb la temperatura ordenada creixentment.

```
T<- c(75,83,85,85,92,97,99)
WC<- c(16,20,25,27,32,48,48)
TMG<- c(1.85,1.25,1.5,1.75,1.15,1.75,1.6)
data<- data.frame(T,WC,TMG)
print(data)
```

```
##      T WC  TMG
## 1 75 16 1.85
## 2 83 20 1.25
## 3 85 25 1.50
## 4 85 27 1.75
## 5 92 32 1.15
## 6 97 48 1.75
## 7 99 48 1.60
```

Volem testear la significança de les variables Temp i TMG, usant un test permutacional exacte. Les hipòtesis que mirarem per la variable T és:

$$H_0 : \beta_T = 0$$

$$H_1 : \beta_T \neq 0$$

I per a la variable TMG:

$$H_0 : \beta_{TMG} = 0$$

$$H_1 : \beta_{TMG} \neq 0$$

Per a realitzar aquest test el que farem serà:

1. Ajustar el model de regressió lineal i obtenir l'estadístic t real de Temp i de TMG.
2. Generar dades aleatòries sota la hipòtesis nul·la, mantenint les variables independents iguals, però permutant aleatòriament els valors de la variable resposta (WC).
3. Ajustar el model amb les dades permutades, guardant l'estadístic t .
4. Repetir el procés moltes vegades, per obtenir una distribució empírica dels estadístics t . En aquest cas ens demanen un test exacte, per tant, cal calcular totes les permutacions.
5. Calcular els p-valors, com la proporció de valors permutats amb un estadístic t igual o més extrem que el real.

```
mod <- lm(WC ~ T + TMG, data = data)
a <- summary(mod)
zTtrue <- abs(a$coefficients[2,3])
zTMGtrue <- abs(a$coefficients[3,3])
nr <- fact(length(data$WC)) # Perquè volem realitzar un test exacte
permutations <- permn(data$WC)
zT <- numeric(nr)
zTMG <- numeric(nr)
for(i in 1:nr){
  newWC <- permutations[[i]]
  model <- lm(newWC ~ T + TMG, data = data)
  a <- summary(model)
  zT[i] <- abs(a$coefficients[2, 3])
  zTMG[i] <- abs(a$coefficients[3, 3])
}

(pvalue_T <- length(zT[zT >= zTtrue])/nr )

## [1] 0.001190476

(pvalue_TMG <- length(zTMG[zTMG >= zTMGtrue])/nr)
```


```
## [1] 0.009126984
```

Com que els dos p-valors són menors a 0.05, T i TMG són significatives, i per tant, han de ser incloses en el model.

Ara, comparem els resultats obtinguts amb els del model de la regressió múltiple.

```
par(mfrow=c(1,2))
hist(zT,main="Histogram of zT" , col = "lightblue",border = "black")
abline(v = zTtrue, col = "red", lwd = 2)
```

```
hist(zTMG,main="Histogram of zTMG" , col ="lightblue", border = "black")
abline(v = zTMGtrue, col = "red", lwd = 2)
```



Observem que els valors que hem obtingut són molt diferents dels que hem obtingut en el model de regressió múltiple.

Exercici 1.

La fibril·lació auricular és un ritme cardíac anormal (arrítmia) caracteritzat per batecs ràpids i irregulars de les cambres auriculars del cor i s'associa amb un major risc d'insuficiència cardíaca, demència i ictus.

Utilitza la BBDD del campus anomenada “ABALACIO_FA_REMOSTREIG.sav”

- Fes una descripció de la mostra i neteja les dades.
- Proveu la significació de la comparació entre tècniques i calculeu la probabilitat de recurrència mitjançant una prova de permutació.

Exercici 2.

Un equip mèdic vol determinar si el conjunt de variables Edat i Nivell de Proteïna permet explicar de forma robusta el Temps de Recuperació en pacients post-ictus. Es sospita que el model podria no complir les assumpcions de normalitat a causa de la mida reduïda de la mostra ($n = 15$), per la qual cosa s'ha decidit validar la significança global del model mitjançant mètodes no paramètrics.

El model teòric és:

$$\text{Recuperació} = \beta_0 + \beta_1 \cdot \text{Edat} + \beta_2 \cdot \text{Proteïna} + \epsilon$$

##	Edat	Proteïna	Recuperació
## 1	45	43.16097	20
## 2	50	36.75916	22
## 3	62	40.00582	30
## 4	71	47.05449	35
## 5	55	26.57487	25
## 6	48	33.90364	21
## 7	66	21.91258	32
## 8	59	45.04896	28
## 9	70	43.52799	38
## 10	52	18.15528	24
## 11	44	48.17006	19
## 12	68	20.63390	33
## 13	61	33.30869	31
## 14	53	23.84805	23
## 15	57	45.43557	27

- Ajusta el model de regressió lineal múltiple i identifica l'estadístic F global del model.
- Planteja un contrast d'hipòtesis on la H_0 sigui que cap dels predictors té efecte.
- Mitjançant un bucle iteratiu, genera la distribució empírica de l'estadístic F sota la hipòtesi nul·la. Per fer-ho, permuta els valors de la variable resposta per trencar la possible estructura de dependència amb els predictors.
- Mostra els resultats de manera gràfica

Exercici 3.

Les dades corresponen a les profunditats de restes arqueològiques en 4 excavacions a Wind Mountain. Volem provar: $H_0 : m_1 = m_2 = m_3 = m_4$ contra l'alternativa ordenada $H_A : m_1 \leq m_2 \leq m_3 \leq m_4$ (amb alguna desigualtat estricta).

L'estadístic proposat és: $T = 3\bar{R}_4 + \bar{R}_3 - 3\bar{R}_1 - \bar{R}_2$

```
x1 <- c(100, 75, 65, 40, 73, 65, 50, 30, 45, 50, 45, 55)
x2 <- c(85, 45, 80, 28, 75, 70, 65, 55, 50, 40)
x3 <- c(96, 58, 95, 90, 65, 80, 85, 95, 82)
x4 <- c(93, 120, 65, 105, 115, 82, 99, 87, 100, 90, 78, 95, 93, 88, 110)

valors <- c(x1, x2, x3, x4)
grups <- factor(c(rep("X1", length(x1)), rep("X2", length(x2)),
                  rep("X3", length(x3)), rep("X4", length(x4))))
dades <- data.frame(profunditat = valors, excavacio = grups)
```

- Per què no és adequat un ANOVA estàndar?
- Per què es pot fer un test de permutacions?
- Calcular el valor de T sobre la mostra original
- Fes un test de permutacions i mostra un histograma dels resultats
- Calcula el p-valor i fes la conclusió